

Université Lyon 2, Lyon 3, ENSIB, ENS Lyon

**Identifier les marqueurs du
naturalisme par la modélisation
thématique et la classification
automatique : signature d’auteur,
contenu thématique et biais de
corpus**

Mémoire présenté par Morgan RICHARD

Année universitaire 2025–2026

Remerciements

Ce mémoire a été réalisé dans le cadre de mon stage de fin d'études au sein du laboratoire LATTICE, unité mixte de recherche du CNRS, de l'École Normale Supérieure-PSL et de l'Université Sorbonne Nouvelle. Les recherches du laboratoire portent notamment sur la linguistique, le traitement automatique des langues, l'évolution linguistique et les humanités numériques. Ce cadre scientifique m'a permis de mobiliser des méthodes de modélisation thématique et de classification automatique afin d'étudier les régularités lexicales et thématiques associées à l'écriture naturaliste. Le stage a été encadré par Dominique Legallois que je remercie pour son encadrement et pour toutes les nouvelles notions qu'il m'a enseignées au long de ce stage. Je tiens à remercier toutes les autres personnes du laboratoire pour leur accueil chaleureux et leur soutien tout au long de ce projet, notamment à Virgie Pauchont, gestionnaire et secrétaire, à Yoann Dupont, MCF à Sorbonne Nouvelle, à Mathieu Dehouck Chargé de Recherche au CNRS, et à Olga Seminck, ingénieure de recherche au CNRS.

Je remercie également Madame Pegah pour son encadrement ainsi que tous le personnel encadrant du master HN de Lyon pour leurs conseils tout au long de l'année.

Je remercie également mes proches pour leur soutien et leurs encouragements, je pense notamment à mes parents ainsi qu'à ma copine.

Résumé

Ce mémoire porte sur...

Table des matières

Remerciements	i
Résumé	ii
Introduction	1
1 Topic modeling sur les romans d'Émile Zola	7
1.1 Présentation de la méthode	7
1.2 Présentation du corpus d'étude	8
1.2.1 Choix du corpus	8
1.2.2 Préparation des textes	10
1.2.3 Préparation du corpus pour l'analyse thématique	10
1.2.4 Statistiques descriptives du corpus	10
1.2.5 Lemmatisation du corpus de Zola	13
1.3 Analyse par NMF et K-means	13
1.3.1 La méthode NMF	14
1.3.2 La méthode K-means	17
1.4 Résultats	19
1.4.1 Topics obtenus avec le NMF	19
1.4.2 Nombre de segments associés à chaque topic dominant	23
1.4.3 Clusters obtenus avec K-means	25
1.5 Comparaison des deux méthodes	34
1.5.1 Deux représentations complémentaires	34
1.5.2 Convergences lexicales et thématiques	35
1.5.3 Distribution des topics NMF par œuvre	35
1.5.4 Distribution des clusters K-means par œuvre	36
1.5.5 Regroupement en grandes familles	37
1.5.6 Apport de la double approche	38
1.6 Conclusion sur le Topic Modeling	39

2	Dynamique Topic modeling sur le corpus de d'Émile Zola	40
2.1	Présentation du corpus et des données	40
2.1.1	Objectif et organisation du corpus	40
2.1.2	Segmentation et statistiques descriptives	40
2.2	Utilisation de BERTopic	41
2.2.1	Architecture générale et représentation du corpus	42
2.2.2	Réduction de dimension, clustering et représentation lexicale . .	42
2.2.3	Grille de recherche	43
2.2.4	Critères d'évaluation et classement multicritère	44
2.2.5	Contrôle de la stabilité	45
2.2.6	Justification du choix final à 33 topics	45
2.2.7	Portée et limites du protocole	46
2.3	Validation mathématique	47
2.3.1	Validation de la partition brute	47
2.3.2	Réaffectation des documents atypiques	49
2.3.3	Cohérence et diversité du modèle final	49
2.4	Analyse des résultats de BERTopic	51
2.4.1	Principes du classement	51
2.4.2	Visualisation des topics au fil du temps	55
	Conclusion du chapitre	61
3	Nettoyage des romans et insertion de ces derniers dans la base de données	63
3.1	Reflexion sur le stockage des données	63
3.2	Nettoyage des textes	63
3.3	Création de la base de données	64
3.4	Création des informations pour la base de données	67
	Bibliographie	69
	Sitographie	71
	Annexe technique : code	72
.0.1	Le code suivant présente le script Python utilisé pour nettoyer les textes extraits des fichiers EPUB après leur conversion au format .txt	72

Table des figures

1.1	Méthode du coude pour le choix du nombre de topics dans la NMF, entre 2 et 40 topics	15
1.2	Méthode du coude pour le choix du nombre de topics dans la NMF, entre 20 et 39 topics	15
1.3	Évolution du score de silhouette en fonction du nombre de clusters dans K-means	18
1.4	Dendrogramme de la classification hiérarchique des clusters K-means .	29
1.5	Regroupement des clusters K-means en grandes familles de motifs . . .	30
1.6	Noms attribués aux grandes familles de motifs	32
1.7	Distribution des grandes familles de motifs dans le corpus	33
1.8	Distribution des clusters K-means dans le corpus	34
1.9	Proportion des segments par topic NMF dominant et par œuvre	36
1.10	Distribution des clusters K-means par œuvre	37
1.11	Distribution des grandes familles de clusters K-means par œuvre	38
2.1	Présence des topics liés aux milieux populaires et au travail dans le corpus	56
2.2	Présence des topics liés à l'argent dans le corpus	57
2.3	Présence des topics liés à la production, à la vente et à la consommation dans le corpus	57
2.4	Présence des topics liés aux univers sociaux et aux pratiques quotidiennes dans le corpus	58
2.5	Présence du topic lié aux institutions et aux transformations sociales dans le corpus	59
2.6	Présence du topic lié à la souffrance et à la défaillance dans le corpus .	60

Liste des tableaux

1.1	Nombre de tokens par roman de Zola dans l'ordre chronologique	8
1.2	Nombre de paquets de phrases par roman	11
1.3	Statistiques descriptives du nombre de paquets par roman	12
1.4	Statistiques descriptives du nombre de mots par paquet	12
1.5	Mots caractéristiques des topics obtenus avec la NMF	20
1.6	Noms attribués aux topics obtenus avec la NMF	22
1.7	Nombre de segments associés à chaque topic dominant	23
1.8	Mots caractéristiques des clusters obtenus avec K-means	25
1.9	Noms attribués aux clusters obtenus avec K-means	27
1.10	Composition des grandes familles de motifs issues des clusters K-means	31
2.1	Statistiques descriptives du nombre de mots par segment de quarante phrases	41
2.2	Hyperparamètres inclus dans la grille de recherche BERTopic	43
2.3	Comparaison entre le premier rang automatique et le modèle retenu . .	46
2.4	Indicateurs de validation avant et après la réaffectation des outliers . .	50
2.5	Topics présentant une très forte proximité avec le naturalisme	51
2.6	Topics présentant une forte proximité avec le naturalisme	53
2.7	Topics présentant une proximité indirecte avec le naturalisme	54
2.8	Topics présentant une faible spécificité naturaliste	54

Introduction

La modélisation thématique, la stylométrie et la classification automatique constituent trois approches complémentaires de l’analyse quantitative des textes. Elles se distinguent principalement par leurs objectifs : la modélisation thématique cherche à faire émerger les structures sémantiques d’un corpus, la stylométrie mesure les caractéristiques formelles de l’écriture, tandis que la classification automatique attribue aux textes des catégories préalablement définies.

La modélisation thématique (*topic modeling*) vise généralement à dégager, sans annotation préalable, les principaux thèmes présents dans un ensemble de documents. L’allocation de Dirichlet latente (*Latent Dirichlet Allocation*, LDA) s’est imposée comme l’un des modèles probabilistes de référence. Elle représente chaque document comme un mélange de thèmes, eux-mêmes définis par des distributions de probabilités sur les mots du corpus.¹ Les prolongements de cette méthode permettent notamment d’intégrer l’évolution temporelle des thèmes, leurs relations ou les métadonnées associées aux documents.² Plus récemment, les modèles neuronaux et les plongements contextuels ont renouvelé la modélisation thématique, en particulier pour l’analyse des textes courts, multilingues ou sémantiquement complexes.³ BERTopic, par exemple, combine des représentations produites par un modèle de langue, une méthode de regroupement automatique et une variante du TF-IDF pour caractériser les thèmes obtenus.⁴ L’interprétation des résultats demeure néanmoins délicate : les thèmes dépendent de la constitution et du prétraitement du corpus, du nombre de thèmes demandé et des paramètres du modèle. Par ailleurs, une bonne performance statistique ne garantit pas nécessairement que les thèmes produits soient cohérents pour un lecteur humain.⁵

1. David M. Blei, Andrew Y. Ng et Michael I. Jordan, « Latent Dirichlet Allocation », *Journal of Machine Learning Research*, vol. 3, 2003, p. 993–1022, texte intégral en ligne.

2. David M. Blei, « Probabilistic Topic Models », *Communications of the ACM*, vol. 55, no 4, 2012, p. 77–84, texte intégral en ligne.

3. Xiaobao Wu, Thong Nguyen et Anh Tuan Luu, « A Survey on Neural Topic Models : Methods, Applications, and Challenges », *Artificial Intelligence Review*, vol. 57, article 18, 2024, DOI et texte intégral.

4. Maarten Grootendorst, « BERTopic : Neural Topic Modeling with a Class-Based TF-IDF Procedure », prépublication arXiv, 2022, texte intégral en ligne.

5. Jonathan Chang, Jordan Boyd-Graber, Sean Gerrish, Chong Wang et David M. Blei, « Reading Tea Leaves : How Humans Interpret Topic Models », dans *Advances in Neural Information Processing Systems 22*, 2009, p. 288–296, texte intégral en ligne.

La stylométrie cherche, pour sa part, à mesurer les régularités formelles d’une écriture à partir de caractéristiques quantifiables, telles que les fréquences lexicales, l’emploi des mots-outils, la richesse du vocabulaire, la longueur des phrases, la ponctuation, les catégories grammaticales ou les séquences de caractères. Elle a d’abord été principalement utilisée pour résoudre des problèmes d’attribution d’auteur, comme l’illustre l’étude fondatrice de Frederick Mosteller et David Wallace sur les articles anonymes des *Federalist Papers*.⁶ Parmi les méthodes classiques, le *Delta* de John Burrows mesure la distance stylistique entre plusieurs textes à partir des fréquences standardisées de leurs mots les plus courants.⁷ Les recherches contemporaines mobilisent également les n-grammes de caractères, les méthodes d’apprentissage automatique et les représentations produites par les modèles de langue.⁸ La stylométrie comprend désormais plusieurs tâches, notamment l’attribution, la vérification et le profilage d’auteur, ainsi que l’étude de l’évolution du style au cours du temps.⁹ Ses résultats restent toutefois sensibles à la longueur des documents et aux effets du genre, du thème, de la période historique, du support ou de la traduction. Ces facteurs doivent donc être contrôlés afin de ne pas les confondre avec le style individuel.

Enfin, la classification automatique consiste à attribuer un texte à une ou plusieurs catégories définies à l’avance. Contrairement à la modélisation thématique, elle relève généralement de l’apprentissage supervisé : le modèle apprend à partir d’un corpus dont les documents ont préalablement été annotés.¹⁰ Les approches classiques représentent les documents par des fréquences lexicales ou des pondérations TF-IDF, puis utilisent des méthodes comme le classifieur bayésien naïf, la régression logistique ou les machines à vecteurs de support.¹¹ Ces méthodes ont été complétées par les réseaux de neurones, puis par les modèles de langue préentraînés fondés sur l’architecture Transformer. BERT a notamment popularisé une procédure dans laquelle un modèle préentraîné sur de grandes quantités de textes est ensuite spécialisé sur une tâche de classification à partir d’un corpus annoté plus restreint.¹² Les grands modèles de langue permettent également

6. Frederick Mosteller et David L. Wallace, *Inference and Disputed Authorship : The Federalist*, Reading, Addison-Wesley, 1964 ; réédition avec une introduction de John Nerbonne, Stanford, CSLI Publications, 2007, notice éditoriale.

7. John Burrows, « ‘Delta’ : A Measure of Stylistic Difference and a Guide to Likely Authorship », *Literary and Linguistic Computing*, vol. 17, no 3, 2002, p. 267–287, DOI.

8. Efstathios Stamatatos, « A Survey of Modern Authorship Attribution Methods », *Journal of the American Society for Information Science and Technology*, vol. 60, no 3, 2009, p. 538–556, texte intégral en ligne.

9. Enzo Terreau, *Apprentissage de représentations d’auteurs et d’autrices à partir de modèles de langue pour l’analyse des dynamiques d’écriture*, thèse de doctorat en informatique, Université Lyon 2, 2024, notice et résumé en ligne.

10. Fabrizio Sebastiani, « Machine Learning in Automated Text Categorization », *ACM Computing Surveys*, vol. 34, no 1, 2002, p. 1–47, texte intégral en ligne.

11. Christopher D. Manning, Prabhakar Raghavan et Hinrich Schütze, *Introduction to Information Retrieval*, Cambridge, Cambridge University Press, 2008, chap. 13 à 15, édition intégrale en ligne.

12. Jacob Devlin, Ming-Wei Chang, Kenton Lee et Kristina Toutanova, « BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding », dans *Proceedings of NAACL-HLT*

d'effectuer certaines classifications sans apprentissage spécifique ou à partir d'un nombre limité d'exemples. Ils ne rendent cependant pas systématiquement obsolètes les modèles spécialisés : pour de nombreuses tâches, un modèle plus petit correctement entraîné peut rester plus performant, plus stable et moins coûteux.¹³

Dans ces trois domaines, le choix de la méthode ne peut être séparé des conditions de constitution et d'annotation du corpus. Une évaluation rigoureuse suppose notamment de contrôler les effets d'auteur, de source, de genre et de période, de séparer strictement les données d'apprentissage et de test, et de confronter les résultats quantitatifs à une lecture qualitative des textes.¹⁴

Mon objectif est d'appliquer ces méthodes à l'œuvre d'Émile Zola dans un premier temps, puis de les confronter à un corpus comparatif de romans naturalistes et non-naturalistes de la même époque. L'objectif est de déterminer si ces méthodes permettent d'identifier des marqueurs du naturalisme, tout en évitant de confondre signature d'auteur, contenu thématique et artefacts liés à la constitution du corpus.

Le naturalisme constitue l'un des principaux mouvements littéraires et artistiques de la seconde moitié du XIX^e siècle. Prolongeant certaines ambitions du réalisme, il se donne pour objectif de représenter l'être humain et la société avec une précision inspirée des sciences expérimentales. L'œuvre littéraire ne repose donc plus seulement sur l'imagination de l'écrivain : elle s'appuie sur l'observation du réel, sur une documentation minutieuse ainsi que sur l'étude des mécanismes physiologiques, sociaux et psychologiques qui déterminent les comportements individuels.

Émile Zola¹⁵, principal théoricien du mouvement, définit ainsi le naturalisme comme « l'esprit scientifique porté dans toutes nos connaissances ». Il entend substituer à « l'homme métaphysique » un « homme physiologique », inséparable de son hérédité et du milieu dans lequel il évolue¹⁶. Inspiré notamment par *l'Introduction à l'étude de la médecine expérimentale* de Claude Bernard, Zola conçoit le romancier comme un observateur et un expérimentateur. Celui-ci commence par recueillir et consigner des faits, puis place ses personnages dans des circonstances déterminées afin d'étudier le fonctionnement de leurs passions, de leurs instincts et de leurs conduites. Le roman devient alors une forme d'expérience permettant de mettre au jour les lois qui régissent l'individu et la société¹⁷.

Cette conception repose principalement sur le déterminisme. Dans la perspective

2019, p. 4171–4186, texte intégral en ligne.

13. Aleksandra Edwards et Jose Camacho-Collados, « Language Models for Text Classification : Is In-Context Learning Enough ? », dans *Proceedings of LREC-COLING 2024*, p. 10058–10072, texte intégral en ligne.

14. Justin Grimmer et Brandon M. Stewart, « Text as Data : The Promise and Pitfalls of Automatic Content Analysis Methods for Political Texts », *Political Analysis*, vol. 21, no 3, 2013, p. 267–297, DOI.

15. Pour ce qui est des informations sur Émile Zola, je me suis grandement référé à sa page Wikipédia, qui est considérée comme une page de qualité : lien de sa page.

16. [https://fr.wikipedia.org/wiki/Naturalisme_\(litt%C3%A9rature\)](https://fr.wikipedia.org/wiki/Naturalisme_(litt%C3%A9rature))

17. Émile Zola, *Le Roman expérimental*, Paris, Charpentier, 1881.

naturaliste, la personnalité et la destinée d'un individu sont largement conditionnées par son héritage physiologique, son environnement familial, sa situation économique et son appartenance sociale. Le naturalisme ne doit cependant pas être réduit à un ensemble de procédés stylistiques¹⁸. Paul Alexis le présente avant tout comme une méthode permettant de penser¹⁹, de voir, d'étudier et d'expérimenter. De même, Camille Lemonnier l'envisage comme un « réalisme agrandi » par l'analyse des milieux et par l'apport des sciences naturelles et sociales. Le mouvement s'inscrit ainsi dans une vision matérialiste et empirique du monde, selon laquelle les phénomènes humains doivent être expliqués à partir de causes observables²⁰.

Sur le plan esthétique et narratif, cette ambition scientifique entraîne une remise en cause des conventions romanesques traditionnelles. Les naturalistes rejettent les intrigues artificielles, les péripéties invraisemblables et les personnages idéalisés. À la construction d'une fable spectaculaire, ils préfèrent la restitution d'une « tranche de vie », c'est-à-dire l'étude détaillée d'un fragment d'existence ordinaire. Le roman prend alors la forme d'une monographie consacrée à un individu, à une famille, à un métier ou à un milieu social. Le narrateur tend à s'effacer derrière les faits et adopte une posture d'impersonnalité comparable à celle d'un greffier chargé d'exposer les pièces d'un dossier sans formuler explicitement de jugement²¹.

La description occupe, dans cette perspective, une fonction essentielle. Elle ne constitue pas un simple ornement esthétique, mais un instrument d'analyse et d'explication. Les logements, les vêtements, les paysages, les lieux de travail et les conditions matérielles d'existence contribuent à façonner les personnages. Décrire un environnement revient donc à rendre visibles les forces qui agissent sur l'individu. Cette attention portée aux déterminations sociales conduit les écrivains naturalistes à s'intéresser aux catégories jusque-là marginalisées par la littérature : les ouvriers, les paysans, les prostituées, les criminels, les malades ou les exclus. Le héros traditionnel s'efface au profit de personnages ordinaires, souvent confrontés à la pauvreté, à la violence, à la maladie ou au déclassement.

La représentation de ces réalités a toutefois suscité d'importantes controverses morales et esthétiques. La crudité de certaines scènes, l'étude des pathologies et l'attention accordée aux formes de déchéance ont conduit les adversaires du mouvement à l'accuser de complaisance envers la laideur et le vice. Zola défend au contraire la dimension morale de sa démarche. À ses yeux, le romancier agit comme un anatomiste ou un chirurgien : en analysant les causes matérielles et sociales des comportements, il contribue à mieux comprendre les dysfonctionnements de la société et fournit les connaissances nécessaires à leur éventuelle correction. L'écrivain naturaliste serait ainsi un « moraliste

18. [https://fr.wikipedia.org/wiki/Naturalisme_\(litt%C3%A9rature\)](https://fr.wikipedia.org/wiki/Naturalisme_(litt%C3%A9rature))

19. Jules Huret, *Enquête sur l'évolution littéraire*, Paris, Charpentier, 1891.

20. [https://fr.wikipedia.org/wiki/Naturalisme_\(litt%C3%A9rature\)](https://fr.wikipedia.org/wiki/Naturalisme_(litt%C3%A9rature))

21. Émile Zola, *Le Roman expérimental*

expérimentateur », dont la fonction n'est pas de condamner, mais d'expliquer²².

Cette conception est notamment contestée par Ferdinand Brunetière²³, qui reproche au naturalisme français de privilégier la recherche de la grossièreté, le pessimisme et l'« écriture artiste » au détriment de la profondeur psychologique. Il oppose à ce qu'il considère comme un « faux naturalisme » une littérature incarnée par Dickens, George Eliot ou Tolstoï, caractérisée par la probité de l'observation, la simplicité de l'exécution et la sympathie envers les humbles. Edmond Cattier insiste également sur le rôle de l'« imagination sympathique »²⁴, faculté par laquelle l'écrivain dépasse la simple observation extérieure pour pénétrer la conscience d'autrui, comprendre les motifs de ses actions et restituer la complexité de son expérience. Ces critiques mettent en évidence une tension centrale du naturalisme : celle qui oppose l'ambition d'objectivité scientifique à la nécessité d'une compréhension sensible et psychologique de l'être humain.

Le naturalisme ne forme d'ailleurs pas une école parfaitement homogène. S'il revendique l'héritage de Diderot, de Rousseau, de Balzac, de Stendhal, de Flaubert et des frères Goncourt, ses représentants divergent sur la définition même du mouvement. Edmond de Goncourt préfère parler de « naturisme », Joris-Karl Huysmans d'« intimisme », Louis-Marie Desprez d'« impressionnisme », tandis que Guy de Maupassant propose le terme d'« illusionnistes ». Cette diversité terminologique révèle l'existence de pratiques et de conceptions distinctes derrière l'apparente unité du groupe naturaliste²⁵.

Le succès des *Soirées de Médan*, publiées en 1880, marque l'un des moments les plus emblématiques de cette aventure collective. Toutefois, l'unité du mouvement se fragilise rapidement. Le *Manifeste des Cinq*, publié en 1887 contre *La Terre* de Zola, rend visibles les désaccords internes, tandis que plusieurs auteurs s'éloignent progressivement de l'esthétique naturaliste. Huysmans, notamment, ouvre avec *À rebours* la voie à une littérature décadente et symboliste²⁶. À la fin du siècle, le développement du roman psychologique et du symbolisme contribue ainsi au déclin du naturalisme en tant qu'école constituée. La formule attribuée à Stéphane Mallarmé, selon laquelle « le mot mourra quand Zola aura achevé son œuvre », souligne à la fois le rôle déterminant de Zola dans la définition du mouvement et la difficulté du naturalisme à lui survivre sous une forme unifiée²⁷.

Dans quelle mesure les méthodes de modélisation thématique et de classification automatique permettent-elles d'identifier des marqueurs du naturalisme sans confondre signature d'auteur, contenu thématique et artefacts de constitution du corpus ?

Afin de répondre à cette problématique, ce mémoire s'organise en trois chapitres

22. *Ibid.*

23. Ferdinand Brunetière, *Le roman naturaliste*, Paris, Calmann-Lévy, 1883.

24. Edmond Cattier, *Le Naturalisme littéraire*, Bruxelles, Weissenbruch, 1897.

25. [https://fr.wikipedia.org/wiki/Naturalisme_\(litt%C3%A9rature\)](https://fr.wikipedia.org/wiki/Naturalisme_(litt%C3%A9rature))

26. *Ibid.*

27. Jules Huret, *Enquête sur l'évolution littéraire*, Paris, Charpentier, 1891.

complémentaires. Le premier présente une exploration thématique classique des trente et un romans d'Émile Zola à l'aide de la factorisation en matrices non négatives et de la méthode K-means. Cette première analyse vise à dégager des régularités lexicales et thématiques internes à l'œuvre zolienne, considérées comme des marqueurs candidats plutôt que comme des preuves immédiates du naturalisme. Le deuxième chapitre étudie ces régularités au moyen de BERTopic et analyse leur évolution au cours de la carrière de Zola. Le troisième chapitre confronte les hypothèses issues de ces analyses à un corpus comparatif grâce à une classification automatique opposant romans naturalistes et romans relevant d'autres courants. Une attention particulière est accordée aux risques de confusion entre signature d'auteur, contenu thématique et artefacts liés à la constitution du corpus. Enfin, les choix de nettoyage, l'organisation de la base de données et les principaux éléments nécessaires à la reproductibilité des expériences sont présentés en annexe.

Chapitre 1

Topic modeling sur les romans d'Émile Zola

1.1 Présentation de la méthode

Émile Zola, l'un des écrivains majeurs du XIX^e siècle, est connu pour ses romans naturalistes, dans lesquels il explore les dimensions sociales, économiques et psychologiques de la vie humaine. Son œuvre romanesque constitue ainsi un corpus particulièrement riche pour l'analyse des thèmes récurrents, des milieux sociaux et des motifs narratifs.

Dans cette étude, nous examinons les thèmes présents dans les romans de Zola afin de déterminer dans quelle mesure certains motifs apparaissent de manière transversale dans son œuvre. Pour cela, nous mobilisons des méthodes d'analyse textuelle non supervisées, capables d'identifier des regroupements lexicaux à partir des textes eux-mêmes.

La question centrale de cette étude est donc la suivante : dans quelle mesure des méthodes non supervisées comme la NMF et K-means permettent-elles de faire apparaître des structures thématiques récurrentes dans l'œuvre romanesque de Zola ?

L'objectif est de vérifier si les regroupements produits automatiquement correspondent à des motifs interprétables dans le cadre d'une analyse littéraire. Il ne s'agit donc pas de remplacer la lecture critique des textes, mais d'utiliser les outils du traitement automatique du langage comme un moyen d'explorer un corpus littéraire volumineux.

Ce travail constitue le premier volet d'une série d'analyses portant sur des corpus de textes littéraires issus d'auteurs naturalistes et non naturalistes. Il sert à la fois de cas d'étude méthodologique et de base pour de futures comparaisons entre différents ensembles d'œuvres.

Deux méthodes d'analyse ont été utilisées pour identifier les thèmes dans les romans de Zola :

- la NMF (Non-negative Matrix Factorization)¹ : une technique de réduction de dimensionnalité qui permet d'extraire des topics à partir d'un corpus de textes ;
- K-means : une méthode de clustering qui permet de regrouper les segments textuels en fonction de leur proximité lexicale.².

Ces méthodes seront expliquées dans les sections suivantes, avant la présentation des résultats de l'analyse thématique des romans de Zola.

Dans cette étude, le terme *topic* désigne un regroupement lexical produit par le modèle NMF, tandis que le terme *cluster* désigne un groupe de segments obtenu par K-means. Le terme *thème* est réservé à l'interprétation qualitative de ces regroupements. Cette précision terminologique est importante pour éviter toute confusion entre les différentes étapes de l'analyse.

1.2 Présentation du corpus d'étude

1.2.1 Choix du corpus

Cette étude porte sur 31 romans d'Émile Zola, publiés entre 1865 et 1903. Les nouvelles, les essais et les textes journalistiques ont été écartés afin de constituer un ensemble relativement homogène du point de vue du genre et de la longueur. Les romans offrent également un contexte suffisamment développé pour étudier les thèmes, les milieux sociaux et les motifs récurrents de l'œuvre zolienne.

Ce choix répond aussi à une contrainte méthodologique. L'intégration de textes courts aurait accentué les différences de volume entre les œuvres et aurait pu déséquilibrer l'analyse thématique. La restriction du corpus au genre romanesque ne supprime pas toutes les variations de longueur, mais elle les limite et facilite la comparaison entre les textes.

Le corpus réunit cinq romans antérieurs aux *Rougon-Macquart*, les vingt volumes de ce cycle, les trois romans des *Trois Villes* et les trois volumes publiés des *Quatre Évangiles*. Dans ce dernier cycle, *Vérité* paraît à titre posthume, tandis que *Justice*, resté à l'état d'ébauche, n'a jamais été publié.

TABLE 1.1 – Nombre de tokens par roman de Zola dans l'ordre chronologique

Date	Titre du roman	Nombre de tokens
1865	<i>La confession de Claude</i>	47253
1866	<i>Le vœu d'une morte</i>	38722

1. N. Gillis, *Nonnegative Matrix Factorization*, Society for Industrial and Applied Mathematics, coll. « Data Science », 2020.

2. Richard O. Duda, Peter E. Hart et David G. Stork, *Pattern Classification*, Wiley-Interscience, 2001.

Date	Titre du roman	Nombre de tokens
1867	<i>Les mystères de Marseille</i>	125253
1867	<i>Thérèse Raquin</i>	66363
1868	<i>Madeleine Féral</i>	97318
1871	<i>La fortune des Rougon</i>	116685
1872	<i>La curée</i>	105120
1873	<i>Le ventre de Paris</i>	110442
1874	<i>La conquête de Plassans</i>	113245
1875	<i>La faute de l'abbé Mouret</i>	114667
1876	<i>Son Excellence Eugène Rougon</i>	126186
1877	<i>L'assommoir</i>	158340
1878	<i>Une page d'amour</i>	102185
1880	<i>Nana</i>	141573
1882	<i>Pot-Bouille</i>	134844
1883	<i>Au Bonheur des dames</i>	147521
1884	<i>La joie de vivre</i>	117255
1885	<i>Germinal</i>	164473
1886	<i>L'œuvre</i>	130613
1887	<i>La terre</i>	163687
1888	<i>Le rêve</i>	66379
1890	<i>La bête humaine</i>	125418
1891	<i>L'argent</i>	143010
1892	<i>La débâcle</i>	187046
1893	<i>Le docteur Pascal</i>	112713
1894	<i>Lourdes</i>	173511
1896	<i>Rome</i>	233958
1898	<i>Paris</i>	177389
1899	<i>Fécondité</i>	220131
1901	<i>Travail</i>	198712
1903	<i>Vérité</i>	223274

Ce corpus couvre ainsi l'ensemble de la carrière romanesque de Zola, de ses premiers textes à ses dernières œuvres. Cette amplitude chronologique permet d'observer les régularités thématiques de son écriture, mais aussi leurs transformations éventuelles au fil du temps, qui seront étudiées dans le chapitre consacré à BERTopic.

1.2.2 Préparation des textes

Les romans ont été réunis au format `.txt`, puis nettoyés afin de retirer les éléments éditoriaux qui ne relèvent pas directement du récit : mentions d'édition, tables des matières, notes, numéros de page et intitulés de chapitres. Cette étape vise à éviter que ces éléments n'influencent artificiellement les résultats³.

Après nettoyage, chaque fichier a été organisé de manière à ne conserver qu'une phrase par ligne. Cette organisation ne modifie pas le contenu des romans, mais facilite leur traitement automatique et leur segmentation. Elle permet également d'appliquer la même procédure à des textes provenant initialement de formats différents, notamment TXT, PDF ou EPUB.

Le nombre de tokens varie sensiblement d'un roman à l'autre. Les premiers textes, comme *Le vœu d'une morte*, sont relativement courts, tandis que des œuvres tardives comme *Rome, Fécondité, Travail* ou *Vérité* sont beaucoup plus volumineuses. Cette différence doit être prise en compte, car un roman long produit mécaniquement davantage d'occurrences lexicales et d'unités d'analyse qu'un roman court.

1.2.3 Préparation du corpus pour l'analyse thématique

Les romans ont été découpés en segments de 40 phrases. Cette taille constitue un compromis entre deux objectifs : conserver suffisamment de contexte pour identifier un thème et produire des unités plus fines que les chapitres ou les œuvres entières.

Plusieurs tailles de segments ont été expérimentées, notamment 10, 40, 50, 70 et 100 phrases. Les segments de 40 phrases ont donné les résultats les plus lisibles et les plus cohérents au cours des essais exploratoires. Ce choix reste néanmoins en partie empirique et constitue donc une limite méthodologique.

Un découpage par chapitre ou par paragraphe a également été envisagé. Ces solutions ont été écartées en raison de la forte variation de longueur de ces unités. De plus, la structure des paragraphes n'est pas toujours conservée de manière fiable lors de la conversion des fichiers. Les dialogues produisent notamment de nombreux paragraphes très courts. Le découpage par phrases offre donc une solution plus homogène et plus facilement applicable à l'ensemble du corpus.

1.2.4 Statistiques descriptives du corpus

3. Pour ce qui est des scripts de nettoyage, ils sont disponible en annexe et/ou sur mon github

TABLE 1.2 – Nombre de paquets de phrases par roman

Titre du roman	Nombre de paquets
<i>La confession de Claude</i>	65
<i>Le vœu d'une morte</i>	60
<i>Les mystères de Marseille</i>	184
<i>Thérèse Raquin</i>	80
<i>Madeleine Féral</i>	124
<i>La fortune des Rougon</i>	154
<i>La curée</i>	123
<i>Le ventre de Paris</i>	136
<i>La conquête de Plassans</i>	165
<i>La faute de l'abbé Mouret</i>	171
<i>Son Excellence Eugène Rougon</i>	191
<i>L'assommoir</i>	228
<i>Une page d'amour</i>	166
<i>Nana</i>	225
<i>Pot-Bouille</i>	207
<i>Au Bonheur des dames</i>	198
<i>La joie de vivre</i>	164
<i>Germinal</i>	225
<i>L'œuvre</i>	163
<i>La terre</i>	222
<i>Le rêve</i>	82
<i>La bête humaine</i>	154
<i>L'argent</i>	155
<i>La débâcle</i>	221
<i>Le docteur Pascal</i>	135
<i>Lourdes</i>	198
<i>Rome</i>	231
<i>Paris</i>	206
<i>Fécondité</i>	259
<i>Travail</i>	208
<i>Vérité</i>	227

La segmentation produit un nombre variable de paquets selon la longueur des œuvres. Les romans les plus courts, comme *Le vœu d'une morte* et *La confession de Claude*, fournissent moins d'unités d'analyse, tandis que *Fécondité*, *Rome* ou *L'assommoir* en produisent davantage.

TABLE 1.3 – Statistiques descriptives du nombre de paquets par roman

Indicateur	Valeur
Nombre de romans	31
Moyenne	171.84
Écart-type	52.40
Minimum	60
Premier quartile	145
Médiane	171
Troisième quartile	214.5
Maximum	259

Le corpus comprend en moyenne environ 172 paquets par roman, avec une médiane de 171. Ces deux valeurs proches montrent que la distribution n'est pas fortement déséquilibrée. L'écart-type de 52 paquets et l'écart entre le minimum de 60 et le maximum de 259 témoignent toutefois d'une variation réelle entre les œuvres.

Cette différence doit être gardée à l'esprit lors de l'interprétation des résultats : les romans les plus longs contribuent à un plus grand nombre de segments et peuvent donc occuper une place plus importante dans les résultats globaux. La segmentation améliore la comparabilité des unités textuelles, mais elle ne supprime pas entièrement l'effet lié à la longueur des œuvres.

TABLE 1.4 – Statistiques descriptives du nombre de mots par paquet

Indicateur	Valeur
Nombre de paquets	5327
Moyenne	785.30
Écart-type	212.13
Minimum	42
Premier quartile	636
Médiane	753
Troisième quartile	902.5
Maximum	2944

Au total, le corpus segmenté comprend 5,327 paquets. Ils contiennent en moyenne 785 mots, pour une médiane de 753 mots. La moitié centrale des segments se situe entre 636 et environ 903 mots, ce qui indique que la majorité des unités possède une taille relativement comparable.

La variation restante s'explique par le choix d'un nombre fixe de phrases plutôt que d'un nombre fixe de mots. Selon le rythme narratif et la longueur des phrases, deux

segments peuvent donc présenter des volumes différents. Les valeurs extrêmes, comprises entre 42 et 2,944 mots, correspondent probablement à des segments résiduels ou à des passages composés de phrases particulièrement longues. Ces cas doivent être pris en compte, car les segments les plus volumineux contiennent davantage d'information lexicale.

1.2.5 Lemmatisation du corpus de Zola

Les segments ont ensuite été lemmatisés⁴ avec la bibliothèque Python `spaCy` et son modèle français `fr_core_news_lg`. La lemmatisation rassemble les différentes formes fléchies d'un mot sous une forme commune : « mange », « manges » et « manger » sont ainsi associés au lemme « manger ». Cette normalisation réduit la dispersion du vocabulaire et facilite la construction de la matrice terme-document.

Une liste d'exclusion personnalisée a été constituée au fil des essais. Elle comprend les mots-outils, la ponctuation, les nombres et certains termes très fréquents mais peu utiles à l'interprétation des thèmes. Plusieurs noms de personnages ont également été retirés, car leur présence tendait à produire des topics centrés sur les protagonistes plutôt que sur des ensembles thématiques plus généraux.

Pour chaque segment, les lemmes sont convertis en minuscules, puis filtrés. Seuls les noms et les adjectifs sont conservés, ces catégories étant particulièrement utiles pour faire apparaître des contenus thématiques tels que le travail, la famille, la religion, l'argent ou les rapports sociaux. Ce choix oriente donc volontairement l'analyse vers les thèmes et non vers le style grammatical de Zola.

La liste d'exclusion a été ajustée après l'examen des termes les plus fréquents et des premiers résultats. Cette procédure empirique améliore la lisibilité des topics, mais elle introduit également une part d'intervention humaine qui doit être prise en compte dans leur interprétation. À l'issue du traitement, chaque roman est représenté par un ensemble de segments lemmatisés et filtrés, utilisés pour les analyses par NMF et K-means.

1.3 Analyse par NMF et K-means

Deux méthodes non supervisées ont été utilisées pour explorer les régularités thématiques du corpus : la factorisation en matrices non négatives (NMF) et K-means. La première fait apparaître des topics à partir de groupes de mots fréquemment associés, tandis que la seconde rassemble les segments présentant des profils lexicaux proches. Leur comparaison permet d'observer le corpus selon deux perspectives complémentaires.

4. Le code est disponible sur mon gitub

1.3.1 La méthode NMF

La NMF (*Non-negative Matrix Factorization*) est une méthode de réduction dimensionnelle fréquemment utilisée pour l'exploration thématique. Elle décompose une matrice documents-termes en deux matrices non négatives : la première associe les segments aux topics, tandis que la seconde associe les topics aux termes qui les caractérisent.

Chaque segment peut ainsi être rattaché à plusieurs topics avec des poids différents. Cette représentation est adaptée aux textes littéraires, dans lesquels plusieurs thèmes peuvent apparaître simultanément au sein d'un même passage.

Création de la matrice documents-termes

Les segments lemmatisés ont d'abord été transformés en une représentation numérique à l'aide d'une pondération TF-IDF⁵. Cette pondération valorise les termes caractéristiques d'un segment tout en réduisant l'influence des mots présents dans une grande partie du corpus.

Deux paramètres ont été utilisés pour filtrer le vocabulaire. Le paramètre `min_df=3` écarte les termes présents dans moins de trois segments, considérés comme trop rares pour faire apparaître des régularités thématiques. À l'inverse, `max_df=0.8` retire les termes présents dans plus de 80 % des segments, qui sont trop fréquents pour être réellement discriminants⁶.

Plusieurs configurations ont été expérimentées. Les paramètres retenus offrent un compromis entre la réduction du vocabulaire et la conservation des termes utiles à l'interprétation. La matrice obtenue sert ensuite d'entrée au modèle NMF.

Choix du nombre de topics

Le nombre de topics influence directement la précision des résultats. Une valeur trop faible produit des catégories très générales, tandis qu'une valeur trop élevée fragmente les thèmes et multiplie les topics proches ou difficiles à interpréter.

La méthode du coude a d'abord été utilisée pour orienter ce choix⁷. Plusieurs modèles ont été entraînés avec un nombre croissant de topics, puis comparés à partir de leur erreur de reconstruction. Un coude clairement marqué aurait indiqué qu'au-delà d'un certain seuil, l'ajout de nouveaux topics améliorerait peu la reconstruction de la matrice.

5. Le TF-IDF (*term frequency-inverse document frequency*) mesure l'importance d'un terme dans un document en tenant compte de sa fréquence dans l'ensemble du corpus. Le calcul a été réalisé avec la bibliothèque `scikit-learn`.

6. Le code du vectoriseur est disponible sur le dépôt GitHub associé au mémoire.

7. Le code correspondant est présenté en annexe.




FIGURE 1.1 – Méthode du coude pour le choix du nombre de topics dans la NMF, entre 2 et 40 topics

Comme le montre la figure 1.1, l'erreur diminue régulièrement lorsque le nombre de topics augmente. Cette évolution est attendue : un modèle disposant de davantage de topics peut reconstruire plus précisément la matrice initiale. La courbe ne présente cependant aucune rupture suffisamment nette pour désigner une valeur optimale.

Une seconde visualisation a donc été produite entre 20 et 39 topics afin d'examiner plus précisément cette partie de la courbe.




FIGURE 1.2 – Méthode du coude pour le choix du nombre de topics dans la NMF, entre 20 et 39 topics

Ce second graphique confirme l'absence de coude clairement identifiable. Le choix final ne pouvait donc pas reposer uniquement sur l'erreur de reconstruction. Plusieurs modèles, comprenant notamment 10, 15, 20, 29, 30 et 35 topics, ont alors été comparés à partir des mots caractéristiques de chaque topic, de leur cohérence interne et de leur lisibilité.

Le modèle à 29 topics a finalement été retenu. Il offre un niveau de détail suffisant pour distinguer plusieurs ensembles thématiques sans produire une fragmentation excessive. Ce choix reste néanmoins empirique : il correspond au meilleur compromis observé dans le cadre de cette étude, et non à une valeur optimale démontrée de manière absolue.

Paramétrage du modèle

Le modèle final utilise le paramètre `n_components=29`. Le paramètre `random_state=42` assure la reproductibilité du traitement. L'initialisation `nndsvda`⁸ fournit un point de départ stable, tandis que le solveur `cd`, pour *coordinate descent*, optimise progressivement la factorisation.

La matrice `W` contient le poids de chacun des 29 topics dans chaque segment. La matrice `H` indique, pour sa part, le poids des termes dans chaque topic. L'examen des termes les mieux pondérés permet ensuite d'interpréter et de nommer les topics.

Portée et limites de la NMF

La NMF fournit une première cartographie des régularités lexicales du corpus. Elle permet notamment de faire apparaître des ensembles liés au travail, à la religion, à la famille, à l'argent, à la guerre, au commerce, à la médecine ou encore à l'espace domestique.

Les résultats restent toutefois dépendants des choix réalisés en amont : nettoyage, segmentation, lemmatisation, catégories grammaticales conservées, liste d'exclusion, paramètres du vectoriseur et nombre de topics. La modélisation thématique ne constitue donc pas une procédure entièrement automatique, mais une démarche exploratoire associant calcul statistique et interprétation humaine.

La nomination des topics comporte également une part de subjectivité. Deux lecteurs pourraient proposer des intitulés différents pour un même groupe de termes. Ces noms doivent par conséquent être compris comme des outils d'interprétation et non comme des catégories définitives.

Enfin, puisque le prétraitement conserve principalement les noms et les adjectifs, cette analyse porte avant tout sur le contenu thématique. Elle ne permet pas, à elle

8. L'initialisation `nndsvda` est une variante de NNDSVD dans laquelle les valeurs nulles sont remplacées par la moyenne de la matrice. Voir la documentation de `scikit-learn`.

seule, de distinguer ce qui relève du naturalisme, de la signature personnelle de Zola ou des sujets particuliers de ses romans. Cette distinction sera étudiée à l'aide du corpus comparatif et de la classification automatique.

1.3.2 La méthode K-means

K-means a été utilisé comme une seconde manière d'explorer la structure du corpus. Contrairement à la NMF, qui représente chaque segment comme une combinaison de plusieurs topics, K-means attribue chaque segment à un seul cluster en fonction de sa proximité lexicale avec les autres segments.

L'objectif est de déterminer si les segments peuvent être regroupés en ensembles cohérents et si certains de ces regroupements présentent des ressemblances avec les topics obtenus par la NMF. Il ne s'agit pas d'une validation indépendante, puisque les deux méthodes utilisent la même représentation TF-IDF, mais d'une triangulation exploratoire fondée sur deux modes de structuration différents.

Préparation de la matrice TF-IDF

K-means est appliqué à la même matrice TF-IDF que la NMF. Les textes, la lemmatisation, la liste d'exclusion et les paramètres `min_df` et `max_df` restent donc identiques⁹. Ce choix garantit que les différences observées proviennent principalement du fonctionnement des deux méthodes et non d'un changement de représentation du corpus.

Recherche du nombre de clusters

Comme pour la NMF, le nombre de groupes doit être fixé avant l'entraînement du modèle. Une valeur trop faible risque de réunir des motifs distincts, tandis qu'une valeur trop élevée peut produire des clusters très proches ou difficiles à interpréter.

Plusieurs valeurs de `k`, comprises entre 2 et 40, ont été évaluées à l'aide du score de silhouette¹⁰. Ce score mesure à la fois la cohésion interne des clusters et leur séparation : une valeur élevée indique que les segments sont proches des éléments de leur propre groupe et éloignés des autres groupes.

9. Voir la section consacrée à la création de la matrice documents-termes.

10. Peter J. Rousseeuw, « Silhouettes : A Graphical Aid to the Interpretation and Validation of Cluster Analysis », *Journal of Computational and Applied Mathematics*, vol. 20, 1987, p. 53–65.




FIGURE 1.3 – Évolution du score de silhouette en fonction du nombre de clusters dans K-means

La figure 1.3 fournit une indication quantitative sur la structure du corpus, mais elle ne désigne pas à elle seule une valeur incontestable. Le modèle final a été fixé à 29 clusters afin de conserver un niveau de granularité comparable aux 29 topics de la NMF.

Ce choix facilite la confrontation des deux méthodes, mais il ne signifie pas qu’elles convergent indépendamment vers le nombre 29. Les 29 clusters ont été retenus en partie pour rendre la comparaison possible. L’analyse porte donc principalement sur les ressemblances et les différences entre les motifs lexicaux obtenus, et non sur une validation du nombre exact de groupes.

Entraînement du modèle

Le modèle final est entraîné avec `n_clusters=29`. Le paramètre `random_state=42` garantit la reproductibilité, tandis que `n_init=10` lance l’algorithme avec plusieurs initialisations et conserve la meilleure solution.

À l’issue de l’entraînement, chaque segment est rattaché à l’un des 29 clusters. Les termes les plus caractéristiques de chaque groupe et les segments qui lui sont associés servent ensuite à interpréter son contenu.

Portée et limites de K-means

La principale limite de K-means tient à son fonctionnement exclusif : chaque segment appartient à un seul cluster. Or, un passage littéraire peut faire intervenir plusieurs thèmes simultanément, par exemple la famille, l’argent et la souffrance sociale. La NMF

représente plus facilement ce type de coexistence, puisqu'elle attribue plusieurs poids thématiques à un même segment.

Les résultats de K-means sont également sensibles à la représentation TF-IDF et aux étapes de préparation du corpus. Une modification de la segmentation, de la lemmatisation ou du vocabulaire retenu pourrait produire une organisation différente. Comme pour la NMF, les clusters doivent donc être considérés comme une cartographie exploratoire plutôt que comme une classification définitive.

Enfin, leur nomination repose sur l'examen des termes et des segments les plus représentatifs. Cette interprétation humaine est nécessaire pour donner un sens littéraire aux groupes obtenus, mais elle introduit une part de subjectivité qui doit rester explicite.

Bilan méthodologique

La NMF et K-means proposent deux lectures complémentaires du corpus. La NMF décrit chaque segment comme une combinaison de topics, tandis que K-means construit une partition unique fondée sur la proximité lexicale. La comparaison de leurs résultats permet de repérer des motifs récurrents, mais ne constitue pas une validation indépendante puisque les deux méthodes reposent sur les mêmes données et la même matrice TF-IDF.

Une classification hiérarchique appliquée aux centres des clusters permet enfin de rassembler les 29 groupes en cinq familles thématiques plus générales. Cette organisation facilite la lecture des résultats, présentés dans la section suivante.

1.4 Résultats

1.4.1 Topics obtenus avec le NMF

Identification et interprétation des topics

Une fois le modèle entraîné, les mots les plus importants de chaque topic ont été extraits afin de faciliter leur interprétation. Cette étape est essentielle, car le NMF ne produit pas directement des noms de thèmes : elle produit des groupes de mots. L'attribution d'un nom à chaque topic repose donc sur une analyse qualitative des termes les plus représentatifs.

Le tableau suivant présente les dix mots les plus caractéristiques de chaque topic obtenu avec la NMF. Ces mots servent de base à l'interprétation qualitative des thèmes extraits par le modèle.

TABLE 1.5 – Mots caractéristiques des topics obtenus avec la NMF

Topic	Mots caractéristiques
Topic 1	femme, mari, chose, bon, homme, cher, ménage, histoire, vrai, plaisir
Topic 2	travail, peuple, vie, usine, bonheur, justice, ouvrier, œuvre, humanité, terre
Topic 3	arbre, soleil, herbe, eau, ciel, jardin, ombre, terre, feuille, branche
Topic 4	million, bourse, cours, action, universelle, banque, affaire, agent, hausse, titre
Topic 5	abbé, prêtre, curé, église, jardin, trouche, soutane, sous-préfecture, évêque
Topic 6	table, verre, vin, pain, café, eau, maman, assiette, bon, petit
Topic 7	main, œil, mort, bras, sang, tête, corps, face, voix, lèvre
Topic 8	franc, argent, billet, somme, mois, sou, chiffre, pièce, fortune, poche
Topic 9	monsieur, dame, porte, vou, bon, air, voix, tante, main, mot
Topic 10	rue, maison, quartier, trottoir, boutique, boulevard, ville, place, voiture, chaussée
Topic 11	train, gare, heure, machine, chef, voiture, voie, wagon, express, portière
Topic 12	grotte, saint, sœur, malade, miracle, foule, cierge, foi, prêtre, pèlerin
Topic 13	frère, sœur, modèle, petit, écriture, heure, pauvre, fine, lettre, témoin
Topic 14	cardinal, pape, éminence, livre, palais, église, prêtre, don, prélat, romain
Topic 15	école, instituteur, élève, vérité, église, classe, modèle, primaire, enseignement, juif
Topic 16	père, fils, vieux, famille, fille, ferme, terre, paysan, maison, mort
Topic 17	fosse, mineur, ouvrier, camarade, puits, coron, berline, galerie, porion, grève
Topic 18	prussien, soldat, armée, général, route, cheval, corps, canon, capitaine, homme
Topic 19	jeune, fille, homme, oncle, fine, nièce, garçon, mariage, tante, amant
Topic 20	vendeur, rayon, magasin, comptoir, soie, dame, client, vente, bonheur, confection

Topic	Mots caractéristiques
Topic 21	docteur, médecin, malade, maladie, visite, heure, jour, miracle, cher, jambe
Topic 22	tableau, toile, peintre, peinture, œuvre, atelier, art, artiste, salle, étude
Topic 23	chambre, lit, porte, heure, fenêtre, nuit, escalier, pièce, maison, meuble
Topic 24	enfant, mère, petit, fille, maman, pauvre, nourrice, bon, larme, œil
Topic 25	bel, halle, charcuterie, quenu, boutique, gras, charcutier, marchand, normande, blanc
Topic 26	salon, comte, dame, comtesse, satin, marquis, blanc, rose, femme, petit
Topic 27	empereur, ministre, député, préfet, président, colonel, politique, affaire, lettre, ami
Topic 28	amour, cœur, vie, tendresse, jour, pensée, bonheur, amant, heure, joie
Topic 29	insurgé, barricade, national, ville, fusil, garde, républicain, ouvrier, place, peuple

Chaque topic a ensuite été nommé à partir des mots dominants et de l’observation des segments les plus fortement associés à ce topic. Cette double vérification permet de limiter les erreurs d’interprétation. En effet, certains mots peuvent sembler cohérents isolément, mais prendre un sens différent lorsqu’ils sont replacés dans les extraits du corpus.

Les topics obtenus couvrent plusieurs dimensions importantes de l’œuvre de Zola. Certains renvoient à des espaces sociaux précis, comme le magasin, la mine, la bourse, le quartier ou le monde ferroviaire. D’autres correspondent à des thèmes plus transversaux, comme la famille, le désir, la maladie, la religion, la pauvreté ou la mort. Cette diversité montre que le NMF permet de faire apparaître à la fois des thèmes sociaux, des motifs narratifs et des univers propres à certains romans.

Nommer les topics

Les topics ont ensuite été nommés manuellement à partir des mots les plus représentatifs et des segments les plus fortement associés. Cette étape constitue une part qualitative importante de l’analyse. Elle permet de transformer les résultats numériques du modèle en catégories interprétables.

TABLE 1.6 – Noms attribués aux topics obtenus avec la NMF

Topic	Nom attribué
Topic 1	Les relations conjugales et la vie domestique
Topic 2	Le travail, le peuple et la justice sociale
Topic 3	La nature et le paysage
Topic 4	La bourse, la finance et les affaires
Topic 5	Le clergé et la paroisse
Topic 6	La table et les repas
Topic 7	Le corps, la souffrance et la mort
Topic 8	L'argent et la fortune
Topic 9	Les conversations et les scènes domestiques
Topic 10	Le quartier et la ville
Topic 11	Le monde ferroviaire
Topic 12	Le miracle, le pèlerinage et la religion
Topic 13	Les liens familiaux, l'écriture et les proches
Topic 14	Le pouvoir religieux
Topic 15	L'école et l'instruction
Topic 16	La famille, la terre et le monde paysan
Topic 17	Le monde ouvrier et la mine
Topic 18	La guerre, les soldats et l'armée
Topic 19	Le désir, le mariage et les relations amoureuses
Topic 20	Le magasin, la vente et les clientes
Topic 21	Le monde médical et la santé
Topic 22	Le monde artistique et la peinture
Topic 23	La chambre, le lit et l'espace intime
Topic 24	L'enfance, la maternité et la pauvreté
Topic 25	Le commerce alimentaire et les halles
Topic 26	Le salon, l'aristocratie et les scènes mondaines
Topic 27	Le pouvoir politique et les affaires publiques
Topic 28	L'amour, le bonheur et les sentiments
Topic 29	L'insurrection et la révolution

Cette étape montre que l'analyse ne repose pas uniquement sur une extraction automatique. Le modèle propose des regroupements de mots, mais leur interprétation dépend d'un travail humain. Les noms attribués aux topics doivent donc être compris comme des catégories d'analyse construites à partir des résultats du modèle, et non comme des vérités objectives produites automatiquement par l'algorithme.

1.4.2 Nombre de segments associés à chaque topic dominant

Afin d’analyser la répartition des thèmes dans le corpus, un topic dominant a été attribué à chaque segment. Pour cela, les poids de la matrice W ont d’abord été normalisés afin de rendre les contributions des topics comparables entre les segments. Le topic dominant correspond ensuite au topic dont le poids est le plus élevé pour un segment donné.

La colonne **topic_dominant** indique donc le topic le plus représenté dans chaque paquet de phrases. La colonne **poids_topic** mesure l’intensité de cette association : plus cette valeur est élevée, plus le segment est clairement associé à un topic spécifique. À l’inverse, un poids faible peut signaler un segment plus mixte, contenant plusieurs thèmes ou ne correspondant fortement à aucun topic.

Cette attribution permet de passer d’une simple liste de topics à une analyse plus structurée de leur répartition dans le corpus. Elle rend possible l’étude du nombre de segments associés à chaque topic, du poids moyen des topics dans l’ensemble du corpus et de leur présence selon les romans. Le tableau suivant présente le nombre de segments associés à chaque topic dominant.

TABLE 1.7 – Nombre de segments associés à chaque topic dominant

Topic dominant	Nombre de segments
L’amour, le bonheur et les sentiments	335
La chambre, le lit et l’espace intime	327
Le pouvoir politique et les affaires publiques	266
Le salon, l’aristocratie et les scènes mondaines	266
Le travail, le peuple et la justice sociale	262
La nature et le paysage	229
L’enfance, la maternité et la pauvreté	221
Le corps, la souffrance et la mort	218
La table et les repas	214
Le clergé et la paroisse	210
Le quartier et la ville	205
L’argent et la fortune	187
Le monde ouvrier et la mine	185
La famille, la terre et le monde paysan	180
Le miracle, le pèlerinage et la religion	177
Le désir, le mariage et les relations amoureuses	173
La guerre, les soldats et l’armée	173
L’école et l’instruction	168
Le monde médical et la santé	164

Topic dominant	Nombre de segments
Le commerce alimentaire et les halles	163
Les conversations et les scènes domestiques	162
Le monde artistique et la peinture	141
Le pouvoir religieux	140
Le magasin, la vente et les clientes	136
L'insurrection et la révolution	127
Les liens familiaux, l'écriture et les proches	104
Le monde ferroviaire	94
La bourse, la finance et les affaires	69
Les relations conjugales et la vie domestique	31

La répartition des segments montre que les topics ne sont pas représentés de manière parfaitement équilibrée. Certains thèmes regroupent un nombre important de segments, tandis que d'autres apparaissent de façon plus marginale. Cette variation est attendue dans un corpus littéraire, car tous les motifs thématiques ne sont pas présents avec la même intensité dans l'ensemble des romans.

Les topics les plus représentés correspondent aux thèmes qui structurent fortement le corpus. Les premiers résultats font apparaître des motifs liés aux sentiments, à l'espace intime, aux relations sociales, au pouvoir politique, aux scènes mondaines ou encore au travail. Ces ensembles renvoient à des dimensions récurrentes de l'œuvre de Zola, dans laquelle les expériences individuelles sont souvent articulées à des milieux sociaux, familiaux, économiques ou institutionnels.

À l'inverse, les topics les moins représentés ne doivent pas être considérés comme moins importants sur le plan littéraire. Ils peuvent correspondre à des univers plus localisés, associés à certains romans précis ou à des situations narratives particulières. C'est notamment le cas de thèmes comme la bourse, le monde ferroviaire ou certaines formes de relations domestiques, qui peuvent être fortement présents dans quelques œuvres sans être répartis de manière uniforme dans l'ensemble du corpus.

Cette distribution montre donc que la NMF ne produit pas seulement une liste de thèmes interprétables : elle permet aussi d'évaluer leur poids relatif dans le corpus. Le nombre de segments associés à chaque topic donne une première indication de l'importance quantitative des thèmes extraits. Cette mesure doit toutefois être interprétée avec prudence : un topic fréquent n'est pas nécessairement plus important sur le plan littéraire, mais il est plus présent lexicalement dans les segments analysés.

Enfin, cette attribution des topics dominants peut servir de base à des analyses complémentaires. Elle permet notamment d'étudier la distribution des topics par œuvre, de comparer les romans entre eux, ou encore d'appliquer ultérieurement un détecteur

de motifs aux segments associés à chaque topic afin d'identifier les motifs narratifs les plus caractéristiques de chaque thème.

1.4.3 Clusters obtenus avec K-means

Extraction des mots caractéristiques des clusters

Une fois le modèle entraîné, les centres des clusters ont été analysés afin d'identifier les termes les plus représentatifs de chaque groupe. Dans K-means, chaque cluster est représenté par un centroïde, c'est-à-dire un point moyen dans l'espace vectoriel. Les termes les plus fortement associés à ce centroïde permettent de comprendre le contenu thématique du cluster.

Cette étape est comparable à l'extraction des mots dominants dans la NMF. Elle permet d'associer chaque cluster à un ensemble de termes caractéristiques. Cependant, l'interprétation est légèrement différente : dans la NMF, les mots sont associés à un topic latent ; dans K-means, ils décrivent le centre lexical d'un groupe de segments. Autrement dit, les mots obtenus indiquent ce qui rapproche les segments d'un même cluster.

TABLE 1.8 – Mots caractéristiques des clusters obtenus avec K-means

Cluster	Mots caractéristiques
Cluster 1	verre, petit, table, maman, coup, femme, vin, eau, tête, homme
Cluster 2	instituteur, école, enfant, vérité, élève, petit, église, père, classe, bon
Cluster 3	salon, dame, femme, monsieur, petit, blanc, satin, homme, jeune, rose
Cluster 4	chambre, porte, lit, monsieur, heure, femme, petit, maison, escalier, fenêtre
Cluster 5	enfant, femme, nourrice, petit, usine, constance, fille, mari, monsieur, cher
Cluster 6	mère, fille, petit, enfant, père, femme, fils, bon, jeune, œil
Cluster 7	train, gare, chef, machine, voie, heure, express, mécanicien, tunnel, voyageur
Cluster 8	amour, cœur, vie, jeune, enfant, femme, fille, jour, homme, tendresse
Cluster 9	comte, comtesse, monsieur, scène, loge, femme, prulière, homme, théâtre, dame
Cluster 10	abbé, prêtre, curé, monsieur, église, bon, tête, petit, frère, enfant
Cluster 11	arbre, soleil, herbe, ciel, eau, ombre, jardin, blanc, haut, terre

Cluster	Mots caractéristiques
Cluster 12	grotte, saint, miracle, cierge, prêtre, malade, foule, foi, père, église
Cluster 13	docteur, médecin, monsieur, enfant, mère, petit, malade, heure, œil, lit
Cluster 14	sœur, malade, hyacinthe, wagon, saint, train, petit, compartiment, pèlerin, grotte
Cluster 15	insurgé, ville, national, fusil, barricade, républicain, homme, garde, ouvrier, rue
Cluster 16	rue, boutique, trottoir, petit, quartier, maison, femme, bel, halle, heure
Cluster 17	femme, jeune, amant, chambre, main, pensée, œil, bras, nuit, homme
Cluster 18	empereur, ministre, monsieur, député, colonel, homme, affaire, préfet, gouvernement, ami
Cluster 19	travail, vie, enfant, terre, petit, usine, ouvrier, peuple, œuvre, homme
Cluster 20	bourse, million, franc, action, cours, banque, universelle, monsieur, hausse, argent
Cluster 21	franc, argent, monsieur, femme, homme, jeune, jour, billet, somme, bon
Cluster 22	monsieur, dame, femme, petit, porte, bon, fille, air, homme, chambre
Cluster 23	tableau, peintre, toile, peinture, œuvre, art, atelier, femme, artiste, salon
Cluster 24	fosse, mineur, coron, camarade, berline, homme, ouvrier, puits, grève, porion
Cluster 25	vendeur, rayon, magasin, comptoir, dame, soie, vente, client, bonheur, franc
Cluster 26	prussien, soldat, armée, général, route, homme, cheval, capitaine, corps, canon
Cluster 27	cardinal, pape, palais, éminence, livre, prêtre, monde, église, peuple, prélat
Cluster 28	frère, modèle, petit, père, vérité, président, homme, crime, justice, écriture
Cluster 29	père, terre, vieux, petit, coup, bon, vache, homme, paysan, bête

Cette extraction permet de vérifier la cohérence interne des clusters. Lorsqu'un cluster rassemble des mots appartenant au même champ lexical, il devient plus facilement

interprétable. À l'inverse, un cluster contenant des mots trop dispersés ou peu cohérents peut indiquer un regroupement moins stable ou plus difficile à nommer.

Nomination des clusters

Les clusters ont ensuite été nommés manuellement à partir des mots les plus représentatifs et de l'observation des segments associés. Cette étape est indispensable, car K-means ne produit pas directement des intitulés interprétables. Comme pour la NMF, le passage du résultat numérique à l'interprétation thématique repose donc sur une lecture qualitative et est lié à l'interprétation humaine (chaque noms de clusters peut donc être remis en cause).

TABLE 1.9 – Noms attribués aux clusters obtenus avec K-means

Cluster	Nom attribué
Cluster 1	La table, les repas et les boissons
Cluster 2	L'école, les élèves et l'instruction
Cluster 3	Le salon, l'aristocratie et les apparences
Cluster 4	La chambre, le lit et l'espace domestique
Cluster 5	L'enfance, la maternité et la pauvreté
Cluster 6	La mère, les enfants et la famille
Cluster 7	Le monde ferroviaire
Cluster 8	L'amour, les sentiments et la jeunesse
Cluster 9	Le théâtre, la loge et les scènes mondaines
Cluster 10	Le clergé et la paroisse
Cluster 11	La nature et le paysage
Cluster 12	Le miracle, le pèlerinage et la religion
Cluster 13	Le monde médical et la santé
Cluster 14	Le pèlerinage, la maladie et le voyage
Cluster 15	L'insurrection et la révolution
Cluster 16	Le quartier, la rue et la ville
Cluster 17	Le désir, le corps et les relations amoureuses
Cluster 18	Le pouvoir politique et les affaires publiques
Cluster 19	Le travail, le peuple et le monde ouvrier
Cluster 20	La bourse, la finance et les affaires
Cluster 21	L'argent du quotidien
Cluster 22	Les conversations et les scènes domestiques
Cluster 23	Le monde artistique et la peinture
Cluster 24	La mine, les ouvriers et la grève
Cluster 25	Le magasin, la vente et les clientes

Cluster	Nom attribué
Cluster 26	La guerre, les soldats et l'armée
Cluster 27	Le pouvoir religieux
Cluster 28	Les liens familiaux, l'écriture et la justice
Cluster 29	La terre, les animaux et le monde paysan

Les intitulés obtenus montrent que les clusters couvrent des dimensions proches de celles observées avec la NMF. On retrouve par exemple des ensembles liés au travail, à la mine, à la finance, à la religion, à la famille, au monde domestique, à la guerre ou encore aux espaces urbains.

Cependant, les clusters K-means ne doivent pas être interprétés comme des catégories fixes ou naturelles. Ils résultent d'un regroupement algorithmique fondé sur la proximité lexicale des segments. Leur nomination repose donc sur un choix interprétatif, à partir des mots les plus représentatifs et des extraits textuels associés.

Regroupement hiérarchique des clusters

Afin de compléter l'analyse des clusters obtenus avec K-means, une classification ascendante hiérarchique a été appliquée aux centroïdes des 29 clusters. Cette étape permet d'examiner les proximités entre clusters et de regrouper ceux qui présentent des profils lexicaux similaires. Elle offre ainsi une lecture plus synthétique de la structure thématique du corpus, en passant d'une analyse détaillée cluster par cluster à une organisation en grandes familles de motifs.

La méthode de Ward a été retenue pour construire cette hiérarchie. Elle consiste à fusionner progressivement les clusters en minimisant l'augmentation de la variance interne à chaque regroupement. Le dendrogramme obtenu permet de visualiser les distances entre clusters et d'identifier les principaux rapprochements thématiques¹¹.

11. Ludovic Lebart et André Salem, *Statistique textuelle*, Paris, Dunod, 1994.




FIGURE 1.4 – Dendrogramme de la classification hiérarchique des clusters K-means

Dans cette analyse, le seuil de distance a été fixé à 0,40 afin de découper l'arbre hiérarchique en grandes familles de motifs. Ce regroupement rend les résultats plus lisibles : les 29 clusters initiaux peuvent être interprétés non seulement individuellement, mais aussi comme des ensembles thématiques plus larges. Cette organisation facilite ensuite la comparaison entre les motifs dominants du corpus et leur répartition dans les romans de Zola.

Création des grandes familles de motifs

À partir du dendrogramme, les clusters ont été regroupés en cinq grandes familles de motifs. Cette opération permet de simplifier l'analyse et de faire apparaître les grandes zones thématiques du corpus.




FIGURE 1.5 – Regroupement des clusters K-means en grandes familles de motifs

Les groupes obtenus ont ensuite été nommés manuellement, en fonction des clusters qu'ils rassemblent. Le tableau suivant présente la composition de chaque grande famille de motifs.

TABLE 1.10 – Composition des grandes familles de motifs issues des clusters K-means

Groupe	Clusters associés
Groupe 1	Cluster 12 : Le miracle, le pèlerinage et la religion ; Cluster 14 : Le pèlerinage, la maladie et le voyage.
Groupe 2	Cluster 2 : L'école, les élèves et l'instruction ; Cluster 10 : Le clergé et la paroisse ; Cluster 27 : Le pouvoir religieux ; Cluster 28 : Les liens familiaux, l'écriture et la justice.
Groupe 3	Cluster 9 : Le théâtre, la loge et les scènes mondaines ; Cluster 18 : Le pouvoir politique et les affaires publiques ; Cluster 20 : La bourse, la finance et les affaires ; Cluster 21 : L'argent du quotidien ; Cluster 22 : Les conversations et les scènes domestiques ; Cluster 25 : Le magasin, la vente et les clientes.
Groupe 4	Cluster 15 : L'insurrection et la révolution ; Cluster 26 : La guerre, les soldats et l'armée.
Groupe 5	Cluster 1 : La table, les repas et les boissons ; Cluster 3 : Le salon, l'aristocratie et les apparences ; Cluster 4 : La chambre, le lit et l'espace domestique ; Cluster 5 : L'enfance, la maternité et la pauvreté ; Cluster 6 : La mère, les enfants et la famille ; Cluster 7 : Le monde ferroviaire ; Cluster 8 : L'amour, les sentiments et la jeunesse ; Cluster 11 : La nature et le paysage ; Cluster 13 : Le monde médical et la santé ; Cluster 16 : Le quartier, la rue et la ville ; Cluster 17 : Le désir, le corps et les relations amoureuses ; Cluster 19 : Le travail, le peuple et le monde ouvrier ; Cluster 23 : Le monde artistique et la peinture ; Cluster 24 : La mine, les ouvriers et la grève ; Cluster 29 : La terre, les animaux et le monde paysan.

Ces grandes familles permettent d'obtenir une lecture plus synthétique des résultats. La première famille regroupe les motifs liés au miracle, au pèlerinage et à la religion. La deuxième rassemble des clusters associés aux formes d'encadrement social, religieux, scolaire et familial. La troisième renvoie davantage aux espaces sociaux, économiques et mondains, en regroupant notamment la finance, le commerce, le théâtre et les conversations domestiques. La quatrième famille réunit les motifs du conflit collectif, de l'insurrection et de la guerre. Enfin, la cinquième regroupe un ensemble plus large de motifs liés à la vie quotidienne, aux espaces sociaux, au travail, à la famille, à la nature et aux expériences individuelles.

Cette structuration est particulièrement utile pour l'analyse littéraire, car elle permet de passer d'une liste de clusters nombreux à une organisation thématique plus lisible.

Elle montre aussi que les motifs extraits par K-means ne sont pas isolés, mais peuvent être regroupés en ensembles plus larges correspondant à des dimensions importantes de l'œuvre de Zola.

Attribution des grandes familles aux segments

Une fois les groupes hiérarchiques définis, chaque segment du corpus a reçu une étiquette correspondant à la grande famille de motifs associée à son cluster¹². Cette opération permet d'analyser non seulement les clusters détaillés, mais aussi les grandes catégories thématiques dans lesquelles ils s'inscrivent.




FIGURE 1.6 – Noms attribués aux grandes familles de motifs

Cette étape permet de relier chaque paquet de phrases à deux niveaux d'analyse. Le premier niveau est le cluster K-means, qui fournit une catégorie thématique fine. Le second niveau est le groupe CAH, qui fournit une catégorie plus générale. Cette double échelle d'interprétation est utile, car elle permet d'adapter le niveau de détail selon les besoins de l'analyse : on peut étudier les motifs précis, ou bien observer les grandes tendances du corpus.

Analyse de la répartition des clusters

Après la nomination des clusters et des grandes familles, plusieurs visualisations ont été produites afin d'étudier leur répartition dans le corpus. La première consiste à compter le nombre de segments associés à chaque grande famille de motifs.

12. Voir code sur Github.




FIGURE 1.7 – Distribution des grandes familles de motifs dans le corpus

Cette visualisation permet d’identifier les grandes familles les plus représentées dans l’ensemble du corpus. Elle donne une lecture globale de l’organisation thématique des segments. Une famille très représentée indique qu’un ensemble de motifs revient fréquemment dans les romans, tandis qu’une famille moins présente peut correspondre à un thème plus spécifique, associé à certains romans ou à certaines situations narratives.

Une seconde visualisation a été produite à l’échelle des clusters détaillés.




FIGURE 1.8 – Distribution des clusters K-means dans le corpus

Cette représentation permet de voir quels clusters sont les plus fréquents dans le corpus. Elle est plus précise que l'analyse par grandes familles, car elle distingue les motifs thématiques particuliers. Elle permet par exemple d'observer séparément les clusters associés à la mine, à la finance, à la religion, à la famille ou au monde domestique.

1.5 Comparaison des deux méthodes

La NMF et K-means ont été appliqués au même corpus et à la même représentation TF-IDF, mais ils n'en proposent pas la même lecture. La NMF fait apparaître des topics latents auxquels chaque segment est associé avec des poids variables. K-means répartit au contraire les segments en groupes lexicaux distincts. Leur comparaison permet d'identifier les régularités qui se retrouvent dans les deux organisations du corpus, ainsi que les différences liées au fonctionnement de chaque méthode.

1.5.1 Deux représentations complémentaires

La NMF offre une représentation graduelle des thèmes. Un même segment peut être associé à plusieurs topics, par exemple la famille, l'argent et l'espace domestique,

avec une importance différente pour chacun. Cette souplesse correspond assez bien à la complexité des textes littéraires, dans lesquels plusieurs dimensions thématiques peuvent coexister.

K-means produit une organisation plus catégorielle : chaque segment est rattaché à un seul cluster, celui dont il est le plus proche dans l'espace vectoriel. Cette méthode fait ainsi apparaître des groupes lexicaux plus nettement séparés, mais rend moins visible la coexistence de plusieurs thèmes dans un même passage.

Les deux approches ne sont donc pas concurrentes. La NMF décrit la composition thématique des segments, tandis que K-means propose une partition générale du corpus. Leur rapprochement constitue une triangulation exploratoire, mais pas une validation indépendante, puisque les deux modèles utilisent les mêmes données et la même matrice TF-IDF.

1.5.2 Convergences lexicales et thématiques

La comparaison des termes caractéristiques fait apparaître plusieurs ensembles communs aux topics NMF et aux clusters K-means. Les deux méthodes repèrent notamment des motifs liés au travail et à la mine, à l'argent et à la finance, à la religion, à la famille, à la guerre, au commerce, aux espaces urbains et à la vie domestique.

Ces rapprochements montrent que certains champs lexicaux occupent une place structurante dans le corpus. Ils ne signifient toutefois pas que les résultats sont identiques. Un topic NMF peut réunir plusieurs dimensions que K-means répartit entre différents clusters. À l'inverse, un cluster peut rassembler des segments lexicalement proches dont l'interprétation thématique reste assez large.

La convergence entre les méthodes doit donc être appréciée à l'échelle des grands motifs plutôt qu'à travers une correspondance exacte entre chaque topic et chaque cluster. Comme les deux analyses reposent sur le même prétraitement, elle ne suffit pas à prouver l'existence de catégories thématiques objectives. Elle indique néanmoins que certains motifs résistent au changement de méthode de regroupement.

1.5.3 Distribution des topics NMF par œuvre

Pour étudier la répartition des topics dans les romans, chaque segment a été associé au topic possédant le poids NMF le plus élevé. Une table croisée entre les œuvres et les topics dominants a ensuite été construite et normalisée par ligne. Cette normalisation indique, pour chaque roman, la proportion de segments dominés par chacun des 29 topics.




FIGURE 1.9 – Proportion des segments par topic NMF dominant et par œuvre

La figure 1.9 fait apparaître des associations attendues entre certaines œuvres et certains thèmes. Le monde de la mine et du travail ouvrier occupe ainsi une place importante dans *Germinal*, tandis que la finance ressort davantage dans *L'Argent*. Le commerce est particulièrement visible dans *Au Bonheur des dames*, et la guerre dans *La Débâcle*.

D'autres topics sont répartis entre plusieurs romans et correspondent à des motifs plus transversaux, comme la famille, les relations sociales, la religion ou l'espace domestique. La normalisation par œuvre évite que les romans les plus longs soient automatiquement surreprésentés et facilite ainsi la comparaison de leurs profils thématiques.

Cette visualisation repose néanmoins sur le topic dominant de chaque segment. Elle simplifie donc la représentation fournie par la NMF, puisqu'elle ne montre pas les topics secondaires également présents dans les passages.

1.5.4 Distribution des clusters K-means par œuvre

Une seconde heatmap présente la répartition des clusters K-means dans chaque roman. Comme pour la NMF, les valeurs sont exprimées sous forme de proportions afin de neutraliser autant que possible les différences de longueur entre les œuvres.




FIGURE 1.10 – Distribution des clusters K-means par œuvre

La figure 1.10 fait apparaître plusieurs associations proches de celles obtenues par la NMF. *Germinal* se distingue par le cluster consacré à la mine, aux ouvriers et à la grève. *L'Argent* est fortement associé à la finance et aux affaires, tandis que *La Débâcle* se caractérise par le vocabulaire des soldats, de l'armée et de la guerre. Le cluster lié au magasin, à la vente et aux clients est particulièrement présent dans *Au Bonheur des dames*.

Ces rapprochements confirment que plusieurs œuvres possèdent un profil lexical fortement lié à leur univers narratif. La comparaison révèle également des différences : K-means impose un seul cluster à chaque segment, alors que la NMF peut y détecter plusieurs composantes thématiques. La distribution obtenue par K-means paraît donc généralement plus tranchée.

1.5.5 Regroupement en grandes familles

Afin de rendre les 29 clusters plus faciles à interpréter, une classification hiérarchique a été appliquée à leurs centres. Elle permet de les réunir en cinq familles thématiques plus générales.




FIGURE 1.11 – Distribution des grandes familles de clusters K-means par œuvre

La figure 1.11 synthétise la distribution de ces familles dans les romans. Elle distingue les motifs liés à l’argent et à la circulation financière, aux conflits politiques et militaires, aux institutions et à l’encadrement social, à la religion et à l’autorité cléricale, ainsi qu’à la vie quotidienne et aux expériences individuelles.

Cette représentation simplifie la lecture générale du corpus. La famille consacrée à la vie quotidienne est présente dans la majorité des œuvres, tandis que les autres ensembles apparaissent de manière plus concentrée. Les motifs financiers sont notamment visibles dans *L’Argent*, les conflits militaires dans *La Débâcle*, et la religion dans les romans où l’autorité ecclésiastique occupe une place centrale.

1.5.6 Apport de la double approche

La comparaison entre NMF et K-means permet finalement d’articuler deux niveaux d’analyse. La NMF rend compte du caractère souvent multiple des thèmes présents dans un segment, tandis que K-means propose une organisation plus nette des proximités lexicales. Leur rapprochement aide ainsi à distinguer les motifs récurrents des regroupements davantage liés au fonctionnement d’un modèle particulier.

Lorsque les résultats convergent, ils renforcent l’hypothèse qu’un motif occupe une place importante dans le corpus zolien. Lorsqu’ils divergent, l’examen des segments concernés permet de mieux comprendre les limites de chaque représentation. Ces

régularités doivent cependant rester considérées comme des caractéristiques internes à l'œuvre de Zola. Leur éventuelle association au naturalisme devra être évaluée à partir du corpus comparatif et de la classification automatique.

1.6 Conclusion sur le Topic Modeling

Cette étude avait pour objectif d'identifier des structures thématiques récurrentes dans l'œuvre romanesque de Zola à partir de méthodes non supervisées. Le corpus a d'abord été nettoyé, segmenté en paquets de phrases, puis lemmatisé afin de produire des unités textuelles comparables et exploitables par les modèles.

L'application de le NMF a permis de faire apparaître des topics interprétables, associés à des dimensions importantes de l'univers de zola : le travail, la mine, la religion, la famille, l'argent, la guerre, le commerce, la ville ou encore l'espace domestique. Le recours à K-means a ensuite permis de regrouper les segments selon leur proximité lexicale et d'observer des familles de motifs complémentaires et de valider les resultats obtenu avec la methode du NMF.

La comparaison des deux méthodes montre que certains ensembles thématiques apparaissent de manière stable, malgré des fonctionnements algorithmiques différents. le NMF offre une lecture plus graduelle des thèmes, tandis que K-means produit une classification plus nette des segments. Leur combinaison permet donc de renforcer l'analyse en croisant deux formes de structuration du corpus.

Ces résultats doivent toutefois être interprétés avec prudence. Ils dépendent des choix de nettoyage, de lemmatisation, de segmentation, de vectorisation et du nombre de topics ou de clusters retenus. Je tiens donc à appuyer que ces méthodes reposent donc sur une validation qualitative. L'analyse proposée ne remplace donc pas une lecture littéraire des textes, mais elle fournit un outil exploratoire permettant de repérer des régularités lexicales et thématiques à l'échelle d'un corpus volumineux.

Chapitre 2

Dynamique Topic modeling sur le corpus de d'Émile Zola

2.1 Présentation du corpus et des données

2.1.1 Objectif et organisation du corpus

Ce chapitre prolonge l'analyse thématique statique menée au chapitre 1 en examinant la distribution chronologique des topics dans le corpus romanesque d'Émile Zola. Il ne s'agit pas d'un modèle thématique dynamique au sens génératif du terme : les dates de publication ne participent ni à la formation des groupes ni à leur représentation globale. Elles sont mobilisées après la sélection du modèle BERTopic afin d'observer la fréquence de topics fixes au fil de la carrière de l'écrivain. Cette distinction permet d'étudier les récurrences et les inflexions thématiques sans imposer au préalable une trajectoire temporelle aux documents.

Le corpus est identique à celui du chapitre précédent¹. Chaque roman est associé à son année de publication, de manière à replacer les segments dans la chronologie de l'œuvre. Le prétraitement reprend également le protocole déjà décrit : segmentation des textes, suppression des mots vides et lemmatisation. Deux représentations complémentaires sont toutefois conservées. Les segments non lemmatisés servent au calcul des embeddings sémantiques, tandis que leur version lemmatisée est utilisée pour la représentation lexicale des topics et le calcul de la cohérence. La section suivante précise le rôle de ces deux entrées dans l'architecture de BERTopic.

2.1.2 Segmentation et statistiques descriptives

Les romans sont découpés en segments de quarante phrases, selon la même granularité que dans le chapitre 1. Ce choix produit des unités suffisamment longues pour conserver

1. Voir le chapitre 1, section consacrée à la présentation des données.

un contexte narratif, tout en permettant d’observer la circulation des regroupements thématiques à une échelle plus fine que celle du roman entier. Après exclusion des segments vides, le jeu de données comprend 5 327 documents.

TABLE 2.1 – Statistiques descriptives du nombre de mots par segment de quarante phrases

Indicateur	Nombre de mots
Nombre de segments	5 327
Moyenne	785,298
Écart-type	212,129
Minimum	42
Premier quartile	636
Médiane	753
Troisième quartile	902,5
Maximum	2 944

Un segment contient en moyenne 785 mots et la médiane s’établit à 753 mots. La moitié des documents se situe entre 636 et 902,5 mots, ce qui indique une taille relativement homogène pour la majeure partie du corpus malgré un écart-type de 212 mots. L’amplitude, de 42 à 2 944 mots, s’explique par quelques observations atypiques : les derniers segments de certains romans peuvent réunir moins de quarante phrases, tandis que des phrases particulièrement longues augmentent ponctuellement la taille d’une unité.

L’examen des valeurs extrêmes² confirme leur caractère marginal. Douze segments contiennent moins de 300 mots, soit environ 0,23 % du corpus, et vingt-quatre dépassent 1 500 mots, soit 0,45 %. Un seul compte plus de 2 000 mots. Au total, 5 291 segments, soit 99,32 % du jeu de données, sont compris entre 300 et 1 500 mots. La segmentation offre donc une base globalement régulière pour la modélisation, sans masquer la variabilité ponctuelle de la syntaxe et de la composition des romans.

2.2 Utilisation de BERTopic

Cette section présente la construction et la sélection du modèle BERTopic utilisé dans la suite de l’étude. Elle s’appuie exclusivement sur le notebook `01_recherche_hyperparametres.ipynb` : il ne s’agit donc pas encore d’interpréter les topics, mais d’explicitier les choix techniques, les critères de comparaison et l’arbitrage qui conduit au modèle final. Les dates de publication et l’ordre des romans n’interviennent pas dans la formation des groupes. La dimension temporelle n’est introduite qu’après cette sélection, afin de ne pas imposer au modèle une évolution chronologique préalable.

2. Le code correspondant est présenté en annexe.

2.2.1 Architecture générale et représentation du corpus

BERTopic est une méthode modulaire de modélisation thématique. Elle articule quatre opérations distinctes : la représentation sémantique des documents par des embeddings, la réduction de la dimension de ces vecteurs, leur regroupement par densité et, enfin, la représentation lexicale de chaque groupe par le *class-based TF-IDF*, ou c-TF-IDF³. Cette architecture sépare ainsi la proximité sémantique des segments des mots qui rendent les regroupements interprétables.

Le corpus soumis à la recherche comprend 5 327 segments de quarante phrases non vides. Chacun est encodé avec le modèle francophone **dangvantuan/sentence-camembert-base**⁴, qui produit un vecteur dense de 768 dimensions. L’embedding est calculé sur le texte non lemmatisé, afin de préserver l’information contextuelle utile au modèle neuronal. BERTopic reçoit parallèlement les segments lemmatisés pour construire les représentations lexicales ; ceux-ci servent aussi au calcul de la cohérence. Le protocole distingue donc la représentation sémantique, fondée sur le texte continu, de la caractérisation lexicale, fondée sur un vocabulaire normalisé.

Les embeddings sont calculés une seule fois, enregistrés dans un fichier partagé, puis rechargés lors des recherches ultérieures. Le notebook vérifie que leur nombre correspond au nombre de documents et applique un masque identique aux deux objets lorsqu’un segment lemmatisé vide doit être exclu. Ce contrôle prévient tout décalage entre un texte et son vecteur. Il garantit aussi que les 256 configurations sont comparées à partir d’une représentation sémantique strictement identique.

2.2.2 Réduction de dimension, clustering et représentation lexicale

Les vecteurs sont d’abord réduits avec UMAP (*Uniform Manifold Approximation and Projection*). L’algorithme cherche à préserver les voisinages des observations dans un espace de dimension plus faible, où les zones denses deviennent plus faciles à identifier⁵. Deux paramètres sont explorés. **n_neighbors** règle l’étendue du voisinage : une valeur faible privilégie les structures locales, tandis qu’une valeur élevée accorde davantage de poids à l’organisation globale. **n_components** fixe la dimension de l’espace transmis au clustering ; il ne s’agit pas ici d’une simple projection graphique en deux dimensions. La métrique cosinus, **min_dist=0.0**, **random_state=42** et **low_memory=True** restent

3. Maarten Grootendorst, « BERTopic : Neural topic modeling with a class-based TF-IDF procedure », 2022, article original ; voir également la documentation de l’architecture BERTopic, consultés le 28 juillet 2026.

4. Fiche du modèle **sentence-camembert-base** sur Hugging Face, consultée le 28 juillet 2026.

5. Leland McInnes, John Healy et James Melville, « UMAP : Uniform Manifold Approximation and Projection for Dimension Reduction », 2018, arXiv:1802.03426 ; voir aussi la documentation des paramètres UMAP, consultés le 28 juillet 2026.

constants. La graine commune rend les configurations comparables et la distance minimale nulle autorise la formation de zones compactes.

HDBSCAN regroupe ensuite les vecteurs réduits. Cette méthode hiérarchique fondée sur la densité n'exige ni un nombre de groupes fixé à l'avance, ni des clusters de forme ou de taille comparables. Les observations qui n'appartiennent pas à une zone suffisamment dense reçoivent l'étiquette `-1` et sont considérées comme des documents atypiques⁶. `min_cluster_size` détermine la taille minimale recherchée pour un cluster ; `min_samples` règle le caractère conservateur de l'assignation et tend, lorsqu'il augmente, à classer davantage de documents comme atypiques. La distance euclidienne et la méthode d'extraction `eom` sont maintenues. Aucun nombre de topics n'est imposé (`nr_topics=None`) : il résulte de l'interaction entre UMAP et HDBSCAN. Les probabilités et les données de prédiction, inutiles pour ce classement, ne sont pas calculées afin de limiter le coût de la grille.

Après le clustering, les documents d'un même topic sont réunis pour produire leur représentation lexicale. Le `CountVectorizer` conserve les unigrammes présents dans au moins deux segments (`min_df=2`) et dans au plus 80 % du corpus (`max_df=0.8`). Le c-TF-IDF pondère alors les termes fréquents dans une classe mais relativement rares dans les autres. Les options `bm25_weighting=True` et `reduce_frequent_words=True` limitent encore le poids des mots très fréquents⁷. Ces réglages modifient la lisibilité des topics, et non l'appartenance des documents aux clusters déjà formés.

2.2.3 Grille de recherche

La grille est le produit cartésien des quatre paramètres variables présentés dans le tableau 2.2, soit $4^4 = 256$ configurations. Elle confronte des voisinages UMAP plus ou moins locaux, plusieurs dimensions réduites et différents degrés d'exigence pour la densité.

TABLE 2.2 – Hyperparamètres inclus dans la grille de recherche BERTopic

Composant	Paramètre	Valeurs testées
UMAP	<code>n_neighbors</code>	10, 25, 50, 60
UMAP	<code>n_components</code>	5, 10, 15, 20
HDBSCAN	<code>min_cluster_size</code>	20, 40, 80, 120
HDBSCAN	<code>min_samples</code>	1, 5, 10, 15

Chaque modèle est entraîné sur les mêmes documents et embeddings. Ses paramètres,

6. Ricardo J. G. B. Campello, Davoud Moulavi et Jörg Sander, « Density-Based Clustering Based on Hierarchical Density Estimates », 2013, DOI de l'article ; documentation de la sélection des paramètres HDBSCAN, consultés le 28 juillet 2026.

7. Documentation officielle de `ClassTfidfTransformer`, consultée le 28 juillet 2026.

ses métriques, son statut et sa durée d'exécution sont enregistrés après chaque essai ; le modèle est ensuite libéré de la mémoire. Les 256 essais se sont achevés sans erreur. Cette sauvegarde incrémentale assure la traçabilité de la recherche et permet de reprendre le traitement sans perdre les configurations déjà calculées.

2.2.4 Critères d'évaluation et classement multicritère

L'évaluation combine des informations sur la partition, sa géométrie et son vocabulaire. Le nombre de topics exclut l'étiquette -1. Le taux de documents atypiques désigne la proportion de documents qui la reçoivent, tandis que la couverture en est le complément. La taille minimale, médiane et maximale des groupes ainsi que la part du plus grand topic parmi les documents assignés permettent de repérer une solution dominée par un seul cluster.

Le score de silhouette compare la proximité d'une observation avec son propre cluster et avec le cluster voisin le plus proche ; une valeur élevée signale des groupes compacts et séparés⁸. Il est calculé avec la distance euclidienne dans l'espace UMAP, sur les seuls documents assignés et, si nécessaire, sur un échantillon reproductible limité à 2 000 observations. Le DBCV (*Density-Based Clustering Validation*) complète cette mesure : conçu pour les partitions fondées sur la densité, il accepte des formes irrégulières et tient ici compte de l'ensemble des observations, bruit compris⁹.

La cohérence C_v estime la proximité contextuelle des dix principaux mots de chaque topic, après exclusion du groupe -1, à partir du corpus lemmatisé et du dictionnaire Gensim¹⁰. La diversité lexicale correspond au rapport entre le nombre de termes distincts et le nombre total de termes dans ces listes. Elle pénalise ainsi les topics dont les mots caractéristiques se répètent, sans constituer à elle seule une preuve de pertinence thématique.

Avant le classement, trois garde-fous éliminent les solutions trop peu informatives : au moins huit topics, au plus 65 % de documents atypiques et aucun topic représentant plus de 50 % des documents assignés. Parmi les 256 configurations, 92 satisfont ces conditions. Comme les indicateurs utilisent des échelles différentes, ils sont convertis en rangs percentiles. Le score global est ensuite calculé ainsi :

$$S_{\text{global}} = 0,30R_{C_v} + 0,20R_{\text{sil}} + 0,15R_{\text{DBCV}} + 0,15R_{\text{div}} + 0,10R_{\text{couv}} + 0,10R_{\text{eq}}.$$

La cohérence reçoit le poids le plus important, car la lisibilité lexicale est centrale pour l'analyse littéraire. La silhouette mesure la séparation, le DBCV la validité de la

8. Peter J. Rousseeuw, « Silhouettes : A graphical aid to the interpretation and validation of cluster analysis », 1987, DOI de l'article.

9. Davoud Moulavi et al., « Density-Based Clustering Validation », 2014, DOI de l'article.

10. Michael Röder, Andreas Both et Alexander Hinneburg, « Exploring the Space of Topic Coherence Measures », 2015, DOI de l'article.

structure de densité et la diversité limite la redondance. La couverture et l'équilibre complètent le compromis ; pour ce dernier, le rang porte sur 1 moins la part du plus grand topic. Ces pondérations ne définissent pas un optimum universel : elles rendent explicites les priorités retenues et réduisent le nombre de modèles à examiner.

2.2.5 Contrôle de la stabilité

Les dix premières configurations selon le score global sont réentraînées avec six graines aléatoires : 1, 11, 35, 42, 73 et 89. Les 60 entraînements obtenus donnent, pour chaque configuration, quinze comparaisons par paires. La proximité des partitions est mesurée avec l'indice de Rand ajusté (ARI), qui corrige l'accord attendu par hasard et vaut 1 lorsque deux partitions coïncident, indépendamment de la numérotation des groupes¹¹.

Deux ARI sont calculés. Le premier porte sur tous les documents et considère -1 comme une catégorie ; le second ne conserve que les documents assignés à un topic dans les deux exécutions comparées. Cette distinction isole la stabilité du noyau des clusters de la variabilité de leur frontière avec le bruit. Le notebook conserve aussi la part de documents assignés en commun, ainsi que la moyenne et l'écart-type du nombre de topics et du taux de documents atypiques.

Le rang percentile de l'ARI moyen sur les documents assignés fournit le terme de stabilité du classement final :

$$S_{\text{final}} = 0,80S_{\text{global}} + 0,20R_{\text{stab}}.$$

La stabilité intervient donc comme un contrôle sans effacer les critères initiaux. Les écarts-types restent descriptifs et les filtres appliqués à la grille ne sont pas réappliqués aux moyennes des six graines.

2.2.6 Justification du choix final à 33 topics

La première configuration du classement final produit huit topics avec la graine principale. Le modèle retenu est volontairement la deuxième configuration, qui en produit 33. Le tableau 2.3 résume cet arbitrage.

11. Lawrence Hubert et Phipps Arabie, « Comparing Partitions », 1985, DOI de l'article ; voir aussi la documentation de `scikit-learn`, consultée le 28 juillet 2026.

TABLE 2.3 – Comparaison entre le premier rang automatique et le modèle retenu

Indicateur	Premier rang	Modèle retenu
n_neighbors	50	10
n_components	15	20
min_cluster_size	20	20
min_samples	15	5
Topics avec la graine principale	8	33
Taux brut de documents atypiques	62,5 %	55,6 %
Cohérence C_v	0,494	0,452
DBCV	0,039	0,107
ARI moyen sur les documents assignés	0,937	0,839
Score final	0,761	0,743

La solution à huit topics est plus stable et légèrement plus cohérente, mais elle rassemble le corpus dans des catégories très générales. Une telle granularité est peu adaptée à l’objectif de distinguer des motifs littéraires susceptibles d’évoluer au cours de la carrière de Zola. Le modèle à 33 topics offre un découpage plus fin, un taux de documents atypiques inférieur, un meilleur DBCV et une diversité lexicale élevée (0,958), tout en conservant un ARI de 0,839 sur les documents assignés dans les deux exécutions.

Ce résultat doit néanmoins être nuancé : les documents assignés en commun représentent en moyenne 33,6 % du corpus et l’ARI incluant le bruit atteint 0,431. Sur les six graines, la configuration retenue produit en moyenne 38,3 topics (écart-type : 3,82) et 54,3 % de documents atypiques (écart-type : 2,72 points). Elle présente donc un noyau de clusters relativement stable, mais une variabilité réelle aux frontières avec le bruit. Le choix de la deuxième ligne n’affirme pas sa supériorité sur tous les critères : il assume un compromis entre robustesse quantitative et niveau de détail pertinent pour la question de recherche. Le score ordonne les possibilités sans se substituer à cet arbitrage scientifique.

2.2.7 Portée et limites du protocole

La combinaison de plusieurs métriques évite de faire reposer la sélection sur un indicateur unique, et la répétition sur plusieurs graines rend visible la sensibilité à l’initialisation. Le protocole demeure toutefois exploratoire : il n’existe pas de vérité de référence pour le « bon » nombre de topics, tandis que les seuils et pondérations traduisent des priorités de recherche. De plus, UMAP influence à la fois le clustering et deux indices de validation ; une cohérence lexicale élevée ne garantit pas, à elle seule, la

pertinence littéraire d'un topic.

Une limite supplémentaire concerne la longueur des unités textuelles. La configuration publiée de `sentence-camembert-base` fixe une longueur maximale de 128 tokens¹². Or les segments du corpus contiennent en moyenne 785 mots et le notebook ne les redécoupe pas avant l'encodage. Les embeddings représentent donc principalement leur début. Cette troncature devra être gardée à l'esprit lors de l'interprétation ; une amélioration ultérieure consisterait à encoder plusieurs sous-segments puis à agréger leurs vecteurs.

Enfin, les taux de documents atypiques mentionnés ici sont les taux bruts produits par HDBSCAN avant toute réaffectation. Ils permettent de comparer les configurations dans des conditions identiques. Leur traitement appartient à l'entraînement du modèle final et ne doit pas être confondu avec la recherche d'hyperparamètres. La section suivante évalue donc quantitativement la partition brute, puis le modèle obtenu après réaffectation, avant que l'analyse qualitative et temporelle des 33 topics ne soit engagée.

2.3 Validation mathématique

Avant d'interpréter les topics et leur évolution dans le corpus, il convient d'évaluer la qualité de la partition sur laquelle repose l'analyse. Cette validation n'a pas pour objet de démontrer qu'il existerait une unique décomposition thématique correcte des romans de Zola. En l'absence de catégories de référence, elle relève d'une validation interne : plusieurs indicateurs vérifient la séparation géométrique des groupes, leur stabilité lorsque l'initialisation varie et la qualité de leur représentation lexicale.

Deux états du modèle doivent être distingués. Le premier correspond à la partition brute produite par UMAP et HDBSCAN avec les paramètres sélectionnés dans le notebook `01_recherche_hyperparametres.ipynb`. Le second correspond au modèle effectivement utilisé pour les analyses, après réaffectation des documents initialement considérés comme atypiques et mise à jour de la représentation c-TF-IDF dans le notebook `02_exploration_modele.ipynb`. Les indicateurs ne sont pas tous recalculés à cette seconde étape ; les valeurs doivent donc être interprétées dans le périmètre exact où elles ont été obtenues.

2.3.1 Validation de la partition brute

Avec la graine principale fixée à 42, la configuration retenue produit naturellement 33 topics. Sur les 5 327 segments du corpus, 2 366 sont directement rattachés à l'un de ces groupes et 2 961 reçoivent l'étiquette -1, soit un taux brut d'outliers de 55,6 %. Parmi les documents assignés, les topics contiennent entre 22 et 268 segments, avec une médiane de 53 ; le groupe le plus important représente 11,3 % des documents assignés.

12. Configuration Sentence-Transformers de `sentence-camembert-base`, consultée le 28 juillet 2026.

La partition n'est donc pas dominée par un topic unique, mais son taux d'observations atypiques montre que HDBSCAN adopte une définition exigeante des noyaux de densité.

La séparation géométrique est d'abord mesurée par le coefficient de silhouette. Pour un document i , si $a(i)$ désigne sa distance moyenne aux autres documents de son topic et $b(i)$ la plus faible distance moyenne qui le sépare d'un autre topic, sa silhouette est définie par :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}.$$

Le score global est la moyenne des $s(i)$. Il est compris entre -1 et 1 : une valeur positive signifie que les documents sont, en moyenne, plus proches de leur propre groupe que du groupe concurrent le plus proche. Dans le notebook d'optimisation, ce calcul est effectué avec la distance euclidienne dans l'espace UMAP, sur les documents assignés seulement et sur un échantillon reproductible d'au plus 2000 observations. La configuration retenue obtient un score de 0,380. Cette valeur positive atteste une structure identifiable, mais elle demeure intermédiaire : les topics sont séparés sans former des ensembles parfaitement isolés, ce qui est cohérent avec la continuité lexicale et narrative du corpus.

La silhouette est complétée par le DBCV, mieux adapté aux clusters définis par la densité. Contrairement à la silhouette calculée ici, cet indice prend en compte l'ensemble de la projection UMAP, y compris les observations étiquetées -1 . Sa valeur atteint 0,107. Un DBCV positif indique que, dans l'ensemble, la séparation entre les régions denses l'emporte sur leur dispersion interne. La valeur reste néanmoins modeste et ne saurait, prise isolément, suffire à valider la partition. L'intérêt du résultat réside dans la convergence de deux indicateurs construits selon des principes différents : tous deux sont positifs, même si aucun ne décrit une séparation parfaite.

La robustesse à l'initialisation apporte un troisième contrôle. La configuration est réentraînée avec les six graines 1, 11, 35, 42, 73 et 89. Les partitions sont comparées par l'indice de Rand ajusté :

$$\text{ARI} = \frac{\text{RI} - E[\text{RI}]}{1 - E[\text{RI}]},$$

où RI représente l'accord observé entre deux partitions et $E[\text{RI}]$ l'accord attendu par hasard. Sur les documents assignés dans les deux exécutions comparées, l'ARI moyen vaut 0,839, avec un écart-type de 0,054. Ce niveau traduit une forte stabilité du noyau des clusters. Lorsque tous les documents sont inclus et que l'étiquette -1 est traitée comme une catégorie, l'ARI moyen tombe toutefois à 0,431, avec un écart-type de 0,034. En outre, les documents assignés en commun ne représentent en moyenne que 33,6 % du corpus. Le modèle possède donc une structure centrale assez stable, tandis que la

frontière entre les topics et le bruit reste plus sensible à la projection UMAP.

2.3.2 Réaffectation des documents atypiques

Pour que l’analyse temporelle porte sur l’ensemble du corpus, le second notebook réaffecte les 2 961 documents initialement classés comme bruit. La stratégie **embeddings** de BERTopic compare leur représentation sémantique aux représentations des topics et les rattache au groupe le plus proche lorsque la similarité satisfait le seuil fixé. Six seuils, compris entre 0 et 0,50, sont comparés.

Dans l’exécution enregistrée, les seuils de 0 à 0,40 produisent exactement le même résultat : les 2 961 outliers sont réaffectés, les 33 topics sont conservés, le plus petit groupe comprend 38 documents et le plus grand 422, soit 7,9 % du corpus. Au seuil de 0,50, un seul document demeure atypique. Le seuil de 0,30 retenu conduit donc à une couverture de 100 % sans modifier le nombre de topics.

Cette comparaison appelle une précaution méthodologique. Les résultats ne permettent pas d’identifier 0,30 comme un optimum numérique nettement supérieur aux autres seuils, puisque presque toute la plage testée conduit à la même partition. Il s’agit d’un choix opérationnel situé au milieu de la grille. La réaffectation rend possible une analyse exhaustive des romans et aboutit à une distribution moins dominée par le plus grand groupe ; elle ne constitue cependant pas, à elle seule, une nouvelle preuve de séparation géométrique. Le score de silhouette et le DBCV ne sont pas recalculés après cette opération. Les valeurs de 0,380 et 0,107 décrivent donc la partition brute de HDBSCAN, et non les assignations finales des 5 327 documents.

2.3.3 Cohérence et diversité du modèle final

Après la réaffectation, la représentation lexicale des topics est reconstruite. Une courte liste de formes résiduelles propres au corpus est ajoutée aux mots exclus, puis les dix termes les mieux pondérés par le c-TF-IDF sont réestimés. Deux indicateurs évaluent cette représentation finale.

La cohérence C_v mesure dans quelle mesure les principaux mots d’un même topic apparaissent dans des contextes compatibles. Elle est calculée à partir des documents lemmatisés, du dictionnaire Gensim et des dix premiers mots de chacun des 33 topics. Elle passe de 0,452 pour le modèle brut à 0,471 après réaffectation et raffinement lexical, soit une progression de 0,019. Cette augmentation modérée indique que l’intégration des documents auparavant atypiques ne dégrade pas la cohérence des listes de mots et améliore légèrement leur proximité contextuelle.

La diversité lexicale est définie par :

$$D = \frac{|\bigcup_{k=1}^K W_k|}{\sum_{k=1}^K |W_k|},$$

où W_k désigne l'ensemble des dix mots représentatifs du topic k . Une valeur proche de 1 indique que les topics partagent peu de termes parmi leurs représentations principales. La diversité passe de 0,958 à 0,915. Cette diminution signifie que le raffinement final introduit davantage de vocabulaire commun entre les topics, mais plus de neuf positions lexicales sur dix restent associées à des termes distincts. Le modèle conserve ainsi une forte non-redondance tout en obtenant une cohérence légèrement meilleure.

Le tableau 2.4 récapitule les deux étapes de l'évaluation. Le tiret signale qu'un indicateur géométrique n'a pas été recalculé après la réaffectation.

TABLE 2.4 – Indicateurs de validation avant et après la réaffectation des outliers

Indicateur	Partition brute	Modèle final
Nombre de topics	33	33
Documents assignés	2 366 (44,4 %)	5 327 (100 %)
Taille du plus petit topic	22	38
Taille du plus grand topic	268 (11,3 %)	422 (7,9 %)
Silhouette dans l'espace UMAP	0,380	Non recalculée
DBCV dans l'espace UMAP	0,107	Non recalculé
Cohérence C_v	0,452	0,471
Diversité lexicale	0,958	0,915

Au total, la validation met en évidence un compromis plutôt qu'une supériorité absolue. La partition brute présente une séparation positive mais modérée, ainsi qu'un noyau thématique stable entre plusieurs initialisations. La réaffectation assure ensuite une couverture complète du corpus et conserve des groupes de taille raisonnablement équilibrée. Enfin, le modèle final améliore légèrement la cohérence contextuelle tout en maintenant une diversité lexicale élevée. Ces résultats autorisent l'emploi des 33 topics comme instruments d'exploration du corpus, à condition de garder à l'esprit la variabilité des documents situés aux frontières des clusters et le caractère interne, non inférentiel, de cette validation.

2.4 Analyse des résultats de BERTopic

Après avoir validé le modèle, il est désormais possible d'examiner les topics et d'en proposer une interprétation. Cette section présente une analyse qualitative des résultats obtenus par BERTopic sur le corpus romanesque de Zola. Elle porte plus particulièrement sur la proximité entre les regroupements lexicaux produits par le modèle et les principaux domaines d'observation du naturalisme : le corps, l'hérédité, les milieux sociaux, le travail, l'argent, les institutions et les conditions matérielles d'existence.

Cette étape demeure nécessairement interprétative. Les topics identifiés par BERTopic ne constituent pas des thèmes littéraires au sens strict, mais des regroupements de mots et de documents présentant des proximités sémantiques. Leur signification dépend donc à la fois des mots représentatifs calculés par le modèle et du retour aux passages du corpus associés à chaque groupe.

2.4.1 Principes du classement

Les trente-trois topics ont été répartis selon quatre degrés de proximité avec le naturalisme. Le niveau 4 regroupe les topics qui réunissent plusieurs dimensions centrales de l'esthétique naturaliste. Le niveau 3 correspond à une proximité forte, mais moins complète ou lexicalement moins homogène. Le niveau 2 signale une relation indirecte ou hybride. Enfin, le niveau 1 rassemble les topics dont le contenu est peu discriminant pour caractériser le naturalisme.

Le classement repose sur les dix mots représentatifs de chaque topic, complétés par la lecture des documents représentatifs. Afin de ne pas surcharger les tableaux, seuls des termes appartenant aux dix mots exportés sont reproduits ci-dessous. Les justifications sont développées après chaque tableau plutôt que répétées dans une quatrième colonne. La colonne *Effectif* indique le nombre de segments attribués à chaque topic dans le modèle final, après la réaffectation des documents atypiques ; les trente-trois topics regroupent ainsi les 5 327 segments du corpus.

Niveau 4 : une proximité très forte avec le naturalisme

TABLE 2.5 – Topics présentant une très forte proximité avec le naturalisme

Topic	Effectif	Mots les plus discriminants
1	422	nerf, maternité, déchirement, insomnie
5	199	usurier, spéculation, crédit, emprunt, immeuble

Suite à la page suivante

Table 2.5 — suite

Topic	Effectif	Mots les plus discriminants
6	226	hérédité, dot, loyer, spéculation, enseignement
8	212	infirmier, contraction, orbite, artère, major
11	228	fromage, pigeon, paie, berger, champagne
12	132	boudin, marmite, sauce, charcutier, gourmandise
14	159	porion, mineur, cuvelage, fusion, éboulement
15	192	mineur, grève, république, insurgé, représentant
16	176	chapelier, zingueur, patronne, fruitière, forgeron
18	184	chou, cloutier, champagne, carotte, battoir
20	69	accusé, accusation, juré, expert, audience
21	114	accouchée, angine, potion, médecine, toux
22	105	vitrine, commis, maraîcher, carotte, denier
29	48	hausse, émission, actionnaire, liquidation, financier
30	124	brigadier, meute, soudure, cuvelage, aubergiste

Le premier ensemble fortement naturaliste concerne l'observation du corps et des déterminismes biologiques. Le topic 1 associe la maternité aux nerfs et à l'insomnie, tandis que le topic 8 réunit l'infirmier, les contractions, l'orbite et l'artère ; les documents représentatifs précisent ce cadre par des scènes de blessure et d'intervention médicale. Le topic 21 prolonge cette dimension par le vocabulaire de l'accouchement, de la maladie et des soins. Les topics 20 et 30 exigent davantage encore le retour aux passages. Le premier possède une représentation lexicale nettement judiciaire, mais les expertises mises en scène y mobilisent l'hérédité et l'atavisme ; le second présente une liste de mots très hétérogène, alors que ses documents représentatifs rapprochent la folie, la famille, le travail et la misère. Leur classement au niveau 4 tient donc à cette articulation contextuelle et doit être considéré avec plus de prudence que celui des topics dont les dix premiers mots suffisent à établir la cohérence.

Un deuxième ensemble porte sur le travail et les milieux populaires. Le topic 14 décrit la mine, son organisation technique et ses dangers, alors que le topic 15 ajoute la grève et le conflit politique à la condition du mineur. Le topic 16 rassemble plusieurs métiers manuels et commerciaux, donnant à voir la diversité d'un quartier populaire. Ces topics sont fortement naturalistes parce qu'ils ne représentent pas le travail comme un simple décor : celui-ci constitue un milieu qui façonne les corps, les comportements et les rapports entre les classes.

Enfin, les topics 5, 6 et 29 montrent le rôle déterminant de l'argent, du crédit, de la propriété et de la spéculation. Le topic 6 est particulièrement significatif puisqu'il rapproche ces contraintes économiques de l'hérédité et des institutions. Les topics 12 et 22 décrivent clairement la préparation et la vente des aliments ; les topics 11 et 18

associent ce vocabulaire à des termes militaires, professionnels ou mondains et sont donc moins homogènes. Leurs documents représentatifs font néanmoins apparaître la production, la consommation et les travailleurs qui organisent la circulation des marchandises. Cette attention portée à l'alimentation, aux commerces et aux objets ordinaires correspond au souci naturaliste d'observer la société à partir de ses réalités les plus concrètes, tout en laissant subsister des frontières interprétatives entre les regroupements.

Niveau 3 : une forte proximité avec le naturalisme

TABLE 2.6 – Topics présentant une forte proximité avec le naturalisme

Topic	Effectif	Mots les plus discriminants
0	345	pleur, balbutiant, infâme, âcre, défaillant
3	205	nation, salariat, socialisme, démocratie, enseignement
10	147	barricade, régiment, insurgé, batterie, artillerie
13	201	divorce, ride, infirmerie, fleuriste, coiffeur
17	154	corset, chapelet, trousseau, bréviaire, rôtissoire
19	163	vitrine, baron, enclume, brioche, carabine
25	142	tranchée, écuille, prisonnier, dégel, mourir
27	133	obsèque, macquart, ignominie, émancipation, combustion
31	56	salissure, insomnie, flacon, coulure, vivifiant
32	38	mansarde, infâme, verrier, fange, infamie

Les topics de niveau 3 reprennent plusieurs composantes du naturalisme sans présenter la même homogénéité que ceux du niveau précédent. Le topic 0 associe la souffrance, la défaillance et la déchéance morale, mais demeure davantage centré sur l'émotion que sur un déterminisme clairement identifiable. Le topic 3 est fortement social : le salariat, le socialisme, la démocratie et l'enseignement donnent à voir les institutions et les transformations de la société contemporaine. Le topic 10 traite, pour sa part, de la guerre et de l'insurrection à travers un vocabulaire matériel et collectif.

Les topics 13, 17 et 19 se caractérisent par la rencontre de plusieurs univers sociaux. Les métiers, le commerce, le vêtement, la religion, l'aristocratie et les objets du quotidien permettent d'observer des pratiques et des positions sociales concrètes. Leur classement au niveau 3, plutôt qu'au niveau 4, s'explique par une plus grande dispersion des mots représentatifs : leur proximité avec le naturalisme apparaît surtout lorsque les termes sont replacés dans les documents associés.

Le topic 25 rend visibles la guerre, la privation, le froid et la mort, ce qui place les individus dans un environnement matériel hostile. Le topic 27 contient le nom *Macquart* et renvoie ainsi directement à la famille par laquelle Zola étudie les effets de l'hérédité

et du milieu. Le topic 31 rapproche l'insomnie et la salissure d'un univers de travail et de fatigue physiologique perceptible dans les passages représentatifs. Enfin, le topic 32 associe la mansarde, la fange et le métier de verrier : il évoque nettement la pauvreté, l'insalubrité et le travail populaire, malgré la présence de termes plus symboliques dans sa représentation complète.

Niveau 2 : une proximité indirecte ou hybride

TABLE 2.7 – Topics présentant une proximité indirecte avec le naturalisme

Topic	Effectif	Mots les plus discriminants
4	216	cardinal, jésuite, prélat, diocèse, clergé
9	207	ambulance, professeur, souper, carriole, tabouret
23	122	fécondité, floraison, harmonie, chrétien, civilisation
24	126	jardinier, rébellion, géôlier, destinée, dot

Le topic 4 décrit de manière cohérente la hiérarchie catholique. Il peut participer à une analyse naturaliste lorsque l'Église est considérée comme une institution sociale et politique, mais son vocabulaire ne fait pas directement apparaître le corps, le travail ou l'hérédité. Le topic 9 rassemble des objets, des professions, des moyens de transport et des pratiques quotidiennes. Les documents correspondants font apparaître les ouvriers, la bourgeoisie et la politique municipale, mais les mots représentatifs restent trop dispersés pour former un axe naturaliste central.

La fécondité place potentiellement le topic 23 du côté de la reproduction et de la continuité biologique. Toutefois, les notions d'harmonie, de civilisation et de christianisme lui donnent aussi une portée abstraite et symbolique. Le topic 24 contient des indices de position sociale et de contrainte économique, notamment le métier de jardinier, l'enfermement et la dot. Leur juxtaposition ne suffit cependant pas à constituer un ensemble thématique stable. Ces quatre topics entretiennent donc une relation réelle, mais indirecte, avec les objets d'étude du naturalisme.

Niveau 1 : une faible spécificité naturaliste

TABLE 2.8 – Topics présentant une faible spécificité naturaliste

Topic	Effectif	Mots les plus discriminants
2	198	tombeau, temple, statue, paysage, dôme
7	162	antéchrist, vœu, convalescence, confessionnal, meneur
26	63	œillet, pavot, lis, parterre, héliotrope

Table 2.8 — suite

Topic	Effectif	Mots les plus discriminants
28	59	calice, patène, diacre, gothique, hostie

Le topic 2 est principalement consacré aux paysages, aux monuments et aux espaces architecturaux. Ces éléments peuvent naturellement servir de cadre à un roman naturaliste, mais ils ne permettent pas, à eux seuls, de reconnaître un traitement propre au naturalisme. Le topic 7 est dominé par un vocabulaire religieux et moral. Malgré la présence de quelques états corporels ou métiers, il ne fait apparaître aucun axe social, physiologique ou environnemental suffisamment cohérent.

Le topic 26 relève surtout du registre floral, décoratif et sensoriel. Le topic 28 réunit de la même manière des objets liturgiques et des éléments architecturaux ou décoratifs. Dans les deux cas, les termes peuvent contribuer à la description minutieuse d’un milieu, mais ils ne désignent pas spécifiquement les déterminismes biologiques, les conflits sociaux ou les conditions matérielles qui caractérisent le projet naturaliste.

Ce dernier niveau ne doit donc pas être compris comme une exclusion absolue. Il indique seulement que ces topics sont peu discriminants pour identifier le naturalisme à partir de leur lexique. Une conclusion stylistique définitive nécessiterait de revenir aux passages non lemmatisés, à leur narration, à leur focalisation et à la manière dont ils articulent les personnages à leur milieu.

2.4.2 Visualisation des topics au fil du temps

Cette dernière étape met en relation les topics précédemment interprétés avec les dates de publication des romans. Le modèle global est d’abord construit sans information chronologique ; la fonction `topics_over_time` répartit ensuite les segments déjà assignés dans quinze intervalles de largeur chronologique égale, couvrant la période 1865–1903, et recalcule leur représentation lexicale pour chacun d’eux¹³. L’axe vertical indique une fréquence brute : il correspond au nombre de segments rattachés à un topic dans un intervalle, et non à leur proportion dans l’ensemble des textes publiés au même moment. Les variations peuvent donc refléter à la fois une concentration thématique et le volume inégal du corpus selon les périodes. Les graphiques sont utilisés pour étudier la récurrence et les inflexions des topics, sans leur attribuer une importance relative que ces seuls effectifs ne permettraient pas d’établir. Dans la sortie native, lorsqu’un topic est absent d’un intervalle, le tracé relie les points disponibles sans afficher une fréquence nulle. Afin d’éviter cet effet visuel trompeur, les graphiques reproduits ci-dessous représentent explicitement ces absences par une valeur nulle.

13. Voir la documentation officielle de BERTopic consacrée aux topics au fil du temps, consultée le 29 juillet 2026.

Permanence des thèmes les plus fortement naturalistes

Les trois premières figures portent sur des topics classés au niveau 4. Elles permettent de vérifier si les réalités matérielles qui structurent le projet naturaliste — le travail, l'argent et la circulation des marchandises — demeurent observables au-delà des romans auxquels elles sont le plus spontanément associées.




FIGURE 2.1 – Présence des topics liés aux milieux populaires et au travail dans le corpus

La figure 2.1 fait apparaître la famille du travail populaire sur l'ensemble de la chronologie, mais selon des rythmes distincts. Le topic 16, associé aux métiers manuels et aux petits commerces, connaît sa plus forte concentration dans l'intervalle 1876–1877, puis réapparaît à des niveaux plus faibles jusqu'à la fin du corpus. Le topic 14, plus spécialisé dans le monde minier, culmine en 1883–1885, tandis que le topic 15, qui articule travail, grève et politique, est le seul des trois à apparaître dans chacun des quinze intervalles. La continuité observée n'est donc pas celle d'une fréquence constante pour chaque topic : elle résulte de la reprise, sous des formes professionnelles et conflictuelles différentes, d'une même attention aux conditions de travail. Le monde ouvrier ne se réduit ainsi ni à un seul topic ni au seul moment de *Germinal*.




FIGURE 2.2 – Présence des topics liés à l'argent dans le corpus

La figure 2.2 distingue deux temporalités de l'argent. Les topics 5 et 6, qui réunissent le crédit, l'emprunt, le loyer, la dot et la spéculation, sont présents dans chacun des quinze intervalles. Ils montrent que les dépendances économiques ordinaires traversent toute la carrière romanesque. Le topic 29, dominé par le vocabulaire de la Bourse et de la finance, reste en revanche discontinu et faiblement représenté en dehors d'un sommet très net dans l'intervalle 1891-1892. Cette concentration coïncide avec la publication de *L'Argent* en 1891. Le graphique ne décrit donc pas une progression linéaire de l'intérêt de Zola pour l'économie : il oppose plutôt une présence durable des rapports monétaires à la cristallisation tardive d'un lexique financier spécialisé.




FIGURE 2.3 – Présence des topics liés à la production, à la vente et à la consommation dans le corpus

La figure 2.3 prolonge cette lecture sur le terrain des marchandises et de l'alimentation. Le topic 12 se concentre surtout dans les années 1870 ; les topics 18 et 22 se renforcent

à la fin de cette décennie et culminent en 1883–1885, tandis que le topic 11 atteint son niveau le plus élevé en 1886–1887. Les topics 11 et 12 apparaissent dans les quinze intervalles ; les topics 18 et 22 ne sont absents que de celui correspondant à 1868, et tous quatre sont encore attestés dans le dernier intervalle. Ces décalages montrent que la matérialité des échanges ne dépend pas d'un unique univers romanesque : cuisine, production alimentaire, marchés, commerces et vitrines sont successivement mobilisés pour décrire des milieux différents. Les trois figures de niveau 4 font ainsi apparaître une permanence des principaux objets naturalistes sans effacer leurs concentrations ponctuelles.

Continuités et inflexions des topics de niveau 3

Les figures suivantes concernent des topics classés au niveau 3. Leur lexique est moins homogène ou leur rapport au naturalisme moins directement fondé sur un déterminisme biologique, social ou matériel. Leur distribution temporelle permet toutefois de préciser la place durable de l'observation sociale et de la souffrance dans l'œuvre, ainsi que l'inflexion politique des derniers romans.




FIGURE 2.4 – Présence des topics liés aux univers sociaux et aux pratiques quotidiennes dans le corpus

La figure 2.4 réunit les topics 13, 17 et 19, dont les mots représentatifs associent des métiers, des objets domestiques, le vêtement, la religion, le commerce et certaines positions sociales. Les topics 13 et 19 sont présents dans les quinze intervalles et le topic 17 n'est absent que de celui correspondant à 1868. Leurs principaux sommets ne se superposent toutefois pas : le topic 17 se concentre d'abord en 1873–1875, le topic 13 en 1878–1880 et le topic 19 en 1882 ; les topics 13 et 17 connaissent ensuite un regain en 1898–1899. Cette distribution irrégulière confirme la raison de leur classement au niveau 3. Ils ne constituent pas un thème unique et stable ; ils témoignent plutôt du

retour de scènes où les personnages sont caractérisés par leurs usages, leurs objets et leur appartenance à un milieu. La continuité porte ainsi sur une méthode d'observation du social, dont les contenus concrets varient d'un roman à l'autre.




FIGURE 2.5 – Présence du topic lié aux institutions et aux transformations sociales dans le corpus

La figure 2.5 présente une dynamique différente. Le topic 3, caractérisé notamment par les termes *nation*, *salariat*, *socialisme*, *démocratie* et *enseignement*, reste peu fréquent dans la première moitié de la chronologie et ne comporte aucune occurrence dans les deux intervalles couvrant 1878–1882. Sa fréquence augmente à partir des années 1890 et atteint son maximum dans l'intervalle 1901–1903. La répartition par roman confirme que ce sommet est principalement porté par *Travail* et *Vérité*, mais aussi par *Rome*, *Paris* et *Fécondité*. L'inflexion correspond donc aux cycles tardifs des *Trois Villes* et des *Quatre Évangiles*, dans lesquels les questions religieuses, politiques et sociales prennent une place accrue¹⁴. Cette courbe ne prouve donc pas la permanence d'une intensité égale ; elle met en évidence l'élargissement tardif de l'enquête naturaliste vers une formulation plus explicite des transformations collectives.

14. Voir la présentation d'Émile Zola par la Bibliothèque nationale de France, consultée le 29 juillet 2026.




FIGURE 2.6 – Présence du topic lié à la souffrance et à la défaillance dans le corpus

La figure 2.6 montre enfin que le topic 0 est présent dans chacun des quinze intervalles. Les segments qui lui sont rattachés sont nombreux au début des années 1870, connaissent plusieurs reprises dans les décennies suivantes, diminuent fortement au milieu des années 1890, puis remontent dans le dernier intervalle. Le vocabulaire des pleurs, du balbutiement, de l’infamie et de la défaillance forme ainsi un registre persistant de la souffrance physique et morale. Cette permanence doit néanmoins être distinguée d’une spécificité exclusivement naturaliste : l’expression de l’émotion traverse plusieurs esthétiques littéraires et ne désigne pas, à elle seule, un déterminisme. Sa récurrence sur toute la carrière, combinée aux milieux et aux contraintes décrits par les autres topics, justifie donc son classement au niveau 3 plutôt qu’au niveau 4.

Bilan de l’observation temporelle

Considérées ensemble, les six figures ne dessinent ni une stabilité uniforme ni le remplacement simple d’un thème par un autre. Elles montrent que le travail, l’argent, les échanges matériels, l’observation des univers sociaux et la souffrance restent repérables à différents moments de la carrière de Zola, tandis que leur fréquence se déplace en fonction des romans et des cycles. Le topic 3 constitue l’inflexion la plus nette : faiblement représenté au début du corpus, il se développe dans les œuvres tardives. L’analyse temporelle confirme ainsi une permanence sélective des préoccupations naturalistes, accompagnée de spécialisations et de reformulations. Cette conclusion demeure proportionnée à la mesure employée : les courbes décrivent la distribution chronologique de topics globaux en effectifs bruts, et non l’évolution autonome de leur sens ni leur poids relatif dans chaque période.

Conclusion du chapitre

Ce chapitre a présenté la construction du modèle thématique et les conditions méthodologiques dans lesquelles ses résultats peuvent être mobilisés pour étudier le naturalisme dans l'œuvre romanesque d'Émile Zola. L'utilisation de BERTopic a permis de combiner une représentation contextualisée des segments textuels avec des méthodes de réduction dimensionnelle, de regroupement et de caractérisation lexicale. La sélection du modèle ne reposait donc pas uniquement sur le nombre de topics obtenus, mais sur une procédure comprenant l'évaluation de 256 configurations, leur comparaison à partir de plusieurs indicateurs et l'examen de leur stabilité au moyen de différentes initialisations aléatoires.

Le modèle finalement retenu distingue 33 topics. Ce choix vise à préserver la diversité thématique du corpus et à éviter qu'une partition trop générale ne rassemble artificiellement des réalités sociales, matérielles ou narratives différentes. Une solution limitée à huit topics aurait offert une lecture plus synthétique, mais elle aurait également réduit la précision de l'analyse. Le modèle choisi permet ainsi de mieux différencier les espaces sociaux, les métiers, les institutions, les échanges économiques, les objets du quotidien et les diverses formes de souffrance représentées dans les romans. Les indicateurs mobilisés ne prouvent pas l'existence d'un découpage unique et définitif du corpus, mais ils permettent de vérifier que la partition retenue présente une cohérence suffisante et qu'elle ne résulte pas seulement d'une initialisation particulière de l'algorithme.

L'étude des dix termes les plus représentatifs de chaque topic a ensuite permis d'évaluer leur degré de proximité avec le naturalisme. L'adoption de plusieurs niveaux de gradation évite de réduire cette relation à une opposition trop rigide entre topics naturalistes et non naturalistes. Certains ensembles lexicaux sont directement associés à des dimensions centrales de l'esthétique naturaliste, telles que le travail, les milieux populaires, l'argent, les déterminismes sociaux et corporels ou encore les manifestations de la souffrance. D'autres n'entretiennent avec le naturalisme qu'une relation indirecte, tandis que certains correspondent principalement à des situations, à des objets ou à des univers narratifs particuliers. Le naturalisme apparaît dès lors non comme un thème isolé, mais comme une logique transversale qui organise plusieurs dimensions de la représentation zolienne du monde social.

Les visualisations temporelles ont enfin permis de replacer ces ensembles thématiques dans la chronologie de la production romanesque de Zola. Elles indiquent que les préoccupations associées au naturalisme ne sont pas limitées à un roman ou à une période unique de sa carrière. Leur importance varie en fonction des œuvres, des milieux représentés et des enjeux propres à chaque récit, mais plusieurs d'entre elles réapparaissent à différents moments du corpus. Cette distribution invite néanmoins à distinguer la permanence d'une préoccupation de la régularité de sa fréquence :

la présence durable d'un topic n'implique pas une intensité constante, mais peut se manifester par des phases d'apparition, d'accentuation et d'atténuation.

La modélisation thématique offre ainsi un moyen d'observer, à l'échelle de l'ensemble du corpus, des régularités et des évolutions qui seraient plus difficiles à saisir par la seule lecture linéaire des romans. Elle ne se substitue toutefois pas à l'interprétation littéraire : la signification d'un topic dépend des termes qui le caractérisent, des passages auxquels il est associé et du contexte narratif dans lequel il apparaît. Les résultats obtenus constituent donc moins une conclusion définitive sur le naturalisme zolien qu'un cadre d'analyse permettant d'articuler les tendances quantitatives du corpus avec l'étude des choix sociaux, narratifs et esthétiques propres à l'écriture de Zola.

Chapitre 3

Nettoyage des romans et insertion de ces derniers dans la basse de données

3.1 Reflexion sur le stockage des données

Après avoir récupéré un nombre conséquent de romans naturalistes et non naturaliste, il a fallu réfléchir à un moyen de les stocker quelque part. Pour cela, j'ai réfléchi à plusieurs idées pour procéder. Le choix c'est porté sur une base de données SQL avec comme interface PHP admin. Cette base de données à d'abord été remplie en local pour effectuer des tests et ensuite, une fois que tout fonctionnait correctement, j'ai pu extraire un fichier *Dumps* et l'importer dans PHP Admin.

3.2 Nettoyage des textes

Après avoir réfléchi à la manière de stocker les romans, il a fallu réfléchir à un moyen de les nettoyer. En effet, les romans contiennent beaucoup de caractères spéciaux qui ne sont pas utiles pour l'analyse, notamment les caractères de mise en forme, la pagination, les notes de bas de page, les chapitres ainsi que les prologues. En effet, les prologues sont souvent des textes qui ne sont pas écrits par l'auteur du roman et qui ne sont donc pas représentatifs de son style d'écriture.

Les romans naturalistes et non naturalistes sont issus de types de données différents. Il y a trois groupes de formats de données : les romans au format *.epub*, les romans au format *.pdf* et les romans au format *.txt*¹.

Pour ce qui est des textes au format *.epub*, j'ai utilisé le logiciel *Calibre*² pour les

1. Ici, les textes au format *.txt* sont organisés en dossiers, c'est-à-dire qu'un fichier *.txt* correspond à une page du roman. Il a donc fallu les regrouper pour obtenir un seul fichier *.txt* par roman.

2. Lien du logiciel : <https://calibre-ebook.com/fr/about>, site consulté le 18 juin 2026.

convertir au format *.txt*. Pour les textes au format *.pdf*, j'ai utilisé le logiciel *Adobe Acrobat Pro* afin de les convertir au format *.txt*. Pour les textes au format *.txt*, j'ai utilisé un script Python³ pour regrouper les fichiers en un seul fichier par roman.

La grande majorité de mes romans étaient au format *.epub*. Après leur conversion au format *.txt*, j'ai donc utilisé un script Python⁴ pour nettoyer les textes. Ce script supprime les caractères spéciaux, les notes de bas de page, les chapitres et les prologues. Il supprime également les lignes vides et les espaces en trop. Le script est basé sur des expressions régulières pour identifier les éléments à supprimer.

Pour ce qui est du choix des éléments à supprimer, j'ai fait le choix de supprimer les chapitres, car ils ne sont pas représentatifs du style d'écriture de l'auteur. De plus, comme nous l'avons vu dans le chapitre 2, j'ai passé un détecteur de motifs sur les textes afin d'identifier les motifs récurrents. J'ai donc gardé uniquement le corps du texte pour l'analyse. Ce choix se justifie également par la volonté d'obtenir une normalisation entre les textes⁵ (une ligne est égal à une phrase), ce choix peut être mis en opposition avec le choix de garder la distinction entre les différents chapitres du roman mais je me défend en prenant en compte que certains romans ne sont pas découpés en chapitres. Les différents romans sont soit découpés en partie (exemple : Partie I, Partie II, etc.), soit en chapitres (exemple : Chapitre I, Chapitre II, etc.), soit avec une combinaison des deux (exemple : Partie I, Chapitre I, Chapitre II, Partie II, Chapitre III, etc.). Ou pour finir, le titre du chapitre est écrit en majuscules, avec des chiffres romains, ou sans chiffres romains. Il aurait donc fallu faire des ajustements à chaque fois pour identifier les chapitres. De plus, certains romans résultaient de l'assemblage de plusieurs fichiers *.txt*. Dans ces cas, la séparation entre les chapitres, initialement présente dans la structure HTML du roman, n'était plus conservée.

3.3 Création de la base de données

Après avoir nettoyé les textes, il a fallu créer une base de données pour stocker les informations relatives aux romans. J'ai choisi d'utiliser le système de gestion de base de données relationnelle *MySQL*, car il permet d'organiser les données sous forme de tables et de conserver des relations claires entre les auteurs, les romans et les unités textuelles extraites.

Je vais donc présenter la structure de cette base de données ainsi que les différentes tables qui la composent. Chaque table a un rôle précis : certaines servent à stocker les

3. Le script est disponible en annexe.

4. Le script est disponible en annexe. Il faut préciser que je n'ai pas utilisé un seul script, mais plusieurs. Il s'agira donc d'un script général. Il y a eu énormément de modifications internes, notamment pour les chapitres qui sont soit en majuscules, avec chiffres romains, ou sans chiffres romains. Il a donc fallu faire des ajustements à chaque fois.

5. certains textes ne disposant pas de

informations bibliographiques, tandis que d'autres permettent de conserver les textes, les segments ou encore les phrases extraites pour l'analyse.

J'ai choisi de présenter ce code directement dans le corps du mémoire⁶ et non uniquement en annexe, afin de rendre plus claire la manière dont les données ont été organisées avant l'analyse.

Ce code permet de créer la base de données utilisée pour stocker les romans du corpus ainsi que les informations nécessaires à leur analyse. La base, nommée **romans_nlp**, est d'abord créée puis sélectionnée afin que toutes les tables suivantes y soient enregistrées.

La première table, **auteurs**, sert à stocker les informations relatives aux auteurs. Chaque auteur reçoit un identifiant unique, auquel sont associés son nom et, lorsque l'information est disponible, son prénom. Cette table est ensuite complétée par deux colonnes supplémentaires, **date_naissance** et **date_mort**, afin d'enrichir la description des auteurs et de permettre d'éventuelles analyses chronologiques.

La table **romans** contient les informations principales sur les œuvres du corpus. Elle associe à chaque roman un identifiant unique, un titre, une année de publication ainsi que le texte brut du roman. Le choix du type **LONGTEXT** pour le champ **texte_brut** permet de stocker des textes longs, ce qui est nécessaire dans le cas de romans complets.

La table **auteurs_romans** permet de faire le lien entre les auteurs et les romans. Elle sert à gérer une relation de type plusieurs-à-plusieurs : un auteur peut être associé à plusieurs romans, et un roman peut éventuellement être associé à plusieurs auteurs. Les clés étrangères **id_auteur** et **id_roman** permettent de relier cette table aux tables **auteurs** et **romans**.

La table **segments** sert à stocker les segments extraits des romans. Chaque segment est rattaché à un roman grâce à la clé étrangère **id_roman**. Le champ **ordre_segment** permet de conserver l'ordre d'apparition des segments dans le texte d'origine. Cela est important, car même si le texte est découpé pour les traitements, il reste possible de retrouver sa progression initiale.

Enfin, la table **phrase_roman** permet de stocker les phrases extraites des romans. Chaque phrase est associée au roman dont elle provient, à son ordre d'apparition, à son contenu textuel et au motif qui a permis son extraction. Ce dernier champ est important, car il permet de garder une trace de la méthode utilisée pour sélectionner les phrases et de relier chaque extraction à un critère précis.

L'ensemble de cette structure permet donc de conserver à la fois les textes complets, leurs découpages en segments, les phrases extraites et les informations bibliographiques liées aux auteurs et aux œuvres. Elle constitue ainsi une base organisée pour les traitements de fouille de texte et d'analyse automatique du corpus.

6. Je précise également que tous les codes utilisés pour la réalisation de ce mémoire sont disponibles sur mon GitHub.

```

1 CREATE DATABASE romans_nlp;
2 USE romans_nlp;
3
4 -- Creation des tables pour la base de donnees des romans et des auteurs
5 CREATE TABLE auteurs (
6     id_auteur INT PRIMARY KEY AUTO_INCREMENT,
7     nom VARCHAR(100) NOT NULL,
8     prenom VARCHAR(100)
9 );
10
11 -- Table pour stocker les romans, avec leur titre et leur annee de publication
12 CREATE TABLE romans (
13     id_roman INT PRIMARY KEY AUTO_INCREMENT,
14     titre VARCHAR(255) NOT NULL,
15     annee_publication INT,
16     texte_brut LONGTEXT
17 );
18
19 -- Table d'association pour gerer la relation plusieurs-a-plusieurs entre auteurs et romans
20 CREATE TABLE auteurs_romans (
21     id_auteur INT NOT NULL,
22     id_roman INT NOT NULL,
23     PRIMARY KEY (id_auteur, id_roman),
24     FOREIGN KEY (id_auteur) REFERENCES auteurs(id_auteur),
25     FOREIGN KEY (id_roman) REFERENCES romans(id_roman)
26 );
27
28 -- Table pour stocker les segments extraits des romans, avec leur ordre de segmentation
29 CREATE TABLE segments (
30     id_segment INT PRIMARY KEY AUTO_INCREMENT,
31     id_roman INT NOT NULL,
32     ordre_segment INT NOT NULL,
33     texte_segment LONGTEXT NOT NULL,
34     FOREIGN KEY (id_roman) REFERENCES romans(id_roman)
35 );
36
37 /*
38  Apres reflexion, il est egalement possible d'ajouter les dates
39  de naissance et de mort des auteurs afin d'enrichir la base de donnees.
40  */
41 ALTER TABLE auteurs
42 ADD date_naissance INT;
43
44 ALTER TABLE auteurs
45 ADD date_mort INT;
46
47 -- Table pour stocker les phrases extraites des romans, avec leur motif d'extraction
48 CREATE TABLE phrase_roman (
49     id_phrase INT PRIMARY KEY AUTO_INCREMENT,
50     id_roman INT NOT NULL,
51     ordre_phrase INT NOT NULL,
52     texte_phrase TEXT NOT NULL,
53     motif_phrase TEXT NOT NULL,
54     FOREIGN KEY (id_roman) REFERENCES romans(id_roman)
55 );

```

Listing 1 – Création de la base de données romans_nlp

3.4 Création des informations pour la base de données

Après avoir créé les tables nécessaires pour stocker les informations sur les auteurs, les romans et les relations entre eux, il est temps d'insérer les données relatives aux frères Goncourt et à leurs œuvres. Le code suivant présente donc l'insertion des auteurs, des romans et des relations entre ces deux tables.

```
1  /*
2  Insertion des freres Goncourt.
3  */
4  INSERT INTO auteurs (nom, prenom)
5  VALUES
6      ('de Goncourt', 'Edmond'),
7      ('de Goncourt', 'Jules');
8  /*
9  Insertion des romans des freres Goncourt
10 */
11 INSERT INTO romans (titre, annee_publication)
12 VALUES
13     ('Charles Demailly', 1860),
14     ('Soeur Philomene', 1861),
15     ('Renee Mauperin', 1864),
16     ('Germinie Lacerteux', 1865),
17     ('Manette Salomon', 1867),
18     ('Madame Gervaisais', 1869),
19     ('La Fille Elisa', 1877),
20     ('Freres Zemganno', 1879),
21     ('La Faustin', 1882),
22     ('Cherie', 1884);
23 /*
24 Insertion des relations entre les auteurs et les romans.
25 Les six premiers romans sont associes aux deux freres Goncourt.
26 Les romans suivants sont associes uniquement a Edmond de Goncourt.
27 */
28 INSERT INTO auteurs_romans (id_auteur, id_roman)
29 VALUES
30     (1,1), (2,1),
31     (1,2), (2,2),
32     (1,3), (2,3),
33     (1,4), (2,4),
34     (1,5), (2,5),
35     (1,6), (2,6),
36     (1,7),
37     (1,8),
38     (1,9),
39     (1,10);
40 -- Mise a jour des dates de naissance et de mort de Jules de Goncourt.
41 UPDATE auteurs
42 SET date_naissance = 1830,
43     date_mort = 1870
44 WHERE id_auteur = 2;
45
46 -- Mise a jour des dates de naissance et de mort d'Edmond de Goncourt.
47 UPDATE auteurs
48 SET date_naissance = 1822,
```

```
49     date_mort = 1896
50 WHERE id_auteur = 1;
51
```

Ce code permet d'insérer dans la base de données les informations relatives aux frères Goncourt et à leurs romans. Dans un premier temps, les deux auteurs sont ajoutés dans la table **auteurs**. Ils reçoivent chacun un identifiant, qui permettra ensuite de les relier aux œuvres présentes dans la base.

La deuxième partie du code insère les romans des frères Goncourt dans la table **romans**. Chaque œuvre est associée à son titre et à son année de publication. Cette étape permet donc de constituer une partie du corpus à partir des romans retenus pour l'analyse.

Ensuite, la table **auteurs_romans** est utilisée pour associer les auteurs aux romans. Cette table est importante, car elle permet de gérer le cas particulier des œuvres écrites à deux mains. Les six premiers romans sont associés à Edmond et Jules de Goncourt, tandis que les romans publiés après la mort de Jules sont associés uniquement à Edmond. Cela permet de conserver une information plus précise sur l'attribution des œuvres.

Enfin, les deux dernières requêtes mettent à jour les dates de naissance et de mort des auteurs. Ces informations biographiques ne sont pas directement nécessaires pour stocker les textes, mais elles permettent d'enrichir la base de données. Elles peuvent aussi être utiles par la suite si l'on souhaite croiser les résultats de l'analyse avec des éléments chronologiques ou biographiques.

Ce passage sert donc à remplir une première partie de la base de données avec les auteurs, les romans et les relations entre eux. Il montre aussi l'intérêt de séparer les informations dans plusieurs tables : les auteurs sont stockés d'un côté, les romans de l'autre, et la relation entre les deux est conservée dans une table spécifique.

Il faut maintenant ajouter les romans dans la base de données, il peut y avoir plusieurs façons de le faire,

Bibliographie

- BAZÁN, Emilia Pardo (1886). *Le Naturalisme*. Paris : Giraud.
- BIGOT, Charles (sept. 1879). « L'Esthétique naturaliste ». In : *Revue des Deux Mondes*.
- BLEI, David M. (2012). « Probabilistic Topic Models ». In : *Communications of the ACM* 55.4, p. 77-84.
- BLEI, David M., Andrew Y. NG et Michael I. JORDAN (2003). « Latent Dirichlet Allocation ». In : *Journal of Machine Learning Research* 3, p. 993-1022.
- BRUNETIÈRE, Ferdinand (1883). *Le roman naturaliste*. Paris : Calmann-Lévy.
- BURROWS, John (2002). « Delta : A Measure of Stylistic Difference and a Guide to Likely Authorship ». In : *Literary and Linguistic Computing* 17.3, p. 267-287.
- CATTIER, Edmond (1897). *Le Naturalisme littéraire*. Bruxelles : Weissenbruch.
- CHANG, Jonathan et al. (2009). « Reading Tea Leaves : How Humans Interpret Topic Models ». In : *Advances in Neural Information Processing Systems 22*. Curran Associates, p. 288-296.
- DESPREZ, Louis Marie (1884). *L'Évolution naturaliste*. Paris : Tresse.
- DEVLIN, Jacob et al. (2019). « BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding ». In : *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies*. Minneapolis, Minnesota : Association for Computational Linguistics, p. 4171-4186.
- DUDA, Richard O., Peter E. HART et David G. STORK (2001). *Pattern Classification*. 2^e éd. Wiley-Interscience.
- EDWARDS, Aleksandra et Jose CAMACHO-COLLADOS (2024). « Language Models for Text Classification : Is In-Context Learning Enough ? » In : *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation*. Torino, Italy : ELRA et ICCL, p. 10058-10072.
- GRIMMER, Justin et Brandon M. STEWART (2013). « Text as Data : The Promise and Pitfalls of Automatic Content Analysis Methods for Political Texts ». In : *Political Analysis* 21.3, p. 267-297.
- GROOTENDORST, Maarten (2022). « BERTopic : Neural Topic Modeling with a Class-Based TF-IDF Procedure ». In : *arXiv preprint arXiv :2203.05794*. DOI : 10.48550/arXiv.2203.05794.

- HAMON, Philippe (1983). *Le Personnel du roman : Le système des personnages dans les Rougon-Macquart d'Émile Zola*. Histoire des idées et critique littéraire 211. Genève : Librairie Droz.
- HURET, Jules (1891). *Enquête sur l'évolution littéraire*. Paris : Charpentier.
- LEBART, Ludovic et André SALEM (1994). *Statistique textuelle*. Paris : Dunod.
- MACROBE, Antoine (1883). *La flore pornographique : glossaire de l'École naturaliste, extrait des œuvres de M. Émile Zola et de ses disciples*. Paris : Doublet.
- MANNING, Christopher D., Prabhakar RAGHAVAN et Hinrich SCHÜTZE (2008). *Introduction to Information Retrieval*. Cambridge : Cambridge University Press.
- MITTERAND, Henri (1986). *Zola et le naturalisme*. Que sais-je ? 2314. Paris : Presses Universitaires de France.
- (1994). *L'Illusion réaliste : De Balzac à Aragon*. Écriture. Paris : Presses Universitaires de France.
- MOSTELLER, Frederick et David L. WALLACE (1964). *Inference and Disputed Authorship : The Federalist*. Reading, Massachusetts : Addison-Wesley.
- PAGÈS, Alain (déc. 2000). « L'espace littéraire du naturalisme ». In : *Pratiques* 107-108.
- ROUSSEEUW, Peter J. (nov. 1987). « Silhouettes : A graphical aid to the interpretation and validation of cluster analysis ». In : *Journal of Computational and Applied Mathematics* 20, p. 53-65.
- SAPORTA, Gilbert (2006). *Probabilités, analyse des données et statistiques*. Paris : Éditions Technip. 622 p.
- SEBASTIANI, Fabrizio (2002). « Machine Learning in Automated Text Categorization ». In : *ACM Computing Surveys* 34.1, p. 1-47.
- STAMATATOS, Efstathios (2009). « A Survey of Modern Authorship Attribution Methods ». In : *Journal of the American Society for Information Science and Technology* 60.3, p. 538-556.
- TERREAU, Enzo (2024). « Apprentissage de représentations d'auteurs et d'autrices à partir de modèles de langue pour l'analyse des dynamiques d'écriture ». Thèse de doct. Lyon : Université Lumière Lyon 2.
- WU, Xiaobao, Thong NGUYEN et Anh Tuan LUU (2024). « A Survey on Neural Topic Models : Methods, Applications, and Challenges ». In : *Artificial Intelligence Review* 57. Article 18.
- ZOLA, Émile (1881). *Le Roman expérimental*. Paris : Charpentier.

Sitographie

- CONTRIBUTEURS À WIKIPÉDIA (2026a). *Émile Zola*. Wikipédia, l'encyclopédie libre. URL : https://fr.wikipedia.org/wiki/%5C%C3%5C%89mile_Zola (visité le 12/08/2026).
- (2026b). *Frères Goncourt*. Wikipédia, l'encyclopédie libre. URL : https://fr.wikipedia.org/wiki/Fr%C3%5C%A8res_Goncourt (visité le 12/08/2026).
- (2026c). *Gustave Flaubert*. Wikipédia, l'encyclopédie libre. URL : https://fr.wikipedia.org/wiki/Gustave_Flaubert (visité le 12/08/2026).
- (2026d). *Guy de Maupassant*. Wikipédia, l'encyclopédie libre. URL : https://fr.wikipedia.org/wiki/Guy_de_Maupassant (visité le 12/08/2026).
- (2026e). *Naturalisme (littérature)*. Wikipédia, l'encyclopédie libre. URL : [https://fr.wikipedia.org/wiki/Naturalisme_\(litt%C3%5C%A9rature\)](https://fr.wikipedia.org/wiki/Naturalisme_(litt%C3%5C%A9rature)) (visité le 12/08/2026).

Annexe technique : code

.0.1 Le code suivant présente le script Python utilisé pour nettoyer les textes extraits des fichiers EPUB après leur conversion au format *.txt*

```

1 from pathlib import Path
2 import re
3
4
5 def nettoyage_structure_epub(texte):
6     texte_propre = texte
7
8     # Nettoyage initial des espaces insécables
9     texte_propre = re.sub(r'[\xa0\u202f]', ' ', texte_propre)
10
11    # Suppression des éléments placés entre crochets
12    texte_propre = re.sub(r'\[.*?\]', '', texte_propre)
13
14    # Conservation uniquement des caractères utiles pour l'analyse
15    texte_propre = re.sub(
16        r'^[a-zA-Z0-9àáâëèéêïîôöüûçÿÃÄÅÊËĚİÎÔŮŰÜÇœÆ'
17        r'\s.,;:!?"\-\(\)\[\]]',
18        '',
19        texte_propre
20    )
21
22    # Suppression des chiffres collés aux mots
23    texte_propre = re.sub(
24        r'^([a-zA-ZàáâëèéêïîôöüûçÿÃÄÅÊËĚİÎÔŮŰÜÇœÆ])\d+',
25        r'\1',
26        texte_propre
27    )
28
29    # Nettoyage des tirets et des guillemets
30    texte_propre = re.sub(r'-{2,}', '-', texte_propre)
31    texte_propre = re.sub(r'"«»"', '', texte_propre)
32
33    # Suppression des numéros de page isolés
34    texte_propre = re.sub(r'(m)^\\s*d+\\s*$', '', texte_propre)
35
36    # Suppression des titres de chapitre en chiffres romains
37    texte_propre = re.sub(r"(im)^\\s*[IVXLCDM]+\\s*$", "", texte_propre)
38
39    # Suppression de certains éléments propres aux fichiers EPUB
40    texte_propre = re.sub(r"(im)^\\s*Liste des titres\\s*$", "", texte_propre)
41    texte_propre = re.sub(r"(im)^\\s*Table des matières du titre\\s*$", "", texte_propre)
42
43    # Suppression des lignes entièrement écrites en majuscules
44    texte_propre = re.sub(
45        r"(m)^\\s*[A-ZÀÂĂĖĚĚİİÔÖŪŬÇ'']\\s+$",
46        "", texte_propre
47    )
48
```

