

Université Lyon 2, Lyon 3, ENSIB, ENS Lyon

Origine, circularité et transformation des motifs naturalistes

Mémoire présenté par Morgan RICHARD

Année universitaire 2025–2026

Remerciements

Je tiens à remercier mes parents pour leur soutien et leur encouragement tout au long de mes études. Je remercie également mes amis et collègues pour leurs conseils et leur aide précieuse et plus particulièrement à ma conjointe Mathilde DUCOS. Enfin, je souhaite exprimer ma gratitude au professeur Dominique Legallois pour m'avoir accepté en stage au laboratoire LATTICE, pour son encadrement et ses conseils tout au long de ce projet. Je remercie également tous les membres du laboratoire LATTICE pour leur accueil chaleureux et leur soutien. Je remercie également Madame Pegah pour son encadrement et ses conseils tout au long de ce projet. Ainsi que tous le personnel encadrant du master HN de Lyon.

Résumé

Ce mémoire porte sur...

Table des matières

Remerciements	i
Résumé	ii
Introduction	1
1 Topic modeling sur les romans d'Émile Zola	3
1.1 Présentation de la méthode	3
1.2 Présentation du corpus d'étude	4
1.2.1 Choix du corpus	4
1.2.2 Préparation des données brutes en données propres	6
1.2.3 Préparation du corpus pour l'analyse thématique	8
1.2.4 Statistiques descriptives du corpus	10
1.2.5 Lemmatisation du corpus de Zola	13
1.3 Analyse avec la NMF et K-means	15
1.3.1 La méthode NMF	15
1.3.2 La méthode K-means	20
1.4 Résultats	23
1.4.1 Topics obtenus avec le NMF	23
1.4.2 Nombre de segments associés à chaque topic dominant	27
1.4.3 Clusters obtenus avec K-means	29
1.5 Comparaison des deux méthodes	38
1.5.1 Différences entre NMF et K-means	38
1.5.2 Comparaison lexicale des topics NMF et des clusters K-means	39
1.5.3 Convergences thématiques	41
1.5.4 Distribution des thèmes par œuvre	42
1.5.5 Apport de la double approche	44
1.6 Conclusion sur le Topic Modeling	44
2 Dynamique Topic modeling sur le corpus de d'Émile Zola	45
2.1 présentation des données	45
2.1.1 Présentation générale	45

2.1.2	Statistique exploratoires	46
2.2	Utilisation de BerTopic	47
2.2.1	Architecture générale et représentation du corpus	47
2.2.2	Réduction de dimension, clustering et représentation lexicale . .	48
2.2.3	Grille de recherche	49
2.2.4	Critères d'évaluation et classement multicritère	49
2.2.5	Contrôle de la stabilité	50
2.2.6	Justification du choix final à 33 topics	51
2.2.7	Portée et limites du protocole	52
2.3	Validation mathématique	52
2.3.1	Validation de la partition brute	53
2.3.2	Réaffectation des documents atypiques	54
2.3.3	Cohérence et diversité du modèle final	54
2.4	Analyse des résultats de BerTopic	56
2.4.1	Les topics proches de la mouvance naturaliste	56
3	Nettoyage des romans et insertion de ces derniers dans la base de données	57
3.1	Reflexion sur le stockage des données	57
3.2	Nettoyage des textes	57
3.3	Création de la base de données	58
3.4	Création des informations pour la base de données	61
	Bibliographie	63
	Annexe technique : code	64
.0.1	Le code suivant présente le script Python utilisé pour nettoyer les textes extraits des fichiers EPUB après leur conversion au format <i>.txt</i>	64

Table des figures

1.1	Méthode du coude pour le choix du nombre de topics dans la NMF, entre 2 et 40 topics	17
1.2	Méthode du coude pour le choix du nombre de topics dans la NMF, entre 20 et 39 topics	18
1.3	Évolution du score de silhouette en fonction du nombre de clusters dans K-means	21
1.4	Dendrogramme de la classification hiérarchique des clusters K-means .	33
1.5	Regroupement des clusters K-means en grandes familles de motifs . . .	34
1.6	Noms attribués aux grandes familles de motifs	36
1.7	Distribution des grandes familles de motifs dans le corpus	37
1.8	Distribution des clusters K-means dans le corpus	38
1.9	Heatmap des poids des mots dans les topics NMF	39
1.10	Heatmap des poids des mots dans les clusters K-means	40
1.11	Wordcloud des mots caractéristiques des clusters K-means	41
1.12	Poids moyen normalisé des topics NMF par œuvre	42
1.13	Proportion des segments par topic dominant et par œuvre	43

Liste des tableaux

1.1	Corpus des œuvres de Zola utilisées dans l’analyse	4
1.2	Nombre de tokens par roman dans l’ordre chronologique	6
1.3	Nombre de paquets de phrases par roman	10
1.4	Statistiques descriptives du nombre de paquets par roman	11
1.5	Statistiques descriptives du nombre de mots par paquet	12
1.6	Mots caractéristiques des topics obtenus avec la NMF	24
1.7	Noms attribués aux topics obtenus avec la NMF	26
1.8	Nombre de segments associés à chaque topic dominant	27
1.9	Mots caractéristiques des clusters obtenus avec K-means	29
1.10	Noms attribués aux clusters obtenus avec K-means	31
1.11	Composition des grandes familles de motifs issues des clusters K-means	35
2.1	Statistiques descriptives de la variable <i>phrases_paquet</i>	46
2.2	Hyperparamètres inclus dans la grille de recherche BERTopic	49
2.3	Comparaison entre le premier rang automatique et le modèle retenu . .	51
2.4	Indicateurs de validation avant et après la réaffectation des outliers . .	55

Introduction

Le but de ce mémoire est de présenter les travaux réalisés dans le cadre de mon stage de fin d'études, effectué au sein du laboratoire de recherche LATTICE¹. Au cours de ce stage, j'ai travaillé sur de nombreux aspects de *TAL* (Traitement Automatique des Langues). Mon objectif principal était de déterminer comment était rédigée l'écriture naturaliste. Ce stage a été encadré par le professeur *Dominique Legallois* ainsi que par d'autres chercheurs du laboratoire à qui j'ai pu sollicité leur aide notamment lors d'utilisation de technique de *machine Learning*.

Ce projet porte plus précisément sur l'Origine, circularité et transformation des motifs naturalistes. Le but de ce projet est d'analyser les motifs naturalistes dans les textes littéraires et de comprendre comment ils sont utilisés pour créer des effets stylistiques et narratifs. Ce travail a commencé avec la rédaction d'un article scientifique sur le sujet par le professeur *Dominique Legallois*. Ce dernier a commencé une étude sur la caractérisation d'une écriture spécifiquement naturaliste par le biais de méthodes stylométriques et lexicométriques. À partir de l'analyse statistique de fréquences et de patrons lexico-grammaticaux, ses recherches ont mis en évidence la présence de marqueurs et de motifs distinctifs, massivement partagés au sein de ce mouvement littéraire.

Mon travail s'inscrit dans la continuité directe de cet article et vise à approfondir cette détection à plus grande échelle. Pour ce faire, j'ai été amené à manipuler et structurer un vaste corpus issu de la littérature française du XIXe siècle, en me concentrant tout particulièrement sur l'œuvre d'Émile Zola, dont j'ai traité les trente-et-un romans, ainsi

1. Le Lattice est un laboratoire du CNRS (UMR8094), rattaché à l'Ecole Normale Supérieure (IDEX PSL : Paris Sciences et Lettres) et à l'Université Sorbonne Nouvelle-Paris 3. Il regroupe des chercheurs CNRS, des enseignants-chercheurs de l'Université Paris Sorbonne Nouvelle et d'autres universités, ainsi que de nombreux autres personnels permanents ou non-permanents. Les recherches du Lattice sont consacrées à la linguistique et au traitement automatique des langues. Dans le domaine linguistique proprement dit, nos recherches portent, d'une part, sur l'interface entre grammaire et lexique (dans le courant des grammaires cognitives), et d'autre part, sur le discours (en particulier la structuration du discours et la coréférence). Le Lattice accorde également une place majeure à l'étude du changement linguistique, qu'il s'agisse de l'évolution du français – en particulier dans les domaines syntaxique et sémantique – ou des tendances plus générales à l'œuvre dans l'évolution des langues. Dans le domaine du TAL, le Lattice explore les techniques neuronales depuis plusieurs années, et a récemment mis l'accent sur l'analyse syntaxique. Les travaux en linguistique et en TAL sont étroitement corrélés. Enfin notre laboratoire est fortement impliqué dans le domaine des Humanités Numériques et contribue à la construction de ressources enrichies. <https://www.lattice.cnrs.fr/>

que sur les écrits des frères Goncourt.

La première étape de mes missions a consisté en un traitement rigoureux des données textuelles, impliquant le nettoyage, la segmentation fine des textes et une réflexion sur la conception d'une base de données adaptée à la littérature naturaliste. Dans un second temps, j'ai déployé des approches d'apprentissage automatique, plus spécifiquement de modélisation thématique. En m'appuyant sur des techniques telles que *NMF*, *K-means*, *LDA* et *BERTopic*, j'ai mis en place une modélisation de visualisation de topics sur le corpus des romans de Zola et fait une tentative de *Dynamic Topic Modeling* sur ce même auteur afin non seulement d'extraire ces motifs naturalistes, mais également de retracer leur évolution et leur circularité au fil du temps au sein de son oeuvre.

Mon mémoire s'articule en trois chapitres, le premier porte sur le topic modeling et les méthodes de modélisation thématique sur l'écriture naturaliste. Le second chapitre est consacré à l'analyse des motifs naturalistes et l'influence de certains auteurs sur d'autres. Enfin le dernier chapitre est consacré au nettoyage de tout le corpus naturaliste et non naturaliste et leur insertion dans une base de données. Ce mémoire est donc le fruit d'un travail de recherche et d'analyse approfondi, visant à mieux comprendre les caractéristiques de l'écriture naturaliste et à mettre en lumière les motifs qui la définissent.

Comment caractériser l'écriture naturaliste à travers l'analyse des motifs et des thèmes récurrents dans les textes littéraires du XIXe siècle, en utilisant des méthodes de traitement automatique des langues et de modélisation thématique pour identifier les influences et les évolutions stylistiques au sein de ce mouvement littéraire.

Chapitre 1

Topic modeling sur les romans d'Émile Zola

1.1 Présentation de la méthode

Émile Zola, l'un des écrivains majeurs du XIX^e siècle, est connu pour ses romans naturalistes, dans lesquels il explore les dimensions sociales, économiques et psychologiques de la vie humaine. Son œuvre romanesque constitue ainsi un corpus particulièrement riche pour l'analyse des thèmes récurrents, des milieux sociaux et des motifs narratifs.

Dans cette étude, nous examinons les thèmes présents dans les romans de Zola afin de déterminer dans quelle mesure certains motifs apparaissent de manière transversale dans son œuvre. Pour cela, nous mobilisons des méthodes d'analyse textuelle non supervisées, capables d'identifier des regroupements lexicaux à partir des textes eux-mêmes.

La question centrale de cette étude est donc la suivante : dans quelle mesure des méthodes non supervisées comme la NMF et K-means permettent-elles de faire apparaître des structures thématiques récurrentes dans l'œuvre romanesque de Zola ?

L'objectif est de vérifier si les regroupements produits automatiquement correspondent à des motifs interprétables dans le cadre d'une analyse littéraire. Il ne s'agit donc pas de remplacer la lecture critique des textes, mais d'utiliser les outils du traitement automatique du langage comme un moyen d'explorer un corpus littéraire volumineux.

Ce travail constitue le premier volet d'une série d'analyses portant sur des corpus de textes littéraires issus d'auteurs naturalistes et non naturalistes. Il sert à la fois de cas d'étude méthodologique et de base pour de futures comparaisons entre différents ensembles d'œuvres.

Deux méthodes d'analyse ont été utilisées pour identifier les thèmes dans les romans de Zola :

- la NMF (Non-negative Matrix Factorization)¹ : une technique de réduction de dimensionnalité qui permet d'extraire des topics à partir d'un corpus de textes ;
- K-means : une méthode de clustering qui permet de regrouper les segments textuels en fonction de leur proximité lexicale.².

Ces méthodes seront expliquées dans les sections suivantes, avant la présentation des résultats de l'analyse thématique des romans de Zola.

Dans cette étude, le terme *topic* désigne un regroupement lexical produit par le modèle NMF, tandis que le terme *cluster* désigne un groupe de segments obtenu par K-means. Le terme *thème* est réservé à l'interprétation qualitative de ces regroupements. Cette précision terminologique est importante pour éviter toute confusion entre les différentes étapes de l'analyse.

1.2 Présentation du corpus d'étude

1.2.1 Choix du corpus

Cette étude porte sur un corpus composé exclusivement de romans d'Émile Zola. Le choix a été fait de ne pas inclure les nouvelles, les textes journalistiques ni les essais, afin de conserver un ensemble relativement homogène du point de vue générique. Les romans offrent en effet une matière textuelle plus longue et plus développée, ce qui permet d'observer plus finement les thèmes récurrents, les milieux sociaux et les motifs narratifs présents dans l'œuvre de Zola.

L'exclusion des nouvelles répond également à une contrainte méthodologique. Ces textes sont généralement plus courts que les romans et leur intégration aurait pu créer un déséquilibre dans le corpus. Dans le cadre d'une analyse thématique fondée sur des segments textuels, les différences importantes de longueur entre les œuvres peuvent influencer la représentation des thèmes. Limiter le corpus aux romans permet donc de réduire cet effet et de travailler sur un ensemble plus comparable.

Le corpus comprend les œuvres suivantes :

TABLE 1.1 – Corpus des œuvres de Zola utilisées dans l'analyse

Date	Titre	Fichier
1865	<i>La confession de Claude</i>	1865_La_confession_de_Claude._clean.txt
1866	<i>Le vœu d'une morte</i>	1866_Le_voeu_d_une_morte._clean.txt

1. N. Gillis, *Nonnegative Matrix Factorization*, Society for Industrial and Applied Mathematics, coll. « Data Science », 2020.

2. Richard O. Duda, Peter E. Hart et David G. Stork, *Pattern Classification*, Wiley-Interscience, 2001.

Date	Titre	Fichier
1867	<i>Les mystères de Marseille</i>	1867_Les_mysteres_de_Marseille._clean.txt
1867	<i>Thérèse Raquin</i>	1867_Therese_Raquin._clean.txt
1868	<i>Madeleine Férat</i>	1868_Madeleine_Ferat._clean.txt
1871	<i>La fortune des Rougon</i>	1871_1_La_fortune_des_Rougon._clean.txt
1872	<i>La curée</i>	1871_2_La_curee._clean.txt
1873	<i>Le ventre de Paris</i>	1873_3_Le_ventre_de_Paris._clean.txt
1874	<i>La conquête de Plassans</i>	1874_4_La_conquete_de_Plassans._clean.txt
1875	<i>La faute de l'abbé Mouret</i>	1875_5_La_faute_de_l_abbe_Mouret._clean.txt
1876	<i>Son Excellence Eugène Rougon</i>	1876_6_Son_Excellence_Eugene_Rougon._clean.txt
1877	<i>L'assommoir</i>	1877_7_L_assommoir._clean.txt
1878	<i>Une page d'amour</i>	1878_8_Une_page_d_amour._clean.txt
1880	<i>Nana</i>	1880_9_Nana._clean.txt
1882	<i>Pot-Bouille</i>	1882_10_Pot-bouille._clean.txt
1883	<i>Au Bonheur des dames</i>	1883_11_Au_Bonheur_des_dames._clean.txt
1884	<i>La joie de vivre</i>	1884_12_La_joye_de_vivre._clean.txt
1885	<i>Germinal</i>	1885_13_Germinal._clean.txt
1886	<i>L'œuvre</i>	1886_14_L_oeuvre._clean.txt
1887	<i>La terre</i>	1887_15_La_terre._clean.txt
1888	<i>Le rêve</i>	1888_16_Le_reve._clean.txt
1890	<i>La bête humaine</i>	1890_17_La_bete_humaine._clean.txt
1891	<i>L'argent</i>	1891_18_L_argent._clean.txt
1892	<i>La débâcle</i>	1892_19_La_debacle._clean.txt
1893	<i>Le docteur Pascal</i>	1893_20_Le_docteur_Pascal._clean.txt
1894	<i>Lourdes</i>	1894_1_Lourdes._clean.txt
1896	<i>Rome</i>	1896_2_Rome._clean.txt
1898	<i>Paris</i>	1898_3_Paris._clean.txt
1899	<i>Fécondité</i>	1899_1_Fecondite._clean.txt
1901	<i>Travail</i>	1901_2_Travail._clean.txt
1903	<i>Vérité</i>	1903_3_Verite._clean.txt

Le corpus est composé de 31 romans, qui couvrent les principales périodes de la production romanesque de Zola. Il comprend :

- 5 romans antérieurs au cycle des *Rougon-Macquart* ;
- 20 romans appartenant au cycle des *Rougon-Macquart* ;

- 3 romans du cycle des *Trois Villes* ;
- 3 romans publiés du cycle des *Quatre Évangiles*.

Pour ce qui est des *Quatre Évangiles*, *Vérité* paraît à titre posthume. *Justice* ne paraîtra jamais, l’ouvrage étant resté à l’état d’ébauche au moment de la mort de l’écrivain.

Ce corpus permet donc de couvrir une large période de la carrière de Zola, depuis ses premiers romans jusqu’à ses dernières œuvres. Cette amplitude chronologique est importante pour l’analyse, car elle permet d’observer non seulement les thèmes récurrents de l’œuvre romanesque, mais aussi leur possible évolution au fil du temps³.

1.2.2 Préparation des données brutes en données propres

Les romans au format `.txt` correspondent à des versions nettoyées, c’est-à-dire à des textes dont les éléments non textuels ont été supprimés. Ces éléments comprennent notamment les titres, les chapitres, les notes de bas de page et d’autres informations éditoriales qui pourraient perturber l’analyse. Ce nettoyage permet d’obtenir une représentation plus précise des thèmes présents dans les romans.

De plus, le choix a été fait de conserver une seule phrase par ligne. Ce format facilite l’analyse textuelle, notamment pour les méthodes de la NMF et de K-means, qui nécessitent une structure de données homogène pour fonctionner correctement.

Cette logique de formatage a également été appliquée en prévision des analyses futures. Les romans issus de prochains traitements pourront ainsi être intégrés de manière cohérente au corpus. Ce choix permet de limiter les différences de structure entre les fichiers et d’obtenir un format homogène pour l’analyse sans trop complexifier le processus de préparation des données.

TABLE 1.2 – Nombre de tokens par roman dans l’ordre chronologique

Titre du roman	Nombre de tokens
<i>La confession de Claude</i>	47253
<i>Le vœu d’une morte</i>	38722
<i>Les mystères de Marseille</i>	125253
<i>Thérèse Raquin</i>	66363
<i>Madeleine Féral</i>	97318
<i>La fortune des Rougon</i>	116685
<i>La curée</i>	105120
<i>Le ventre de Paris</i>	110442
<i>La conquête de Plassans</i>	113245

3. En vue d’une éventuelle analyse ultérieure par dynamic topic modeling sur ce même corpus.

Titre du roman	Nombre de tokens
<i>La faute de l'abbé Mouret</i>	114667
<i>Son Excellence Eugène Rougon</i>	126186
<i>L'assommoir</i>	158340
<i>Une page d'amour</i>	102185
<i>Nana</i>	141573
<i>Pot-Bouille</i>	134844
<i>Au Bonheur des dames</i>	147521
<i>La joie de vivre</i>	117255
<i>Germinal</i>	164473
<i>L'œuvre</i>	130613
<i>La terre</i>	163687
<i>Le rêve</i>	66379
<i>La bête humaine</i>	125418
<i>L'argent</i>	143010
<i>La débâcle</i>	187046
<i>Le docteur Pascal</i>	112713
<i>Lourdes</i>	173511
<i>Rome</i>	233958
<i>Paris</i>	177389
<i>Fécondité</i>	220131
<i>Travail</i>	198712
<i>Vérité</i>	223274

Le tableau fournit une description quantitative du corpus en indiquant, pour chaque roman, le nombre de tokens obtenus après nettoyage. Les œuvres sont présentées dans l'ordre chronologique, ce qui permet d'observer l'évolution du volume textuel au sein de la production romanesque de Zola. Les écarts sont importants entre les romans courts du début de carrière, comme *Le vœu d'une morte*, et les œuvres plus volumineuses de la fin de carrière, notamment *Rome*, *Fécondité*, *Travail* et *Vérité*.

Cette information est importante pour l'interprétation des résultats, car la longueur des textes peut avoir un effet sur la représentation des thèmes. Un roman plus long fournit mécaniquement davantage d'occurrences lexicales et davantage de segments analysables. La segmentation en paquets de phrases vise donc à produire des unités d'analyse plus comparables, tout en conservant suffisamment de contexte pour identifier les thèmes dominants.

1.2.3 Préparation du corpus pour l'analyse thématique

Pour préparer le corpus à l'analyse thématique, nous avons adopté une procédure visant à produire des unités textuelles comparables et exploitables par les modèles.

Les romans ont été segmentés en paquets de phrases⁴. Chaque paquet est composé de 40 phrases. Cette taille a été retenue car elle offre un compromis entre deux exigences : conserver suffisamment de contexte pour identifier les thèmes présents dans les romans, tout en permettant une analyse plus fine qu'un découpage à l'échelle du chapitre ou de l'œuvre entière.

Ce choix reste toutefois méthodologique et partiellement arbitraire. Plusieurs tailles de paquets ont été testées⁵. Les paquets de 40 phrases ont été retenus, car ils produisaient les résultats les plus cohérents et les plus interprétables parmi les configurations testées. Ce choix n'est donc pas parfait, mais il constitue le meilleur compromis observé dans le cadre de cette analyse.

D'autres modes de segmentation ont également été envisagés, notamment un découpage par chapitre ou par paragraphe. Le découpage par chapitre a été écarté, car les chapitres ne constituent pas des unités suffisamment homogènes en longueur et en contenu. Certains chapitres sont très courts, tandis que d'autres sont beaucoup plus longs, ce qui rend la comparaison entre unités d'analyse plus difficile.

Le découpage par paragraphe a également été étudié, mais il posait plusieurs problèmes. D'abord, les paragraphes varient fortement en longueur : certains sont très courts, tandis que d'autres sont beaucoup plus développés. Cette difficulté pourrait être partiellement corrigée par un filtrage des paragraphes trop courts ou trop longs, mais cela introduirait une étape supplémentaire et rendrait le traitement moins homogène.

Ensuite, l'architecture matérielle des textes n'est pas toujours conservée de manière fiable dans les fichiers disponibles. Certains romans ne présentent plus une mise en page avec des paragraphes clairement identifiables, en particulier lorsque les textes proviennent de formats différents, comme des fichiers `.txt`, `.pdf` ou `.epub`. Or, ce travail s'inscrit dans une perspective d'élargissement du corpus à d'autres romans et à d'autres sources textuelles. Dans ce contexte, la segmentation par phrase apparaît plus facilement généralisable à des formats hétérogènes.

Enfin, la structure interne des romans pose un dernier problème. Les dialogues peuvent être considérés comme des paragraphes indépendants, ce qui produit parfois des unités d'analyse très courtes, composées de seulement quelques mots. Là encore, un filtrage serait possible, mais il complexifierait le protocole et risquerait d'introduire des différences de traitement entre les textes.

Pour ces raisons, le découpage en paquets de 40 phrases a été retenu. Il permet

4. Le code pour segmenter les romans est disponible en annexe, dans la section « Segmentation du corpus ».

5. Différents essais ont été réalisés avec des paquets de 10, 50, 70 et 100 phrases.

de produire des unités d'analyse relativement homogènes, applicables à l'ensemble du corpus, tout en conservant une quantité suffisante de contexte pour l'analyse thématique.

1.2.4 Statistiques descriptives du corpus

TABLE 1.3 – Nombre de paquets de phrases par roman

Titre du roman	Nombre de paquets
<i>La confession de Claude</i>	65
<i>Le vœu d'une morte</i>	60
<i>Les mystères de Marseille</i>	184
<i>Thérèse Raquin</i>	80
<i>Madeleine Férat</i>	124
<i>La fortune des Rougon</i>	154
<i>La curée</i>	123
<i>Le ventre de Paris</i>	136
<i>La conquête de Plassans</i>	165
<i>La faute de l'abbé Mouret</i>	171
<i>Son Excellence Eugène Rougon</i>	191
<i>L'assommoir</i>	228
<i>Une page d'amour</i>	166
<i>Nana</i>	225
<i>Pot-Bouille</i>	207
<i>Au Bonheur des dames</i>	198
<i>La joie de vivre</i>	164
<i>Germinal</i>	225
<i>L'œuvre</i>	163
<i>La terre</i>	222
<i>Le rêve</i>	82
<i>La bête humaine</i>	154
<i>L'argent</i>	155
<i>La débâcle</i>	221
<i>Le docteur Pascal</i>	135
<i>Lourdes</i>	198
<i>Rome</i>	231
<i>Paris</i>	206
<i>Fécondité</i>	259
<i>Travail</i>	208
<i>Vérité</i>	227

Ce tableau indique le nombre de paquets de phrases obtenus pour chaque roman après segmentation du corpus. Les écarts observés reflètent principalement les différences

de longueur entre les œuvres : les textes les plus courts, comme *Le vœu d'une morte* ou *La confession de Claude*, produisent peu de paquets, tandis que les romans plus volumineux, comme *Fécondité*, *Rome* ou *L'assommoir*, en produisent davantage.

Analyse des statistiques descriptives du nombre de paquets par roman

TABLE 1.4 – Statistiques descriptives du nombre de paquets par roman

Indicateur	Valeur
Nombre de romans	31
Moyenne	171.84
Écart-type	52.40
Minimum	60
Premier quartile	145
Médiane	171
Troisième quartile	214.5
Maximum	259

Les statistiques descriptives du nombre de paquets par roman permettent d'évaluer la structure quantitative du corpus après segmentation. Le corpus comprend 31 romans, avec une moyenne d'environ 172 paquets de phrases par œuvre. La médiane, située à 171 paquets, est très proche de cette moyenne. Cette proximité indique que la distribution générale du nombre de paquets n'est pas fortement asymétrique : la majorité des romans se situe autour d'un volume intermédiaire, même si certains textes s'écartent nettement de cette tendance.

L'écart-type, d'environ 52 paquets, montre toutefois une dispersion importante autour de la moyenne. Cette variation s'explique principalement par les différences de longueur entre les romans. Les œuvres les plus courtes, comme *Le vœu d'une morte*, produisent seulement 60 paquets, tandis que les textes les plus longs, comme *Fécondité*, atteignent 259 paquets. L'écart entre le minimum et le maximum est donc notable, puisqu'il existe presque un rapport de un à quatre entre le roman le moins segmenté et le roman le plus segmenté.

Les quartiles permettent de préciser cette répartition. Le premier quartile, situé à 145 paquets, indique qu'un quart des romans contient 145 paquets ou moins. Le troisième quartile, situé à 214,5 paquets, indique qu'environ trois quarts des romans restent sous ce seuil. La moitié centrale du corpus se situe donc entre 145 et 214,5 paquets, ce qui montre que la majorité des œuvres conserve une taille relativement comparable après segmentation. Les valeurs extrêmes ne remettent donc pas en cause l'homogénéité

générale du corpus, mais elles doivent être prises en compte dans l'interprétation des résultats.

Le coefficient de variation est d'environ 30 %, puisqu'il correspond au rapport entre l'écart-type et la moyenne. Cette valeur signale une variabilité modérée : les romans ne sont pas tous de taille équivalente, mais les écarts restent attendus pour un corpus littéraire composé d'œuvres publiées à des périodes différentes et appartenant à plusieurs cycles romanesques. Cette dispersion est donc méthodologiquement acceptable, à condition de garder à l'esprit que les romans les plus longs fournissent davantage d'unités d'analyse.

Cette information est importante pour l'analyse thématique. Chaque paquet de phrases constitue une unité soumise aux méthodes de topic modeling. Par conséquent, un roman plus long contribue mécaniquement à un plus grand nombre d'observations qu'un roman court. Les thèmes présents dans les romans volumineux peuvent donc être davantage représentés dans les résultats globaux. La segmentation en paquets de 40 phrases permet néanmoins de réduire cet effet, car elle transforme les romans en unités textuelles comparables tout en conservant suffisamment de contexte pour identifier des thèmes cohérents.

Ainsi, ces statistiques montrent que le corpus présente un équilibre satisfaisant pour une analyse thématique. Les différences de taille entre les romans existent, mais elles sont documentées et peuvent être intégrées à l'interprétation des résultats. Cette étape descriptive permet donc de mieux contrôler les effets liés à la longueur des œuvres avant l'application des méthodes de NMF et de K-means.

Analyse des statistiques descriptives du nombre de mots par paquet

TABLE 1.5 – Statistiques descriptives du nombre de mots par paquet

Indicateur	Valeur
Nombre de paquets	5327
Moyenne	785.30
Écart-type	212.13
Minimum	42
Premier quartile	636
Médiane	753
Troisième quartile	902.5
Maximum	2944

Les statistiques descriptives du nombre de mots par paquet permettent d'évaluer la taille effective des unités textuelles utilisées pour l'analyse thématique. Le corpus

segmenté comprend 5327 paquets, avec une moyenne d'environ 785 mots par paquet. La médiane, située à 753 mots, est relativement proche de cette moyenne, ce qui indique que la majorité des paquets se situe autour d'un volume textuel comparable.

L'écart-type est d'environ 212 mots, ce qui traduit une dispersion modérée autour de la moyenne. Le coefficient de variation est d'environ 27 %, puisqu'il correspond au rapport entre l'écart-type et la moyenne. Cette valeur indique que les paquets ne sont pas parfaitement homogènes en longueur, mais que la variabilité reste acceptable pour une analyse thématique. Cette variation s'explique par le fait que les paquets sont construits à partir d'un nombre fixe de phrases, et non d'un nombre fixe de mots : selon le style, le rythme narratif ou la longueur syntaxique des phrases, deux paquets de 40 phrases peuvent contenir un nombre de mots assez différent.

Les quartiles permettent de préciser cette distribution. Un quart des paquets contient au maximum 636 mots, tandis que la moitié des paquets contient au maximum 753 mots. Le troisième quartile, situé à 902,5 mots, indique que 75 % des paquets ne dépassent pas environ 903 mots. Ainsi, la majorité des unités d'analyse se concentre dans une zone relativement stable, comprise approximativement entre 636 et 903 mots pour la moitié centrale du corpus. Cette concentration est favorable au topic modeling, car elle limite les écarts de taille entre les unités comparées.

Les valeurs extrêmes doivent toutefois être prises en compte. Le paquet le plus court contient seulement 42 mots, tandis que le plus long atteint 2944 mots. Ces deux valeurs indiquent la présence d'unités atypiques. Le paquet de 42 mots correspond probablement à une fin de roman ou à un segment résiduel composé de moins de phrases que les autres. À l'inverse, le paquet de 2944 mots peut provenir d'un passage composé de phrases particulièrement longues ou d'une segmentation imparfaite du texte source. Ces cas extrêmes peuvent influencer l'analyse, car un paquet très long contient davantage d'information lexicale et peut donc peser plus fortement dans la représentation des thèmes.

Dans l'ensemble, ces statistiques montrent que la segmentation en paquets de 40 phrases produit des unités textuelles globalement comparables. Malgré une variabilité réelle, la distribution reste suffisamment concentrée autour de la médiane pour permettre une analyse thématique cohérente. Il serait toutefois pertinent d'examiner les paquets extrêmes afin de vérifier s'ils correspondent à des cas normaux du corpus ou à des problèmes de segmentation.

1.2.5 Lemmatisation du corpus de Zola

Après avoir obtenu un corpus segmenté en paquets de phrases et relativement homogène en termes de nombre de mots, l'étape suivante de préparation des données a

consisté à effectuer une lemmatisation du corpus⁶.

Pour réaliser cette lemmatisation, nous avons utilisé la bibliothèque `spaCy` en Python, qui offre des outils performants pour le traitement automatique du langage. La lemmatisation permet de regrouper les différentes formes d'un même mot sous une seule forme de base : par exemple, les mots « manger », « mange » et « manges » sont tous réduits au lemme « manger ». Cette étape facilite l'identification des thèmes et contribue à réduire la dimensionnalité du corpus.

Comme pour la segmentation en paquets de phrases, plusieurs essais ont été réalisés avec la bibliothèque de lemmatisation `spaCy`.

Nous avons choisi d'utiliser le modèle `fr_core_news_lg` de `spaCy`, qui est un modèle de langue française de grande taille. Ce choix a été motivé par la richesse lexicale et la complexité syntaxique des romans de Zola, qui nécessitent un modèle capable de gérer une grande variété de formes linguistiques. Le modèle `fr_core_news_lg` a été retenu, car il offre une lemmatisation plus précise que des modèles plus légers⁷, ce qui est important pour l'identification des thèmes dans les textes littéraires.

Une liste de mots à exclure a été construite progressivement au cours de plusieurs itérations de prétraitement⁸. Elle résulte de l'observation conjointe des sorties de lemmatisation et de la matrice terme-document. L'objectif était d'identifier les formes lexicales très fréquentes dans le corpus, mais peu discriminantes pour l'analyse thématique.

Cette liste contient d'abord des mots-outils, tels que les pronoms personnels, les conjonctions, les déterminants et les prépositions. Ces termes structurent grammaticalement les phrases, mais ils ne permettent pas d'identifier les thèmes dominants des romans. Leur présence importante dans la matrice terme-document risquait donc de réduire la lisibilité des topics produits par la NMF.

La liste a également été enrichie par l'ajout de certains noms propres, notamment des noms de personnages récurrents dans les romans de Zola. Ces noms apparaissent fréquemment dans les textes, mais leur poids lexical tendait à orienter les topics vers des personnages plutôt que vers des thèmes plus généraux, comme le travail, la famille, la religion, l'argent ou les rapports sociaux. Leur exclusion permet donc de privilégier une interprétation thématique plutôt qu'une simple identification des protagonistes.

Ce filtrage relève d'un choix méthodologique empirique. Lors des premiers essais, plusieurs mots restaient fortement représentés dans les résultats malgré les paramètres appliqués au lemmatiseur et au vectoriseur. La liste d'exclusion a donc été ajustée à partir de l'examen des termes les plus fréquents et des premiers topics obtenus. Elle vise à améliorer la qualité interprétative de la matrice terme-document en conservant prioritairement les mots porteurs d'information thématique.

6. Code disponible en annexe, dans la section « Lemmatisation et filtrage lexical ».

7. Les modèles `fr_core_news_sm` et `fr_core_news_md` ont également été envisagés.

8. Elle est présente en annexe du document.

Une fonction applique le modèle **spaCy** à chaque segment du corpus afin d'en extraire une version lemmatisée et filtrée⁹. Pour chaque token, le lemme est d'abord converti en minuscules afin de normaliser les formes lexicales. La fonction exclut ensuite les mots vides, la ponctuation, les nombres, les espaces, ainsi que les lemmes trop courts ou présents dans la liste personnalisée de mots à retirer. Le filtrage conserve uniquement les noms et les adjectifs, car ces catégories grammaticales sont généralement les plus porteuses d'information thématique dans le cadre d'une analyse de topics. Le résultat final est une chaîne de caractères composée des lemmes retenus, qui peut ensuite être utilisée pour construire la matrice terme-document.

À l'issue de cette préparation, chaque roman est représenté par un ensemble de segments lemmatisés et filtrés. Ces segments constituent les unités d'analyse utilisées pour les deux méthodes de modélisation thématique présentées dans la section suivante.

1.3 Analyse avec la NMF et K-means

Comme mentionné précédemment, deux méthodes d'analyse ont été utilisées pour identifier les thèmes dans les romans de Zola : la NMF (Non-negative Matrix Factorization) et K-means. Cette section présente ces deux méthodes et expose les choix retenus pour leur application au corpus préparé.

1.3.1 La méthode NMF

La NMF est une technique de réduction de dimensionnalité qui permet d'extraire des thèmes à partir d'un corpus de textes. Elle fonctionne en factorisant la matrice terme-document en deux matrices non négatives : une matrice de thèmes et une matrice de poids. La matrice de thèmes contient les mots les plus représentatifs de chaque thème, tandis que la matrice de poids indique l'importance de chaque thème dans chaque document ou paquet de phrases.

La présentation commence par la NMF, avant d'aborder le clustering par K-means comme méthode complémentaire.

Après la préparation du corpus, la segmentation en paquets de phrases et la lemmatisation des textes, l'étape suivante consiste à appliquer une méthode de modélisation thématique. L'objectif est d'identifier automatiquement les grands thèmes présents dans les romans de Zola, à partir des termes les plus représentatifs de chaque segment textuel.

Dans cette analyse, la méthode retenue est la NMF, pour *Non-negative Matrix Factorization*. Cette méthode permet de décomposer une matrice terme-document en deux matrices plus simples : une matrice associant les segments de texte aux topics,

9. Fonction en Python disponible en annexe du document.

et une matrice associant les topics aux termes les plus caractéristiques. La NMF est particulièrement adaptée à ce type d'analyse, car elle produit des résultats relativement interprétables : chaque topic peut être compris comme un ensemble de mots fortement associés entre eux.

Création de la matrice terme-document

La première étape consiste à transformer les textes lemmatisés en une représentation numérique exploitable par le modèle. Pour cela, une matrice terme-document a été construite à l'aide d'une pondération TF-IDF¹⁰. Cette méthode permet de donner un poids plus important aux termes caractéristiques d'un segment, tout en réduisant l'influence des mots trop fréquents dans l'ensemble du corpus.

Les paramètres `min_df` et `max_df` jouent un rôle important dans la qualité de la matrice obtenue. Le paramètre `min_df=3` permet d'exclure les mots qui apparaissent dans moins de trois segments. Ces mots sont généralement trop rares pour contribuer efficacement à l'identification de thèmes récurrents. À l'inverse, le paramètre `max_df=0.8` exclut les termes présents dans plus de 80 % des segments, car ils sont trop fréquents pour être réellement discriminants¹¹.

Ce choix relève d'un arbitrage méthodologique. Plusieurs combinaisons ont été testées, puis évaluées à partir de la qualité des mots conservés et de la cohérence des premiers topics obtenus. L'objectif n'était donc pas seulement de réduire la taille de la matrice, mais surtout de conserver les termes les plus utiles pour l'analyse thématique. La matrice finale sert ensuite de base à l'application du modèle NMF.

Choix du nombre de topics

Le choix du nombre de topics constitue une étape importante dans une analyse par NMF. Un nombre trop faible de topics risque de produire des catégories trop générales, dans lesquelles plusieurs thèmes distincts se trouvent regroupés. À l'inverse, un nombre trop élevé peut conduire à une fragmentation excessive des résultats, avec des topics trop proches les uns des autres ou difficiles à interpréter.

Afin d'orienter ce choix, une méthode du coude a d'abord été utilisée¹². Cette méthode consiste à entraîner plusieurs modèles NMF avec différents nombres de topics, puis à observer l'évolution de l'erreur de reconstruction. L'objectif est d'identifier un éventuel seuil à partir duquel l'ajout de nouveaux topics n'améliore plus fortement la qualité de reconstruction du modèle.

10. Utilisée via la bibliothèque `scikit-learn`.

11. Le vectoriseur est disponible en annexe.

12. Code visible en annexe.




FIGURE 1.1 – Méthode du coude pour le choix du nombre de topics dans la NMF, entre 2 et 40 topics

La première visualisation présente l'évolution de l'erreur de reconstruction pour un nombre de topics compris entre 2 et 40. On observe une diminution régulière de l'erreur lorsque le nombre de topics augmente. Cette baisse est attendue : plus le modèle dispose de topics, plus il peut reconstruire finement la matrice terme-document. Cependant, la courbe ne présente pas de rupture nette permettant d'identifier un coude évident. Le critère quantitatif ne suffit donc pas, à lui seul, à déterminer un nombre optimal de topics.

Une seconde visualisation a été produite en resserrant l'observation sur une zone plus restreinte, comprise entre 20 et 39 topics. Ce zoom permet d'examiner plus précisément la partie de la courbe dans laquelle plusieurs valeurs candidates pouvaient être envisagées.




FIGURE 1.2 – Méthode du coude pour le choix du nombre de topics dans la NMF, entre 20 et 39 topics

Ce second graphique confirme l’absence de seuil clairement marqué. L’erreur de reconstruction continue de diminuer de manière progressive, sans stabilisation brutale ni changement de pente suffisamment net pour imposer une valeur unique. Le choix du nombre de topics ne peut donc pas reposer uniquement sur la méthode du coude.

Le choix final a ainsi été complété par une analyse qualitative des résultats. Plusieurs valeurs ont été testées, notamment 10, 15, 20, 30 et 35 topics. Les modèles obtenus ont été comparés à partir des mots caractéristiques de chaque topic, de leur cohérence interne et de leur capacité à correspondre à des thèmes interprétables dans l’œuvre de Zola. Dans cette perspective, le choix de 29 topics a été retenu comme un compromis entre précision, lisibilité et stabilité interprétative.

Ce choix a également été mis en relation avec l’analyse par K-means. Le nombre de clusters retenu pour K-means a été fixé à 29 afin de permettre une comparaison directe entre les deux méthodes. Cette seconde approche ne sert pas à prouver définitivement que 29 est le nombre optimal de topics, mais elle permet de vérifier si une structuration thématique comparable apparaît lorsque les segments sont regroupés selon une logique différente. Autrement dit, K-means joue ici un rôle de validation complémentaire : si certains motifs apparaissent à la fois dans les topics NMF et dans les clusters K-means, cela renforce leur pertinence pour l’analyse du corpus.

Paramétrage du modèle NMF

Après plusieurs essais, le modèle final a été construit avec 29 topics. Cette valeur a été retenue, car elle permettait d’obtenir un niveau de détail suffisant, sans produire

une fragmentation trop importante des thèmes ni introduire trop de bruit. Les topics obtenus correspondent à des ensembles thématiques distincts, comme le monde ouvrier, la religion, la famille, la finance, la guerre, le commerce, la médecine ou encore l’espace domestique, comme nous le verrons dans la section consacrée aux résultats.

Le paramètre `n_components=29` correspond au nombre de topics recherchés. Le paramètre `random_state=42` permet d’assurer la reproductibilité des résultats. L’initialisation `nndsvda`¹³ est adaptée à la NMF, car elle fournit une initialisation stable à partir de la structure de la matrice. Le solveur `cd`, pour *coordinate descent*, est utilisé pour optimiser la factorisation.

La matrice **W** contient les poids des topics pour chaque segment du corpus. Autrement dit, elle indique dans quelle mesure chaque segment est associé à chacun des 29 topics. La matrice **H**, quant à elle, contient les poids des mots pour chaque topic. Elle permet donc d’identifier les termes les plus représentatifs de chaque thème.

Limites de l’approche

L’utilisation de la NMF présente plusieurs avantages, notamment sa lisibilité et sa capacité à produire des topics relativement interprétables. Cependant, cette méthode comporte aussi des limites. Le choix du nombre de topics reste en partie subjectif, surtout lorsque la méthode du coude ne permet pas d’identifier une valeur optimale claire. Dans cette analyse, le choix de 29 topics repose donc sur un compromis entre précision, lisibilité et cohérence interprétative. La validation humaine des résultats est donc essentielle pour s’assurer que les topics produits correspondent à des thèmes réels et pertinents dans l’œuvre de Zola.

De plus, les noms attribués aux topics résultent d’une interprétation humaine. Deux personnes pourraient parfois proposer des intitulés légèrement différents pour un même groupe de mots. Il est donc important de considérer ces noms comme des outils d’analyse, et non comme des catégories fixes ou définitives. Cette subjectivité ne remet pas en cause la validité de l’analyse, mais elle souligne l’importance d’une approche critique et réflexive dans l’interprétation des résultats.

Enfin, les résultats dépendent fortement des choix effectués en amont : nettoyage du texte, lemmatisation, liste de mots à exclure, taille des segments, paramètres du vecteur et nombre de topics. La modélisation thématique ne doit donc pas être comprise comme une méthode entièrement automatique, mais comme un processus exploratoire qui combine traitement statistique et interprétation qualitative avec validation humaine à chaque étape.

13. L’initialisation `nndsvda` correspond à une variante de NNDSVD dans laquelle les zéros sont remplacés par la moyenne de la matrice. Voir la documentation de `scikit-learn`.

Bilan méthodologique

Cette étape de modélisation par NMF permet d’obtenir une première cartographie thématique du corpus romanesque de Zola. Elle fournit une base quantitative pour observer des régularités lexicales qui seront ensuite interprétées dans la section consacrée aux résultats.

La NMF constitue donc un outil pertinent pour explorer les thèmes récurrents dans un corpus littéraire volumineux. Elle ne remplace pas l’analyse littéraire, mais elle permet de faire apparaître des régularités lexicales et thématiques qui peuvent ensuite être interprétées plus finement. Dans le cadre de cette étude, elle sert à établir une base quantitative pour l’analyse des thèmes présents dans les romans de Zola.

1.3.2 La méthode K-means

Après l’application de la NMF, une seconde méthode a été utilisée afin de compléter l’analyse thématique du corpus : le clustering par K-means. Contrairement à la NMF, qui cherche à décomposer la matrice terme-document en topics latents, K-means vise à regrouper les segments textuels en ensembles homogènes à partir de leur proximité lexicale. L’objectif n’est donc pas exactement le même : la NMF permet d’identifier des thèmes sous forme de combinaisons de mots, tandis que K-means permet de regrouper les paquets de phrases qui présentent des profils lexicaux similaires.

Cette seconde méthode a été utilisée comme un outil complémentaire de comparaison et de validation. Elle permet de vérifier si les regroupements produits par la NMF correspondent également à des ensembles cohérents lorsque l’on applique une méthode de clustering non supervisée. Dans le cadre de cette analyse, chaque paquet de phrases constitue une unité d’observation, représentée numériquement par une matrice TF-IDF. Les clusters obtenus correspondent donc à des groupes de segments partageant des termes caractéristiques.

Préparation de la matrice TF-IDF

Comme pour la NMF, la première étape consiste à transformer les textes lemmatisés en une représentation numérique. La matrice utilisée pour le K-means est construite à partir des segments lemmatisés du corpus. Le même type de vectorisation TF-IDF et les mêmes paramètres ont été conservés afin d’assurer une cohérence méthodologique entre les deux approches¹⁴.

Ce choix permet de travailler sur une matrice plus lisible et plus pertinente pour le clustering. Le but n’est pas seulement de réduire le nombre de dimensions, mais aussi de conserver les mots qui participent réellement à la différenciation des segments. Cette

14. Voir la section consacrée à la préparation de la matrice terme-document dans l’approche NMF.

étape est essentielle, car la qualité des clusters dépend directement de la qualité de la représentation vectorielle utilisée.

Recherche du nombre de clusters

Le choix du nombre de clusters est une étape centrale dans l'utilisation de K-means. Un nombre trop faible de clusters risque de produire des groupes trop généraux, dans lesquels plusieurs thèmes différents seraient mélangés. À l'inverse, un nombre trop élevé peut produire des groupes trop fragmentés, difficiles à interpréter ou très proches les uns des autres, nous avons donc le même problème qu'avec l'approche NMF.

Afin d'orienter ce choix, plusieurs valeurs de k ont été testées. Pour chaque valeur comprise entre 2 et 40, un modèle K-means a été entraîné, puis évalué à l'aide du score de silhouette¹⁵.

Ce score mesure la qualité de la séparation entre les clusters : plus il est élevé, plus les segments sont proches des éléments de leur propre cluster et éloignés des autres groupes.

Une visualisation des scores de silhouette a ensuite été produite afin d'observer l'évolution de la qualité du clustering selon le nombre de clusters.




FIGURE 1.3 – Évolution du score de silhouette en fonction du nombre de clusters dans K-means

Dans cette analyse, le score de silhouette fournit une indication quantitative, mais il ne suffit pas à lui seul à déterminer le nombre de clusters à retenir. Comme pour la NMF, le choix final repose donc sur un compromis entre indicateurs statistiques, lisibilité des résultats et cohérence interprétative. Le nombre de 29 clusters a été retenu afin de

15. Peter J. Rousseeuw, « Silhouettes : A graphical aid to the interpretation and validation of cluster analysis », *Journal of Computational and Applied Mathematics*, vol. 20, 1er novembre 1987, p. 53–65.

permettre une comparaison directe avec les 29 topics issus de la NMF, tout en conservant un niveau de détail suffisant pour distinguer les principaux motifs thématiques du corpus. De plus, le score de silhouette reste relativement stable autour de cette valeur, ce qui indique que les clusters obtenus sont globalement cohérents. Le choix de 29 topics pour la NMF et de 29 clusters pour K-means permet donc d'obtenir une structuration thématique comparable entre les deux méthodes, facilitant ainsi l'interprétation des résultats et la mise en évidence de régularités dans le corpus. Il y a donc une validation croisée entre les deux approches, qui renforce la confiance dans les regroupements identifiés (29 topics et 29 clusters).

Entraînement du modèle K-means

Le modèle K-means final a été entraîné avec 29 clusters. Le paramètre `random_state=42` permet d'assurer la reproductibilité des résultats, tandis que le paramètre `n_init=10` indique que l'algorithme est lancé plusieurs fois avec des initialisations différentes afin de retenir la meilleure solution.

Chaque segment du corpus reçoit ainsi un numéro de cluster après l'entraînement du modèle. L'ajout de + 1 permet de numérotter les clusters à partir de 1 plutôt qu'à partir de 0, ce qui rend les résultats plus lisibles dans les tableaux et les visualisations. Chaque paquet de phrases est donc associé à un groupe thématique déterminé par sa proximité avec les autres segments du corpus.

Limites de l'approche par K-means

L'utilisation de K-means présente plusieurs limites qu'il faut prendre en compte. Tout d'abord, la méthode impose une appartenance unique de chaque segment à un cluster. Or, dans un texte littéraire, un même passage peut contenir plusieurs thèmes simultanément. Un segment peut par exemple associer la famille, l'argent et la souffrance sociale, mais K-means l'attribue malgré tout à un seul groupe. Cette contrainte rend la méthode moins souple que la NMF pour représenter la complexité thématique des textes.

Ensuite, le choix du nombre de clusters reste en partie subjectif. Le score de silhouette fournit une indication utile, mais il ne suffit pas toujours à identifier une valeur optimale. Dans cette analyse, le choix de 29 clusters repose donc sur un arbitrage méthodologique : il permet de conserver un niveau de détail comparable à celui de la NMF, tout en produisant des catégories suffisamment interprétables. Néanmoins, les deux choix retenant 29 topics et 29 clusters ne sont pas nécessairement les seuls possibles, et d'autres valeurs pourraient également être défendues selon les critères retenus mais il y a quand même une tendance à la convergence des deux méthodes sur ce nombre de regroupements au vu des résultats obtenus.

Une autre limite concerne la sensibilité de K-means à la représentation vectorielle. Les clusters dépendent fortement de la matrice TF-IDF, des choix de lemmatisation, de la liste de mots exclus et des paramètres `min_df` et `max_df`. Une modification de ces choix peut modifier la structure des clusters obtenus, comme cela peut également être le cas avec la NMF. Les résultats doivent donc être compris comme une cartographie exploratoire du corpus, et non comme une classification définitive.

Enfin, comme pour la NMF, la nomination des clusters repose sur une interprétation humaine. Les intitulés attribués aux clusters et aux grandes familles de motifs sont construits à partir des mots les plus représentatifs et de l'observation des segments. Cette étape qualitative est nécessaire pour donner du sens aux résultats, mais elle introduit aussi une part de subjectivité.

Bilan méthodologique

L'ajout d'une classification hiérarchique sur les centres des clusters permet également d'organiser les résultats en grandes familles de motifs. Cette étape rend l'analyse plus lisible, car elle permet de passer de 29 clusters détaillés à cinq ensembles thématiques plus généraux, qui seront interprétés dans la section consacrée aux résultats.

Après la présentation des deux méthodes, la section suivante expose les principaux résultats obtenus, d'abord pour la NMF, puis pour K-means.

1.4 Résultats

1.4.1 Topics obtenus avec le NMF

Identification et interprétation des topics

Une fois le modèle entraîné, les mots les plus importants de chaque topic ont été extraits afin de faciliter leur interprétation. Cette étape est essentielle, car le NMF ne produit pas directement des noms de thèmes : elle produit des groupes de mots. L'attribution d'un nom à chaque topic repose donc sur une analyse qualitative des termes les plus représentatifs.

Le tableau suivant présente les dix mots les plus caractéristiques de chaque topic obtenu avec la NMF. Ces mots servent de base à l'interprétation qualitative des thèmes extraits par le modèle.

TABLE 1.6 – Mots caractéristiques des topics obtenus avec la NMF

Topic	Mots caractéristiques
Topic 1	femme, mari, chose, bon, homme, cher, ménage, histoire, vrai, plaisir
Topic 2	travail, peuple, vie, usine, bonheur, justice, ouvrier, œuvre, humanité, terre
Topic 3	arbre, soleil, herbe, eau, ciel, jardin, ombre, terre, feuille, branche
Topic 4	million, bourse, cours, action, universelle, banque, affaire, agent, hausse, titre
Topic 5	abbé, prêtre, curé, église, jardin, trouche, soutane, sous-préfecture, évêque
Topic 6	table, verre, vin, pain, café, eau, maman, assiette, bon, petit
Topic 7	main, œil, mort, bras, sang, tête, corps, face, voix, lèvre
Topic 8	franc, argent, billet, somme, mois, sou, chiffre, pièce, fortune, poche
Topic 9	monsieur, dame, porte, vou, bon, air, voix, tante, main, mot
Topic 10	rue, maison, quartier, trottoir, boutique, boulevard, ville, place, voiture, chaussée
Topic 11	train, gare, heure, machine, chef, voiture, voie, wagon, express, portière
Topic 12	grotte, saint, sœur, malade, miracle, foule, cierge, foi, prêtre, pèlerin
Topic 13	frère, sœur, modèle, petit, écriture, heure, pauvre, fine, lettre, témoin
Topic 14	cardinal, pape, éminence, livre, palais, église, prêtre, don, prélat, romain
Topic 15	école, instituteur, élève, vérité, église, classe, modèle, primaire, enseignement, juif
Topic 16	père, fils, vieux, famille, fille, ferme, terre, paysan, maison, mort
Topic 17	fosse, mineur, ouvrier, camarade, puits, coron, berline, galerie, porion, grève
Topic 18	prussien, soldat, armée, général, route, cheval, corps, canon, capitaine, homme
Topic 19	jeune, fille, homme, oncle, fine, nièce, garçon, mariage, tante, amant
Topic 20	vendeur, rayon, magasin, comptoir, soie, dame, client, vente, bonheur, confection

Topic	Mots caractéristiques
Topic 21	docteur, médecin, malade, maladie, visite, heure, jour, miracle, cher, jambe
Topic 22	tableau, toile, peintre, peinture, œuvre, atelier, art, artiste, salle, étude
Topic 23	chambre, lit, porte, heure, fenêtre, nuit, escalier, pièce, maison, meuble
Topic 24	enfant, mère, petit, fille, maman, pauvre, nourrice, bon, larme, œil
Topic 25	bel, halle, charcuterie, quenu, boutique, gras, charcutier, marchand, normande, blanc
Topic 26	salon, comte, dame, comtesse, satin, marquis, blanc, rose, femme, petit
Topic 27	empereur, ministre, député, préfet, président, colonel, politique, affaire, lettre, ami
Topic 28	amour, cœur, vie, tendresse, jour, pensée, bonheur, amant, heure, joie
Topic 29	insurgé, barricade, national, ville, fusil, garde, républicain, ouvrier, place, peuple

Chaque topic a ensuite été nommé à partir des mots dominants et de l’observation des segments les plus fortement associés à ce topic. Cette double vérification permet de limiter les erreurs d’interprétation. En effet, certains mots peuvent sembler cohérents isolément, mais prendre un sens différent lorsqu’ils sont replacés dans les extraits du corpus.

Les topics obtenus couvrent plusieurs dimensions importantes de l’œuvre de Zola. Certains renvoient à des espaces sociaux précis, comme le magasin, la mine, la bourse, le quartier ou le monde ferroviaire. D’autres correspondent à des thèmes plus transversaux, comme la famille, le désir, la maladie, la religion, la pauvreté ou la mort. Cette diversité montre que le NMF permet de faire apparaître à la fois des thèmes sociaux, des motifs narratifs et des univers propres à certains romans.

Nommer les topics

Les topics ont ensuite été nommés manuellement à partir des mots les plus représentatifs et des segments les plus fortement associés. Cette étape constitue une part qualitative importante de l’analyse. Elle permet de transformer les résultats numériques du modèle en catégories interprétables.

TABLE 1.7 – Noms attribués aux topics obtenus avec la NMF

Topic	Nom attribué
Topic 1	Les relations conjugales et la vie domestique
Topic 2	Le travail, le peuple et la justice sociale
Topic 3	La nature et le paysage
Topic 4	La bourse, la finance et les affaires
Topic 5	Le clergé et la paroisse
Topic 6	La table et les repas
Topic 7	Le corps, la souffrance et la mort
Topic 8	L'argent et la fortune
Topic 9	Les conversations et les scènes domestiques
Topic 10	Le quartier et la ville
Topic 11	Le monde ferroviaire
Topic 12	Le miracle, le pèlerinage et la religion
Topic 13	Les liens familiaux, l'écriture et les proches
Topic 14	Le pouvoir religieux
Topic 15	L'école et l'instruction
Topic 16	La famille, la terre et le monde paysan
Topic 17	Le monde ouvrier et la mine
Topic 18	La guerre, les soldats et l'armée
Topic 19	Le désir, le mariage et les relations amoureuses
Topic 20	Le magasin, la vente et les clientes
Topic 21	Le monde médical et la santé
Topic 22	Le monde artistique et la peinture
Topic 23	La chambre, le lit et l'espace intime
Topic 24	L'enfance, la maternité et la pauvreté
Topic 25	Le commerce alimentaire et les halles
Topic 26	Le salon, l'aristocratie et les scènes mondaines
Topic 27	Le pouvoir politique et les affaires publiques
Topic 28	L'amour, le bonheur et les sentiments
Topic 29	L'insurrection et la révolution

Cette étape montre que l'analyse ne repose pas uniquement sur une extraction automatique. Le modèle propose des regroupements de mots, mais leur interprétation dépend d'un travail humain. Les noms attribués aux topics doivent donc être compris comme des catégories d'analyse construites à partir des résultats du modèle, et non comme des vérités objectives produites automatiquement par l'algorithme.

1.4.2 Nombre de segments associés à chaque topic dominant

Afin d'analyser la répartition des thèmes dans le corpus, un topic dominant a été attribué à chaque segment. Pour cela, les poids de la matrice W ont d'abord été normalisés afin de rendre les contributions des topics comparables entre les segments. Le topic dominant correspond ensuite au topic dont le poids est le plus élevé pour un segment donné.

La colonne **topic_dominant** indique donc le topic le plus représenté dans chaque paquet de phrases. La colonne **poids_topic** mesure l'intensité de cette association : plus cette valeur est élevée, plus le segment est clairement associé à un topic spécifique. À l'inverse, un poids faible peut signaler un segment plus mixte, contenant plusieurs thèmes ou ne correspondant fortement à aucun topic.

Cette attribution permet de passer d'une simple liste de topics à une analyse plus structurée de leur répartition dans le corpus. Elle rend possible l'étude du nombre de segments associés à chaque topic, du poids moyen des topics dans l'ensemble du corpus et de leur présence selon les romans. Le tableau suivant présente le nombre de segments associés à chaque topic dominant.

TABLE 1.8 – Nombre de segments associés à chaque topic dominant

Topic dominant	Nombre de segments
L'amour, le bonheur et les sentiments	335
La chambre, le lit et l'espace intime	327
Le pouvoir politique et les affaires publiques	266
Le salon, l'aristocratie et les scènes mondaines	266
Le travail, le peuple et la justice sociale	262
La nature et le paysage	229
L'enfance, la maternité et la pauvreté	221
Le corps, la souffrance et la mort	218
La table et les repas	214
Le clergé et la paroisse	210
Le quartier et la ville	205
L'argent et la fortune	187
Le monde ouvrier et la mine	185
La famille, la terre et le monde paysan	180
Le miracle, le pèlerinage et la religion	177
Le désir, le mariage et les relations amoureuses	173
La guerre, les soldats et l'armée	173
L'école et l'instruction	168
Le monde médical et la santé	164

Topic dominant	Nombre de segments
Le commerce alimentaire et les halles	163
Les conversations et les scènes domestiques	162
Le monde artistique et la peinture	141
Le pouvoir religieux	140
Le magasin, la vente et les clientes	136
L'insurrection et la révolution	127
Les liens familiaux, l'écriture et les proches	104
Le monde ferroviaire	94
La bourse, la finance et les affaires	69
Les relations conjugales et la vie domestique	31

La répartition des segments montre que les topics ne sont pas représentés de manière parfaitement équilibrée. Certains thèmes regroupent un nombre important de segments, tandis que d'autres apparaissent de façon plus marginale. Cette variation est attendue dans un corpus littéraire, car tous les motifs thématiques ne sont pas présents avec la même intensité dans l'ensemble des romans.

Les topics les plus représentés correspondent aux thèmes qui structurent fortement le corpus. Les premiers résultats font apparaître des motifs liés aux sentiments, à l'espace intime, aux relations sociales, au pouvoir politique, aux scènes mondaines ou encore au travail. Ces ensembles renvoient à des dimensions récurrentes de l'œuvre de Zola, dans laquelle les expériences individuelles sont souvent articulées à des milieux sociaux, familiaux, économiques ou institutionnels.

À l'inverse, les topics les moins représentés ne doivent pas être considérés comme moins importants sur le plan littéraire. Ils peuvent correspondre à des univers plus localisés, associés à certains romans précis ou à des situations narratives particulières. C'est notamment le cas de thèmes comme la bourse, le monde ferroviaire ou certaines formes de relations domestiques, qui peuvent être fortement présents dans quelques œuvres sans être répartis de manière uniforme dans l'ensemble du corpus.

Cette distribution montre donc que la NMF ne produit pas seulement une liste de thèmes interprétables : elle permet aussi d'évaluer leur poids relatif dans le corpus. Le nombre de segments associés à chaque topic donne une première indication de l'importance quantitative des thèmes extraits. Cette mesure doit toutefois être interprétée avec prudence : un topic fréquent n'est pas nécessairement plus important sur le plan littéraire, mais il est plus présent lexicalement dans les segments analysés.

Enfin, cette attribution des topics dominants peut servir de base à des analyses complémentaires. Elle permet notamment d'étudier la distribution des topics par œuvre, de comparer les romans entre eux, ou encore d'appliquer ultérieurement un détecteur

de motifs aux segments associés à chaque topic afin d'identifier les motifs narratifs les plus caractéristiques de chaque thème.

1.4.3 Clusters obtenus avec K-means

Extraction des mots caractéristiques des clusters

Une fois le modèle entraîné, les centres des clusters ont été analysés afin d'identifier les termes les plus représentatifs de chaque groupe. Dans K-means, chaque cluster est représenté par un centroïde, c'est-à-dire un point moyen dans l'espace vectoriel. Les termes les plus fortement associés à ce centroïde permettent de comprendre le contenu thématique du cluster.

Cette étape est comparable à l'extraction des mots dominants dans la NMF. Elle permet d'associer chaque cluster à un ensemble de termes caractéristiques. Cependant, l'interprétation est légèrement différente : dans la NMF, les mots sont associés à un topic latent ; dans K-means, ils décrivent le centre lexical d'un groupe de segments. Autrement dit, les mots obtenus indiquent ce qui rapproche les segments d'un même cluster.

TABLE 1.9 – Mots caractéristiques des clusters obtenus avec K-means

Cluster	Mots caractéristiques
Cluster 1	verre, petit, table, maman, coup, femme, vin, eau, tête, homme
Cluster 2	instituteur, école, enfant, vérité, élève, petit, église, père, classe, bon
Cluster 3	salon, dame, femme, monsieur, petit, blanc, satin, homme, jeune, rose
Cluster 4	chambre, porte, lit, monsieur, heure, femme, petit, maison, escalier, fenêtre
Cluster 5	enfant, femme, nourrice, petit, usine, constance, fille, mari, monsieur, cher
Cluster 6	mère, fille, petit, enfant, père, femme, fils, bon, jeune, œil
Cluster 7	train, gare, chef, machine, voie, heure, express, mécanicien, tunnel, voyageur
Cluster 8	amour, cœur, vie, jeune, enfant, femme, fille, jour, homme, tendresse
Cluster 9	comte, comtesse, monsieur, scène, loge, femme, prulière, homme, théâtre, dame
Cluster 10	abbé, prêtre, curé, monsieur, église, bon, tête, petit, frère, enfant
Cluster 11	arbre, soleil, herbe, ciel, eau, ombre, jardin, blanc, haut, terre

Cluster	Mots caractéristiques
Cluster 12	grotte, saint, miracle, cierge, prêtre, malade, foule, foi, père, église
Cluster 13	docteur, médecin, monsieur, enfant, mère, petit, malade, heure, œil, lit
Cluster 14	sœur, malade, hyacinthe, wagon, saint, train, petit, compartiment, pèlerin, grotte
Cluster 15	insurgé, ville, national, fusil, barricade, républicain, homme, garde, ouvrier, rue
Cluster 16	rue, boutique, trottoir, petit, quartier, maison, femme, bel, halle, heure
Cluster 17	femme, jeune, amant, chambre, main, pensée, œil, bras, nuit, homme
Cluster 18	empereur, ministre, monsieur, député, colonel, homme, affaire, préfet, gouvernement, ami
Cluster 19	travail, vie, enfant, terre, petit, usine, ouvrier, peuple, œuvre, homme
Cluster 20	bourse, million, franc, action, cours, banque, universelle, monsieur, hausse, argent
Cluster 21	franc, argent, monsieur, femme, homme, jeune, jour, billet, somme, bon
Cluster 22	monsieur, dame, femme, petit, porte, bon, fille, air, homme, chambre
Cluster 23	tableau, peintre, toile, peinture, œuvre, art, atelier, femme, artiste, salon
Cluster 24	fosse, mineur, coron, camarade, berline, homme, ouvrier, puits, grève, porion
Cluster 25	vendeur, rayon, magasin, comptoir, dame, soie, vente, client, bonheur, franc
Cluster 26	prussien, soldat, armée, général, route, homme, cheval, capitaine, corps, canon
Cluster 27	cardinal, pape, palais, éminence, livre, prêtre, monde, église, peuple, prélat
Cluster 28	frère, modèle, petit, père, vérité, président, homme, crime, justice, écriture
Cluster 29	père, terre, vieux, petit, coup, bon, vache, homme, paysan, bête

Cette extraction permet de vérifier la cohérence interne des clusters. Lorsqu'un cluster rassemble des mots appartenant au même champ lexical, il devient plus facilement

interprétable. À l'inverse, un cluster contenant des mots trop dispersés ou peu cohérents peut indiquer un regroupement moins stable ou plus difficile à nommer.

Nomination des clusters

Les clusters ont ensuite été nommés manuellement à partir des mots les plus représentatifs et de l'observation des segments associés. Cette étape est indispensable, car K-means ne produit pas directement des intitulés interprétables. Comme pour la NMF, le passage du résultat numérique à l'interprétation thématique repose donc sur une lecture qualitative et est lié à l'interprétation humaine (chaque noms de clusters peut donc être remis en cause).

TABLE 1.10 – Noms attribués aux clusters obtenus avec K-means

Cluster	Nom attribué
Cluster 1	La table, les repas et les boissons
Cluster 2	L'école, les élèves et l'instruction
Cluster 3	Le salon, l'aristocratie et les apparences
Cluster 4	La chambre, le lit et l'espace domestique
Cluster 5	L'enfance, la maternité et la pauvreté
Cluster 6	La mère, les enfants et la famille
Cluster 7	Le monde ferroviaire
Cluster 8	L'amour, les sentiments et la jeunesse
Cluster 9	Le théâtre, la loge et les scènes mondaines
Cluster 10	Le clergé et la paroisse
Cluster 11	La nature et le paysage
Cluster 12	Le miracle, le pèlerinage et la religion
Cluster 13	Le monde médical et la santé
Cluster 14	Le pèlerinage, la maladie et le voyage
Cluster 15	L'insurrection et la révolution
Cluster 16	Le quartier, la rue et la ville
Cluster 17	Le désir, le corps et les relations amoureuses
Cluster 18	Le pouvoir politique et les affaires publiques
Cluster 19	Le travail, le peuple et le monde ouvrier
Cluster 20	La bourse, la finance et les affaires
Cluster 21	L'argent du quotidien
Cluster 22	Les conversations et les scènes domestiques
Cluster 23	Le monde artistique et la peinture
Cluster 24	La mine, les ouvriers et la grève
Cluster 25	Le magasin, la vente et les clientes

Cluster	Nom attribué
Cluster 26	La guerre, les soldats et l'armée
Cluster 27	Le pouvoir religieux
Cluster 28	Les liens familiaux, l'écriture et la justice
Cluster 29	La terre, les animaux et le monde paysan

Les intitulés obtenus montrent que les clusters couvrent des dimensions proches de celles observées avec la NMF. On retrouve par exemple des ensembles liés au travail, à la mine, à la finance, à la religion, à la famille, au monde domestique, à la guerre ou encore aux espaces urbains.

Cependant, les clusters K-means ne doivent pas être interprétés comme des catégories fixes ou naturelles. Ils résultent d'un regroupement algorithmique fondé sur la proximité lexicale des segments. Leur nomination repose donc sur un choix interprétatif, à partir des mots les plus représentatifs et des extraits textuels associés.

Regroupement hiérarchique des clusters

Afin de compléter l'analyse des clusters obtenus avec K-means, une classification ascendante hiérarchique a été appliquée aux centroïdes des 29 clusters. Cette étape permet d'examiner les proximités entre clusters et de regrouper ceux qui présentent des profils lexicaux similaires. Elle offre ainsi une lecture plus synthétique de la structure thématique du corpus, en passant d'une analyse détaillée cluster par cluster à une organisation en grandes familles de motifs.

La méthode de Ward a été retenue pour construire cette hiérarchie. Elle consiste à fusionner progressivement les clusters en minimisant l'augmentation de la variance interne à chaque regroupement. Le dendrogramme obtenu permet de visualiser les distances entre clusters et d'identifier les principaux rapprochements thématiques¹⁶.

16. Ludovic Lebart et André Salem, *Statistique textuelle*, Paris, Dunod, 1994.




FIGURE 1.4 – Dendrogramme de la classification hiérarchique des clusters K-means

Dans cette analyse, le seuil de distance a été fixé à 0,40 afin de découper l'arbre hiérarchique en grandes familles de motifs. Ce regroupement rend les résultats plus lisibles : les 29 clusters initiaux peuvent être interprétés non seulement individuellement, mais aussi comme des ensembles thématiques plus larges. Cette organisation facilite ensuite la comparaison entre les motifs dominants du corpus et leur répartition dans les romans de Zola.

Création des grandes familles de motifs

À partir du dendrogramme, les clusters ont été regroupés en cinq grandes familles de motifs. Cette opération permet de simplifier l'analyse et de faire apparaître les grandes zones thématiques du corpus.




FIGURE 1.5 – Regroupement des clusters K-means en grandes familles de motifs

Les groupes obtenus ont ensuite été nommés manuellement, en fonction des clusters qu'ils rassemblent. Le tableau suivant présente la composition de chaque grande famille de motifs.

TABLE 1.11 – Composition des grandes familles de motifs issues des clusters K-means

Groupe	Clusters associés
Groupe 1	Cluster 12 : Le miracle, le pèlerinage et la religion ; Cluster 14 : Le pèlerinage, la maladie et le voyage.
Groupe 2	Cluster 2 : L'école, les élèves et l'instruction ; Cluster 10 : Le clergé et la paroisse ; Cluster 27 : Le pouvoir religieux ; Cluster 28 : Les liens familiaux, l'écriture et la justice.
Groupe 3	Cluster 9 : Le théâtre, la loge et les scènes mondaines ; Cluster 18 : Le pouvoir politique et les affaires publiques ; Cluster 20 : La bourse, la finance et les affaires ; Cluster 21 : L'argent du quotidien ; Cluster 22 : Les conversations et les scènes domestiques ; Cluster 25 : Le magasin, la vente et les clientes.
Groupe 4	Cluster 15 : L'insurrection et la révolution ; Cluster 26 : La guerre, les soldats et l'armée.
Groupe 5	Cluster 1 : La table, les repas et les boissons ; Cluster 3 : Le salon, l'aristocratie et les apparences ; Cluster 4 : La chambre, le lit et l'espace domestique ; Cluster 5 : L'enfance, la maternité et la pauvreté ; Cluster 6 : La mère, les enfants et la famille ; Cluster 7 : Le monde ferroviaire ; Cluster 8 : L'amour, les sentiments et la jeunesse ; Cluster 11 : La nature et le paysage ; Cluster 13 : Le monde médical et la santé ; Cluster 16 : Le quartier, la rue et la ville ; Cluster 17 : Le désir, le corps et les relations amoureuses ; Cluster 19 : Le travail, le peuple et le monde ouvrier ; Cluster 23 : Le monde artistique et la peinture ; Cluster 24 : La mine, les ouvriers et la grève ; Cluster 29 : La terre, les animaux et le monde paysan.

Ces grandes familles permettent d'obtenir une lecture plus synthétique des résultats. La première famille regroupe les motifs liés au miracle, au pèlerinage et à la religion. La deuxième rassemble des clusters associés aux formes d'encadrement social, religieux, scolaire et familial. La troisième renvoie davantage aux espaces sociaux, économiques et mondains, en regroupant notamment la finance, le commerce, le théâtre et les conversations domestiques. La quatrième famille réunit les motifs du conflit collectif, de l'insurrection et de la guerre. Enfin, la cinquième regroupe un ensemble plus large de motifs liés à la vie quotidienne, aux espaces sociaux, au travail, à la famille, à la nature et aux expériences individuelles.

Cette structuration est particulièrement utile pour l'analyse littéraire, car elle permet de passer d'une liste de clusters nombreux à une organisation thématique plus lisible.

Elle montre aussi que les motifs extraits par K-means ne sont pas isolés, mais peuvent être regroupés en ensembles plus larges correspondant à des dimensions importantes de l'œuvre de Zola.

Attribution des grandes familles aux segments

Une fois les groupes hiérarchiques définis, chaque segment du corpus a reçu une étiquette correspondant à la grande famille de motifs associée à son cluster¹⁷. Cette opération permet d'analyser non seulement les clusters détaillés, mais aussi les grandes catégories thématiques dans lesquelles ils s'inscrivent.




FIGURE 1.6 – Noms attribués aux grandes familles de motifs

Cette étape permet de relier chaque paquet de phrases à deux niveaux d'analyse. Le premier niveau est le cluster K-means, qui fournit une catégorie thématique fine. Le second niveau est le groupe CAH, qui fournit une catégorie plus générale. Cette double échelle d'interprétation est utile, car elle permet d'adapter le niveau de détail selon les besoins de l'analyse : on peut étudier les motifs précis, ou bien observer les grandes tendances du corpus.

Analyse de la répartition des clusters

Après la nomination des clusters et des grandes familles, plusieurs visualisations ont été produites afin d'étudier leur répartition dans le corpus. La première consiste à compter le nombre de segments associés à chaque grande famille de motifs.

17. Voir code en annexe




FIGURE 1.7 – Distribution des grandes familles de motifs dans le corpus

Cette visualisation permet d’identifier les grandes familles les plus représentées dans l’ensemble du corpus. Elle donne une lecture globale de l’organisation thématique des segments. Une famille très représentée indique qu’un ensemble de motifs revient fréquemment dans les romans, tandis qu’une famille moins présente peut correspondre à un thème plus spécifique, associé à certains romans ou à certaines situations narratives.

Une seconde visualisation a été produite à l’échelle des clusters détaillés.




FIGURE 1.8 – Distribution des clusters K-means dans le corpus

Cette représentation permet de voir quels clusters sont les plus fréquents dans le corpus. Elle est plus précise que l'analyse par grandes familles, car elle distingue les motifs thématiques particuliers. Elle permet par exemple d'observer séparément les clusters associés à la mine, à la finance, à la religion, à la famille ou au monde domestique.

1.5 Comparaison des deux méthodes

Cette section compare les résultats obtenus avec la NMF et avec K-means. Les deux méthodes ont été appliquées au même corpus préparé, mais elles ne produisent pas le même type de sortie : la NMF fait apparaître des topics latents, tandis que K-means regroupe les segments en clusters lexicalement proches. La comparaison permet donc de vérifier si les structures thématiques identifiées par une méthode se retrouvent, au moins en partie, dans l'autre.

1.5.1 Différences entre NMF et K-means

La principale différence entre les deux méthodes tient à la manière dont elles attribuent les thèmes aux segments. La NMF associe chaque segment à plusieurs topics,

avec des poids plus ou moins élevés. Elle autorise donc une lecture graduelle : un même segment peut relever à la fois de plusieurs dimensions thématiques, par exemple la famille, l'argent ou le monde domestique.

K-means fonctionne différemment. Chaque segment est attribué à un seul cluster, c'est-à-dire au groupe dont il est le plus proche dans l'espace vectoriel. Cette méthode produit donc une classification plus nette, mais aussi plus rigide. Elle permet d'identifier des groupes de segments cohérents sur le plan lexical, mais elle rend moins visible la coexistence de plusieurs thèmes dans un même passage.

Ces deux approches ne doivent donc pas être considérées comme concurrentes. La NMF permet d'observer la présence simultanée de plusieurs topics dans les segments, tandis que K-means propose une organisation plus catégorielle du corpus. Leur comparaison est utile précisément parce qu'elles donnent deux lectures différentes d'un même ensemble de textes.

1.5.2 Comparaison lexicale des topics NMF et des clusters K-means

Une première comparaison peut être réalisée à partir des mots les plus caractéristiques des topics NMF et des clusters K-means. Les heatmaps suivantes permettent d'observer la structure lexicale produite par les deux méthodes. Elles montrent quels termes contribuent le plus fortement à chaque regroupement et permettent de repérer les proximités entre les champs lexicaux obtenus.




FIGURE 1.9 – Heatmap des poids des mots dans les topics NMF

La heatmap des topics NMF met en évidence une organisation thématique relative-

ment lisible. Certains topics sont associés à des champs lexicaux spécialisés, comme la mine, la finance, la religion, la guerre, le commerce ou le monde ferroviaire. D'autres renvoient à des motifs plus transversaux, comme la famille, l'espace domestique, les sentiments, la maladie ou les relations sociales. Cette visualisation confirme que la NMF produit des regroupements interprétables à partir des poids des mots dans chaque topic.




FIGURE 1.10 – Heatmap des poids des mots dans les clusters K-means

La heatmap des clusters K-means présente une structure comparable, mais avec une logique plus catégorielle. Les mots caractéristiques sont rattachés à des groupes de segments plutôt qu'à des topics latents. On retrouve néanmoins plusieurs ensembles proches de ceux observés avec la NMF : la mine et le monde ouvrier, la bourse et l'argent, le clergé et la religion, la guerre, la ville, le commerce, l'école ou encore l'espace domestique.

La comparaison des deux heatmaps montre donc une convergence partielle entre les méthodes. Certains champs lexicaux apparaissent de manière stable, indépendamment du modèle utilisé. Cette stabilité renforce leur pertinence pour l'analyse du corpus : lorsqu'un même ensemble lexical apparaît à la fois dans les topics NMF et dans les clusters K-means, il devient plus difficile de l'attribuer à un simple effet du modèle. Il s'agit plutôt d'un motif fortement structurant dans le corpus.

Cependant, les deux heatmaps ne doivent pas être interprétées de la même manière. Dans la NMF, les mots caractérisent des topics qui peuvent contribuer simultanément à plusieurs segments. Dans K-means, les mots décrivent le centre lexical de groupes distincts. La NMF donne donc une lecture plus souple des thèmes, tandis que K-means accentue les séparations entre groupes de segments.




FIGURE 1.11 – Wordcloud des mots caractéristiques des clusters K-means

Le wordcloud des clusters K-means complète cette lecture en donnant une vue plus synthétique des mots les plus représentatifs des regroupements. Il permet d'observer rapidement les champs lexicaux dominants dans les clusters, mais il reste moins précis que les heatmaps, car il ne montre pas la distribution des mots cluster par cluster. Il doit donc être compris comme une visualisation d'appui, et non comme un outil principal d'interprétation.

1.5.3 Convergences thématiques

Les intitulés attribués aux topics et aux clusters confirment les convergences observées dans les heatmaps. On retrouve, dans les deux méthodes, des ensembles liés au travail, à la mine, à la finance, à la religion, à la famille, au monde domestique, à la guerre, au commerce ou encore aux espaces urbains. Ces convergences indiquent que certains thèmes sont suffisamment présents dans le corpus pour émerger malgré des fonctionnements algorithmiques différents.

Cette convergence n'implique pas que les deux méthodes produisent des résultats identiques. Certains topics NMF peuvent regrouper plusieurs dimensions lexicales que

K-means sépare en clusters distincts. Inversement, certains clusters K-means peuvent rassembler des segments proches lexicalement, mais dont l'interprétation thématique reste plus large. La comparaison doit donc porter sur les régularités générales plutôt que sur une correspondance exacte entre chaque topic et chaque cluster.

1.5.4 Distribution des thèmes par œuvre

Afin d'observer la présence des thèmes dans chaque roman, deux visualisations complémentaires ont été produites. La première repose sur les poids moyens normalisés des topics NMF par œuvre. Elle permet d'observer la contribution moyenne de chaque topic dans chaque roman, même lorsque ce topic n'est pas nécessairement dominant dans les segments concernés.

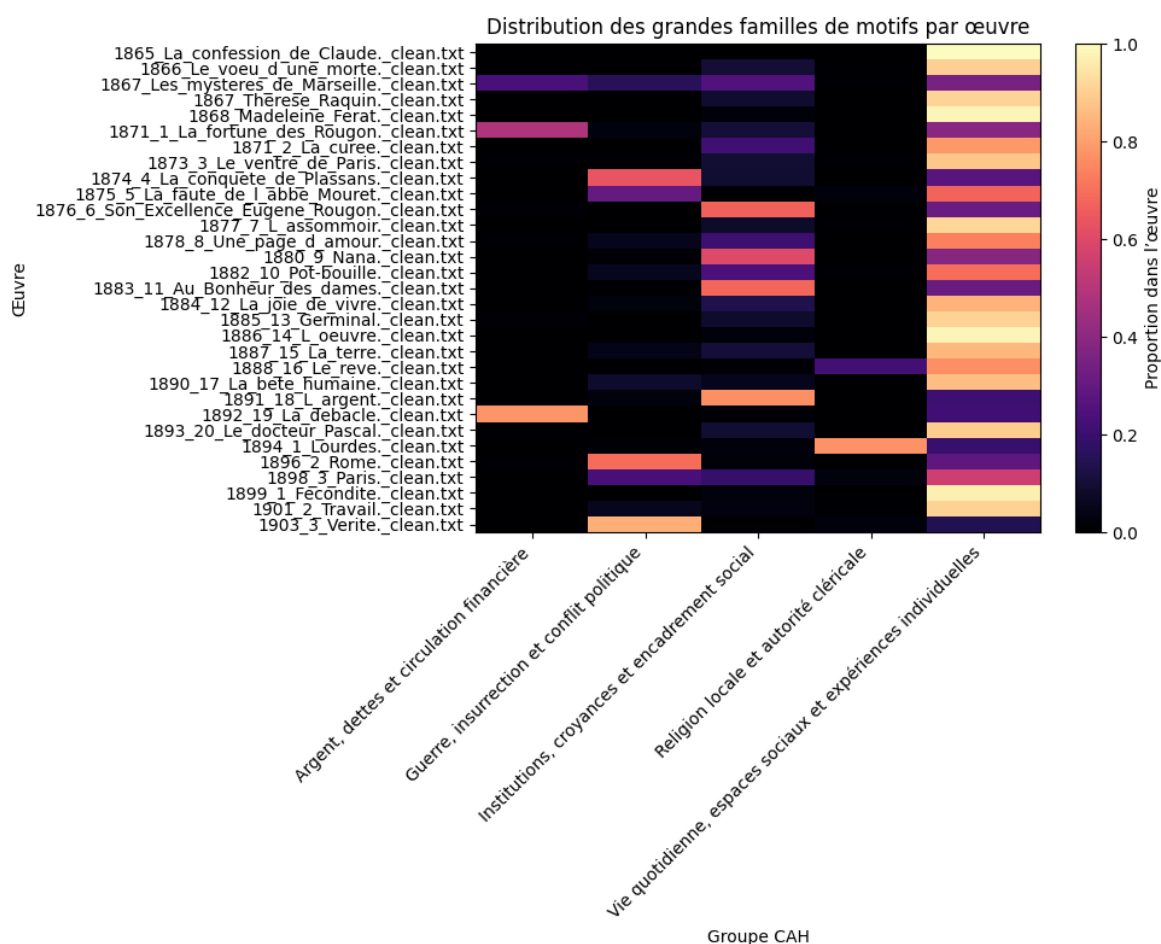


FIGURE 1.12 – Poids moyen normalisé des topics NMF par œuvre

Cette première heatmap propose une lecture graduelle de la présence des topics dans les œuvres. Elle permet de repérer les thèmes qui traversent plusieurs romans, mais aussi ceux qui sont plus fortement associés à certaines œuvres. Par exemple, un topic lié à la mine peut être plus visible dans *Germinal*, tandis qu'un topic lié à la finance peut être plus marqué dans *L'Argent*. Cette visualisation est utile parce qu'elle conserve la

logique propre à la NMF : un topic peut être présent à des degrés variables dans un même roman.

La seconde visualisation repose sur le topic dominant attribué à chaque segment. Une table croisée a été construite entre les œuvres et les topics dominants, puis normalisée par ligne. Cette normalisation permet d'obtenir, pour chaque roman, la proportion de segments associés à chaque topic dominant. Elle est particulièrement utile pour comparer les œuvres entre elles malgré leurs différences de longueur.




FIGURE 1.13 – Proportion des segments par topic dominant et par œuvre

Cette seconde heatmap donne une lecture plus directement interprétable des thèmes dominants par œuvre. Contrairement à un comptage brut, la normalisation par ligne évite que les romans les plus longs soient mécaniquement surreprésentés. Les zones les plus marquées indiquent les topics qui occupent une place importante dans un roman donné. Cette lecture permet de relier plus facilement certains thèmes à des œuvres précises, comme la mine dans *Germinal*, le commerce dans *Au Bonheur des dames*, la finance dans *L'Argent* ou la guerre dans *La Débâcle*.

Les deux heatmaps ne mesurent donc pas exactement la même chose. La première indique la contribution moyenne des topics dans chaque œuvre, tandis que la seconde montre la proportion de segments pour lesquels un topic est dominant. Leur combinaison permet de distinguer les thèmes diffus, présents à faible intensité dans de nombreux segments, des thèmes plus structurants, qui dominent nettement certains passages ou certaines œuvres.

1.5.5 Apport de la double approche

La comparaison entre NMF et K-means montre l'intérêt d'une double approche. La NMF offre une lecture souple et graduelle des thèmes, tandis que K-means propose une classification plus nette des segments. Le croisement des deux méthodes permet donc de mieux distinguer les thèmes stables de ceux qui dépendent davantage du modèle utilisé.

Ainsi, K-means ne remplace pas la NMF, mais il constitue un complément méthodologique utile. Lorsque les deux méthodes font apparaître des champs lexicaux proches, l'interprétation gagne en solidité. Lorsqu'elles divergent, ces écarts invitent au contraire à examiner plus précisément les segments concernés et à nuancer l'interprétation. Cette double lecture permet donc de renforcer l'analyse tout en conservant une part d'interprétation qualitative indispensable dans l'étude d'un corpus littéraire.

1.6 Conclusion sur le Topic Modeling

Cette étude avait pour objectif d'identifier des structures thématiques récurrentes dans l'œuvre romanesque de Zola à partir de méthodes non supervisées. Le corpus a d'abord été nettoyé, segmenté en paquets de phrases, puis lemmatisé afin de produire des unités textuelles comparables et exploitables par les modèles.

L'application de la NMF a permis de faire apparaître des topics interprétables, associés à des dimensions importantes de l'univers de Zola : le travail, la mine, la religion, la famille, l'argent, la guerre, le commerce, la ville ou encore l'espace domestique. Le recours à K-means a ensuite permis de regrouper les segments selon leur proximité lexicale et d'observer des familles de motifs complémentaires et de valider les résultats obtenus avec la méthode du NMF.

La comparaison des deux méthodes montre que certains ensembles thématiques apparaissent de manière stable, malgré des fonctionnements algorithmiques différents. La NMF offre une lecture plus graduelle des thèmes, tandis que K-means produit une classification plus nette des segments. Leur combinaison permet donc de renforcer l'analyse en croisant deux formes de structuration du corpus.

Ces résultats doivent toutefois être interprétés avec prudence. Ils dépendent des choix de nettoyage, de lemmatisation, de segmentation, de vectorisation et du nombre de topics ou de clusters retenus. Je tiens donc à appuyer que ces méthodes reposent donc sur une validation qualitative. L'analyse proposée ne remplace donc pas une lecture littéraire des textes, mais elle fournit un outil exploratoire permettant de repérer des régularités lexicales et thématiques à l'échelle d'un corpus volumineux.

Chapitre 2

Dynamique Topic modeling sur le corpus de d'Émile Zola

2.1 présentation des données

2.1.1 Présentation générale

Ici, je vais présenter une autre façon de faire du topic modeling sur le corpus d'Émile Zola. Cette fois-ci, je vais utiliser une approche de *Dynamic Topic Modeling* (DTM) pour analyser l'évolution des thèmes au fil du temps dans les romans de Zola. L'objectif est de comprendre comment les motifs naturalistes se transforment et circulent à travers son œuvre, du début de sa carrière jusqu'à ses derniers romans.

Le corpus que j'ai utilisé pour faire le DTM est le même¹ que celui utilisé pour le topic modeling classique².

Ici ce qui sera intéressant, c'est de voir comment les topics évoluent au fil du temps, voir quels topics apparaissent, disparaissent, se transforment ou plus intéressent voir quels topic restent constant dans le temps au cours de la carrière de Zola. Voir quels topics restent constant dans le temps permettra de voir si certains thèmes que l'on sait naturalistes sont bien présents dans l'ensemble de son œuvre ou si certains apparaissent seulement à un moment donné de sa carrière.

Pour ce qui est de la méthodologie, j'ai utilisé le même prétraitement que pour le topic modeling classique. J'ai donc tokenisé les textes, supprimé les stop words, et appliqué une lemmatisation pour réduire les mots à leur forme de base.

Les données sont organisées de manière à ce que chaque roman soit associé à une année de publication, ce qui permet de suivre l'évolution des topics au fil du temps.

1. Cf. chapitre 1 dans la sous-partie présentation des données

2. Ici quand je dis *Topic Modeling* classique, c'est du *Topic Modeling* statique ou figé sur l'ensemble global de son œuvre

2.1.2 Statistique exploratoires

Les romans sont segmentés en paquets de 40 phrases, c'est la même segmentation que pour le *Topic Modeling* dans le chapitre 1, cela permet d'avoir une meilleure granularité dans l'analyse des topics.

On se retrouve donc avec un jeu de donnée 5327 documents³.

TABLE 2.1 – Statistiques descriptives de la variable *phrases_paquet*

Métrique	Valeur
count	5327.000
mean	785.298
std	212.129
min	42.000
25%	636.000
50%	753.000
75%	902.500
max	2944.000

En moyenne, un paquet contient environ 785 mots, tandis que la médiane s'élève à 753 mots, ce qui indique que la distribution est légèrement influencée par certains paquets particulièrement longs. La moitié des documents comprend entre 636 et 902,5 mots, ce qui montre que la majorité des paquets possède une taille relativement homogène malgré un écart type de 212 mots. Les valeurs extrêmes, comprises entre 42 et 2,944 mots, révèlent néanmoins une forte variabilité ponctuelle, qui peut s'expliquer par les différences de longueur des phrases entre les romans, mais aussi par la présence éventuelle de paquets incomplets, notamment à la fin de chaque œuvre. Dans l'ensemble, ces résultats confirment que la segmentation en 40 phrases produit des unités textuelles suffisamment riches pour l'analyse thématique, tout en conservant une certaine diversité de longueur.

L'examen des valeurs extrêmes⁴ montre que la forte amplitude observée entre le minimum et le maximum concerne en réalité une très faible proportion du corpus. Parmi les 5,327 paquets, seuls 12 contiennent moins de 300 mots, soit environ 0,23% des documents, tandis que 24 dépassent 1,500 mots, soit environ 0,45%. Parmi ces derniers, un seul paquet contient plus de 2,000 mots, ce qui confirme que la valeur maximale de 2,944 mots constitue un cas particulièrement isolé. Au total, 5,291 paquets, soit environ 99,32% du jeu de données, comportent entre 300 et 1,500 mots. La variabilité mise en évidence par l'écart type est donc principalement liée à quelques observations atypiques et ne remet pas en cause l'homogénéité globale de la segmentation. Les paquets les plus courts peuvent notamment correspondre aux dernières sections des

3. C'est à dire 5327 paquets de phrase

4. Le code est disponible en annexe du document

romans, lorsqu'il reste moins de 40 phrases à regrouper, tandis que les paquets les plus longs peuvent s'expliquer par la présence de phrases particulièrement développées ou par des spécificités de ponctuation et de segmentation propres à certains textes.

2.2 Utilisation de BerTopic

Cette section présente la construction et la sélection du modèle BERTopic utilisé dans la suite de l'étude. Elle s'appuie exclusivement sur le notebook `01_recherche_hyperparametres.ipynb` : il ne s'agit donc pas encore d'interpréter les topics, mais d'explicitier les choix techniques, les critères de comparaison et l'arbitrage qui conduit au modèle final. Les dates de publication et l'ordre des romans n'interviennent pas dans la formation des groupes. La dimension temporelle n'est introduite qu'après cette sélection, afin de ne pas imposer au modèle une évolution chronologique préalable.

2.2.1 Architecture générale et représentation du corpus

BERTopic est une méthode modulaire de modélisation thématique. Elle articule quatre opérations distinctes : la représentation sémantique des documents par des embeddings, la réduction de la dimension de ces vecteurs, leur regroupement par densité et, enfin, la représentation lexicale de chaque groupe par le *class-based TF-IDF*, ou c-TF-IDF⁵. Cette architecture sépare ainsi la proximité sémantique des segments des mots qui rendent les regroupements interprétables.

Le corpus soumis à la recherche comprend 5 327 paquets de phrases non vides. Chacun est encodé avec le modèle francophone `dangvantuan/sentence-camembert-base`⁶, qui produit un vecteur dense de 768 dimensions. L'embedding est calculé sur le texte non lemmatisé, afin de préserver l'information contextuelle utile au modèle neuronal. BERTopic reçoit parallèlement les segments lemmatisés pour construire les représentations lexicales ; ceux-ci servent aussi au calcul de la cohérence. Le protocole distingue donc la représentation sémantique, fondée sur le texte continu, de la caractérisation lexicale, fondée sur un vocabulaire normalisé.

Les embeddings sont calculés une seule fois, enregistrés dans un fichier partagé, puis rechargés lors des recherches ultérieures. Le notebook vérifie que leur nombre correspond au nombre de documents et applique un masque identique aux deux objets lorsqu'un segment lemmatisé vide doit être exclu. Ce contrôle prévient tout décalage entre un texte et son vecteur. Il garantit aussi que les 256 configurations sont comparées à partir d'une représentation sémantique strictement identique.

5. Maarten Grootendorst, « BERTopic : Neural topic modeling with a class-based TF-IDF procedure », 2022, article original ; voir également la documentation de l'architecture BERTopic, consultés le 28 juillet 2026.

6. Fiche du modèle `sentence-camembert-base` sur Hugging Face, consultée le 28 juillet 2026.

2.2.2 Réduction de dimension, clustering et représentation lexicale

Les vecteurs sont d’abord réduits avec UMAP (*Uniform Manifold Approximation and Projection*). L’algorithme cherche à préserver les voisinages des observations dans un espace de dimension plus faible, où les zones denses deviennent plus faciles à identifier⁷. Deux paramètres sont explorés. `n_neighbors` règle l’étendue du voisinage : une valeur faible privilégie les structures locales, tandis qu’une valeur élevée accorde davantage de poids à l’organisation globale. `n_components` fixe la dimension de l’espace transmis au clustering ; il ne s’agit pas ici d’une simple projection graphique en deux dimensions. La métrique cosinus, `min_dist=0.0`, `random_state=42` et `low_memory=True` restent constants. La graine commune rend les configurations comparables et la distance minimale nulle autorise la formation de zones compactes.

HDBSCAN regroupe ensuite les vecteurs réduits. Cette méthode hiérarchique fondée sur la densité n’exige ni un nombre de groupes fixé à l’avance, ni des clusters de forme ou de taille comparables. Les observations qui n’appartiennent pas à une zone suffisamment dense reçoivent l’étiquette `-1` et sont considérées comme du bruit⁸. `min_cluster_size` détermine la taille minimale recherchée pour un cluster ; `min_samples` règle le caractère conservateur de l’assignation et tend, lorsqu’il augmente, à classer davantage de documents comme atypiques. La distance euclidienne et la méthode d’extraction `eom` sont maintenues. Aucun nombre de topics n’est imposé (`nr_topics=None`) : il résulte de l’interaction entre UMAP et HDBSCAN. Les probabilités et les données de prédiction, inutiles pour ce classement, ne sont pas calculées afin de limiter le coût de la grille.

Après le clustering, les documents d’un même topic sont réunis pour produire leur représentation lexicale. Le `CountVectorizer` conserve les unigrammes présents dans au moins deux segments (`min_df=2`) et dans au plus 80 % du corpus (`max_df=0.8`). Le c-TF-IDF pondère alors les termes fréquents dans une classe mais relativement rares dans les autres. Les options `bm25_weighting=True` et `reduce_frequent_words=True` limitent encore le poids des mots très fréquents⁹. Ces réglages modifient la lisibilité des topics, et non l’appartenance des documents aux clusters déjà formés.

7. Leland McInnes, John Healy et James Melville, « UMAP : Uniform Manifold Approximation and Projection for Dimension Reduction », 2018, arXiv:1802.03426 ; voir aussi la documentation des paramètres UMAP, consultés le 28 juillet 2026.

8. Ricardo J. G. B. Campello, Davoud Moulavi et Jörg Sander, « Density-Based Clustering Based on Hierarchical Density Estimates », 2013, DOI de l’article ; documentation de la sélection des paramètres HDBSCAN, consultés le 28 juillet 2026.

9. Documentation officielle de `ClassTfidfTransformer`, consultée le 28 juillet 2026.

2.2.3 Grille de recherche

La grille est le produit cartésien des quatre paramètres variables présentés dans le tableau 2.2, soit $4^4 = 256$ configurations. Elle confronte des voisinages UMAP plus ou moins locaux, plusieurs dimensions réduites et différents degrés d'exigence pour la densité.

TABLE 2.2 – Hyperparamètres inclus dans la grille de recherche BERTopic

Composant	Paramètre	Valeurs testées
UMAP	n_neighbors	10, 25, 50, 60
UMAP	n_components	5, 10, 15, 20
HDBSCAN	min_cluster_size	20, 40, 80, 120
HDBSCAN	min_samples	1, 5, 10, 15

Chaque modèle est entraîné sur les mêmes documents et embeddings. Ses paramètres, ses métriques, son statut et sa durée d'exécution sont enregistrés après chaque essai ; le modèle est ensuite libéré de la mémoire. Les 256 essais se sont achevés sans erreur. Cette sauvegarde incrémentale assure la traçabilité de la recherche et permet de reprendre le traitement sans perdre les configurations déjà calculées.

2.2.4 Critères d'évaluation et classement multicritère

L'évaluation combine des informations sur la partition, sa géométrie et son vocabulaire. Le nombre de topics exclut l'étiquette -1. Le taux d'outliers désigne la proportion de documents qui la reçoivent, tandis que la couverture en est le complément. La taille minimale, médiane et maximale des groupes ainsi que la part du plus grand topic parmi les documents assignés permettent de repérer une solution dominée par un seul cluster.

Le score de silhouette compare la proximité d'une observation avec son propre cluster et avec le cluster voisin le plus proche ; une valeur élevée signale des groupes compacts et séparés¹⁰. Il est calculé avec la distance euclidienne dans l'espace UMAP, sur les seuls documents assignés et, si nécessaire, sur un échantillon reproductible limité à 2 000 observations. Le DBCV (*Density-Based Clustering Validation*) complète cette mesure : conçu pour les partitions fondées sur la densité, il accepte des formes irrégulières et tient ici compte de l'ensemble des observations, bruit compris¹¹.

La cohérence C_v estime la proximité contextuelle des dix principaux mots de chaque topic, après exclusion du groupe -1, à partir du corpus lemmatisé et du dictionnaire

10. Peter J. Rousseeuw, « Silhouettes : A graphical aid to the interpretation and validation of cluster analysis », 1987, DOI de l'article.

11. Davoud Moulavi et al., « Density-Based Clustering Validation », 2014, DOI de l'article.

Gensim¹². La diversité lexicale correspond au rapport entre le nombre de termes distincts et le nombre total de termes dans ces listes. Elle pénalise ainsi les topics dont les mots caractéristiques se répètent, sans constituer à elle seule une preuve de pertinence thématique.

Avant le classement, trois garde-fous éliminent les solutions trop peu informatives : au moins huit topics, au plus 65 % d’outliers et aucun topic représentant plus de 50 % des documents assignés. Parmi les 256 configurations, 92 satisfont ces conditions. Comme les indicateurs utilisent des échelles différentes, ils sont convertis en rangs percentiles. Le score global est ensuite calculé ainsi :

$$S_{\text{global}} = 0,30R_{C_v} + 0,20R_{\text{sil}} + 0,15R_{\text{DBCV}} + 0,15R_{\text{div}} + 0,10R_{\text{couv}} + 0,10R_{\text{eq}}.$$

La cohérence reçoit le poids le plus important, car la lisibilité lexicale est centrale pour l’analyse littéraire. La silhouette mesure la séparation, le DBCV la validité de la structure de densité et la diversité limite la redondance. La couverture et l’équilibre complètent le compromis ; pour ce dernier, le rang porte sur 1 moins la part du plus grand topic. Ces pondérations ne définissent pas un optimum universel : elles rendent explicites les priorités retenues et réduisent le nombre de modèles à examiner.

2.2.5 Contrôle de la stabilité

Les dix premières configurations selon le score global sont réentraînées avec six graines aléatoires : 1, 11, 35, 42, 73 et 89. Les 60 entraînements obtenus donnent, pour chaque configuration, quinze comparaisons par paires. La proximité des partitions est mesurée avec l’indice de Rand ajusté (ARI), qui corrige l’accord attendu par hasard et vaut 1 lorsque deux partitions coïncident, indépendamment de la numérotation des groupes¹³.

Deux ARI sont calculés. Le premier porte sur tous les documents et considère -1 comme une catégorie ; le second ne conserve que les documents assignés à un topic dans les deux exécutions comparées. Cette distinction isole la stabilité du noyau des clusters de la variabilité de leur frontière avec le bruit. Le notebook conserve aussi la part de documents assignés en commun, ainsi que la moyenne et l’écart-type du nombre de topics et du taux d’outliers.

Le rang percentile de l’ARI moyen sur les documents assignés fournit le terme de stabilité du classement final :

$$S_{\text{final}} = 0,80S_{\text{global}} + 0,20R_{\text{stab}}.$$

12. Michael Röder, Andreas Both et Alexander Hinneburg, « Exploring the Space of Topic Coherence Measures », 2015, DOI de l’article.

13. Lawrence Hubert et Phipps Arabie, « Comparing Partitions », 1985, DOI de l’article ; voir aussi la documentation de `scikit-learn`, consultée le 28 juillet 2026.

La stabilité intervient donc comme un contrôle sans effacer les critères initiaux. Les écarts-types restent descriptifs et les filtres appliqués à la grille ne sont pas réappliqués aux moyennes des six graines.

2.2.6 Justification du choix final à 33 topics

La première configuration du classement final produit huit topics avec la graine principale. Le modèle retenu est volontairement la deuxième configuration, qui en produit 33. Le tableau 2.3 résume cet arbitrage.

TABLE 2.3 – Comparaison entre le premier rang automatique et le modèle retenu

Indicateur	Premier rang	Modèle retenu
n_neighbors	50	10
n_components	15	20
min_cluster_size	20	20
min_samples	15	5
Topics avec la graine principale	8	33
Taux brut d'outliers	62,5 %	55,6 %
Cohérence C_v	0,494	0,452
DBCV	0,039	0,107
ARI moyen sur les documents assignés	0,937	0,839
Score final	0,761	0,743

La solution à huit topics est plus stable et légèrement plus cohérente, mais elle rassemble le corpus dans des catégories très générales. Une telle granularité est peu adaptée à l'objectif de distinguer des motifs littéraires susceptibles d'évoluer au cours de la carrière de Zola. Le modèle à 33 topics offre un découpage plus fin, un taux d'outliers inférieur, un meilleur DBCV et une diversité lexicale élevée (0,958), tout en conservant un ARI de 0,839 sur les documents assignés dans les deux exécutions.

Ce résultat doit néanmoins être nuancé : les documents assignés en commun représentent en moyenne 33,6 % du corpus et l'ARI incluant le bruit atteint 0,431. Sur les six graines, la configuration retenue produit en moyenne 38,3 topics (écart-type : 3,82) et 54,3 % d'outliers (écart-type : 2,72 points). Elle présente donc un noyau de clusters relativement stable, mais une variabilité réelle aux frontières avec le bruit. Le choix de la deuxième ligne n'affirme pas sa supériorité sur tous les critères : il assume un compromis entre robustesse quantitative et niveau de détail pertinent pour la question de recherche. Le score ordonne les possibilités sans se substituer à cet arbitrage scientifique.

2.2.7 Portée et limites du protocole

La combinaison de plusieurs métriques évite de faire reposer la sélection sur un indicateur unique, et la répétition sur plusieurs graines rend visible la sensibilité à l’initialisation. Le protocole demeure toutefois exploratoire : il n’existe pas de vérité de référence pour le « bon » nombre de topics, tandis que les seuils et pondérations traduisent des priorités de recherche. De plus, UMAP influence à la fois le clustering et deux indices de validation ; une cohérence lexicale élevée ne garantit pas, à elle seule, la pertinence littéraire d’un topic.

Une limite supplémentaire concerne la longueur des unités textuelles. La configuration publiée de `sentence-camembert-base` fixe une longueur maximale de 128 tokens¹⁴. Or les paquets du corpus contiennent en moyenne 785 mots et le notebook ne les redécoupe pas avant l’encodage. Les embeddings représentent donc principalement leur début. Cette troncature devra être gardée à l’esprit lors de l’interprétation ; une amélioration ultérieure consisterait à encoder plusieurs sous-segments puis à agréger leurs vecteurs.

Enfin, les taux d’outliers mentionnés ici sont les taux bruts produits par HDBSCAN avant toute réaffectation. Ils permettent de comparer les configurations dans des conditions identiques. Leur éventuel traitement appartient à l’entraînement du modèle final et ne doit pas être confondu avec la recherche d’hyperparamètres. La section suivante peut dès lors aborder les résultats à partir d’un modèle dont la procédure de sélection, le compromis et les limites ont été explicités.

2.3 Validation mathématique

Avant d’interpréter les topics et leur évolution dans le corpus, il convient d’évaluer la qualité de la partition sur laquelle repose l’analyse. Cette validation n’a pas pour objet de démontrer qu’il existerait une unique décomposition thématique correcte des romans de Zola. En l’absence de catégories de référence, elle relève d’une validation interne : plusieurs indicateurs vérifient la séparation géométrique des groupes, leur stabilité lorsque l’initialisation varie et la qualité de leur représentation lexicale.

Deux états du modèle doivent être distingués. Le premier correspond à la partition brute produite par UMAP et HDBSCAN avec les paramètres sélectionnés dans le notebook `01_recherche_hyperparametres.ipynb`. Le second correspond au modèle effectivement utilisé pour les analyses, après réaffectation des documents initialement considérés comme atypiques et mise à jour de la représentation c-TF-IDF dans le notebook `02_exploration_modele.ipynb`. Les indicateurs ne sont pas tous recalculés à cette seconde étape ; les valeurs doivent donc être interprétées dans le périmètre exact où elles ont été obtenues.

14. Configuration Sentence-Transformers de `sentence-camembert-base`, consultée le 28 juillet 2026.

2.3.1 Validation de la partition brute

Avec la graine principale fixée à 42, la configuration retenue produit naturellement 33 topics. Sur les 5 327 segments du corpus, 2 366 sont directement rattachés à l'un de ces groupes et 2 961 reçoivent l'étiquette -1, soit un taux brut d'outliers de 55,6 %. Parmi les documents assignés, les topics contiennent entre 22 et 268 segments, avec une médiane de 53 ; le groupe le plus important représente 11,3 % des documents assignés. La partition n'est donc pas dominée par un topic unique, mais son taux d'observations atypiques montre que HDBSCAN adopte une définition exigeante des noyaux de densité.

La séparation géométrique est d'abord mesurée par le coefficient de silhouette. Pour un document i , si $a(i)$ désigne sa distance moyenne aux autres documents de son topic et $b(i)$ la plus faible distance moyenne qui le sépare d'un autre topic, sa silhouette est définie par :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}.$$

Le score global est la moyenne des $s(i)$. Il est compris entre -1 et 1 : une valeur positive signifie que les documents sont, en moyenne, plus proches de leur propre groupe que du groupe concurrent le plus proche. Dans le notebook d'optimisation, ce calcul est effectué avec la distance euclidienne dans l'espace UMAP, sur les documents assignés seulement et sur un échantillon reproductible d'au plus 2 000 observations. La configuration retenue obtient un score de 0,380. Cette valeur positive atteste une structure identifiable, mais elle demeure intermédiaire : les topics sont séparés sans former des ensembles parfaitement isolés, ce qui est cohérent avec la continuité lexicale et narrative du corpus.

La silhouette est complétée par le DBCV, mieux adapté aux clusters définis par la densité. Contrairement à la silhouette calculée ici, cet indice prend en compte l'ensemble de la projection UMAP, y compris les observations étiquetées -1. Sa valeur atteint 0,107. Un DBCV positif indique que, dans l'ensemble, la séparation entre les régions denses l'emporte sur leur dispersion interne. La valeur reste néanmoins modeste et ne saurait, prise isolément, suffire à valider la partition. L'intérêt du résultat réside dans la convergence de deux indicateurs construits selon des principes différents : tous deux sont positifs, même si aucun ne décrit une séparation parfaite.

La robustesse à l'initialisation apporte un troisième contrôle. La configuration est réentraînée avec les six graines 1, 11, 35, 42, 73 et 89. Les partitions sont comparées par l'indice de Rand ajusté :

$$\text{ARI} = \frac{\text{RI} - E[\text{RI}]}{1 - E[\text{RI}]},$$

où RI représente l'accord observé entre deux partitions et $E[RI]$ l'accord attendu par hasard. Sur les documents assignés dans les deux exécutions comparées, l'ARI moyen vaut 0,839, avec un écart-type de 0,054. Ce niveau traduit une forte stabilité du noyau des clusters. Lorsque tous les documents sont inclus et que l'étiquette -1 est traitée comme une catégorie, l'ARI moyen tombe toutefois à 0,431, avec un écart-type de 0,034. En outre, les documents assignés en commun ne représentent en moyenne que 33,6 % du corpus. Le modèle possède donc une structure centrale assez stable, tandis que la frontière entre les topics et le bruit reste plus sensible à la projection UMAP.

2.3.2 Réaffectation des documents atypiques

Pour que l'analyse temporelle porte sur l'ensemble du corpus, le second notebook réaffecte les 2 961 documents initialement classés comme bruit. La stratégie **embeddings** de BERTopic compare leur représentation sémantique aux représentations des topics et les rattache au groupe le plus proche lorsque la similarité satisfait le seuil fixé. Six seuils, compris entre 0 et 0,50, sont comparés.

Dans l'exécution enregistrée, les seuils de 0 à 0,40 produisent exactement le même résultat : les 2 961 outliers sont réaffectés, les 33 topics sont conservés, le plus petit groupe comprend 38 documents et le plus grand 422, soit 7,9 % du corpus. Au seuil de 0,50, un seul document demeure atypique. Le seuil de 0,30 retenu conduit donc à une couverture de 100 % sans modifier le nombre de topics.

Cette comparaison appelle une précaution méthodologique. Les résultats ne permettent pas d'identifier 0,30 comme un optimum numérique nettement supérieur aux autres seuils, puisque presque toute la plage testée conduit à la même partition. Il s'agit d'un choix opérationnel situé au milieu de la grille. La réaffectation rend possible une analyse exhaustive des romans et aboutit à une distribution moins dominée par le plus grand groupe ; elle ne constitue cependant pas, à elle seule, une nouvelle preuve de séparation géométrique. Le score de silhouette et le DBCV ne sont pas recalculés après cette opération. Les valeurs de 0,380 et 0,107 décrivent donc la partition brute de HDBSCAN, et non les assignations finales des 5 327 documents.

2.3.3 Cohérence et diversité du modèle final

Après la réaffectation, la représentation lexicale des topics est reconstruite. Une courte liste de formes résiduelles propres au corpus est ajoutée aux mots exclus, puis les dix termes les mieux pondérés par le c-TF-IDF sont réestimés. Deux indicateurs évaluent cette représentation finale.

La cohérence C_v mesure dans quelle mesure les principaux mots d'un même topic apparaissent dans des contextes compatibles. Elle est calculée à partir des documents lemmatisés, du dictionnaire Gensim et des dix premiers mots de chacun des 33 topics.

Elle passe de 0,452 pour le modèle brut à 0,471 après réaffectation et raffinement lexical, soit une progression de 0,019. Cette augmentation modérée indique que l'intégration des documents auparavant atypiques ne dégrade pas la cohérence des listes de mots et améliore légèrement leur proximité contextuelle.

La diversité lexicale est définie par :

$$D = \frac{|\bigcup_{k=1}^K W_k|}{\sum_{k=1}^K |W_k|},$$

où W_k désigne l'ensemble des dix mots représentatifs du topic k . Une valeur proche de 1 indique que les topics partagent peu de termes parmi leurs représentations principales. La diversité passe de 0,958 à 0,915. Cette diminution signifie que le raffinement final introduit davantage de vocabulaire commun entre les topics, mais plus de neuf positions lexicales sur dix restent associées à des termes distincts. Le modèle conserve ainsi une forte non-redondance tout en obtenant une cohérence légèrement meilleure.

Le tableau 2.4 récapitule les deux étapes de l'évaluation. Le tiret signale qu'un indicateur géométrique n'a pas été recalculé après la réaffectation.

TABLE 2.4 – Indicateurs de validation avant et après la réaffectation des outliers

Indicateur	Partition brute	Modèle final
Nombre de topics	33	33
Documents assignés	2 366 (44,4 %)	5 327 (100 %)
Taille du plus petit topic	22	38
Taille du plus grand topic	268 (11,3 %)	422 (7,9 %)
Silhouette dans l'espace UMAP	0,380	Non recalculée
DBCV dans l'espace UMAP	0,107	Non recalculé
Cohérence C_v	0,452	0,471
Diversité lexicale	0,958	0,915

Au total, la validation met en évidence un compromis plutôt qu'une supériorité absolue. La partition brute présente une séparation positive mais modérée, ainsi qu'un noyau thématique stable entre plusieurs initialisations. La réaffectation assure ensuite une couverture complète du corpus et conserve des groupes de taille raisonnablement équilibrée. Enfin, le modèle final améliore légèrement la cohérence contextuelle tout en maintenant une diversité lexicale élevée. Ces résultats autorisent l'emploi des 33 topics comme instruments d'exploration du corpus, à condition de garder à l'esprit la variabilité des documents situés aux frontières des clusters et le caractère interne, non

inférentiel, de cette validation.

2.4 Analyse des resulats de BerTopic

Après avoir validé le modèle, il est possible d'examiner les topics et de les interpréter. Cette section présente une analyse qualitative des résultats obtenus par BerTopic sur le corpus de Zola, en mettant l'accent sur la signification des topics, leur évolution dans le temps et leur pertinence par rapport aux thèmes récurrents dans les oeuvres des auteurs naturalistes.

Je tiens à préciser que l'analyse des topics est une étape subjective et interprétative, qui nécessite une connaissance approfondie du corpus et de son contexte historique et littéraire. Les topics identifiés par BerTopic sont des regroupements de mots et de documents qui partagent des caractéristiques lexicales similaires, mais leur signification peut varier en fonction de l'interprétation humaine.

Je mets ici l'accent sur la mentions de "regroupement de mots significatifs", nous ne sommes donc pas en présence de topics "thématiques" au sens strict, mais de regroupements de mots qui peuvent être interprétés comme des thèmes ou des concepts récurrents dans les oeuvres de Zola. L'analyse qualitative des topics permet donc d'identifier les thèmes principaux abordés par l'auteur, ainsi que les relations entre ces thèmes et leur évolution dans le temps.

2.4.1 Les topics proches de la mouvence naturaliste

Chapitre 3

Nettoyage des romans et insertion de ces derniers dans la basse de données

3.1 Reflexion sur le stockage des données

Après avoir récupéré un nombre conséquent de romans naturalistes et non naturaliste, il a fallu réfléchir à un moyen de les stocker quelque part. Pour cela, j'ai réfléchi à plusieurs idées pour procéder. Le choix c'est porté sur une base de données SQL avec comme interface PHP admin. Cette base de données à d'abord été remplie en local pour effectuer des tests et ensuite, une fois que tout fonctionnait correctement, j'ai pu extraire un fichier *Dumps* et l'importer dans PHP Admin.

3.2 Nettoyage des textes

Après avoir réfléchi à la manière de stocker les romans, il a fallu réfléchir à un moyen de les nettoyer. En effet, les romans contiennent beaucoup de caractères spéciaux qui ne sont pas utiles pour l'analyse, notamment les caractères de mise en forme, la pagination, les notes de bas de page, les chapitres ainsi que les prologues. En effet, les prologues sont souvent des textes qui ne sont pas écrits par l'auteur du roman et qui ne sont donc pas représentatifs de son style d'écriture.

Les romans naturalistes et non naturalistes sont issus de types de données différents. Il y a trois groupes de formats de données : les romans au format *.epub*, les romans au format *.pdf* et les romans au format *.txt*¹.

Pour ce qui est des textes au format *.epub*, j'ai utilisé le logiciel *Calibre*² pour les

1. Ici, les textes au format *.txt* sont organisés en dossiers, c'est-à-dire qu'un fichier *.txt* correspond à une page du roman. Il a donc fallu les regrouper pour obtenir un seul fichier *.txt* par roman.

2. Lien du logiciel : <https://calibre-ebook.com/fr/about>, site consulté le 18 juin 2026.

convertir au format *.txt*. Pour les textes au format *.pdf*, j'ai utilisé le logiciel *Adobe Acrobat Pro* afin de les convertir au format *.txt*. Pour les textes au format *.txt*, j'ai utilisé un script Python³ pour regrouper les fichiers en un seul fichier par roman.

La grande majorité de mes romans étaient au format *.epub*. Après leur conversion au format *.txt*, j'ai donc utilisé un script Python⁴ pour nettoyer les textes. Ce script supprime les caractères spéciaux, les notes de bas de page, les chapitres et les prologues. Il supprime également les lignes vides et les espaces en trop. Le script est basé sur des expressions régulières pour identifier les éléments à supprimer.

Pour ce qui est du choix des éléments à supprimer, j'ai fait le choix de supprimer les chapitres, car ils ne sont pas représentatifs du style d'écriture de l'auteur. De plus, comme nous l'avons vu dans le chapitre 2, j'ai passé un détecteur de motifs sur les textes afin d'identifier les motifs récurrents. J'ai donc gardé uniquement le corps du texte pour l'analyse. Ce choix se justifie également par la volonté d'obtenir une normalisation entre les textes⁵ (une ligne est égal à une phrase), ce choix peut être mis en opposition avec le choix de garder la distinction entre les différents chapitres du roman mais je me défend en prenant en compte que certains romans ne sont pas découpés en chapitres. Les différents romans sont soit découpés en partie (exemple : Partie I, Partie II, etc.), soit en chapitres (exemple : Chapitre I, Chapitre II, etc.), soit avec une combinaison des deux (exemple : Partie I, Chapitre I, Chapitre II, Partie II, Chapitre III, etc.). Ou pour finir, le titre du chapitre est écrit en majuscules, avec des chiffres romains, ou sans chiffres romains. Il aurait donc fallu faire des ajustements à chaque fois pour identifier les chapitres. De plus, certains romans résultaient de l'assemblage de plusieurs fichiers *.txt*. Dans ces cas, la séparation entre les chapitres, initialement présente dans la structure HTML du roman, n'était plus conservée.

3.3 Création de la base de données

Après avoir nettoyé les textes, il a fallu créer une base de données pour stocker les informations relatives aux romans. J'ai choisi d'utiliser le système de gestion de base de données relationnelle *MySQL*, car il permet d'organiser les données sous forme de tables et de conserver des relations claires entre les auteurs, les romans et les unités textuelles extraites.

Je vais donc présenter la structure de cette base de données ainsi que les différentes tables qui la composent. Chaque table a un rôle précis : certaines servent à stocker les

3. Le script est disponible en annexe.

4. Le script est disponible en annexe. Il faut préciser que je n'ai pas utilisé un seul script, mais plusieurs. Il s'agit donc d'un script général. Il y a eu énormément de modifications internes, notamment pour les chapitres qui sont soit en majuscules, avec chiffres romains, ou sans chiffres romains. Il a donc fallu faire des ajustements à chaque fois.

5. certains textes ne disposant pas de

informations bibliographiques, tandis que d'autres permettent de conserver les textes, les segments ou encore les phrases extraites pour l'analyse.

J'ai choisi de présenter ce code directement dans le corps du mémoire⁶ et non uniquement en annexe, afin de rendre plus claire la manière dont les données ont été organisées avant l'analyse.

Ce code permet de créer la base de données utilisée pour stocker les romans du corpus ainsi que les informations nécessaires à leur analyse. La base, nommée **romans_nlp**, est d'abord créée puis sélectionnée afin que toutes les tables suivantes y soient enregistrées.

La première table, **auteurs**, sert à stocker les informations relatives aux auteurs. Chaque auteur reçoit un identifiant unique, auquel sont associés son nom et, lorsque l'information est disponible, son prénom. Cette table est ensuite complétée par deux colonnes supplémentaires, **date_naissance** et **date_mort**, afin d'enrichir la description des auteurs et de permettre d'éventuelles analyses chronologiques.

La table **romans** contient les informations principales sur les œuvres du corpus. Elle associe à chaque roman un identifiant unique, un titre, une année de publication ainsi que le texte brut du roman. Le choix du type **LONGTEXT** pour le champ **texte_brut** permet de stocker des textes longs, ce qui est nécessaire dans le cas de romans complets.

La table **auteurs_romans** permet de faire le lien entre les auteurs et les romans. Elle sert à gérer une relation de type plusieurs-à-plusieurs : un auteur peut être associé à plusieurs romans, et un roman peut éventuellement être associé à plusieurs auteurs. Les clés étrangères **id_auteur** et **id_roman** permettent de relier cette table aux tables **auteurs** et **romans**.

La table **segments** sert à stocker les segments extraits des romans. Chaque segment est rattaché à un roman grâce à la clé étrangère **id_roman**. Le champ **ordre_segment** permet de conserver l'ordre d'apparition des segments dans le texte d'origine. Cela est important, car même si le texte est découpé pour les traitements, il reste possible de retrouver sa progression initiale.

Enfin, la table **phrase_roman** permet de stocker les phrases extraites des romans. Chaque phrase est associée au roman dont elle provient, à son ordre d'apparition, à son contenu textuel et au motif qui a permis son extraction. Ce dernier champ est important, car il permet de garder une trace de la méthode utilisée pour sélectionner les phrases et de relier chaque extraction à un critère précis.

L'ensemble de cette structure permet donc de conserver à la fois les textes complets, leurs découpages en segments, les phrases extraites et les informations bibliographiques liées aux auteurs et aux œuvres. Elle constitue ainsi une base organisée pour les traitements de fouille de texte et d'analyse automatique du corpus.

6. Je précise également que tous les codes utilisés pour la réalisation de ce mémoire sont disponibles sur mon GitHub.

```

1 CREATE DATABASE romans_nlp;
2 USE romans_nlp;
3
4 -- Creation des tables pour la base de donnees des romans et des auteurs
5 CREATE TABLE auteurs (
6     id_auteur INT PRIMARY KEY AUTO_INCREMENT,
7     nom VARCHAR(100) NOT NULL,
8     prenom VARCHAR(100)
9 );
10
11 -- Table pour stocker les romans, avec leur titre et leur annee de publication
12 CREATE TABLE romans (
13     id_roman INT PRIMARY KEY AUTO_INCREMENT,
14     titre VARCHAR(255) NOT NULL,
15     annee_publication INT,
16     texte_brut LONGTEXT
17 );
18
19 -- Table d'association pour gerer la relation plusieurs-a-plusieurs entre auteurs et romans
20 CREATE TABLE auteurs_romans (
21     id_auteur INT NOT NULL,
22     id_roman INT NOT NULL,
23     PRIMARY KEY (id_auteur, id_roman),
24     FOREIGN KEY (id_auteur) REFERENCES auteurs(id_auteur),
25     FOREIGN KEY (id_roman) REFERENCES romans(id_roman)
26 );
27
28 -- Table pour stocker les segments extraits des romans, avec leur ordre de segmentation
29 CREATE TABLE segments (
30     id_segment INT PRIMARY KEY AUTO_INCREMENT,
31     id_roman INT NOT NULL,
32     ordre_segment INT NOT NULL,
33     texte_segment LONGTEXT NOT NULL,
34     FOREIGN KEY (id_roman) REFERENCES romans(id_roman)
35 );
36
37 /*
38  Apres reflexion, il est egalement possible d'ajouter les dates
39  de naissance et de mort des auteurs afin d'enrichir la base de donnees.
40  */
41 ALTER TABLE auteurs
42 ADD date_naissance INT;
43
44 ALTER TABLE auteurs
45 ADD date_mort INT;
46
47 -- Table pour stocker les phrases extraites des romans, avec leur motif d'extraction
48 CREATE TABLE phrase_roman (
49     id_phrase INT PRIMARY KEY AUTO_INCREMENT,
50     id_roman INT NOT NULL,
51     ordre_phrase INT NOT NULL,
52     texte_phrase TEXT NOT NULL,
53     motif_phrase TEXT NOT NULL,
54     FOREIGN KEY (id_roman) REFERENCES romans(id_roman)
55 );

```

Listing 1 – Création de la base de données romans_nlp

3.4 Création des informations pour la base de données

Après avoir créé les tables nécessaires pour stocker les informations sur les auteurs, les romans et les relations entre eux, il est temps d'insérer les données relatives aux frères Goncourt et à leurs œuvres. Le code suivant présente donc l'insertion des auteurs, des romans et des relations entre ces deux tables.

```
1  /*
2  Insertion des freres Goncourt.
3  */
4  INSERT INTO auteurs (nom, prenom)
5  VALUES
6      ('de Goncourt', 'Edmond'),
7      ('de Goncourt', 'Jules');
8  /*
9  Insertion des romans des freres Goncourt
10 */
11 INSERT INTO romans (titre, annee_publication)
12 VALUES
13     ('Charles Demailly', 1860),
14     ('Soeur Philomene', 1861),
15     ('Renee Mauperin', 1864),
16     ('Germinie Lacerteux', 1865),
17     ('Manette Salomon', 1867),
18     ('Madame Gervaisais', 1869),
19     ('La Fille Elisa', 1877),
20     ('Freres Zemganno', 1879),
21     ('La Faustin', 1882),
22     ('Cherie', 1884);
23 /*
24 Insertion des relations entre les auteurs et les romans.
25 Les six premiers romans sont associes aux deux freres Goncourt.
26 Les romans suivants sont associes uniquement a Edmond de Goncourt.
27 */
28 INSERT INTO auteurs_romans (id_auteur, id_roman)
29 VALUES
30     (1,1), (2,1),
31     (1,2), (2,2),
32     (1,3), (2,3),
33     (1,4), (2,4),
34     (1,5), (2,5),
35     (1,6), (2,6),
36     (1,7),
37     (1,8),
38     (1,9),
39     (1,10);
40 -- Mise a jour des dates de naissance et de mort de Jules de Goncourt.
41 UPDATE auteurs
42 SET date_naissance = 1830,
43     date_mort = 1870
44 WHERE id_auteur = 2;
45
46 -- Mise a jour des dates de naissance et de mort d'Edmond de Goncourt.
47 UPDATE auteurs
48 SET date_naissance = 1822,
```

```
49     date_mort = 1896
50 WHERE id_auteur = 1;
51
```

Ce code permet d'insérer dans la base de données les informations relatives aux frères Goncourt et à leurs romans. Dans un premier temps, les deux auteurs sont ajoutés dans la table **auteurs**. Ils reçoivent chacun un identifiant, qui permettra ensuite de les relier aux œuvres présentes dans la base.

La deuxième partie du code insère les romans des frères Goncourt dans la table **romans**. Chaque œuvre est associée à son titre et à son année de publication. Cette étape permet donc de constituer une partie du corpus à partir des romans retenus pour l'analyse.

Ensuite, la table **auteurs_romans** est utilisée pour associer les auteurs aux romans. Cette table est importante, car elle permet de gérer le cas particulier des œuvres écrites à deux mains. Les six premiers romans sont associés à Edmond et Jules de Goncourt, tandis que les romans publiés après la mort de Jules sont associés uniquement à Edmond. Cela permet de conserver une information plus précise sur l'attribution des œuvres.

Enfin, les deux dernières requêtes mettent à jour les dates de naissance et de mort des auteurs. Ces informations biographiques ne sont pas directement nécessaires pour stocker les textes, mais elles permettent d'enrichir la base de données. Elles peuvent aussi être utiles par la suite si l'on souhaite croiser les résultats de l'analyse avec des éléments chronologiques ou biographiques.

Ce passage sert donc à remplir une première partie de la base de données avec les auteurs, les romans et les relations entre eux. Il montre aussi l'intérêt de séparer les informations dans plusieurs tables : les auteurs sont stockés d'un côté, les romans de l'autre, et la relation entre les deux est conservée dans une table spécifique.

Il faut maintenant ajouter les romans dans la base de données, il peut y avoir plusieurs façons de le faire,

Bibliographie

- DUDA, Richard O., Peter E. HART et David G. STORK (2001). *Pattern Classification*. 2^e éd. Wiley-Interscience.
- HAMON, Philippe (1983). *Le Personnel du roman : Le système des personnages dans les Rougon-Macquart d'Émile Zola*. Histoire des idées et critique littéraire 211. Genève : Librairie Droz.
- LEBART, Ludovic et André SALEM (1994). *Statistique textuelle*. Paris : Dunod.
- MITTERAND, Henri (1986). *Zola et le naturalisme*. Que sais-je ? 2314. Paris : Presses Universitaires de France.
- (1994). *L'Illusion réaliste : De Balzac à Aragon*. Écriture. Paris : Presses Universitaires de France.
- ROUSSEUW, Peter J. (nov. 1987). « Silhouettes : A graphical aid to the interpretation and validation of cluster analysis ». In : *Journal of Computational and Applied Mathematics* 20, p. 53-65.
- SAPORTA, Gilbert (2006). *Probabilités, analyse des données et statistiques*. Paris : Éditions Technip. 622 p.

Annexe technique : code

.0.1 Le code suivant présente le script Python utilisé pour nettoyer les textes extraits des fichiers EPUB après leur conversion au format *.txt*

```

1 from pathlib import Path
2 import re
3
4
5 def nettoyage_structure_epub(texte):
6     texte_propre = texte
7
8     # Nettoyage initial des espaces insécables
9     texte_propre = re.sub(r'[\xa0\u202f]', ' ', texte_propre)
10
11    # Suppression des éléments placés entre crochets
12    texte_propre = re.sub(r'\[.*?\]', '', texte_propre)
13
14    # Conservation uniquement des caractères utiles pour l'analyse
15    texte_propre = re.sub(
16        r'^[a-zA-Z0-9àáâãäåæçèéëîïóôûüÿÿÀĀĂĄÊĚĖİİŌŬŪŮȲǼÆ'
17        r'\s.,;!?~\-\(\)\[\]]',
18        '',
19        texte_propre
20    )
21
22    # Suppression des chiffres collés aux mots
23    texte_propre = re.sub(
24        r'^[a-zA-ZàáâãäåæçèéëîïóôûüÿÿÀĀĂĄÊĚĖİİŌŬŪŮȲǼÆ]\d+',
25        r'\1',
26        texte_propre
27    )
28
29    # Nettoyage des tirets et des guillemets
30    texte_propre = re.sub(r'[-{2,}]', '-', texte_propre)
31    texte_propre = re.sub(r'"«»"', '', texte_propre)
32
33    # Suppression des numéros de page isolés
34    texte_propre = re.sub(r'(m)^\\s*d+\\s*$', '', texte_propre)
35
36    # Suppression des titres de chapitre en chiffres romains
37    texte_propre = re.sub(r"(im)^\\s*[IVXLCDM]+\\s*$", "", texte_propre)
38
39    # Suppression de certains éléments propres aux fichiers EPUB
40    texte_propre = re.sub(r"(im)^\\s*Liste des titres\\s*$", "", texte_propre)
41    texte_propre = re.sub(r"(im)^\\s*Table des matières du titre\\s*$", "", texte_propre)
42
43    # Suppression des lignes entièrement écrites en majuscules
44    texte_propre = re.sub(
45        r"(m)^\\s*[A-ZĀĂĄÊĚĖİİŌŬŪŮȲǼÆ]'\\s'+\\s*$",
46        "", texte_propre
47    )
48

```

