

Université Lyon 2, Lyon 3, ENSIB, ENS Lyon

**Identifier les marqueurs du
naturalisme par la modélisation
thématique et la classification
automatique : signature d’auteur,
contenu thématique et biais de
corpus**

Mémoire présenté par Morgan RICHARD

Sous la direction de Pegah ALIZADEH

Année universitaire 2025–2026

Remerciements

Ce mémoire a été réalisé dans le cadre de mon stage de fin d'études au sein du laboratoire LATTICE, unité mixte de recherche du CNRS, de l'École Normale Supérieure-PSL et de l'Université Sorbonne Nouvelle. Les recherches du laboratoire portent notamment sur la linguistique, le traitement automatique des langues, l'évolution linguistique et les humanités numériques. Ce cadre scientifique m'a permis de mobiliser des méthodes de modélisation thématique et de classification automatique afin d'étudier les régularités lexicales et thématiques associées à l'écriture naturaliste. Le stage a été encadré par Dominique Legallois que je remercie pour son encadrement et pour toutes les nouvelles notions qu'il m'a enseignées au long de ce stage. Je tiens à remercier toutes les autres personnes du laboratoire pour leur accueil chaleureux et leur soutien tout au long de ce projet, notamment à Virgie Pauchont, gestionnaire et secrétaire, à Yoann Dupont, MCF à Sorbonne Nouvelle, à Mathieu Dehouck Chargé de Recherche au CNRS, et à Olga Seminck, ingénieure de recherche au CNRS.

Je remercie également Madame Pegah pour son encadrement ainsi que tous le personnel encadrant du master HN de Lyon pour leurs conseils tout au long de l'année.

Je remercie également mes proches pour leur soutien et leurs encouragements, je pense notamment à mes parents ainsi qu'à ma copine Mathilde Ducos.

Résumé

Ce mémoire examine dans quelle mesure la modélisation thématique et la classification automatique peuvent faire apparaître des marqueurs du naturalisme sans les confondre avec la signature d'Émile Zola, les thèmes propres à ses romans ou les biais de constitution du corpus. Les trente et un romans de Zola sont d'abord étudiés avec la factorisation en matrices non négatives (NMF) et K-means, puis avec BERTopic afin d'observer la répartition et les recompositions chronologiques des principaux domaines lexicaux. Une classification supervisée confronte ensuite le signal appris à partir de Zola à des œuvres naturalistes et à des œuvres relevant d'autres courants, écrites par des auteurs absents de l'apprentissage. Deux conditions sont comparées, avec et sans suppression automatique des noms propres.

N.B. : Le code et les données sont disponibles sur mon github. De plus, un LLM à été utilisé pour la correction orthographique et grammaticale de ce mémoire, ainsi que pour la reformulation de certaines phrases. Le LLM a été utilisé dans le respect des règles éthiques, tout l'aspect rédactionnel et scientifique du mémoire a été réalisé par l'auteur.

Mots-clés : naturalisme ; Émile Zola ; modélisation thématique ; BERTopic ; classification automatique ; stylométrie.

Table des matières

Remerciements	i
Résumé	ii
Introduction	1
1 Topic modeling sur les romans d'Émile Zola	7
1.1 Présentation de la méthode	7
1.2 Présentation du corpus d'étude	8
1.2.1 Choix du corpus	8
1.2.2 Préparation des textes	10
1.2.3 Préparation du corpus pour l'analyse thématique	10
1.2.4 Statistiques descriptives du corpus	10
1.2.5 Lemmatisation du corpus de Zola	13
1.3 Analyse par NMF et K-means	13
1.3.1 La méthode NMF	14
1.3.2 La méthode K-means	17
1.4 Résultats	19
1.4.1 Topics obtenus avec le NMF	19
1.4.2 Nombre de segments associés à chaque topic dominant	23
1.4.3 Clusters obtenus avec K-means	25
1.5 Comparaison des deux méthodes	34
1.5.1 Deux représentations complémentaires	34
1.5.2 Convergences lexicales et thématiques	35
1.5.3 Distribution des topics NMF par œuvre	35
1.5.4 Distribution des clusters K-means par œuvre	36
1.5.5 Regroupement en grandes familles	37
1.5.6 Apport de la double approche	38
1.6 Conclusion sur le Topic Modeling	39

2	Dynamique Topic modeling sur le corpus de d'Émile Zola	40
2.1	Présentation du corpus et des données	40
2.1.1	Objectif et organisation du corpus	40
2.1.2	Segmentation et statistiques descriptives	41
2.2	Utilisation de BERTopic	42
2.2.1	Architecture du modèle	42
2.2.2	Recherche et sélection des hyperparamètres	42
2.2.3	Configuration retenue	43
2.3	Validation interne du modèle	44
2.3.1	Séparation et stabilité de la partition	44
2.3.2	Réentraînement et réaffectation des documents atypiques	45
2.3.3	Cohérence et diversité des mots représentatifs	46
2.4	Analyse des résultats de BERTopic	47
2.4.1	Des topics aux familles thématiques	48
2.4.2	Lecture qualitative des six familles	50
2.4.3	Évolution des topics au fil du temps	51
2.4.4	Bilan interprétatif	57
2.5	Mise en regard de la NMF, de K-means et de BERTopic	58
2.5.1	Des conditions de modélisation différentes	58
2.5.2	Des correspondances thématiques réelles mais asymétriques . . .	60
2.5.3	Apports et limites propres à chaque approche	62
2.5.4	Ce que la comparaison permet de conclure	63
	Conclusion du chapitre	64
3	Machine learning sur le corpus de d'Émile Zola et auteurs contemporains	65
3.1	Présentation du protocole expérimental	65
3.1.1	Question de recherche et unité de classification	66
3.1.2	Constitution du corpus et séparation des auteurs	66
3.1.3	Préparation et segmentation des textes	67
3.1.4	Deux conditions expérimentales : ANP et SNP	68
3.1.5	Représentation des textes et modèles comparés	68
3.1.6	Sélection des configurations et évaluation	69
3.2	Résultats des expériences ANP et SNP	70
3.2.1	Résultats de l'expérience ANP	70
3.2.2	Résultats de l'expérience SNP	71
3.3	Comparaison des expériences ANP et SNP	72
3.3.1	Effet du retrait des noms propres	73
3.3.2	Nature du signal et effet de la chronologie	74

3.3.3	Portée, limites et prolongements	74
	Conclusion du chapitre	75
	Conclusion	76
	Bibliographie	78
	Sitographie	81
	Annexe	82
.1	Reflexion sur le stockage des données	82
.2	Nettoyage des textes	82
.3	Création de la base de données	83
.4	Création des informations pour la base de données	85

Table des figures

1.1	Méthode du coude pour le choix du nombre de topics dans la NMF, entre 2 et 40 topics	15
1.2	Méthode du coude pour le choix du nombre de topics dans la NMF, entre 20 et 39 topics	15
1.3	Évolution du score de silhouette en fonction du nombre de clusters dans K-means	18
1.4	Dendrogramme de la classification hiérarchique des clusters K-means .	29
1.5	Regroupement des clusters K-means en grandes familles de motifs . . .	30
1.6	Noms attribués aux grandes familles de motifs	32
1.7	Distribution des grandes familles de motifs dans le corpus	33
1.8	Distribution des clusters K-means dans le corpus	34
1.9	Proportion des segments par topic NMF dominant et par œuvre	36
1.10	Distribution des clusters K-means par œuvre	37
1.11	Distribution des grandes familles de clusters K-means par œuvre	38
2.1	Évolution en effectifs bruts des topics 5, 8 et 10 : corps, apparences et vie privée ou mondaine	52
2.2	Évolution en effectifs bruts des topics 4, 6, 9 et 14 : travail, argent et conditions matérielles	53
2.3	Évolution en effectifs bruts des topics 1, 12, 13 et 15 : institutions, religion et pouvoir	54
2.4	Évolution en effectifs bruts des topics 2, 7, 11 et 16 : relations affectives, couple et famille	55
2.5	Évolution en effectifs bruts du topic 0 : espaces, paysages et architecture	56
2.6	Évolution en effectifs bruts du topic 3 : guerre et violence collective . .	57

Liste des tableaux

1.1	Nombre de tokens par roman de Zola dans l'ordre chronologique	8
1.2	Nombre de paquets de phrases par roman	11
1.3	Statistiques descriptives du nombre de paquets par roman	12
1.4	Statistiques descriptives du nombre de mots par paquet	12
1.5	Mots caractéristiques des topics obtenus avec la NMF	20
1.6	Noms attribués aux topics obtenus avec la NMF	22
1.7	Nombre de segments associés à chaque topic dominant	23
1.8	Mots caractéristiques des clusters obtenus avec K-means	25
1.9	Noms attribués aux clusters obtenus avec K-means	27
1.10	Composition des grandes familles de motifs issues des clusters K-means	31
2.1	Longueur des segments produits, en tokens CamemBERT	41
2.2	Grille de recherche et configuration BERTopic retenue	43
2.3	Indicateurs enregistrés aux trois étapes de la modélisation	47
2.4	Regroupement interprétatif des 17 topics en six familles	48
2.5	Interprétation synthétique des 17 topics du modèle final	48
2.6	Principales différences entre les trois chaînes de traitement	59
2.7	Principales correspondances entre NMF, K-means et BERTopic	60
3.1	Composition des ensembles utilisés pour la classification	67
3.2	Résultats de l'expérience ANP par auteur du test	70
3.3	Résultats de l'expérience SNP par auteur du test	72
3.4	Comparaison des résultats ANP et SNP sur les œuvres du test	73

Introduction

La modélisation thématique, la stylométrie et la classification automatique constituent trois approches complémentaires de l’analyse quantitative des textes. Elles se distinguent principalement par leurs objectifs : la modélisation thématique cherche à faire émerger les structures sémantiques d’un corpus, la stylométrie mesure les caractéristiques formelles de l’écriture, tandis que la classification automatique attribue aux textes des catégories préalablement définies.

La modélisation thématique (*topic modeling*) vise généralement à dégager, sans annotation préalable, les principaux thèmes présents dans un ensemble de documents. L’allocation de Dirichlet latente (*Latent Dirichlet Allocation*, LDA) s’est imposée comme l’un des modèles probabilistes de référence. Elle représente chaque document comme un mélange de thèmes, eux-mêmes définis par des distributions de probabilités sur les mots du corpus.¹ Les prolongements de cette méthode permettent notamment d’intégrer l’évolution temporelle des thèmes, leurs relations ou les métadonnées associées aux documents.² Plus récemment, les modèles neuronaux et les plongements contextuels ont renouvelé la modélisation thématique, en particulier pour l’analyse des textes courts, multilingues ou sémantiquement complexes.³ BERTopic, par exemple, combine des représentations produites par un modèle de langue, une méthode de regroupement automatique et une variante du TF-IDF pour caractériser les thèmes obtenus.⁴ L’interprétation des résultats demeure néanmoins délicate : les thèmes dépendent de la constitution et du prétraitement du corpus, du nombre de thèmes demandé et des paramètres du modèle. Par ailleurs, une bonne performance statistique ne garantit pas nécessairement que les thèmes produits soient cohérents pour un lecteur humain.⁵

1. David M. Blei, Andrew Y. Ng et Michael I. Jordan, « Latent Dirichlet Allocation », *Journal of Machine Learning Research*, vol. 3, 2003, p. 993–1022, texte intégral en ligne.

2. David M. Blei, « Probabilistic Topic Models », *Communications of the ACM*, vol. 55, no 4, 2012, p. 77–84, texte intégral en ligne.

3. Xiaobao Wu, Thong Nguyen et Anh Tuan Luu, « A Survey on Neural Topic Models : Methods, Applications, and Challenges », *Artificial Intelligence Review*, vol. 57, article 18, 2024, DOI et texte intégral.

4. Maarten Grootendorst, « BERTopic : Neural Topic Modeling with a Class-Based TF-IDF Procedure », prépublication arXiv, 2022, texte intégral en ligne.

5. Jonathan Chang, Jordan Boyd-Graber, Sean Gerrish, Chong Wang et David M. Blei, « Reading Tea Leaves : How Humans Interpret Topic Models », dans *Advances in Neural Information Processing Systems 22*, 2009, p. 288–296, texte intégral en ligne.

La stylométrie cherche, pour sa part, à mesurer les régularités formelles d’une écriture à partir de caractéristiques quantifiables, telles que les fréquences lexicales, l’emploi des mots-outils, la richesse du vocabulaire, la longueur des phrases, la ponctuation, les catégories grammaticales ou les séquences de caractères. Elle a d’abord été principalement utilisée pour résoudre des problèmes d’attribution d’auteur, comme l’illustre l’étude fondatrice de Frederick Mosteller et David Wallace sur les articles anonymes des *Federalist Papers*.⁶ Parmi les méthodes classiques, le *Delta* de John Burrows mesure la distance stylistique entre plusieurs textes à partir des fréquences standardisées de leurs mots les plus courants.⁷ Les recherches contemporaines mobilisent également les n-grammes de caractères, les méthodes d’apprentissage automatique et les représentations produites par les modèles de langue.⁸ La stylométrie comprend désormais plusieurs tâches, notamment l’attribution, la vérification et le profilage d’auteur, ainsi que l’étude de l’évolution du style au cours du temps.⁹ Ses résultats restent toutefois sensibles à la longueur des documents et aux effets du genre, du thème, de la période historique, du support ou de la traduction. Ces facteurs doivent donc être contrôlés afin de ne pas les confondre avec le style individuel.

Enfin, la classification automatique consiste à attribuer un texte à une ou plusieurs catégories définies à l’avance. Contrairement à la modélisation thématique, elle relève généralement de l’apprentissage supervisé : le modèle apprend à partir d’un corpus dont les documents ont préalablement été annotés.¹⁰ Les approches classiques représentent les documents par des fréquences lexicales ou des pondérations TF-IDF, puis utilisent des méthodes comme le classifieur bayésien naïf, la régression logistique ou les machines à vecteurs de support.¹¹ Ces méthodes ont été complétées par les réseaux de neurones, puis par les modèles de langue préentraînés fondés sur l’architecture Transformer. BERT a notamment popularisé une procédure dans laquelle un modèle préentraîné sur de grandes quantités de textes est ensuite spécialisé sur une tâche de classification à partir d’un corpus annoté plus restreint.¹² Les grands modèles de langue permettent également

6. Frederick Mosteller et David L. Wallace, *Inference and Disputed Authorship : The Federalist*, Reading, Addison-Wesley, 1964 ; réédition avec une introduction de John Nerbonne, Stanford, CSLI Publications, 2007, notice éditoriale.

7. John Burrows, « ‘Delta’ : A Measure of Stylistic Difference and a Guide to Likely Authorship », *Literary and Linguistic Computing*, vol. 17, no 3, 2002, p. 267–287, DOI.

8. Efstathios Stamatatos, « A Survey of Modern Authorship Attribution Methods », *Journal of the American Society for Information Science and Technology*, vol. 60, no 3, 2009, p. 538–556, texte intégral en ligne.

9. Enzo Terreau, *Apprentissage de représentations d’auteurs et d’autrices à partir de modèles de langue pour l’analyse des dynamiques d’écriture*, thèse de doctorat en informatique, Université Lyon 2, 2024, notice et résumé en ligne.

10. Fabrizio Sebastiani, « Machine Learning in Automated Text Categorization », *ACM Computing Surveys*, vol. 34, no 1, 2002, p. 1–47, texte intégral en ligne.

11. Christopher D. Manning, Prabhakar Raghavan et Hinrich Schütze, *Introduction to Information Retrieval*, Cambridge, Cambridge University Press, 2008, chap. 13 à 15, édition intégrale en ligne.

12. Jacob Devlin, Ming-Wei Chang, Kenton Lee et Kristina Toutanova, « BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding », dans *Proceedings of NAACL-HLT*

d'effectuer certaines classifications sans apprentissage spécifique ou à partir d'un nombre limité d'exemples. Ils ne rendent cependant pas systématiquement obsolètes les modèles spécialisés : pour de nombreuses tâches, un modèle plus petit correctement entraîné peut rester plus performant, plus stable et moins coûteux.¹³

Dans ces trois domaines, le choix de la méthode ne peut être séparé des conditions de constitution et d'annotation du corpus. Une évaluation rigoureuse suppose notamment de contrôler les effets d'auteur, de source, de genre et de période, de séparer strictement les données d'apprentissage et de test, et de confronter les résultats quantitatifs à une lecture qualitative des textes.¹⁴

Mon objectif est d'appliquer ces méthodes à l'œuvre d'Émile Zola dans un premier temps, puis de les confronter à un corpus comparatif de romans naturalistes et non-naturalistes de la même époque. L'objectif est de déterminer si ces méthodes permettent d'identifier des marqueurs du naturalisme, tout en évitant de confondre signature d'auteur, contenu thématique et artefacts liés à la constitution du corpus.

Le naturalisme constitue l'un des principaux mouvements littéraires et artistiques de la seconde moitié du XIX^e siècle. Prolongeant certaines ambitions du réalisme, il se donne pour objectif de représenter l'être humain et la société avec une précision inspirée des sciences expérimentales. L'œuvre littéraire ne repose donc plus seulement sur l'imagination de l'écrivain : elle s'appuie sur l'observation du réel, sur une documentation minutieuse ainsi que sur l'étude des mécanismes physiologiques, sociaux et psychologiques qui déterminent les comportements individuels.

Émile Zola¹⁵, principal théoricien du mouvement, définit ainsi le naturalisme comme « l'esprit scientifique porté dans toutes nos connaissances ». Il entend substituer à « l'homme métaphysique » un « homme physiologique », inséparable de son hérédité et du milieu dans lequel il évolue¹⁶. Inspiré notamment par *l'Introduction à l'étude de la médecine expérimentale* de Claude Bernard, Zola conçoit le romancier comme un observateur et un expérimentateur. Celui-ci commence par recueillir et consigner des faits, puis place ses personnages dans des circonstances déterminées afin d'étudier le fonctionnement de leurs passions, de leurs instincts et de leurs conduites. Le roman devient alors une forme d'expérience permettant de mettre au jour les lois qui régissent l'individu et la société¹⁷.

Cette conception repose principalement sur le déterminisme. Dans la perspective

2019, p. 4171–4186, texte intégral en ligne.

13. Aleksandra Edwards et Jose Camacho-Collados, « Language Models for Text Classification : Is In-Context Learning Enough ? », dans *Proceedings of LREC-COLING 2024*, p. 10058–10072, texte intégral en ligne.

14. Justin Grimmer et Brandon M. Stewart, « Text as Data : The Promise and Pitfalls of Automatic Content Analysis Methods for Political Texts », *Political Analysis*, vol. 21, no 3, 2013, p. 267–297, DOI.

15. Pour ce qui est des informations sur Émile Zola, je me suis grandement référé à sa page Wikipédia, qui est considérée comme une page de qualité : lien de sa page.

16. [https://fr.wikipedia.org/wiki/Naturalisme_\(litt%C3%A9rature\)](https://fr.wikipedia.org/wiki/Naturalisme_(litt%C3%A9rature))

17. Émile Zola, *Le Roman expérimental*, Paris, Charpentier, 1881.

naturaliste, la personnalité et la destinée d'un individu sont largement conditionnées par son héritage physiologique, son environnement familial, sa situation économique et son appartenance sociale. Le naturalisme ne doit cependant pas être réduit à un ensemble de procédés stylistiques¹⁸. Paul Alexis le présente avant tout comme une méthode permettant de penser¹⁹, de voir, d'étudier et d'expérimenter. De même, Camille Lemonnier l'envisage comme un « réalisme agrandi » par l'analyse des milieux et par l'apport des sciences naturelles et sociales. Le mouvement s'inscrit ainsi dans une vision matérialiste et empirique du monde, selon laquelle les phénomènes humains doivent être expliqués à partir de causes observables²⁰.

Sur le plan esthétique et narratif, cette ambition scientifique entraîne une remise en cause des conventions romanesques traditionnelles. Les naturalistes rejettent les intrigues artificielles, les péripéties invraisemblables et les personnages idéalisés. À la construction d'une fable spectaculaire, ils préfèrent la restitution d'une « tranche de vie », c'est-à-dire l'étude détaillée d'un fragment d'existence ordinaire. Le roman prend alors la forme d'une monographie consacrée à un individu, à une famille, à un métier ou à un milieu social. Le narrateur tend à s'effacer derrière les faits et adopte une posture d'impersonnalité comparable à celle d'un greffier chargé d'exposer les pièces d'un dossier sans formuler explicitement de jugement²¹.

La description occupe, dans cette perspective, une fonction essentielle. Elle ne constitue pas un simple ornement esthétique, mais un instrument d'analyse et d'explication. Les logements, les vêtements, les paysages, les lieux de travail et les conditions matérielles d'existence contribuent à façonner les personnages. Décrire un environnement revient donc à rendre visibles les forces qui agissent sur l'individu. Cette attention portée aux déterminations sociales conduit les écrivains naturalistes à s'intéresser aux catégories jusque-là marginalisées par la littérature : les ouvriers, les paysans, les prostituées, les criminels, les malades ou les exclus. Le héros traditionnel s'efface au profit de personnages ordinaires, souvent confrontés à la pauvreté, à la violence, à la maladie ou au déclassement.

La représentation de ces réalités a toutefois suscité d'importantes controverses morales et esthétiques. La crudité de certaines scènes, l'étude des pathologies et l'attention accordée aux formes de déchéance ont conduit les adversaires du mouvement à l'accuser de complaisance envers la laideur et le vice. Zola défend au contraire la dimension morale de sa démarche. À ses yeux, le romancier agit comme un anatomiste ou un chirurgien : en analysant les causes matérielles et sociales des comportements, il contribue à mieux comprendre les dysfonctionnements de la société et fournit les connaissances nécessaires à leur éventuelle correction. L'écrivain naturaliste serait ainsi un « moraliste

18. [https://fr.wikipedia.org/wiki/Naturalisme_\(litt%C3%A9rature\)](https://fr.wikipedia.org/wiki/Naturalisme_(litt%C3%A9rature))

19. Jules Huret, *Enquête sur l'évolution littéraire*, Paris, Charpentier, 1891.

20. [https://fr.wikipedia.org/wiki/Naturalisme_\(litt%C3%A9rature\)](https://fr.wikipedia.org/wiki/Naturalisme_(litt%C3%A9rature))

21. Émile Zola, *Le Roman expérimental*

expérimentateur », dont la fonction n'est pas de condamner, mais d'expliquer²².

Cette conception est notamment contestée par Ferdinand Brunetière²³, qui reproche au naturalisme français de privilégier la recherche de la grossièreté, le pessimisme et l'« écriture artiste » au détriment de la profondeur psychologique. Il oppose à ce qu'il considère comme un « faux naturalisme » une littérature incarnée par Dickens, George Eliot ou Tolstoï, caractérisée par la probité de l'observation, la simplicité de l'exécution et la sympathie envers les humbles. Edmond Cattier insiste également sur le rôle de l'« imagination sympathique »²⁴, faculté par laquelle l'écrivain dépasse la simple observation extérieure pour pénétrer la conscience d'autrui, comprendre les motifs de ses actions et restituer la complexité de son expérience. Ces critiques mettent en évidence une tension centrale du naturalisme : celle qui oppose l'ambition d'objectivité scientifique à la nécessité d'une compréhension sensible et psychologique de l'être humain.

Le naturalisme ne forme d'ailleurs pas une école parfaitement homogène. S'il revendique l'héritage de Diderot, de Rousseau, de Balzac, de Stendhal, de Flaubert et des frères Goncourt, ses représentants divergent sur la définition même du mouvement. Edmond de Goncourt préfère parler de « naturisme », Joris-Karl Huysmans d'« intimisme », Louis-Marie Desprez d'« impressionnisme », tandis que Guy de Maupassant propose le terme d'« illusionnistes ». Cette diversité terminologique révèle l'existence de pratiques et de conceptions distinctes derrière l'apparente unité du groupe naturaliste²⁵.

Le succès des *Soirées de Médan*, publiées en 1880, marque l'un des moments les plus emblématiques de cette aventure collective. Toutefois, l'unité du mouvement se fragilise rapidement. Le *Manifeste des Cinq*, publié en 1887 contre *La Terre* de Zola, rend visibles les désaccords internes, tandis que plusieurs auteurs s'éloignent progressivement de l'esthétique naturaliste. Huysmans, notamment, ouvre avec *À rebours* la voie à une littérature décadente et symboliste²⁶. À la fin du siècle, le développement du roman psychologique et du symbolisme contribue ainsi au déclin du naturalisme en tant qu'école constituée. La formule attribuée à Stéphane Mallarmé, selon laquelle « le mot mourra quand Zola aura achevé son œuvre », souligne à la fois le rôle déterminant de Zola dans la définition du mouvement et la difficulté du naturalisme à lui survivre sous une forme unifiée²⁷.

Dans quelle mesure les méthodes de modélisation thématique et de classification automatique permettent-elles d'identifier des marqueurs du naturalisme sans confondre signature d'auteur, contenu thématique et artefacts de constitution du corpus ?

Afin de répondre à cette problématique, ce mémoire s'organise en trois chapitres

22. *Ibid.*

23. Ferdinand Brunetière, *Le roman naturaliste*, Paris, Calmann-Lévy, 1883.

24. Edmond Cattier, *Le Naturalisme littéraire*, Bruxelles, Weissenbruch, 1897.

25. [https://fr.wikipedia.org/wiki/Naturalisme_\(litt%C3%A9rature\)](https://fr.wikipedia.org/wiki/Naturalisme_(litt%C3%A9rature))

26. *Ibid.*

27. Jules Huret, *Enquête sur l'évolution littéraire*, Paris, Charpentier, 1891.

complémentaires. Le premier présente une exploration thématique classique des trente et un romans d'Émile Zola à l'aide de la factorisation en matrices non négatives et de la méthode K-means. Cette première analyse vise à dégager des régularités lexicales et thématiques internes à l'œuvre zolienne, considérées comme des marqueurs candidats plutôt que comme des preuves immédiates du naturalisme. Le deuxième chapitre étudie ces régularités au moyen de BERTopic et analyse leur évolution au cours de la carrière de Zola. Le troisième chapitre confronte les hypothèses issues de ces analyses à un corpus comparatif grâce à une classification automatique opposant romans naturalistes et romans relevant d'autres courants. Une attention particulière est accordée aux risques de confusion entre signature d'auteur, contenu thématique et artefacts liés à la constitution du corpus. Enfin, les choix de nettoyage, l'organisation de la base de données et les principaux éléments nécessaires à la reproductibilité des expériences sont présentés en annexe.

Chapitre 1

Topic modeling sur les romans d'Émile Zola

1.1 Présentation de la méthode

Émile Zola, l'un des écrivains majeurs du XIX^e siècle, est connu pour ses romans naturalistes, dans lesquels il explore les dimensions sociales, économiques et psychologiques de la vie humaine. Son œuvre romanesque constitue ainsi un corpus particulièrement riche pour l'analyse des thèmes récurrents, des milieux sociaux et des motifs narratifs.

Dans cette étude, nous examinons les thèmes présents dans les romans de Zola afin de déterminer dans quelle mesure certains motifs apparaissent de manière transversale dans son œuvre. Pour cela, nous mobilisons des méthodes d'analyse textuelle non supervisées, capables d'identifier des regroupements lexicaux à partir des textes eux-mêmes.

La question centrale de cette étude est donc la suivante : dans quelle mesure des méthodes non supervisées comme la NMF et K-means permettent-elles de faire apparaître des structures thématiques récurrentes dans l'œuvre romanesque de Zola ?

L'objectif est de vérifier si les regroupements produits automatiquement correspondent à des motifs interprétables dans le cadre d'une analyse littéraire. Il ne s'agit donc pas de remplacer la lecture critique des textes, mais d'utiliser les outils du traitement automatique du langage comme un moyen d'explorer un corpus littéraire volumineux.

Ce travail constitue le premier volet d'une série d'analyses portant sur des corpus de textes littéraires issus d'auteurs naturalistes et non naturalistes. Il sert à la fois de cas d'étude méthodologique et de base pour de futures comparaisons entre différents ensembles d'œuvres.

Deux méthodes d'analyse ont été utilisées pour identifier les thèmes dans les romans de Zola :

- la NMF (Non-negative Matrix Factorization)¹ : une technique de réduction de dimensionnalité qui permet d'extraire des topics à partir d'un corpus de textes ;
- K-means : une méthode de clustering qui permet de regrouper les segments textuels en fonction de leur proximité lexicale.².

Ces méthodes seront expliquées dans les sections suivantes, avant la présentation des résultats de l'analyse thématique des romans de Zola.

Dans cette étude, le terme *topic* désigne un regroupement lexical produit par le modèle NMF, tandis que le terme *cluster* désigne un groupe de segments obtenu par K-means. Le terme *thème* est réservé à l'interprétation qualitative de ces regroupements. Cette précision terminologique est importante pour éviter toute confusion entre les différentes étapes de l'analyse.

1.2 Présentation du corpus d'étude

1.2.1 Choix du corpus

Cette étude porte sur 31 romans d'Émile Zola, publiés entre 1865 et 1903. Les nouvelles, les essais et les textes journalistiques ont été écartés afin de constituer un ensemble relativement homogène du point de vue du genre et de la longueur. Les romans offrent également un contexte suffisamment développé pour étudier les thèmes, les milieux sociaux et les motifs récurrents de l'œuvre zolienne.

Ce choix répond aussi à une contrainte méthodologique. L'intégration de textes courts aurait accentué les différences de volume entre les œuvres et aurait pu déséquilibrer l'analyse thématique. La restriction du corpus au genre romanesque ne supprime pas toutes les variations de longueur, mais elle les limite et facilite la comparaison entre les textes.

Le corpus réunit cinq romans antérieurs aux *Rougon-Macquart*, les vingt volumes de ce cycle, les trois romans des *Trois Villes* et les trois volumes publiés des *Quatre Évangiles*. Dans ce dernier cycle, *Vérité* paraît à titre posthume, tandis que *Justice*, resté à l'état d'ébauche, n'a jamais été publié.

TABLE 1.1 – Nombre de tokens par roman de Zola dans l'ordre chronologique

Date	Titre du roman	Nombre de tokens
1865	<i>La confession de Claude</i>	47253
1866	<i>Le vœu d'une morte</i>	38722

1. N. Gillis, *Nonnegative Matrix Factorization*, Society for Industrial and Applied Mathematics, coll. « Data Science », 2020.

2. Richard O. Duda, Peter E. Hart et David G. Stork, *Pattern Classification*, Wiley-Interscience, 2001.

Date	Titre du roman	Nombre de tokens
1867	<i>Les mystères de Marseille</i>	125253
1867	<i>Thérèse Raquin</i>	66363
1868	<i>Madeleine Féral</i>	97318
1871	<i>La fortune des Rougon</i>	116685
1872	<i>La curée</i>	105120
1873	<i>Le ventre de Paris</i>	110442
1874	<i>La conquête de Plassans</i>	113245
1875	<i>La faute de l'abbé Mouret</i>	114667
1876	<i>Son Excellence Eugène Rougon</i>	126186
1877	<i>L'assommoir</i>	158340
1878	<i>Une page d'amour</i>	102185
1880	<i>Nana</i>	141573
1882	<i>Pot-Bouille</i>	134844
1883	<i>Au Bonheur des dames</i>	147521
1884	<i>La joie de vivre</i>	117255
1885	<i>Germinal</i>	164473
1886	<i>L'œuvre</i>	130613
1887	<i>La terre</i>	163687
1888	<i>Le rêve</i>	66379
1890	<i>La bête humaine</i>	125418
1891	<i>L'argent</i>	143010
1892	<i>La débâcle</i>	187046
1893	<i>Le docteur Pascal</i>	112713
1894	<i>Lourdes</i>	173511
1896	<i>Rome</i>	233958
1898	<i>Paris</i>	177389
1899	<i>Fécondité</i>	220131
1901	<i>Travail</i>	198712
1903	<i>Vérité</i>	223274

Ce corpus couvre ainsi l'ensemble de la carrière romanesque de Zola, de ses premiers textes à ses dernières œuvres. Cette amplitude chronologique permet d'observer les régularités thématiques de son écriture, mais aussi leurs transformations éventuelles au fil du temps, qui seront étudiées dans le chapitre consacré à BERTopic.

1.2.2 Préparation des textes

Les romans ont été réunis au format `.txt`, puis nettoyés afin de retirer les éléments éditoriaux qui ne relèvent pas directement du récit : mentions d'édition, tables des matières, notes, numéros de page et intitulés de chapitres. Cette étape vise à éviter que ces éléments n'influencent artificiellement les résultats³.

Après nettoyage, chaque fichier a été organisé de manière à ne conserver qu'une phrase par ligne. Cette organisation ne modifie pas le contenu des romans, mais facilite leur traitement automatique et leur segmentation. Elle permet également d'appliquer la même procédure à des textes provenant initialement de formats différents, notamment TXT, PDF ou EPUB.

Le nombre de tokens varie sensiblement d'un roman à l'autre. Les premiers textes, comme *Le vœu d'une morte*, sont relativement courts, tandis que des œuvres tardives comme *Rome, Fécondité, Travail* ou *Vérité* sont beaucoup plus volumineuses. Cette différence doit être prise en compte, car un roman long produit mécaniquement davantage d'occurrences lexicales et d'unités d'analyse qu'un roman court.

1.2.3 Préparation du corpus pour l'analyse thématique

Les romans ont été découpés en segments de 40 phrases. Cette taille constitue un compromis entre deux objectifs : conserver suffisamment de contexte pour identifier un thème et produire des unités plus fines que les chapitres ou les œuvres entières.

Plusieurs tailles de segments ont été expérimentées, notamment 10, 40, 50, 70 et 100 phrases. Les segments de 40 phrases ont donné les résultats les plus lisibles et les plus cohérents au cours des essais exploratoires. Ce choix reste néanmoins en partie empirique et constitue donc une limite méthodologique.

Un découpage par chapitre ou par paragraphe a également été envisagé. Ces solutions ont été écartées en raison de la forte variation de longueur de ces unités. De plus, la structure des paragraphes n'est pas toujours conservée de manière fiable lors de la conversion des fichiers. Les dialogues produisent notamment de nombreux paragraphes très courts. Le découpage par phrases offre donc une solution plus homogène et plus facilement applicable à l'ensemble du corpus.

1.2.4 Statistiques descriptives du corpus

3. Pour ce qui est des scripts de nettoyage, ils sont disponible sur mon github

TABLE 1.2 – Nombre de paquets de phrases par roman

Titre du roman	Nombre de paquets
<i>La confession de Claude</i>	65
<i>Le vœu d'une morte</i>	60
<i>Les mystères de Marseille</i>	184
<i>Thérèse Raquin</i>	80
<i>Madeleine Féral</i>	124
<i>La fortune des Rougon</i>	154
<i>La curée</i>	123
<i>Le ventre de Paris</i>	136
<i>La conquête de Plassans</i>	165
<i>La faute de l'abbé Mouret</i>	171
<i>Son Excellence Eugène Rougon</i>	191
<i>L'assommoir</i>	228
<i>Une page d'amour</i>	166
<i>Nana</i>	225
<i>Pot-Bouille</i>	207
<i>Au Bonheur des dames</i>	198
<i>La joie de vivre</i>	164
<i>Germinal</i>	225
<i>L'œuvre</i>	163
<i>La terre</i>	222
<i>Le rêve</i>	82
<i>La bête humaine</i>	154
<i>L'argent</i>	155
<i>La débâcle</i>	221
<i>Le docteur Pascal</i>	135
<i>Lourdes</i>	198
<i>Rome</i>	231
<i>Paris</i>	206
<i>Fécondité</i>	259
<i>Travail</i>	208
<i>Vérité</i>	227

La segmentation produit un nombre variable de paquets selon la longueur des œuvres. Les romans les plus courts, comme *Le vœu d'une morte* et *La confession de Claude*, fournissent moins d'unités d'analyse, tandis que *Fécondité*, *Rome* ou *L'assommoir* en produisent davantage.

TABLE 1.3 – Statistiques descriptives du nombre de paquets par roman

Indicateur	Valeur
Nombre de romans	31
Moyenne	171.84
Écart-type	52.40
Minimum	60
Premier quartile	145
Médiane	171
Troisième quartile	214.5
Maximum	259

Le corpus comprend en moyenne environ 172 paquets par roman, avec une médiane de 171. Ces deux valeurs proches montrent que la distribution n'est pas fortement déséquilibrée. L'écart-type de 52 paquets et l'écart entre le minimum de 60 et le maximum de 259 témoignent toutefois d'une variation réelle entre les œuvres.

Cette différence doit être gardée à l'esprit lors de l'interprétation des résultats : les romans les plus longs contribuent à un plus grand nombre de segments et peuvent donc occuper une place plus importante dans les résultats globaux. La segmentation améliore la comparabilité des unités textuelles, mais elle ne supprime pas entièrement l'effet lié à la longueur des œuvres.

TABLE 1.4 – Statistiques descriptives du nombre de mots par paquet

Indicateur	Valeur
Nombre de paquets	5327
Moyenne	785.30
Écart-type	212.13
Minimum	42
Premier quartile	636
Médiane	753
Troisième quartile	902.5
Maximum	2944

Au total, le corpus segmenté comprend 5,327 paquets. Ils contiennent en moyenne 785 mots, pour une médiane de 753 mots. La moitié centrale des segments se situe entre 636 et environ 903 mots, ce qui indique que la majorité des unités possède une taille relativement comparable.

La variation restante s'explique par le choix d'un nombre fixe de phrases plutôt que d'un nombre fixe de mots. Selon le rythme narratif et la longueur des phrases, deux

segments peuvent donc présenter des volumes différents. Les valeurs extrêmes, comprises entre 42 et 2,944 mots, correspondent probablement à des segments résiduels ou à des passages composés de phrases particulièrement longues. Ces cas doivent être pris en compte, car les segments les plus volumineux contiennent davantage d'information lexicale.

1.2.5 Lemmatisation du corpus de Zola

Les segments ont ensuite été lemmatisés⁴ avec la bibliothèque Python `spaCy` et son modèle français `fr_core_news_lg`. La lemmatisation rassemble les différentes formes fléchies d'un mot sous une forme commune : « mange », « manges » et « manger » sont ainsi associés au lemme « manger ». Cette normalisation réduit la dispersion du vocabulaire et facilite la construction de la matrice terme-document.

Une liste d'exclusion personnalisée a été constituée au fil des essais. Elle comprend les mots-outils, la ponctuation, les nombres et certains termes très fréquents mais peu utiles à l'interprétation des thèmes. Plusieurs noms de personnages ont également été retirés, car leur présence tendait à produire des topics centrés sur les protagonistes plutôt que sur des ensembles thématiques plus généraux.

Pour chaque segment, les lemmes sont convertis en minuscules, puis filtrés. Seuls les noms et les adjectifs sont conservés, ces catégories étant particulièrement utiles pour faire apparaître des contenus thématiques tels que le travail, la famille, la religion, l'argent ou les rapports sociaux. Ce choix oriente donc volontairement l'analyse vers les thèmes et non vers le style grammatical de Zola.

La liste d'exclusion a été ajustée après l'examen des termes les plus fréquents et des premiers résultats. Cette procédure empirique améliore la lisibilité des topics, mais elle introduit également une part d'intervention humaine qui doit être prise en compte dans leur interprétation. À l'issue du traitement, chaque roman est représenté par un ensemble de segments lemmatisés et filtrés, utilisés pour les analyses par NMF et K-means.

1.3 Analyse par NMF et K-means

Deux méthodes non supervisées ont été utilisées pour explorer les régularités thématiques du corpus : la factorisation en matrices non négatives (NMF) et K-means. La première fait apparaître des topics à partir de groupes de mots fréquemment associés, tandis que la seconde rassemble les segments présentant des profils lexicaux proches. Leur comparaison permet d'observer le corpus selon deux perspectives complémentaires.

4. Le code est disponible sur mon gitub

1.3.1 La méthode NMF

La NMF (*Non-negative Matrix Factorization*) est une méthode de réduction dimensionnelle fréquemment utilisée pour l'exploration thématique. Elle décompose une matrice documents-termes en deux matrices non négatives : la première associe les segments aux topics, tandis que la seconde associe les topics aux termes qui les caractérisent.

Chaque segment peut ainsi être rattaché à plusieurs topics avec des poids différents. Cette représentation est adaptée aux textes littéraires, dans lesquels plusieurs thèmes peuvent apparaître simultanément au sein d'un même passage.

Création de la matrice documents-termes

Les segments lemmatisés ont d'abord été transformés en une représentation numérique à l'aide d'une pondération TF-IDF⁵. Cette pondération valorise les termes caractéristiques d'un segment tout en réduisant l'influence des mots présents dans une grande partie du corpus.

Deux paramètres ont été utilisés pour filtrer le vocabulaire. Le paramètre `min_df=3` écarte les termes présents dans moins de trois segments, considérés comme trop rares pour faire apparaître des régularités thématiques. À l'inverse, `max_df=0.8` retire les termes présents dans plus de 80 % des segments, qui sont trop fréquents pour être réellement discriminants⁶.

Plusieurs configurations ont été expérimentées. Les paramètres retenus offrent un compromis entre la réduction du vocabulaire et la conservation des termes utiles à l'interprétation. La matrice obtenue sert ensuite d'entrée au modèle NMF.

Choix du nombre de topics

Le nombre de topics influence directement la précision des résultats. Une valeur trop faible produit des catégories très générales, tandis qu'une valeur trop élevée fragmente les thèmes et multiplie les topics proches ou difficiles à interpréter.

La méthode du coude a d'abord été utilisée pour orienter ce choix⁷. Plusieurs modèles ont été entraînés avec un nombre croissant de topics, puis comparés à partir de leur erreur de reconstruction. Un coude clairement marqué aurait indiqué qu'au-delà d'un certain seuil, l'ajout de nouveaux topics améliorerait peu la reconstruction de la matrice.

5. Le TF-IDF (*term frequency-inverse document frequency*) mesure l'importance d'un terme dans un document en tenant compte de sa fréquence dans l'ensemble du corpus. Le calcul a été réalisé avec la bibliothèque `scikit-learn`.

6. Le code du vectoriseur est disponible sur le dépôt GitHub associé au mémoire.

7. Le code correspondant est présenté en annexe.




FIGURE 1.1 – Méthode du coude pour le choix du nombre de topics dans la NMF, entre 2 et 40 topics

Comme le montre la figure 1.1, l'erreur diminue régulièrement lorsque le nombre de topics augmente. Cette évolution est attendue : un modèle disposant de davantage de topics peut reconstruire plus précisément la matrice initiale. La courbe ne présente cependant aucune rupture suffisamment nette pour désigner une valeur optimale.

Une seconde visualisation a donc été produite entre 20 et 39 topics afin d'examiner plus précisément cette partie de la courbe.




FIGURE 1.2 – Méthode du coude pour le choix du nombre de topics dans la NMF, entre 20 et 39 topics

Ce second graphique confirme l'absence de coude clairement identifiable. Le choix final ne pouvait donc pas reposer uniquement sur l'erreur de reconstruction. Plusieurs modèles, comprenant notamment 10, 15, 20, 29, 30 et 35 topics, ont alors été comparés à partir des mots caractéristiques de chaque topic, de leur cohérence interne et de leur lisibilité.

Le modèle à 29 topics a finalement été retenu. Il offre un niveau de détail suffisant pour distinguer plusieurs ensembles thématiques sans produire une fragmentation excessive. Ce choix reste néanmoins empirique : il correspond au meilleur compromis observé dans le cadre de cette étude, et non à une valeur optimale démontrée de manière absolue.

Paramétrage du modèle

Le modèle final utilise le paramètre `n_components=29`. Le paramètre `random_state=42` assure la reproductibilité du traitement. L'initialisation `nndsvda`⁸ fournit un point de départ stable, tandis que le solveur `cd`, pour *coordinate descent*, optimise progressivement la factorisation.

La matrice `W` contient le poids de chacun des 29 topics dans chaque segment. La matrice `H` indique, pour sa part, le poids des termes dans chaque topic. L'examen des termes les mieux pondérés permet ensuite d'interpréter et de nommer les topics.

Portée et limites de la NMF

La NMF fournit une première cartographie des régularités lexicales du corpus. Elle permet notamment de faire apparaître des ensembles liés au travail, à la religion, à la famille, à l'argent, à la guerre, au commerce, à la médecine ou encore à l'espace domestique.

Les résultats restent toutefois dépendants des choix réalisés en amont : nettoyage, segmentation, lemmatisation, catégories grammaticales conservées, liste d'exclusion, paramètres du vectoriseur et nombre de topics. La modélisation thématique ne constitue donc pas une procédure entièrement automatique, mais une démarche exploratoire associant calcul statistique et interprétation humaine.

La nomination des topics comporte également une part de subjectivité. Deux lecteurs pourraient proposer des intitulés différents pour un même groupe de termes. Ces noms doivent par conséquent être compris comme des outils d'interprétation et non comme des catégories définitives.

Enfin, puisque le prétraitement conserve principalement les noms et les adjectifs, cette analyse porte avant tout sur le contenu thématique. Elle ne permet pas, à elle

8. L'initialisation `nndsvda` est une variante de NNDSVD dans laquelle les valeurs nulles sont remplacées par la moyenne de la matrice. Voir la documentation de `scikit-learn`.

seule, de distinguer ce qui relève du naturalisme, de la signature personnelle de Zola ou des sujets particuliers de ses romans. Cette distinction sera étudiée à l'aide du corpus comparatif et de la classification automatique.

1.3.2 La méthode K-means

K-means a été utilisé comme une seconde manière d'explorer la structure du corpus. Contrairement à la NMF, qui représente chaque segment comme une combinaison de plusieurs topics, K-means attribue chaque segment à un seul cluster en fonction de sa proximité lexicale avec les autres segments.

L'objectif est de déterminer si les segments peuvent être regroupés en ensembles cohérents et si certains de ces regroupements présentent des ressemblances avec les topics obtenus par la NMF. Il ne s'agit pas d'une validation indépendante, puisque les deux méthodes utilisent la même représentation TF-IDF, mais d'une triangulation exploratoire fondée sur deux modes de structuration différents.

Préparation de la matrice TF-IDF

K-means est appliqué à la même matrice TF-IDF que la NMF. Les textes, la lemmatisation, la liste d'exclusion et les paramètres `min_df` et `max_df` restent donc identiques⁹. Ce choix garantit que les différences observées proviennent principalement du fonctionnement des deux méthodes et non d'un changement de représentation du corpus.

Recherche du nombre de clusters

Comme pour la NMF, le nombre de groupes doit être fixé avant l'entraînement du modèle. Une valeur trop faible risque de réunir des motifs distincts, tandis qu'une valeur trop élevée peut produire des clusters très proches ou difficiles à interpréter.

Plusieurs valeurs de `k`, comprises entre 2 et 40, ont été évaluées à l'aide du score de silhouette¹⁰. Ce score mesure à la fois la cohésion interne des clusters et leur séparation : une valeur élevée indique que les segments sont proches des éléments de leur propre groupe et éloignés des autres groupes.

9. Voir la section consacrée à la création de la matrice documents-termes.

10. Peter J. Rousseeuw, « Silhouettes : A Graphical Aid to the Interpretation and Validation of Cluster Analysis », *Journal of Computational and Applied Mathematics*, vol. 20, 1987, p. 53–65.




FIGURE 1.3 – Évolution du score de silhouette en fonction du nombre de clusters dans K-means

La figure 1.3 fournit une indication quantitative sur la structure du corpus, mais elle ne désigne pas à elle seule une valeur incontestable. Le modèle final a été fixé à 29 clusters afin de conserver un niveau de granularité comparable aux 29 topics de la NMF.

Ce choix facilite la confrontation des deux méthodes, mais il ne signifie pas qu’elles convergent indépendamment vers le nombre 29. Les 29 clusters ont été retenus en partie pour rendre la comparaison possible. L’analyse porte donc principalement sur les ressemblances et les différences entre les motifs lexicaux obtenus, et non sur une validation du nombre exact de groupes.

Entraînement du modèle

Le modèle final est entraîné avec `n_clusters=29`. Le paramètre `random_state=42` garantit la reproductibilité, tandis que `n_init=10` lance l’algorithme avec plusieurs initialisations et conserve la meilleure solution.

À l’issue de l’entraînement, chaque segment est rattaché à l’un des 29 clusters. Les termes les plus caractéristiques de chaque groupe et les segments qui lui sont associés servent ensuite à interpréter son contenu.

Portée et limites de K-means

La principale limite de K-means tient à son fonctionnement exclusif : chaque segment appartient à un seul cluster. Or, un passage littéraire peut faire intervenir plusieurs thèmes simultanément, par exemple la famille, l’argent et la souffrance sociale. La NMF

représente plus facilement ce type de coexistence, puisqu'elle attribue plusieurs poids thématiques à un même segment.

Les résultats de K-means sont également sensibles à la représentation TF-IDF et aux étapes de préparation du corpus. Une modification de la segmentation, de la lemmatisation ou du vocabulaire retenu pourrait produire une organisation différente. Comme pour la NMF, les clusters doivent donc être considérés comme une cartographie exploratoire plutôt que comme une classification définitive.

Enfin, leur nomination repose sur l'examen des termes et des segments les plus représentatifs. Cette interprétation humaine est nécessaire pour donner un sens littéraire aux groupes obtenus, mais elle introduit une part de subjectivité qui doit rester explicite.

Bilan méthodologique

La NMF et K-means proposent deux lectures complémentaires du corpus. La NMF décrit chaque segment comme une combinaison de topics, tandis que K-means construit une partition unique fondée sur la proximité lexicale. La comparaison de leurs résultats permet de repérer des motifs récurrents, mais ne constitue pas une validation indépendante puisque les deux méthodes reposent sur les mêmes données et la même matrice TF-IDF.

Une classification hiérarchique appliquée aux centres des clusters permet enfin de rassembler les 29 groupes en cinq familles thématiques plus générales. Cette organisation facilite la lecture des résultats, présentés dans la section suivante.

1.4 Résultats

1.4.1 Topics obtenus avec le NMF

Identification et interprétation des topics

Une fois le modèle entraîné, les mots les plus importants de chaque topic ont été extraits afin de faciliter leur interprétation. Cette étape est essentielle, car le NMF ne produit pas directement des noms de thèmes : elle produit des groupes de mots. L'attribution d'un nom à chaque topic repose donc sur une analyse qualitative des termes les plus représentatifs.

Le tableau suivant présente les dix mots les plus caractéristiques de chaque topic obtenu avec la NMF. Ces mots servent de base à l'interprétation qualitative des thèmes extraits par le modèle.

TABLE 1.5 – Mots caractéristiques des topics obtenus avec la NMF

Topic	Mots caractéristiques
Topic 1	femme, mari, chose, bon, homme, cher, ménage, histoire, vrai, plaisir
Topic 2	travail, peuple, vie, usine, bonheur, justice, ouvrier, œuvre, humanité, terre
Topic 3	arbre, soleil, herbe, eau, ciel, jardin, ombre, terre, feuille, branche
Topic 4	million, bourse, cours, action, universelle, banque, affaire, agent, hausse, titre
Topic 5	abbé, prêtre, curé, église, jardin, trouche, soutane, sous-préfecture, évêque
Topic 6	table, verre, vin, pain, café, eau, maman, assiette, bon, petit
Topic 7	main, œil, mort, bras, sang, tête, corps, face, voix, lèvre
Topic 8	franc, argent, billet, somme, mois, sou, chiffre, pièce, fortune, poche
Topic 9	monsieur, dame, porte, vou, bon, air, voix, tante, main, mot
Topic 10	rue, maison, quartier, trottoir, boutique, boulevard, ville, place, voiture, chaussée
Topic 11	train, gare, heure, machine, chef, voiture, voie, wagon, express, portière
Topic 12	grotte, saint, sœur, malade, miracle, foule, cierge, foi, prêtre, pèlerin
Topic 13	frère, sœur, modèle, petit, écriture, heure, pauvre, fine, lettre, témoin
Topic 14	cardinal, pape, éminence, livre, palais, église, prêtre, don, prélat, romain
Topic 15	école, instituteur, élève, vérité, église, classe, modèle, primaire, enseignement, juif
Topic 16	père, fils, vieux, famille, fille, ferme, terre, paysan, maison, mort
Topic 17	fosse, mineur, ouvrier, camarade, puits, coron, berline, galerie, porion, grève
Topic 18	prussien, soldat, armée, général, route, cheval, corps, canon, capitaine, homme
Topic 19	jeune, fille, homme, oncle, fine, nièce, garçon, mariage, tante, amant
Topic 20	vendeur, rayon, magasin, comptoir, soie, dame, client, vente, bonheur, confection

Topic	Mots caractéristiques
Topic 21	docteur, médecin, malade, maladie, visite, heure, jour, miracle, cher, jambe
Topic 22	tableau, toile, peintre, peinture, œuvre, atelier, art, artiste, salle, étude
Topic 23	chambre, lit, porte, heure, fenêtre, nuit, escalier, pièce, maison, meuble
Topic 24	enfant, mère, petit, fille, maman, pauvre, nourrice, bon, larme, œil
Topic 25	bel, halle, charcuterie, quenu, boutique, gras, charcutier, marchand, normande, blanc
Topic 26	salon, comte, dame, comtesse, satin, marquis, blanc, rose, femme, petit
Topic 27	empereur, ministre, député, préfet, président, colonel, politique, affaire, lettre, ami
Topic 28	amour, cœur, vie, tendresse, jour, pensée, bonheur, amant, heure, joie
Topic 29	insurgé, barricade, national, ville, fusil, garde, républicain, ouvrier, place, peuple

Chaque topic a ensuite été nommé à partir des mots dominants et de l’observation des segments les plus fortement associés à ce topic. Cette double vérification permet de limiter les erreurs d’interprétation. En effet, certains mots peuvent sembler cohérents isolément, mais prendre un sens différent lorsqu’ils sont replacés dans les extraits du corpus.

Les topics obtenus couvrent plusieurs dimensions importantes de l’œuvre de Zola. Certains renvoient à des espaces sociaux précis, comme le magasin, la mine, la bourse, le quartier ou le monde ferroviaire. D’autres correspondent à des thèmes plus transversaux, comme la famille, le désir, la maladie, la religion, la pauvreté ou la mort. Cette diversité montre que le NMF permet de faire apparaître à la fois des thèmes sociaux, des motifs narratifs et des univers propres à certains romans.

Nommer les topics

Les topics ont ensuite été nommés manuellement à partir des mots les plus représentatifs et des segments les plus fortement associés. Cette étape constitue une part qualitative importante de l’analyse. Elle permet de transformer les résultats numériques du modèle en catégories interprétables.

TABLE 1.6 – Noms attribués aux topics obtenus avec la NMF

Topic	Nom attribué
Topic 1	Les relations conjugales et la vie domestique
Topic 2	Le travail, le peuple et la justice sociale
Topic 3	La nature et le paysage
Topic 4	La bourse, la finance et les affaires
Topic 5	Le clergé et la paroisse
Topic 6	La table et les repas
Topic 7	Le corps, la souffrance et la mort
Topic 8	L'argent et la fortune
Topic 9	Les conversations et les scènes domestiques
Topic 10	Le quartier et la ville
Topic 11	Le monde ferroviaire
Topic 12	Le miracle, le pèlerinage et la religion
Topic 13	Les liens familiaux, l'écriture et les proches
Topic 14	Le pouvoir religieux
Topic 15	L'école et l'instruction
Topic 16	La famille, la terre et le monde paysan
Topic 17	Le monde ouvrier et la mine
Topic 18	La guerre, les soldats et l'armée
Topic 19	Le désir, le mariage et les relations amoureuses
Topic 20	Le magasin, la vente et les clientes
Topic 21	Le monde médical et la santé
Topic 22	Le monde artistique et la peinture
Topic 23	La chambre, le lit et l'espace intime
Topic 24	L'enfance, la maternité et la pauvreté
Topic 25	Le commerce alimentaire et les halles
Topic 26	Le salon, l'aristocratie et les scènes mondaines
Topic 27	Le pouvoir politique et les affaires publiques
Topic 28	L'amour, le bonheur et les sentiments
Topic 29	L'insurrection et la révolution

Cette étape montre que l'analyse ne repose pas uniquement sur une extraction automatique. Le modèle propose des regroupements de mots, mais leur interprétation dépend d'un travail humain. Les noms attribués aux topics doivent donc être compris comme des catégories d'analyse construites à partir des résultats du modèle, et non comme des vérités objectives produites automatiquement par l'algorithme.

1.4.2 Nombre de segments associés à chaque topic dominant

Afin d’analyser la répartition des thèmes dans le corpus, un topic dominant a été attribué à chaque segment. Pour cela, les poids de la matrice W ont d’abord été normalisés afin de rendre les contributions des topics comparables entre les segments. Le topic dominant correspond ensuite au topic dont le poids est le plus élevé pour un segment donné.

La colonne **topic_dominant** indique donc le topic le plus représenté dans chaque paquet de phrases. La colonne **poids_topic** mesure l’intensité de cette association : plus cette valeur est élevée, plus le segment est clairement associé à un topic spécifique. À l’inverse, un poids faible peut signaler un segment plus mixte, contenant plusieurs thèmes ou ne correspondant fortement à aucun topic.

Cette attribution permet de passer d’une simple liste de topics à une analyse plus structurée de leur répartition dans le corpus. Elle rend possible l’étude du nombre de segments associés à chaque topic, du poids moyen des topics dans l’ensemble du corpus et de leur présence selon les romans. Le tableau suivant présente le nombre de segments associés à chaque topic dominant.

TABLE 1.7 – Nombre de segments associés à chaque topic dominant

Topic dominant	Nombre de segments
L’amour, le bonheur et les sentiments	335
La chambre, le lit et l’espace intime	327
Le pouvoir politique et les affaires publiques	266
Le salon, l’aristocratie et les scènes mondaines	266
Le travail, le peuple et la justice sociale	262
La nature et le paysage	229
L’enfance, la maternité et la pauvreté	221
Le corps, la souffrance et la mort	218
La table et les repas	214
Le clergé et la paroisse	210
Le quartier et la ville	205
L’argent et la fortune	187
Le monde ouvrier et la mine	185
La famille, la terre et le monde paysan	180
Le miracle, le pèlerinage et la religion	177
Le désir, le mariage et les relations amoureuses	173
La guerre, les soldats et l’armée	173
L’école et l’instruction	168
Le monde médical et la santé	164

Topic dominant	Nombre de segments
Le commerce alimentaire et les halles	163
Les conversations et les scènes domestiques	162
Le monde artistique et la peinture	141
Le pouvoir religieux	140
Le magasin, la vente et les clientes	136
L'insurrection et la révolution	127
Les liens familiaux, l'écriture et les proches	104
Le monde ferroviaire	94
La bourse, la finance et les affaires	69
Les relations conjugales et la vie domestique	31

La répartition des segments montre que les topics ne sont pas représentés de manière parfaitement équilibrée. Certains thèmes regroupent un nombre important de segments, tandis que d'autres apparaissent de façon plus marginale. Cette variation est attendue dans un corpus littéraire, car tous les motifs thématiques ne sont pas présents avec la même intensité dans l'ensemble des romans.

Les topics les plus représentés correspondent aux thèmes qui structurent fortement le corpus. Les premiers résultats font apparaître des motifs liés aux sentiments, à l'espace intime, aux relations sociales, au pouvoir politique, aux scènes mondaines ou encore au travail. Ces ensembles renvoient à des dimensions récurrentes de l'œuvre de Zola, dans laquelle les expériences individuelles sont souvent articulées à des milieux sociaux, familiaux, économiques ou institutionnels.

À l'inverse, les topics les moins représentés ne doivent pas être considérés comme moins importants sur le plan littéraire. Ils peuvent correspondre à des univers plus localisés, associés à certains romans précis ou à des situations narratives particulières. C'est notamment le cas de thèmes comme la bourse, le monde ferroviaire ou certaines formes de relations domestiques, qui peuvent être fortement présents dans quelques œuvres sans être répartis de manière uniforme dans l'ensemble du corpus.

Cette distribution montre donc que la NMF ne produit pas seulement une liste de thèmes interprétables : elle permet aussi d'évaluer leur poids relatif dans le corpus. Le nombre de segments associés à chaque topic donne une première indication de l'importance quantitative des thèmes extraits. Cette mesure doit toutefois être interprétée avec prudence : un topic fréquent n'est pas nécessairement plus important sur le plan littéraire, mais il est plus présent lexicalement dans les segments analysés.

Enfin, cette attribution des topics dominants peut servir de base à des analyses complémentaires. Elle permet notamment d'étudier la distribution des topics par œuvre, de comparer les romans entre eux, ou encore d'appliquer ultérieurement un détecteur

de motifs aux segments associés à chaque topic afin d'identifier les motifs narratifs les plus caractéristiques de chaque thème.

1.4.3 Clusters obtenus avec K-means

Extraction des mots caractéristiques des clusters

Une fois le modèle entraîné, les centres des clusters ont été analysés afin d'identifier les termes les plus représentatifs de chaque groupe. Dans K-means, chaque cluster est représenté par un centroïde, c'est-à-dire un point moyen dans l'espace vectoriel. Les termes les plus fortement associés à ce centroïde permettent de comprendre le contenu thématique du cluster.

Cette étape est comparable à l'extraction des mots dominants dans la NMF. Elle permet d'associer chaque cluster à un ensemble de termes caractéristiques. Cependant, l'interprétation est légèrement différente : dans la NMF, les mots sont associés à un topic latent ; dans K-means, ils décrivent le centre lexical d'un groupe de segments. Autrement dit, les mots obtenus indiquent ce qui rapproche les segments d'un même cluster.

TABLE 1.8 – Mots caractéristiques des clusters obtenus avec K-means

Cluster	Mots caractéristiques
Cluster 1	verre, petit, table, maman, coup, femme, vin, eau, tête, homme
Cluster 2	instituteur, école, enfant, vérité, élève, petit, église, père, classe, bon
Cluster 3	salon, dame, femme, monsieur, petit, blanc, satin, homme, jeune, rose
Cluster 4	chambre, porte, lit, monsieur, heure, femme, petit, maison, escalier, fenêtre
Cluster 5	enfant, femme, nourrice, petit, usine, constance, fille, mari, monsieur, cher
Cluster 6	mère, fille, petit, enfant, père, femme, fils, bon, jeune, œil
Cluster 7	train, gare, chef, machine, voie, heure, express, mécanicien, tunnel, voyageur
Cluster 8	amour, cœur, vie, jeune, enfant, femme, fille, jour, homme, tendresse
Cluster 9	comte, comtesse, monsieur, scène, loge, femme, prulière, homme, théâtre, dame
Cluster 10	abbé, prêtre, curé, monsieur, église, bon, tête, petit, frère, enfant
Cluster 11	arbre, soleil, herbe, ciel, eau, ombre, jardin, blanc, haut, terre

Cluster	Mots caractéristiques
Cluster 12	grotte, saint, miracle, cierge, prêtre, malade, foule, foi, père, église
Cluster 13	docteur, médecin, monsieur, enfant, mère, petit, malade, heure, œil, lit
Cluster 14	sœur, malade, hyacinthe, wagon, saint, train, petit, compartiment, pèlerin, grotte
Cluster 15	insurgé, ville, national, fusil, barricade, républicain, homme, garde, ouvrier, rue
Cluster 16	rue, boutique, trottoir, petit, quartier, maison, femme, bel, halle, heure
Cluster 17	femme, jeune, amant, chambre, main, pensée, œil, bras, nuit, homme
Cluster 18	empereur, ministre, monsieur, député, colonel, homme, affaire, préfet, gouvernement, ami
Cluster 19	travail, vie, enfant, terre, petit, usine, ouvrier, peuple, œuvre, homme
Cluster 20	bourse, million, franc, action, cours, banque, universelle, monsieur, hausse, argent
Cluster 21	franc, argent, monsieur, femme, homme, jeune, jour, billet, somme, bon
Cluster 22	monsieur, dame, femme, petit, porte, bon, fille, air, homme, chambre
Cluster 23	tableau, peintre, toile, peinture, œuvre, art, atelier, femme, artiste, salon
Cluster 24	fosse, mineur, coron, camarade, berline, homme, ouvrier, puits, grève, porion
Cluster 25	vendeur, rayon, magasin, comptoir, dame, soie, vente, client, bonheur, franc
Cluster 26	prussien, soldat, armée, général, route, homme, cheval, capitaine, corps, canon
Cluster 27	cardinal, pape, palais, éminence, livre, prêtre, monde, église, peuple, prélat
Cluster 28	frère, modèle, petit, père, vérité, président, homme, crime, justice, écriture
Cluster 29	père, terre, vieux, petit, coup, bon, vache, homme, paysan, bête

Cette extraction permet de vérifier la cohérence interne des clusters. Lorsqu'un cluster rassemble des mots appartenant au même champ lexical, il devient plus facilement

interprétable. À l'inverse, un cluster contenant des mots trop dispersés ou peu cohérents peut indiquer un regroupement moins stable ou plus difficile à nommer.

Nomination des clusters

Les clusters ont ensuite été nommés manuellement à partir des mots les plus représentatifs et de l'observation des segments associés. Cette étape est indispensable, car K-means ne produit pas directement des intitulés interprétables. Comme pour la NMF, le passage du résultat numérique à l'interprétation thématique repose donc sur une lecture qualitative et est lié à l'interprétation humaine (chaque noms de clusters peut donc être remis en cause).

TABLE 1.9 – Noms attribués aux clusters obtenus avec K-means

Cluster	Nom attribué
Cluster 1	La table, les repas et les boissons
Cluster 2	L'école, les élèves et l'instruction
Cluster 3	Le salon, l'aristocratie et les apparences
Cluster 4	La chambre, le lit et l'espace domestique
Cluster 5	L'enfance, la maternité et la pauvreté
Cluster 6	La mère, les enfants et la famille
Cluster 7	Le monde ferroviaire
Cluster 8	L'amour, les sentiments et la jeunesse
Cluster 9	Le théâtre, la loge et les scènes mondaines
Cluster 10	Le clergé et la paroisse
Cluster 11	La nature et le paysage
Cluster 12	Le miracle, le pèlerinage et la religion
Cluster 13	Le monde médical et la santé
Cluster 14	Le pèlerinage, la maladie et le voyage
Cluster 15	L'insurrection et la révolution
Cluster 16	Le quartier, la rue et la ville
Cluster 17	Le désir, le corps et les relations amoureuses
Cluster 18	Le pouvoir politique et les affaires publiques
Cluster 19	Le travail, le peuple et le monde ouvrier
Cluster 20	La bourse, la finance et les affaires
Cluster 21	L'argent du quotidien
Cluster 22	Les conversations et les scènes domestiques
Cluster 23	Le monde artistique et la peinture
Cluster 24	La mine, les ouvriers et la grève
Cluster 25	Le magasin, la vente et les clientes

Cluster	Nom attribué
Cluster 26	La guerre, les soldats et l'armée
Cluster 27	Le pouvoir religieux
Cluster 28	Les liens familiaux, l'écriture et la justice
Cluster 29	La terre, les animaux et le monde paysan

Les intitulés obtenus montrent que les clusters couvrent des dimensions proches de celles observées avec la NMF. On retrouve par exemple des ensembles liés au travail, à la mine, à la finance, à la religion, à la famille, au monde domestique, à la guerre ou encore aux espaces urbains.

Cependant, les clusters K-means ne doivent pas être interprétés comme des catégories fixes ou naturelles. Ils résultent d'un regroupement algorithmique fondé sur la proximité lexicale des segments. Leur nomination repose donc sur un choix interprétatif, à partir des mots les plus représentatifs et des extraits textuels associés.

Regroupement hiérarchique des clusters

Afin de compléter l'analyse des clusters obtenus avec K-means, une classification ascendante hiérarchique a été appliquée aux centroïdes des 29 clusters. Cette étape permet d'examiner les proximités entre clusters et de regrouper ceux qui présentent des profils lexicaux similaires. Elle offre ainsi une lecture plus synthétique de la structure thématique du corpus, en passant d'une analyse détaillée cluster par cluster à une organisation en grandes familles de motifs.

La méthode de Ward a été retenue pour construire cette hiérarchie. Elle consiste à fusionner progressivement les clusters en minimisant l'augmentation de la variance interne à chaque regroupement. Le dendrogramme obtenu permet de visualiser les distances entre clusters et d'identifier les principaux rapprochements thématiques¹¹.

11. Ludovic Lebart et André Salem, *Statistique textuelle*, Paris, Dunod, 1994.




FIGURE 1.4 – Dendrogramme de la classification hiérarchique des clusters K-means

Dans cette analyse, le seuil de distance a été fixé à 0,40 afin de découper l'arbre hiérarchique en grandes familles de motifs. Ce regroupement rend les résultats plus lisibles : les 29 clusters initiaux peuvent être interprétés non seulement individuellement, mais aussi comme des ensembles thématiques plus larges. Cette organisation facilite ensuite la comparaison entre les motifs dominants du corpus et leur répartition dans les romans de Zola.

Création des grandes familles de motifs

À partir du dendrogramme, les clusters ont été regroupés en cinq grandes familles de motifs. Cette opération permet de simplifier l'analyse et de faire apparaître les grandes zones thématiques du corpus.




FIGURE 1.5 – Regroupement des clusters K-means en grandes familles de motifs

Les groupes obtenus ont ensuite été nommés manuellement, en fonction des clusters qu'ils rassemblent. Le tableau suivant présente la composition de chaque grande famille de motifs.

TABLE 1.10 – Composition des grandes familles de motifs issues des clusters K-means

Groupe	Clusters associés
Groupe 1	Cluster 12 : Le miracle, le pèlerinage et la religion ; Cluster 14 : Le pèlerinage, la maladie et le voyage.
Groupe 2	Cluster 2 : L'école, les élèves et l'instruction ; Cluster 10 : Le clergé et la paroisse ; Cluster 27 : Le pouvoir religieux ; Cluster 28 : Les liens familiaux, l'écriture et la justice.
Groupe 3	Cluster 9 : Le théâtre, la loge et les scènes mondaines ; Cluster 18 : Le pouvoir politique et les affaires publiques ; Cluster 20 : La bourse, la finance et les affaires ; Cluster 21 : L'argent du quotidien ; Cluster 22 : Les conversations et les scènes domestiques ; Cluster 25 : Le magasin, la vente et les clientes.
Groupe 4	Cluster 15 : L'insurrection et la révolution ; Cluster 26 : La guerre, les soldats et l'armée.
Groupe 5	Cluster 1 : La table, les repas et les boissons ; Cluster 3 : Le salon, l'aristocratie et les apparences ; Cluster 4 : La chambre, le lit et l'espace domestique ; Cluster 5 : L'enfance, la maternité et la pauvreté ; Cluster 6 : La mère, les enfants et la famille ; Cluster 7 : Le monde ferroviaire ; Cluster 8 : L'amour, les sentiments et la jeunesse ; Cluster 11 : La nature et le paysage ; Cluster 13 : Le monde médical et la santé ; Cluster 16 : Le quartier, la rue et la ville ; Cluster 17 : Le désir, le corps et les relations amoureuses ; Cluster 19 : Le travail, le peuple et le monde ouvrier ; Cluster 23 : Le monde artistique et la peinture ; Cluster 24 : La mine, les ouvriers et la grève ; Cluster 29 : La terre, les animaux et le monde paysan.

Ces grandes familles permettent d'obtenir une lecture plus synthétique des résultats. La première famille regroupe les motifs liés au miracle, au pèlerinage et à la religion. La deuxième rassemble des clusters associés aux formes d'encadrement social, religieux, scolaire et familial. La troisième renvoie davantage aux espaces sociaux, économiques et mondains, en regroupant notamment la finance, le commerce, le théâtre et les conversations domestiques. La quatrième famille réunit les motifs du conflit collectif, de l'insurrection et de la guerre. Enfin, la cinquième regroupe un ensemble plus large de motifs liés à la vie quotidienne, aux espaces sociaux, au travail, à la famille, à la nature et aux expériences individuelles.

Cette structuration est particulièrement utile pour l'analyse littéraire, car elle permet de passer d'une liste de clusters nombreux à une organisation thématique plus lisible.

Elle montre aussi que les motifs extraits par K-means ne sont pas isolés, mais peuvent être regroupés en ensembles plus larges correspondant à des dimensions importantes de l'œuvre de Zola.

Attribution des grandes familles aux segments

Une fois les groupes hiérarchiques définis, chaque segment du corpus a reçu une étiquette correspondant à la grande famille de motifs associée à son cluster¹². Cette opération permet d'analyser non seulement les clusters détaillés, mais aussi les grandes catégories thématiques dans lesquelles ils s'inscrivent.




FIGURE 1.6 – Noms attribués aux grandes familles de motifs

Cette étape permet de relier chaque paquet de phrases à deux niveaux d'analyse. Le premier niveau est le cluster K-means, qui fournit une catégorie thématique fine. Le second niveau est le groupe CAH, qui fournit une catégorie plus générale. Cette double échelle d'interprétation est utile, car elle permet d'adapter le niveau de détail selon les besoins de l'analyse : on peut étudier les motifs précis, ou bien observer les grandes tendances du corpus.

Analyse de la répartition des clusters

Après la nomination des clusters et des grandes familles, plusieurs visualisations ont été produites afin d'étudier leur répartition dans le corpus. La première consiste à compter le nombre de segments associés à chaque grande famille de motifs.

12. Voir code sur Github.




FIGURE 1.7 – Distribution des grandes familles de motifs dans le corpus

Cette visualisation permet d’identifier les grandes familles les plus représentées dans l’ensemble du corpus. Elle donne une lecture globale de l’organisation thématique des segments. Une famille très représentée indique qu’un ensemble de motifs revient fréquemment dans les romans, tandis qu’une famille moins présente peut correspondre à un thème plus spécifique, associé à certains romans ou à certaines situations narratives.

Une seconde visualisation a été produite à l’échelle des clusters détaillés.




FIGURE 1.8 – Distribution des clusters K-means dans le corpus

Cette représentation permet de voir quels clusters sont les plus fréquents dans le corpus. Elle est plus précise que l'analyse par grandes familles, car elle distingue les motifs thématiques particuliers. Elle permet par exemple d'observer séparément les clusters associés à la mine, à la finance, à la religion, à la famille ou au monde domestique.

1.5 Comparaison des deux méthodes

La NMF et K-means ont été appliqués au même corpus et à la même représentation TF-IDF, mais ils n'en proposent pas la même lecture. La NMF fait apparaître des topics latents auxquels chaque segment est associé avec des poids variables. K-means répartit au contraire les segments en groupes lexicaux distincts. Leur comparaison permet d'identifier les régularités qui se retrouvent dans les deux organisations du corpus, ainsi que les différences liées au fonctionnement de chaque méthode.

1.5.1 Deux représentations complémentaires

La NMF offre une représentation graduelle des thèmes. Un même segment peut être associé à plusieurs topics, par exemple la famille, l'argent et l'espace domestique,

avec une importance différente pour chacun. Cette souplesse correspond assez bien à la complexité des textes littéraires, dans lesquels plusieurs dimensions thématiques peuvent coexister.

K-means produit une organisation plus catégorielle : chaque segment est rattaché à un seul cluster, celui dont il est le plus proche dans l'espace vectoriel. Cette méthode fait ainsi apparaître des groupes lexicaux plus nettement séparés, mais rend moins visible la coexistence de plusieurs thèmes dans un même passage.

Les deux approches ne sont donc pas concurrentes. La NMF décrit la composition thématique des segments, tandis que K-means propose une partition générale du corpus. Leur rapprochement constitue une triangulation exploratoire, mais pas une validation indépendante, puisque les deux modèles utilisent les mêmes données et la même matrice TF-IDF.

1.5.2 Convergences lexicales et thématiques

La comparaison des termes caractéristiques fait apparaître plusieurs ensembles communs aux topics NMF et aux clusters K-means. Les deux méthodes repèrent notamment des motifs liés au travail et à la mine, à l'argent et à la finance, à la religion, à la famille, à la guerre, au commerce, aux espaces urbains et à la vie domestique.

Ces rapprochements montrent que certains champs lexicaux occupent une place structurante dans le corpus. Ils ne signifient toutefois pas que les résultats sont identiques. Un topic NMF peut réunir plusieurs dimensions que K-means répartit entre différents clusters. À l'inverse, un cluster peut rassembler des segments lexicalement proches dont l'interprétation thématique reste assez large.

La convergence entre les méthodes doit donc être appréciée à l'échelle des grands motifs plutôt qu'à travers une correspondance exacte entre chaque topic et chaque cluster. Comme les deux analyses reposent sur le même prétraitement, elle ne suffit pas à prouver l'existence de catégories thématiques objectives. Elle indique néanmoins que certains motifs résistent au changement de méthode de regroupement.

1.5.3 Distribution des topics NMF par œuvre

Pour étudier la répartition des topics dans les romans, chaque segment a été associé au topic possédant le poids NMF le plus élevé. Une table croisée entre les œuvres et les topics dominants a ensuite été construite et normalisée par ligne. Cette normalisation indique, pour chaque roman, la proportion de segments dominés par chacun des 29 topics.




FIGURE 1.9 – Proportion des segments par topic NMF dominant et par œuvre

La figure 1.9 fait apparaître des associations attendues entre certaines œuvres et certains thèmes. Le monde de la mine et du travail ouvrier occupe ainsi une place importante dans *Germinal*, tandis que la finance ressort davantage dans *L'Argent*. Le commerce est particulièrement visible dans *Au Bonheur des dames*, et la guerre dans *La Débâcle*.

D'autres topics sont répartis entre plusieurs romans et correspondent à des motifs plus transversaux, comme la famille, les relations sociales, la religion ou l'espace domestique. La normalisation par œuvre évite que les romans les plus longs soient automatiquement surreprésentés et facilite ainsi la comparaison de leurs profils thématiques.

Cette visualisation repose néanmoins sur le topic dominant de chaque segment. Elle simplifie donc la représentation fournie par la NMF, puisqu'elle ne montre pas les topics secondaires également présents dans les passages.

1.5.4 Distribution des clusters K-means par œuvre

Une seconde heatmap présente la répartition des clusters K-means dans chaque roman. Comme pour la NMF, les valeurs sont exprimées sous forme de proportions afin de neutraliser autant que possible les différences de longueur entre les œuvres.




FIGURE 1.10 – Distribution des clusters K-means par œuvre

La figure 1.10 fait apparaître plusieurs associations proches de celles obtenues par la NMF. *Germinal* se distingue par le cluster consacré à la mine, aux ouvriers et à la grève. *L'Argent* est fortement associé à la finance et aux affaires, tandis que *La Débâcle* se caractérise par le vocabulaire des soldats, de l'armée et de la guerre. Le cluster lié au magasin, à la vente et aux clients est particulièrement présent dans *Au Bonheur des dames*.

Ces rapprochements confirment que plusieurs œuvres possèdent un profil lexical fortement lié à leur univers narratif. La comparaison révèle également des différences : K-means impose un seul cluster à chaque segment, alors que la NMF peut y détecter plusieurs composantes thématiques. La distribution obtenue par K-means paraît donc généralement plus tranchée.

1.5.5 Regroupement en grandes familles

Afin de rendre les 29 clusters plus faciles à interpréter, une classification hiérarchique a été appliquée à leurs centres. Elle permet de les réunir en cinq familles thématiques plus générales.




FIGURE 1.11 – Distribution des grandes familles de clusters K-means par œuvre

La figure 1.11 synthétise la distribution de ces familles dans les romans. Elle distingue les motifs liés à l'argent et à la circulation financière, aux conflits politiques et militaires, aux institutions et à l'encadrement social, à la religion et à l'autorité cléricale, ainsi qu'à la vie quotidienne et aux expériences individuelles.

Cette représentation simplifie la lecture générale du corpus. La famille consacrée à la vie quotidienne est présente dans la majorité des œuvres, tandis que les autres ensembles apparaissent de manière plus concentrée. Les motifs financiers sont notamment visibles dans *L'Argent*, les conflits militaires dans *La Débâcle*, et la religion dans les romans où l'autorité ecclésiastique occupe une place centrale.

1.5.6 Apport de la double approche

La comparaison entre NMF et K-means permet finalement d'articuler deux niveaux d'analyse. La NMF rend compte du caractère souvent multiple des thèmes présents dans un segment, tandis que K-means propose une organisation plus nette des proximités lexicales. Leur rapprochement aide ainsi à distinguer les motifs récurrents des regroupements davantage liés au fonctionnement d'un modèle particulier.

Lorsque les résultats convergent, ils renforcent l'hypothèse qu'un motif occupe une place importante dans le corpus zolien. Lorsqu'ils divergent, l'examen des segments concernés permet de mieux comprendre les limites de chaque représentation. Ces

régularités doivent cependant rester considérées comme des caractéristiques internes à l'œuvre de Zola. Leur éventuelle association au naturalisme devra être évaluée à partir du corpus comparatif et de la classification automatique.

1.6 Conclusion sur le Topic Modeling

Cette étude avait pour objectif d'identifier des structures thématiques récurrentes dans l'œuvre romanesque de Zola à partir de méthodes non supervisées. Le corpus a d'abord été nettoyé, segmenté en paquets de phrases, puis lemmatisé afin de produire des unités textuelles comparables et exploitables par les modèles.

L'application de le NMF a permis de faire apparaître des topics interprétables, associés à des dimensions importantes de l'univers de zola : le travail, la mine, la religion, la famille, l'argent, la guerre, le commerce, la ville ou encore l'espace domestique. Le recours à K-means a ensuite permis de regrouper les segments selon leur proximité lexicale et d'observer des familles de motifs complémentaires et de retrouver partiellement les resultats obtenu avec la methode du NMF.

La comparaison des deux méthodes montre que certains ensembles thématiques apparaissent de manière stable, malgré des fonctionnements algorithmiques différents. le NMF offre une lecture plus graduelle des thèmes, tandis que K-means produit une classification plus nette des segments. Leur combinaison permet donc de renforcer l'analyse en croisant deux formes de structuration du corpus.

Ces résultats doivent toutefois être interprétés avec prudence. Ils dépendent des choix de nettoyage, de lemmatisation, de segmentation, de vectorisation et du nombre de topics ou de clusters retenus. Je tiens donc à appuyer que ces méthodes reposent donc sur une validation qualitative. L'analyse proposée ne remplace donc pas une lecture littéraire des textes, mais elle fournit un outil exploratoire permettant de repérer des régularités lexicales et thématiques à l'échelle d'un corpus volumineux.

Chapitre 2

Dynamique Topic modeling sur le corpus de d'Émile Zola

2.1 Présentation du corpus et des données

2.1.1 Objectif et organisation du corpus

Ce chapitre prolonge l'analyse thématique statique menée au chapitre 1 en étudiant la distribution des topics dans la chronologie de l'œuvre romanesque d'Émile Zola. Il ne met toutefois pas en œuvre un modèle thématique dynamique au sens génératif : l'année de publication n'intervient ni dans le calcul des embeddings, ni dans la réduction de dimension, ni dans la formation ou la représentation globale des groupes. Elle n'est mobilisée qu'après la sélection du modèle BERTopic, afin de suivre la fréquence de topics fixes au cours de la carrière de l'écrivain. Cette démarche permet d'observer des permanences et des inflexions thématiques sans imposer au préalable une trajectoire temporelle aux documents.

Le corpus source reprend les mêmes œuvres que celui du chapitre précédent¹ : il réunit 31 romans publiés entre 1865 et 1903. L'année est extraite du nom de chaque fichier, puis les œuvres et leurs segments sont classés chronologiquement. Chaque segment conserve ainsi son roman d'origine, son année de publication et sa position dans le texte.

Deux versions synchronisées de chaque segment sont utilisées. Le texte non lemmatisé sert au calcul des embeddings avec le modèle `dangvantuan/sentence-camembert-base`, qui produit des vecteurs de 768 dimensions. Une seconde version est obtenue avec le modèle `spaCy fr_core_news_lg` : seuls les noms, les adjectifs et les verbes sont conservés sous leur forme lemmatisée, tandis que la ponctuation, les nombres, les espaces et les lemmes de moins de deux caractères sont écartés. Le prétraitement n'applique donc

1. Voir le chapitre 1, section consacrée à la présentation des données.

pas, à ce stade, de liste générale de mots vides. Les segments lemmatisés servent à la représentation lexicale des topics et au calcul de leur cohérence, tandis que les textes non lemmatisés préservent le contexte nécessaire à leur représentation sémantique.

2.1.2 Segmentation et statistiques descriptives

La segmentation est directement déterminée par la capacité du modèle `sentence-camembert-base`. Celui-ci accepte au maximum 128 tokens, tokens spéciaux compris². Le programme vise donc des segments d'environ 110 tokens de contenu et réserve l'espace nécessaire aux tokens ajoutés par CamemBERT. Les unités textuelles non vides sont regroupées tant que cette limite n'est pas dépassée ; lorsqu'une unité est trop longue pour tenir seule, elle est exceptionnellement découpée. La fin de chaque roman est systématiquement conservée, même lorsqu'elle forme un segment très court.

TABLE 2.1 – Longueur des segments produits, en tokens CamemBERT

Indicateur	Nombre de tokens
Nombre de segments	61 435
Moyenne	105,37
Écart-type	19,77
Minimum	4
Cinquième percentile	65
Premier quartile	96
Médiane	112
Troisième quartile	120
Quatre-vingt-quinzième percentile	127
Maximum	128

Cette procédure produit d'abord 61 435 segments. Leur longueur moyenne s'élève à 105,37 tokens et leur médiane à 112 tokens. La moitié des segments se situe entre 96 et 120 tokens ; les cinquième et quatre-vingt-quinzième percentiles atteignent respectivement 65 et 127 tokens. La distribution reste donc concentrée autour de la taille visée, tout en respectant le plafond de 128 tokens imposé par le modèle. Les valeurs les plus faibles correspondent à des unités très brèves qui ne peuvent être rattachées à une unité voisine sans franchir ce plafond ; elles sont conservées plutôt qu'écartées.

La lemmatisation laisse ensuite trois segments sans contenu lexical exploitable — deux occurrences de « Ah ! » et une de « Oh ! » — qui sont retirés. Le corpus effectivement transmis à BERTopic comprend ainsi 61 432 segments issus de 31 romans. Le tableau de données final associe à chacun le titre du roman, l'année de publication, le rang chronologique de l'œuvre, sa position dans le roman, le texte non lemmatisé, son nombre de tokens CamemBERT et sa version lemmatisée. Les embeddings correspondants

2. Fiche du modèle sur Hugging Face

forment une matrice de $61\,432 \times 768$, dont l’alignement avec les segments est contrôlé avant la modélisation.

2.2 Utilisation de BERTopic

Cette section présente uniquement la construction et la sélection du modèle BERTopic. Elle s’appuie sur le notebook `01_recherche_hyperparametres.ipynb`. L’année de publication et l’ordre des romans ne participent pas à la formation des topics : ils ne sont réintroduits qu’au moment de l’analyse temporelle.

2.2.1 Architecture du modèle

BERTopic combine quatre opérations : la création d’embeddings, leur réduction-dimensionnelle avec UMAP, leur regroupement par HDBSCAN et la représentation lexicale des groupes par c-TF-IDF³. Le nombre de topics n’est donc pas fixé à l’avance, mais déterminé par la structure du corpus.

Les 61 432 segments sont représentés par des vecteurs de 768 dimensions produits avec `dangvantuan/sentence-camembert-base`⁴. Les embeddings sont calculés sur le texte non lemmatisé afin de préserver son contexte, tandis que les segments lemmatisés servent à nommer et à évaluer les topics.

UMAP projette les embeddings dans un espace plus compact, puis HDBSCAN repère les zones denses et attribue l’étiquette `-1` aux documents qu’il ne peut rattacher avec suffisamment de confiance⁵. Pour chaque groupe, le c-TF-IDF fait ensuite ressortir les termes qui le distinguent du reste du corpus. Le `CountVectorizer` conserve les unigrammes présents dans au moins deux segments et dans au plus 80 % du corpus ; la pondération BM25 et la réduction des mots fréquents limitent la domination des termes les plus communs.

2.2.2 Recherche et sélection des hyperparamètres

La grille présentée dans le tableau 2.2 comprend $3 \times 4 \times 3 \times 2 = 72$ configurations. Les valeurs de `min_cluster_size` correspondent approximativement à 0,3 %, 0,4 % et 0,5 % des documents. UMAP conserve une distance cosinus, `min_dist=0.0` et la graine 42 ; HDBSCAN utilise une distance euclidienne et la méthode d’extraction `eom`.

3. Maarten Grootendorst, « BERTopic : Neural topic modeling with a class-based TF-IDF procedure », 2022, article original ; documentation de BERTopic, consultés le 28 juillet 2026.

4. Fiche du modèle sur Hugging Face, consultée le 28 juillet 2026.

5. Leland McInnes, John Healy et James Melville, « UMAP : Uniform Manifold Approximation and Projection for Dimension Reduction », 2018 ; Ricardo J. G. B. Campello, Davoud Moulavi et Jörg Sander, « Density-Based Clustering Based on Hierarchical Density Estimates », 2013.

TABLE 2.2 – Grille de recherche et configuration BERTopic retenue

Composant	Paramètre	Valeurs testées	Valeur retenue
UMAP	n_neighbors	40, 50, 60	50
UMAP	n_components	5, 10, 15, 20	20
HDBSCAN	min_cluster_size	184, 246, 307	246
HDBSCAN	min_samples	1, 2	1

Les 72 modèles sont évalués sur les mêmes documents et embeddings. Trois filtres écartent les partitions peu exploitables : moins de dix topics, plus de 75 % de documents étiquetés -1, ou un topic réunissant plus de 40 % des documents assignés. Vingt-deux configurations satisfont ces conditions.

Leur classement combine la cohérence C_v , la silhouette, le DBCV, la diversité lexicale, la couverture et l'équilibre des topics⁶. Après conversion de chaque indicateur en rang percentile, le score est calculé ainsi :

$$S_{\text{global}} = 0,30R_{C_v} + 0,20R_{\text{sil}} + 0,15R_{\text{DBCV}} + 0,15R_{\text{div}} + 0,10R_{\text{couv}} + 0,10R_{\text{équ}}.$$

La stabilité des quinze meilleures configurations est ensuite contrôlée avec les graines 11, 30, 42, 57 et 73. L'indice de Rand ajusté (ARI)⁷ compare les partitions sur l'ensemble du corpus, puis sur les seuls documents assignés dans les deux exécutions⁸. Le rang de ce second ARI complète le classement initial :

$$S_{\text{final}} = 0,80S_{\text{global}} + 0,20R_{\text{stabilité}}.$$

2.2.3 Configuration retenue

La configuration retenue occupe le quatrième rang du classement final. Elle produit 17 topics avec la graine 42, contre 13 pour la première solution du classement. Ce choix conserve ainsi une granularité plus fine, tout en maintenant une stabilité élevée : l'ARI moyen atteint 0,861 sur les documents assignés dans les deux exécutions et 0,652 sur l'ensemble du corpus. Selon la graine, le modèle produit en moyenne 16,8 topics, avec un écart-type de 0,4.

Réentraînée dans le notebook `02_exploration_modele.ipynb`, cette configuration

6. Peter J. Rousseeuw, « Silhouettes : A graphical aid to the interpretation and validation of cluster analysis », 1987 ; Davoud Moulavi et al., « Density-Based Clustering Validation », 2014, ; Michael Röder, Andreas Both et Alexander Hinneburg, « Exploring the Space of Topic Coherence Measures », 2015.

7. W. M. Rand, « Objective criteria for the evaluation of clustering methods », *Journal of the American Statistical Association*, vol. 66, n° 336, 1971, p. 846-850.

8. Lawrence Hubert et Phipps Arabie, « Comparing Partitions », 1985.

retrouve 17 topics. HDBSCAN classe d’abord 76,5 % des segments dans le bruit. Ce taux brut traduit une partition conservatrice et ne correspond pas au résultat utilisé pour l’analyse : la réaffectation ultérieure de ces documents est examinée dans la section suivante. Le modèle retenu reste donc un compromis méthodologique, et non la preuve d’un découpage thématique unique du corpus.

2.3 Validation interne du modèle

Avant d’interpréter les topics et leur évolution, il convient d’évaluer la partition sur laquelle repose l’analyse. En l’absence de catégories de référence, cette démarche ne peut établir l’existence d’un découpage thématique unique : elle associe des indices internes de partition, fondés sur la séparation et la stabilité des groupes, à des mesures intrinsèques de la représentation des topics⁹.

Trois états doivent être distingués. Le premier correspond à la configuration retenue lors de la recherche d’hyperparamètres ; le deuxième à son réentraînement dans le notebook `02_exploration_modele.ipynb` ; le troisième au modèle utilisé pour l’analyse, après réaffectation des documents atypiques et mise à jour du c-TF-IDF. Cette distinction est nécessaire, car les indicateurs ne sont pas tous recalculés à chaque étape.

2.3.1 Séparation et stabilité de la partition

Lors de la grille de recherche, la configuration retenue produit 17 topics et assigne 17 564 des 61 432 segments. Les 43 868 autres reçoivent l’étiquette -1, soit un taux de bruit de 71,4 %. Parmi les documents assignés, les topics comprennent entre 258 et 5 690 segments, avec une médiane de 547 ; le plus important représente 32,4 % des documents assignés.

Pour un document i , la silhouette compare sa distance moyenne $a(i)$ aux documents de son topic à la plus faible distance moyenne $b(i)$ qui le sépare d’un autre topic¹⁰ :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}.$$

La silhouette moyenne, calculée dans l’espace UMAP sur un échantillon reproductible d’au plus 4 000 documents assignés, atteint 0,376. Cette valeur positive indique que ces documents sont en moyenne plus proches de leur propre groupe que des groupes voisins, sans pour autant montrer une séparation nette.

9. Maria HALKIDI, Yannis BATISTAKIS et Michalis VAZIRGIANNIS (2001). « On Clustering Validation Techniques ». In : *Journal of Intelligent Information Systems* 17, p. 107-145

10. Peter J. ROUSSEEUW (nov. 1987). « Silhouettes : A graphical aid to the interpretation and validation of cluster analysis ». In : *Journal of Computational and Applied Mathematics* 20, p. 53-65

Le DBCV complète cette mesure en évaluant la compacité et la séparation de clusters de densité dans la projection UMAP¹¹. Les segments étiquetés -1 ne forment pas un cluster ordinaire ; la valeur doit donc être lue conjointement avec le taux de bruit. Elle est ici légèrement négative ($-0,035$) et ne fournit pas d’argument en faveur d’une séparation globale satisfaisante. Les deux mesures décrivent plutôt un noyau assigné partiellement structuré au sein d’une partition globale fragile.

La robustesse aux graines d’initialisation est évaluée avec les graines 11, 30, 42, 57 et 73. Les partitions sont comparées par l’indice de Rand ajusté¹² :

$$\text{ARI} = \frac{\text{RI} - E[\text{RI}]}{1 - E[\text{RI}]}.$$

L’ARI moyen atteint $0,861 \pm 0,085$ sur les documents assignés dans les deux exécutions et $0,652 \pm 0,028$ sur l’ensemble du corpus. Le nombre de topics reste stable, avec une moyenne de $16,8 \pm 0,4$, mais les documents assignés en commun ne représentent que 18,8 % du corpus. La stabilité concerne donc un noyau restreint, tandis que la frontière entre les topics et le bruit demeure sensible à l’initialisation.

2.3.2 Réentraînement et réaffectation des documents atypiques

Le réentraînement final avec les mêmes hyperparamètres et la même graine retrouve 17 topics, mais ne reproduit pas exactement la partition de la grille : 14 467 segments sont assignés et 46 965 sont classés comme bruit, soit 76,5 % du corpus. Les topics bruts contiennent alors entre 281 et 2 729 segments, avec une médiane de 534. Les métriques géométriques de la grille doivent par conséquent être comprises comme des résultats de sélection et non comme des mesures de cette seconde partition.

Le notebook compare ensuite six seuils de réaffectation, de 0 à 0,50, avec la stratégie `embeddings` de BERTopic¹³. Celle-ci rapproche chaque segment initialement classé comme bruit de l’embedding de topic le plus similaire, selon la similarité cosinus. Le seuil de 0,20 conserve les 17 topics et réattribue 46 952 des 46 965 segments initialement étiquetés -1. Treize segments conservent cette étiquette, ce qui porte la couverture finale à 99,98 %. Les topics comptent alors entre 1 339 et 7 588 segments, avec une médiane de 2 999 ; le plus grand rassemble 12,4 % des documents assignés.

Cette opération permet d’étendre l’analyse à la quasi-totalité du corpus, mais elle ne constitue pas une nouvelle validation géométrique. La silhouette et le DBCV ne sont

11. Davoud MOULAVI et al. (2014). « Density-Based Clustering Validation ». In : *Proceedings of the 2014 SIAM International Conference on Data Mining*. Society for Industrial et Applied Mathematics, p. 839-847

12. Lawrence HUBERT et Phipps ARABIE (1985). « Comparing Partitions ». In : *Journal of Classification* 2, p. 193-218

13. Maarten GROOTENDORST (2026). *Outlier reduction*. BERTopic Documentation. URL : <https://maartengr.github.io/BERTopic/api/bertopic.html> (visité le 27/08/2026)

pas recalculés après la réaffectation ; leurs valeurs ne décrivent donc pas les assignations finales.

2.3.3 Cohérence et diversité des mots représentatifs

Après la réaffectation, la représentation des topics est reconstruite avec une courte liste de formes résiduelles exclues du vocabulaire. La cohérence C_v ¹⁴, calculée à partir des documents lemmatisés et des dix premiers termes de chaque topic, atteint 0,389. Ce score dépend notamment du corpus de cooccurrence, de la tokenisation et du nombre de termes retenus ; il s’interprète donc surtout par comparaison au sein d’un même protocole. Comme la cohérence n’est pas recalculée sur la partition brute du réentraînement final, cette valeur ne permet pas d’affirmer que la réaffectation améliore ou dégrade directement la cohérence.

Dans cette étude, la diversité des mots représentatifs reprend le principe de la *topic diversity*¹⁵ et mesure la proportion de termes distincts parmi les dix premiers mots de chaque topic :

$$D = \frac{\left| \bigcup_{k=1}^K W_k \right|}{\sum_{k=1}^K |W_k|},$$

où W_k désigne l’ensemble des dix premiers mots du topic k . La valeur finale de 0,947 indique que 94,7 % des positions de ces listes sont occupées par des termes distincts. Elle signale ainsi un faible chevauchement lexical entre les représentations, sans mesurer la richesse lexicale du corpus ni garantir à elle seule la cohérence sémantique des topics.

Le tableau 2.3 récapitule les résultats disponibles. Le tiret signale qu’un indicateur n’a pas été recalculé dans le périmètre concerné.

14. Michael RÖDER, Andreas BOTH et Alexander HINNEBURG (2015). « Exploring the Space of Topic Coherence Measures ». In : *Proceedings of the Eighth ACM International Conference on Web Search and Data Mining*. WSDM ’15. Association for Computing Machinery, p. 399-408

15. Adjil B. DIENG, Francisco J. R. RUIZ et David M. BLEI (2020). « Topic Modeling in Embedding Spaces ». In : *Transactions of the Association for Computational Linguistics* 8, p. 439-453. URL : <https://aclanthology.org/2020.tacl-1.29/>

TABLE 2.3 – Indicateurs enregistrés aux trois étapes de la modélisation

Indicateur	Sélection par la grille	Réentraînement brut	Après réaffectation
Nombre de topics	17	17	17
Documents assignés	17 564 (28,6 %)	14 467 (23,5 %)	61 419 (99,98 %)
Documents atypiques	43 868 (71,4 %)	46 965 (76,5 %)	13 (0,02 %)
Taille minimale d'un topic	258	281	1 339
Taille médiane d'un topic	547	534	2 999
Taille maximale d'un topic	5 690 (32,4 %)	2 729 (18,9 %)	7 588 (12,4 %)
Silhouette dans l'espace UMAP	0,376	–	–
DBCV dans l'espace UMAP	−0,035	–	–
Cohérence C_v	0,580	–	0,389
Diversité des termes	0,976	–	0,947

La validation met ainsi en évidence un résultat contrasté. La silhouette et la robustesse aux graines suggèrent une structure partielle parmi les documents assignés dans la projection UMAP retenue, mais le DBCV négatif, le taux de bruit initial et la faible part de documents assignés en commun interdisent de parler d'une partition fortement validée. Après réaffectation, le modèle offre néanmoins 17 topics couvrant presque tout le corpus et dont les listes de mots représentatifs se chevauchent peu. Il peut donc servir d'instrument exploratoire, à condition de préserver cette prudence lors de l'interprétation littéraire.

2.4 Analyse des résultats de BERTopic

Le modèle final distingue 17 topics et attribue un topic à 61 419 des 61 432 segments du corpus ; seuls 13 segments conservent l'étiquette -1. Cette couverture presque complète rend possible une lecture d'ensemble, mais elle ne supprime pas les réserves formulées lors de la validation : 46 952 affectations finales, soit 76,4 %, proviennent de la réattribution des documents initialement atypiques. Les effectifs décrivent donc principalement une allocation par proximité aux 17 noyaux sémantiques du modèle, et non la taille de 17 amas denses directement découverts par HDBSCAN.

Un topic BERTopic ne constitue pas un thème littéraire déjà nommé. Il rassemble des segments proches dans l'espace sémantique, puis les caractérise par un vocabulaire pondéré. Son interprétation repose ici sur trois indices complémentaires : les quinze termes les mieux classés par le c-TF-IDF, les documents représentatifs et la distribution

des segments entre les romans. Les intitulés employés dans cette section sont par conséquent des étiquettes de lecture ; ils synthétisent le contenu dominant sans prétendre épuiser tous les usages d'un topic.

2.4.1 Des topics aux familles thématiques

Afin de rendre les résultats lisibles, les 17 topics ont été réunis a posteriori en six familles thématiques. Cette opération ne modifie ni le modèle ni l'affectation des segments : elle rapproche seulement des topics voisins pour organiser l'analyse et les visualisations temporelles. Il faut donc conserver deux niveaux de lecture : la famille fait apparaître un domaine général, tandis que les topics qui la composent en décrivent des dimensions parfois très différentes.

TABLE 2.4 – Regroupement interprétatif des 17 topics en six familles

Famille thématique	Topics	Segments	Part des segments assignés
Corps, apparences et vie privée ou mondaine	5, 8, 10	15 460	25,17 %
Travail, argent et conditions matérielles	4, 6, 9, 14	14 814	24,12 %
Institutions, religion et pouvoir	1, 12, 13, 15	12 107	19,71 %
Relations affectives, couple et famille	2, 7, 11, 16	10 986	17,89 %
Espaces, paysages et architecture	0	5 397	8,79 %
Guerre et violence collective	3	2 655	4,32 %

Ces proportions décrivent la taille des regroupements produits par le modèle, non l'importance intrinsèque des thèmes dans l'œuvre. Elles dépendent notamment de la segmentation, de la granularité choisie et de la capacité de certains lexiques à former un groupe homogène. Le tableau 2.5 revient donc au niveau des topics et associe à chacun un intitulé analytique, son effectif et cinq de ses termes les plus discriminants.

TABLE 2.5 – Interprétation synthétique des 17 topics du modèle final

Topic	Effectif	Intitulé analytique	Termes discriminants
Corps, apparences et vie privée ou mondaine			
5	5 277	Nuit, sommeil et espace intime	oreiller, insomnie, recoucher, respiration, parquet

Suite à la page suivante

Table 2.5 — suite

Topic	Effectif	Intitulé analytique	Termes discriminants
8	7 588	Vie domestique et sociabilité mondaine	thé, loge, cocher, piano, vestibule
10	2 595	Corps, vêtements et portraits physiques	hanche, blancheur, chevelure, corsage, physionomie
Travail, argent et conditions matérielles			
4	3 817	Finance, propriété et spéculation	banque, capital, spéculation, immeuble, faillite
6	5 714	Alimentation et sociabilité populaire	soupe, Gervaise, blanchisseur, zingueur, casserole
9	2 873	Machines, industrie et infrastructures	rail, berline, câble, fonte, acier
14	2 410	Dette et économie quotidienne	centime, rembourser, emprunter, usurier, créance
Institutions, religion et pouvoir			
1	4 554	Discours socio-religieux et projet collectif	nation, catholicisme, démocratie, salariat, solidarité
12	2 631	Hiéarchie ecclésiastique	éminence, prélat, monsignor, pape, congrégation
13	1 923	Enquête, preuve et justice	paraphe, accusé, arrestation, expert, audience
15	2 999	Conflit clérical et politique	jésuite, clérical, laïque, réactionnaire, municipal
Relations affectives, couple et famille			
2	3 188	Parole amoureuse et affective	pleure, mienne, mien, épouse, désire
7	4 725	Couple, maternité et sacrifice	épouse, maternité, virginité, union, sein
11	1 734	Supplication, pardon et devoir moral	supplie, conjure, miséricorde, confesse, pénitence
16	1 339	Union, séparation et intimité	séparation, union, fiançaille, fiancé, embrassement
Espaces, paysages et architecture			
0	5 397	Paysages naturels et espaces construits	toiture, feuillage, nef, coteau, dôme
Guerre et violence collective			
3	2 655	Guerre, armée et affrontement collectif	troupe, barricade, batterie, allemand, artillerie

2.4.2 Lecture qualitative des six familles

Corps, apparences et vie privée ou mondaine. Cette première famille est la plus volumineuse, mais son unité tient moins au seul corps qu'aux scènes où celui-ci est observé dans un espace social ou intime. Le topic 5 rassemble la chambre, le sommeil, l'insomnie, la respiration et parfois la défaillance physique ; il est particulièrement présent dans *Thérèse Raquin* et *La Joie de vivre*. Le topic 10 correspond plus nettement au portrait : le corps y devient visible par la chevelure, les vêtements, les formes et la physionomie. Le topic 8, le plus grand du modèle avec 7 588 segments, déplace l'attention vers les pratiques domestiques et mondaines, les visites, le théâtre, les moyens de transport et le personnel de maison. Sa forte représentation dans *Nana*, *Pot-Bouille* et *Une page d'amour* montre que le modèle saisit moins une catégorie sociale unique qu'une mise en scène répétée des individus à travers leurs intérieurs, leurs apparences et leurs codes de sociabilité.

Travail, argent et conditions matérielles. Les quatre topics de cette famille décrivent plusieurs échelles de la vie économique. Le topic 6 part du quotidien populaire : les repas, les métiers et les échanges familiers, fortement associés à *L'Assommoir*, *La Terre* et *Le Ventre de Paris*. La présence de Gervaise parmi ses termes les plus discriminants montre toutefois qu'une partie de sa cohérence provient directement de *L'Assommoir* et invite à ne pas l'assimiler sans réserve à l'ensemble des milieux populaires. Le topic 9 isole au contraire la matérialité industrielle par les rails, les câbles, les charpentes et les machines ; *Germinal* en constitue le foyer principal. Le topic 4 porte sur la banque, la propriété et la spéculation, avec une concentration attendue dans *L'Argent*, mais aussi dans *La Curée* et *Au Bonheur des dames*. Enfin, le topic 14 rend visible une économie plus diffuse, faite de centimes, d'emprunts, de dots et de créances. Leur regroupement met ainsi en relation le budget domestique, la consommation, le travail industriel et la finance : l'argent n'apparaît pas comme un thème isolé, mais comme un système de contraintes qui relie les corps, les métiers et les positions sociales.

Institutions, religion et pouvoir. Cette famille associe quatre formes de discours institutionnel. Le topic 12 représente la hiérarchie catholique à travers ses titres, ses audiences et ses congrégations ; il est particulièrement caractéristique de *Rome*, tout en étant déjà visible dans *La Conquête de Plassans* et *Son Excellence Eugène Rougon*. Le topic 15 porte davantage sur l'affrontement entre cléricaux, laïques, réactionnaires et socialistes, notamment dans *Vérité*. Le topic 13 décrit le fonctionnement de la justice par l'enquête, les expertises, les témoignages et l'accusation ; sa concentration dans *Vérité* confirme la cohérence de cette interprétation. Plus abstrait, le topic 1 rassemble les discours sur la nation, le catholicisme, la démocratie, le salariat et la transformation

sociale. L'ensemble fait apparaître le passage des institutions comme cadres du récit aux institutions comme objets explicites de critique et de projet politique.

Relations affectives, couple et famille. Les topics 2, 7, 11 et 16 décrivent l'intimité à partir de positions d'énonciation et de situations relationnelles différentes. Le topic 2 est dominé par l'adresse à l'autre, le désir et la plainte ; le topic 11 par la supplication, le pardon et l'obligation morale. Les topics 7 et 16 structurent plus directement le couple autour de la maternité, de la virginité, de l'union, de la séparation et des fiançailles. La famille est très présente dans les premiers romans, notamment *La Confession de Claude*, *Le Vœu d'une morte*, *Thérèse Raquin* et *Madeleine Féral*, mais elle ne relève pas d'un simple registre sentimental : les documents représentatifs associent régulièrement l'affect aux normes conjugales, au sacrifice, à la sexualité et au devoir familial.

Espaces, paysages et architecture. Le topic 0 réunit des éléments naturels et construits : feuillages, coteaux et rives voisinent avec les toitures, les nefs, les dômes et les alignements. Cette proximité montre que le topic isole avant tout une opération descriptive fondée sur l'organisation visuelle de l'espace. Il est particulièrement présent dans *La Faute de l'abbé Mouret*, *Le Ventre de Paris* et *Rome*, trois œuvres qui mobilisent pourtant des milieux très différents. Le regroupement est donc cohérent sur le plan discursif sans correspondre à un décor unique ; il peut contribuer à l'étude naturaliste du milieu, mais ne constitue pas à lui seul un marqueur exclusif du naturalisme.

Guerre et violence collective. Le topic 3 est le plus spécialisé du modèle. Son vocabulaire militaire — troupes, divisions, batteries, obus, artillerie et nationalités combattantes — renvoie principalement à *La Débâcle*, qui réunit 1 095 de ses 2 655 segments. Des concentrations plus modestes apparaissent dans *La Fortune des Rougon*, *Les Mystères de Marseille* et *Germinal*, où le lexique de l'affrontement collectif peut être mobilisé dans des contextes insurrectionnels ou sociaux. La cohérence de ce topic facilite son interprétation, mais sa forte dépendance à quelques romans rappelle qu'un groupe lexical très net peut représenter un épisode spécialisé plutôt qu'une préoccupation uniformément distribuée dans toute l'œuvre.

2.4.3 Évolution des topics au fil du temps

Le modèle a été construit sans intégrer la date de publication. La fonction `topics_over_time` répartit ensuite les segments déjà assignés dans quinze intervalles chronologiques de largeur égale entre 1865 et 1903, puis recalcule une représentation lexicale pour chaque topic et chaque intervalle. Les figures ci-dessous ne montrent pas une courbe additionnée par famille : elles mettent en évidence, dans une même image, les trajectoires individuelles des topics qui composent cette famille.

L'option `normalize_frequency=False` ayant été conservée dans le notebook, l'axe vertical représente des effectifs bruts. Or le nombre de segments assignés varie de 1 340 à 6 307 selon les intervalles, soit un rapport de 1 à 4,7. Une courbe élevée peut donc traduire à la fois la place d'un topic dans les romans concernés et un volume textuel plus important. Pour limiter ce biais, l'analyse confronte les effectifs visibles à la part qu'ils représentent dans chaque intervalle et à leur répartition par roman ; elle porte sur la fréquence de topics globaux, non sur une évolution autonome de leur sens.

Les abscisses correspondent aux bornes inférieures de classes d'environ 2,53 années, et non à des dates d'observation exactes ; le point situé vers 1890,3 regroupe par exemple les romans publiés en 1891 et 1892. Les lignes reliant les points facilitent la lecture, mais ne doivent pas être comprises comme une continuité annuelle entre des œuvres publiées de manière discontinue.

Corps, apparences et vie privée ou mondaine




FIGURE 2.1 – Évolution en effectifs bruts des topics 5, 8 et 10 : corps, apparences et vie privée ou mondaine

La figure 2.1 fait surtout apparaître le poids du topic 8. Celui-ci atteint 978 segments dans l'intervalle contenant les publications de 1878 et 1880, puis 586 dans celui de 1882 ; ces valeurs sont principalement portées par *Une page d'amour*, *Nana* et *Pot-Bouille*. Les trois topics réunis représentent respectivement 46,6 % et 45,7 % des segments assignés dans ces deux intervalles, ce qui confirme que les sommets ne résultent pas uniquement du volume du corpus. Le pic brut le plus élevé de la famille apparaît toutefois en 1883–1885 avec 1 737 segments : ramené aux 6 307 segments de l'intervalle, il ne représente plus que 27,5 %. La distinction entre effectif et proportion modifie donc sensiblement la lecture de la courbe.

Les topics 5 et 10 suivent des trajectoires moins concentrées. Le premier atteint 696 segments en 1883–1885 et relie des scènes nocturnes ou intimes présentes dans plusieurs

univers romanesques ; le second reste plus faible et diffuse les descriptions corporelles sur l'ensemble de la chronologie. Cette famille ne dessine donc pas une progression continue. Elle met plutôt en évidence un moment de forte densité domestique et mondaine autour de 1878–1882, entouré d'une présence plus régulière du corps, du sommeil et du portrait.

Travail, argent et conditions matérielles




FIGURE 2.2 – Évolution en effectifs bruts des topics 4, 6, 9 et 14 : travail, argent et conditions matérielles

Les courbes de la figure 2.2 montrent que la famille matérielle ne possède pas un sommet unique. Le topic 6 atteint 1 253 segments dans l'intervalle 1876–1877, dont 1 138 dans *L'Assommoir* ; avec les topics 4, 9 et 14, la famille représente alors 44,6 % des segments assignés. En 1883–1885, le topic 9 culmine à 684 segments, dont 496 dans *Germinal*, tandis que le topic 6 demeure élevé sous l'effet conjoint d'*Au Bonheur des dames*, de *La Joie de vivre* et de *Germinal*. L'intervalle rassemble 2 348 segments de la famille, soit 37,2 % des segments qui y sont assignés.

Le topic 4 connaît son maximum en 1891–1892 avec 594 segments, dont 498 appartiennent à *L'Argent*. Le topic 14 ne présente pas une spécialisation comparable : son vocabulaire de la dette et des petites sommes demeure réparti entre de nombreux romans. La succession de ces pics n'indique donc pas le remplacement d'un thème par un autre. Elle montre plutôt trois formes de détermination matérielle que le modèle distingue : la vie populaire et alimentaire autour de *L'Assommoir*, la mécanisation du travail autour de *Germinal*, puis la finance autour de *L'Argent*. C'est cette articulation, plus que la hauteur globale d'une courbe, qui rend la famille centrale pour l'analyse du projet naturaliste.

Institutions, religion et pouvoir




FIGURE 2.3 – Évolution en effectifs bruts des topics 1, 12, 13 et 15 : institutions, religion et pouvoir

La figure 2.3 présente l’inflexion chronologique la plus nette. À l’échelle des ensembles romanesques, la famille représente 12,2 % des segments des *Rougon-Macquart*, contre 37,8 % dans les *Trois Villes* et 37,0 % dans les trois romans publiés du cycle des *Quatre Évangiles* présents dans le corpus. Dans l’intervalle qui contient uniquement *Rome* en 1896, les quatre topics réunissent 1 674 segments, soit 47,7 % du roman. Le dernier intervalle, qui regroupe *Travail* et *Vérité*, atteint 2 831 segments et 45,4 % des segments assignés.

Cette hausse ne repose pas sur un seul topic. Le topic 1, consacré aux discours socio-religieux et aux projets collectifs, atteint 1 349 segments dans le dernier intervalle ; le topic 15, centré sur le conflit cléricale et politique, en compte 676 ; le topic 13, judiciaire, 568. Le topic 12 suit une trajectoire plus discontinue : il est déjà élevé dans l’intervalle 1873–1875, notamment à cause de *La Conquête de Plassans*, puis atteint 450 segments dans *Rome*. Les résultats ne montrent donc pas une apparition tardive des institutions, mais une reconfiguration : les œuvres finales combinent plus fortement discours idéologique, conflit religieux, organisation politique et procédure judiciaire.

Relations affectives, couple et famille




FIGURE 2.4 – Évolution en effectifs bruts des topics 2, 7, 11 et 16 : relations affectives, couple et famille

La figure 2.4 révèle une présence particulièrement forte au début du corpus. La famille représente 33,5 % des segments de l'intervalle 1865–1867 et 51,1 % de celui qui contient *Madeleine Féral* en 1868. À l'échelle des romans, elle atteint également 59,2 % dans *La Confession de Claude*, 44,5 % dans *Le Vœu d'une morte* et 38,9 % dans *Thérèse Raquin*. Ces valeurs confirment que les premiers récits structurent fortement les affects autour de la parole amoureuse, de l'union, de la jalousie, du sacrifice et de la faute.

La famille ne disparaît cependant pas avec le développement des grands romans sociaux. Sa part tombe à 6,2 % en 1876–1877, puis fluctue avant d'atteindre 21,8 % en 1898–1899 et 19,4 % en 1901–1903. Le topic 7, centré sur le couple et la maternité, porte une grande partie de cette reprise, notamment dans *Fécondité*. La courbe décrit donc moins un recul linéaire du registre affectif qu'un changement de contexte : d'abord au premier plan de récits intimes, il est ensuite réinscrit dans des ensembles où la famille est articulée à des enjeux sociaux, moraux ou collectifs.

Espaces, paysages et architecture




FIGURE 2.5 – Évolution en effectifs bruts du topic 0 : espaces, paysages et architecture

Le topic 0 est présent dans les quinze intervalles, mais sa courbe reste irrégulière. Son maximum brut, 742 segments en 1873–1875, est exactement formé par *Le Ventre de Paris*, *La Conquête de Plassans* et *La Faute de l'abbé Mouret*. Ces œuvres associent respectivement architecture marchande, ville provinciale et paysage végétal, ce qui confirme que le topic repère une manière de construire l'espace plutôt qu'un lieu homogène. Un second sommet de 639 segments correspond à *Rome* en 1896 ; il représente alors 18,2 % du roman, soit la part la plus élevée de la chronologie.

La présence transversale du topic montre que la description du milieu accompagne plusieurs phases de l'œuvre, mais ses variations sont largement dépendantes des décors propres à chaque roman. On ne peut donc pas déduire de la courbe une intensification ou un effacement général de la description. Elle indique plutôt que BERTopic rapproche des passages où l'environnement est organisé comme un ensemble visible, qu'il s'agisse d'un paysage, d'un édifice ou d'un espace urbain.

Guerre et violence collective




FIGURE 2.6 – Évolution en effectifs bruts du topic 3 : guerre et violence collective

La figure 2.6 se distingue par un pic massif et ponctuel. Le topic 3 atteint 1143 segments dans l'intervalle 1891–1892, soit 23,1 % des segments assignés de cette période. Parmi eux, 1095, ou 95,8 %, proviennent de *La Débâcle* ; ce roman rassemble à lui seul 41,2 % de tous les segments du topic. L'association entre le vocabulaire militaire et cette œuvre est donc beaucoup plus directe que pour les familles transversales.

Les autres hausses restent nettement plus faibles : 234 segments dans l'intervalle de 1871, principalement sous l'effet de *La Fortune des Rougon*, et 245 en 1883–1885, dont 193 dans *Germinal*. Ces occurrences montrent que l'affrontement collectif traverse aussi les scènes insurrectionnelles ou sociales, mais elles ne remettent pas en cause la spécialisation du topic. Cette trajectoire constitue un cas utile : elle illustre la capacité du modèle à isoler un lexique historiquement et narrativement concentré, tout en rappelant qu'un sommet temporel peut d'abord être l'empreinte d'un seul roman.

2.4.4 Bilan interprétatif

Les six familles ne suivent pas une évolution commune. Les relations affectives dominent plusieurs œuvres de jeunesse puis sont reformulées dans les romans tardifs ; le travail et les conditions matérielles connaissent des concentrations successives autour de la vie populaire, de l'industrie et de la finance ; les institutions deviennent beaucoup plus présentes dans les cycles finaux ; enfin, la guerre dépend très fortement de *La Débâcle*. Les espaces et les scènes privées restent plus transversaux, mais leur fréquence varie avec les milieux particuliers mis en récit.

Cette lecture confirme l'intérêt de BERTopic pour identifier des régularités de contenu à l'échelle d'un vaste corpus. Le modèle distingue notamment les mécanismes

économiques, les univers professionnels, les institutions, les formes de sociabilité et l'inscription des personnages dans des espaces matériels. Ces résultats rejoignent plusieurs objets privilégiés par l'enquête naturaliste, sans suffire à définir le naturalisme dans son ensemble : aucun topic n'isole clairement l'hérédité, et les courbes ne mesurent ni la construction narrative, ni la causalité entre milieu et personnage, ni le traitement stylistique des scènes.

Le regroupement en familles doit enfin rester réversible. Il facilite la comparaison temporelle, mais il peut masquer des trajectoires opposées à l'intérieur d'un même ensemble, par exemple entre l'économie domestique du topic 14 et la finance du topic 4, ou entre la hiérarchie ecclésiastique du topic 12 et la justice du topic 13. L'apport principal de l'analyse réside donc moins dans une taxonomie définitive que dans l'articulation de trois échelles : les segments représentatifs donnent accès au contexte, les topics isolent des régularités sémantiques et les familles permettent de suivre leurs recompositions dans l'œuvre.

2.5 Mise en regard de la NMF, de K-means et de BERTopic

Les deux premiers chapitres appliquent trois méthodes non supervisées aux mêmes 31 romans de Zola. Les fichiers sources utilisés dans les deux projets sont strictement identiques, ce qui fournit un point de comparaison commun. Cette identité du corpus ne suffit toutefois pas à isoler l'effet des algorithmes : entre l'analyse classique et BERTopic, la segmentation, le prétraitement, la représentation des textes, le nombre de groupes et le traitement des documents atypiques changent simultanément. La comparaison porte donc sur trois chaînes de traitement complètes, et non sur trois modèles placés dans des conditions expérimentales identiques.

2.5.1 Des conditions de modélisation différentes

La NMF et K-means partagent exactement les mêmes 5 327 segments, la même lemmatisation et une matrice TF-IDF de $5\,327 \times 11\,640$. Leur rapprochement évalue surtout l'effet du passage d'une décomposition graduelle à une partition exclusive. BERTopic repose au contraire sur 61 432 segments courts et sur deux représentations complémentaires : les plongements Sentence-CamemBERT sont calculés à partir du texte brut, tandis que les mots caractéristiques des topics sont extraits des textes lemmatisés.

TABLE 2.6 – Principales différences entre les trois chaînes de traitement

Méthode	Unités textuelles	Représentation	Sortie et principale réserve
NMF	5 327 blocs de 40 lignes non vides ; 785 mots bruts en moyenne	TF-IDF sur les noms et adjectifs lemmatisés ; suppression manuelle de plusieurs personnages	29 composantes graduelles ; nombre choisi sans coude net, puis simplifié en topic dominant dans certaines visualisations
K-means	Les mêmes 5 327 blocs que la NMF	La même matrice TF-IDF que la NMF	29 clusters exclusifs ; silhouette de 0,0103, indiquant une très faible séparation
BERTopic	61 432 segments ; 105 tokens CamemBERT en moyenne	Embeddings du texte brut ; c-TF-IDF sur les noms, adjectifs et verbes lemmatisés	17 topics exclusifs dans l'analyse finale ; 76,4 % des affectations proviennent de la réattribution des documents initialement atypiques

La différence d'échelle est considérable : les deux mesures ne sont pas strictement équivalentes, mais les 785 mots bruts d'un bloc classique contrastent nettement avec les 105 tokens CamemBERT d'un segment BERTopic. Les longs blocs favorisent la coexistence de plusieurs sujets et conviennent à la représentation souple de la NMF, mais ils deviennent plus difficiles à résumer par une seule étiquette dans K-means. Les segments courts de BERTopic isolent plus facilement une scène, une description ou un échange verbal, mais ils fragmentent les développements longs et rendent les noms de personnages plus visibles. Le topic 6, marqué notamment par Gervaise et Lorilleux, illustre ainsi une cohérence qui tient à la fois au milieu populaire et à la signature lexicale de *L'Assommoir*.

Le nettoyage produit un second écart. Le pipeline classique retire explicitement de nombreux personnages, parmi lesquels Gervaise, Boccanera et Lorilleux, alors que la liste finale de BERTopic est beaucoup plus limitée. Il conserve en revanche les verbes dans sa représentation lexicale, ce qui facilite l'apparition de topics partiellement discursifs, comme la parole affective du topic 2 ou la supplication du topic 11. Une différence entre les résultats peut donc provenir du contenu conservé avant la modélisation, sans être

causée par la seule opposition entre TF-IDF et embeddings.

Les indicateurs internes ne peuvent pas davantage être placés sur une même échelle. L’erreur de reconstruction de la NMF, la silhouette de K-means, la silhouette calculée dans l’espace UMAP, le DBCV et la cohérence C_v de BERTopic évaluent des propriétés différentes, dans des espaces et sur des ensembles de segments différents. La silhouette de 0,376 obtenue lors de la sélection de BERTopic ne peut donc pas être directement opposée à celle de 0,0103 de K-means comme la preuve d’une supériorité du premier modèle ; elle porte uniquement sur les documents alors assignés à un topic, tandis que le DBCV légèrement négatif nuance lui-même la séparation globale.

2.5.2 Des correspondances thématiques réelles mais asymétriques

Malgré ces écarts, les résultats ne sont pas sans relation. Les mêmes grands domaines réapparaissent dans les trois analyses : travail, argent, corps, relations familiales, institutions, guerre et description des milieux. Les correspondances du tableau 2.7 sont établies à partir des termes caractéristiques et des passages représentatifs. Elles sont plusieurs-à-plusieurs : elles indiquent des proximités interprétatives, non une identité mathématique entre les partitions. Les topics de la NMF et les clusters de K-means sont numérotés à partir de 1, ceux de BERTopic à partir de 0.

TABLE 2.7 – Principales correspondances entre NMF, K-means et BERTopic

Domaine interprétatif	NMF	K-means	BERTopic
Travail et doctrine sociale	T2	C19	T1, avec une composante religieuse et politique
Alimentation et vie populaire	T6	C1	T6
Mine, rail et industrie	T11, T17	C7, C24	T9
Finance et spéculation	T4	C20	T4
Argent quotidien et dette	T8	C21	T14
Couple, famille et affects	T1, T19, T24, T28	C5, C6, C8, C17	T2, T7, T16
Chambre, corps et santé	T7, T21, T23	C4, C13, C17	T5, T10 ; aucun topic médical autonome
Religion, pouvoir et institutions	T5, T12, T14, T15, T27	C2, C10, C12, C14, C18, C27	T1, T11, T12, T15

Suite à la page suivante

Table 2.7 — suite

Domaine interprétatif	NMF	K-means	BERTopic
Justice, enquête et preuve	T15 (par <i>Vérité</i>), partiellement T13	C2, C28	T13
Guerre et insurrection	T18, T29	C15, C26	T3
Paysage, ville et monde rural	T3, T10, T16	C11, C16, C29	T0
Vie domestique, mondaine et commerce	T9, T20, T26	C3, C9, C22, C25	T8, et partiellement T6
Art et peinture	T22	C23	Aucun équivalent autonome

Les convergences les plus fortes concernent les domaines appuyés sur un vocabulaire spécialisé. La finance réunit ainsi presque terme à terme le topic 4 de la NMF, le cluster 20 de K-means et le topic 4 de BERTopic ; l’argent quotidien rapproche de la même manière NMF T8, K-means C21 et BERTopic T14. La guerre, la mine, le chemin de fer et l’alimentation populaire produisent également des ensembles immédiatement reconnaissables dans les trois modèles. Cette stabilité montre que certains champs lexicaux résistent à un changement important de segmentation et de représentation.

BERTopic condense toutefois plusieurs distinctions conservées par les méthodes classiques. La mine et le chemin de fer, séparés par NMF T17 et T11 ainsi que par K-means C24 et C7, convergent dans son topic 9 autour des machines, des rails, des câbles et des infrastructures. La guerre militaire et l’insurrection, distinguées par NMF T18 et T29 ou K-means C26 et C15, sont réunies dans le topic 3. Le topic 8 absorbe pour sa part une partie des scènes domestiques, mondaines et commerciales que la NMF et K-means répartissent entre le magasin, le salon, le théâtre et les conversations ordinaires. Cette condensation offre une vue plus synthétique, mais elle fait perdre certaines oppositions utiles à l’interprétation littéraire.

L’inverse se produit également. Le portrait physique forme dans BERTopic un topic 10 relativement autonome, tandis qu’il est davantage mêlé au corps, au désir ou aux scènes mondaines dans les deux approches classiques. Les marqueurs de dialogue, de plainte et de supplication structurent les topics 2 et 11 sans posséder d’équivalents exacts dans les listes classiques, plus fortement nominales. Ces écarts montrent que BERTopic ne découvre pas simplement une version plus courte des 29 groupes : il déplace les frontières entre thème, type de scène et modalité de discours.

Deux absences sont particulièrement instructives. Le monde médical est clairement isolé par NMF T21 et K-means C13, mais il ne subsiste que partiellement dans le topic 5

de BERTopic, consacré plus largement au sommeil, à la chambre et à la défaillance corporelle. De même, la peinture constitue un ensemble très net avec NMF T22 et K-means C23, sans former de topic BERTopic autonome. Une méthode plus condensée peut donc rapprocher des passages sémantiquement voisins tout en rendant invisibles des domaines lexicaux moins volumineux.

La convergence est enfin plus difficile à apprécier pour les thèmes transversaux. L’amour, le corps, la famille, la vie domestique ou l’espace apparaissent partout dans l’œuvre et disposent d’un lexique moins spécialisé que la mine ou la finance. Leur découpage dépend davantage de la longueur des segments et du mode d’affectation. Les trois méthodes convergent donc surtout lorsqu’un domaine est porté par un vocabulaire distinctif ou par l’univers d’un roman ; elles divergent davantage lorsque plusieurs dimensions narratives coexistent dans les mêmes passages.

2.5.3 Apports et limites propres à chaque approche

NMF. La factorisation fournit la représentation la plus souple des trois méthodes : un même bloc peut combiner plusieurs composantes et rendre compte de la coexistence du travail, de la famille, de l’argent ou du milieu. Ses termes pondérés restent directement lisibles dans la matrice TF-IDF, ce qui facilite l’interprétation. Cette souplesse est toutefois partiellement perdue lorsque les visualisations attribuent à chaque bloc son seul topic dominant. Par ailleurs, le choix de 29 composantes ne repose pas sur un coude clairement identifiable et n’a pas été accompagné d’une étude de stabilité ; la NMF constitue donc une base classique interprétable, mais non une partition optimale démontrée.

K-means. L’affectation exclusive fournit une autre vue des mêmes proximités lexicales et produit de nombreuses correspondances avec la NMF. Cette convergence est attendue, puisque les deux modèles partagent les segments, le vocabulaire, la pondération TF-IDF et le nombre de groupes. Elle ne représente donc pas une validation indépendante de la NMF. Le score de silhouette de 0,0103 pour 29 clusters, très proche de zéro, montre en outre que les frontières restent peu marquées ; K-means doit être utilisé comme une exploration complémentaire plutôt que comme une preuve de la solidité des thèmes.

La classification hiérarchique appliquée aux centroïdes de K-means confirme cette fragilité. Les noms enregistrés dans le notebook ne correspondent pas à la composition effective des groupes 2, 3 et 4. Les intitulés cohérents avec les clusters réellement réunis sont : « Pèlerinage, maladie et religion », « École, clergé, justice et encadrement institutionnel », « Vie mondaine, politique, commerce et argent », « Guerre, insurrection et conflit politique » et « Vie quotidienne, espaces sociaux et expériences individuelles ». La cinquième famille rassemble à elle seule 15 des 29 clusters et 61,5 % des segments ;

cette synthèse est donc utile pour s’orienter, mais trop déséquilibrée pour valider une organisation stable en cinq ensembles.

BERTopic. Les plongements contextualisés et les segments courts permettent de rapprocher des formulations qui ne partagent pas nécessairement les mêmes mots. Le modèle produit une organisation plus condensée en 17 topics, exploitable pour suivre leur distribution entre les romans et au cours du temps. Cette réduction ne constitue pourtant pas une supériorité intrinsèque de BERTopic : elle résulte aussi des paramètres UMAP et HDBSCAN, du seuil de taille des groupes, du prétraitement et de la réattribution finale. Comme 46 952 segments initialement atypiques ont été rapprochés a posteriori des noyaux découverts, les effectifs finaux décrivent surtout une allocation par proximité sémantique ; ils ne correspondent pas à 17 groupes denses directement observés dans les données.

Les trois approches sont ainsi complémentaires. La NMF conserve le caractère composite des longs passages ; K-means met à l’épreuve une lecture catégorielle du même espace lexical ; BERTopic privilégie la proximité sémantique locale et facilite une lecture chronologique. Leurs désaccords ne constituent pas seulement des erreurs : ils montrent quelles catégories résistent au changement d’échelle et lesquelles dépendent du découpage ou du vocabulaire retenu.

2.5.4 Ce que la comparaison permet de conclure

Le résultat le plus robuste est la réapparition de plusieurs domaines malgré le changement de pipeline. Le travail, l’industrie, l’argent, les institutions religieuses, les rapports familiaux, la guerre et les espaces décrits structurent durablement le corpus zolien. La convergence entre NMF, K-means et BERTopic confirme donc l’existence de régularités thématiques internes à l’œuvre ; elle ne démontre ni l’identité des partitions ni la supériorité générale d’une méthode.

Cette convergence atteste encore moins la spécificité de ces thèmes au naturalisme. L’amour, le portrait, la famille, la religion, la guerre ou le paysage appartiennent plus largement au roman du XIX^e siècle. Même le travail et les conditions matérielles, particulièrement importants pour le projet naturaliste, ne deviennent des marqueurs distinctifs qu’à condition d’être significativement plus présents ou traités différemment que dans d’autres courants. Le topic modeling identifie ici des caractéristiques candidates de l’univers zolien, non des critères suffisants pour définir un mouvement littéraire.

Les associations les plus fortes avec une œuvre illustrent cette limite. Dans les résultats BERTopic, le topic 3 représente 38,9 % des segments de *La Débâcle*, le topic 4 23,2 % de ceux de *L’Argent*, le topic 6 49,2 % de ceux de *L’Assommoir*, le topic 9 20,2 % de ceux de *Germinal* et le topic 1 27,6 % de ceux de *Travail*. Ces concentrations

confirment la cohérence interprétative des topics, mais elles peuvent surtout refléter l'intrigue, le décor et le lexique propres à chaque roman.

Les topics plus diffus, comme le topic 10 consacré aux apparences physiques, le topic 14 associé à la dette quotidienne ou, dans une moindre mesure, le topic 0 consacré aux espaces, constituent de meilleurs candidats pour une comparaison transversale. Ils ne sont pourtant pas automatiquement naturalistes : leur intérêt tient précisément à la possibilité de mesurer leur répartition dans d'autres œuvres. L'absence d'un topic clairement consacré à l'hérédité rappelle par ailleurs que les modèles saisissent plus facilement des champs lexicaux que les relations causales ou les principes esthétiques qui organisent le naturalisme.

Conclusion du chapitre

BERTopic confirme plusieurs structures déjà visibles dans la NMF et K-means, tout en les réorganisant à une échelle plus locale et plus sémantique. Il condense la mine et le rail, la guerre et l'insurrection ou encore différentes formes de sociabilité, mais isole aussi le portrait physique et certaines modalités de parole. Les convergences sont les plus nettes pour les lexiques spécialisés ; les divergences concernent davantage les motifs transversaux et les domaines moins volumineux, comme la médecine ou la peinture.

Le bilan des deux premiers chapitres doit donc rester double. D'un côté, les analyses non supervisées dégagent un ensemble cohérent d'hypothèses sur le corps, le travail, l'argent, les institutions et les milieux. De l'autre, elles ne permettent pas de distinguer ce qui relève du naturalisme, de la signature de Zola ou du contenu particulier de ses romans. Le passage d'une méthode à l'autre renforce la plausibilité de certains motifs, mais seul un corpus comparatif peut en évaluer la portée littéraire.

Chapitre 3

Machine learning sur le corpus de d'Émile Zola et auteurs contemporains

3.1 Présentation du protocole expérimental

Les deux premiers chapitres ont fait apparaître plusieurs régularités lexicales et thématiques dans l'œuvre romanesque de Zola. Ces motifs constituent des marqueurs candidats, mais ils ne permettent pas encore de déterminer ce qui relève du naturalisme, de la signature personnelle de l'écrivain ou du contenu particulier de ses romans. Le présent chapitre déplace donc l'analyse vers un corpus comparatif et vers une tâche de classification supervisée. Il s'agit de déterminer si une signature textuelle apprise à partir de Zola se retrouve dans des œuvres d'auteurs absents de l'apprentissage, et si le modèle attribue des scores plus élevés aux romans étiquetés naturalistes qu'aux romans rattachés à d'autres courants.

Deux notebooks mettent cette hypothèse à l'épreuve. Le premier conserve les noms propres et correspond à la condition ANP, « avec noms propres »¹. Le second reprend la même expérience après leur suppression automatique ; il correspond à la condition SNP, « sans noms propres »². Les œuvres retenues, leur répartition, leur segmentation, leur représentation et les modèles comparés sont identiques. Seul le traitement des noms propres varie. La comparaison des deux conditions constitue ainsi une expérience d'ablation contrôlée, destinée à mesurer la part de ces indices dans les décisions du classifieur.

1. Notebook ANP : `zola_vs_naturaliste_ANP.ipynb`.

2. Notebook SNP : `zola_vs_naturaliste_SNP.ipynb`.

3.1.1 Question de recherche et unité de classification

Le protocole ne cherche pas à répartir définitivement les écrivains entre deux groupes, l'un naturaliste et l'autre non naturaliste. Une telle opposition serait peu adaptée aux trajectoires étudiées : plusieurs auteurs se sont rapprochés du naturalisme à un moment de leur carrière avant de s'en éloigner, tandis que certaines œuvres occupent une position intermédiaire. Les étiquettes « naturaliste » et « autre courant » sont donc attribuées au niveau de l'œuvre. Chacun des auteurs utilisés pour la validation et le test est représenté dans les deux classes.

La question effectivement posée est plus restreinte : un classifieur dont les seuls exemples naturalistes d'apprentissage sont les œuvres de Zola peut-il généraliser à des romans écrits par d'autres auteurs ? Une réponse positive indiquerait qu'une partie du signal appris dépasse la simple reconnaissance d'un texte zolien. Elle ne suffirait toutefois pas à établir que le modèle a isolé une définition générale du naturalisme, puisque ses exemples positifs proviennent tous d'un même écrivain. Le terme de « transfert » désigne ici cette généralisation inter-auteurs d'un signal textuel, et non le transfert d'un modèle préentraîné au sens habituel de l'apprentissage automatique.

3.1.2 Constitution du corpus et séparation des auteurs

Le fichier de métadonnées réunit initialement 191 œuvres. Trois textes ont été écartés : *L'Âme étrangère* et *Angelus* de Guy de Maupassant, deux fragments posthumes et inachevés, ainsi que *Un dilemme* de Joris-Karl Huysmans, retenu comme une nouvelle plutôt que comme un roman. Après ces exclusions, le corpus disponible comprend 188 œuvres, dont 68 étiquetées naturalistes et 120 rattachées à d'autres courants. Les règles de partition en retiennent 107 pour l'expérience ; les 81 autres restent hors des ensembles d'apprentissage, de validation et de test.

La séparation est effectuée au niveau des auteurs avant tout découpage des textes. L'ensemble d'apprentissage contient les 31 œuvres de Zola, qui forment l'intégralité de la classe positive, et 34 œuvres appartenant à l'autre classe. Ces dernières proviennent de vingt auteurs dont toutes les œuvres retenues sont étiquetées « autre courant » et sont publiées entre 1865 et 1903, soit la période couverte par le corpus zolien. L'apprentissage réunit ainsi 65 œuvres de 21 auteurs.

L'ensemble de validation rassemble Guy de Maupassant, Camille Lemonnier et Georges Eekhoud. Il comprend 17 œuvres, dont six naturalistes et onze relevant d'autres courants. Le test réunit les frères Goncourt, Joris-Karl Huysmans et Octave Mirbeau, pour un total de 25 œuvres presque équilibré entre les deux classes. Cette construction permet d'évaluer les différences entre œuvres chez un même auteur, plutôt que de confondre systématiquement le courant littéraire et l'identité de l'écrivain.

TABLE 3.1 – Composition des ensembles utilisés pour la classification

Ensemble	Auteurs	Œuvres naturalistes	Autres œuvres	Total
Apprentissage	21	31	34	65
Validation	3	6	11	17
Test	3	13	12	25

Aucun auteur n’est partagé entre les trois ensembles. Le code vérifie également qu’un même texte nettoyé ne réapparaît pas sous deux titres différents, à partir de son empreinte SHA-256. Cette précaution repère les copies exactes, sans garantir l’absence de deux éditions seulement partielles ou très proches. La validation croisée aléatoire par œuvre n’a pas été retenue comme mesure principale : elle aurait réparti plusieurs romans de Zola entre différents plis et aurait surtout mesuré la reconnaissance d’un auteur déjà connu. La sélection repose au contraire sur trois auteurs entièrement absents de l’apprentissage, avant une évaluation sur trois autres auteurs également tenus à l’écart.

3.1.3 Préparation et segmentation des textes

Les textes sont normalisés selon la forme Unicode NFC et certains paratextes éditoriaux provenant notamment de Project Gutenberg ou de Wikisource sont retirés en mémoire, sans modification des fichiers sources. Les identifiants des auteurs sont harmonisés et plusieurs contrôles vérifient la correspondance entre les métadonnées et les fichiers, la conservation de chaque œuvre au cours du traitement et l’unicité de son étiquette.

Les romans sont ensuite découpés en segments non chevauchants, en respectant autant que possible les limites de phrases. Trois longueurs cibles sont comparées : 1 000, 1 500 et 2 500 mots. Les phrases sont regroupées jusqu’à atteindre la taille visée ; un dernier fragment inférieur à la moitié de cette taille est fusionné avec le segment précédent. Une phrase exceptionnellement longue peut elle-même être divisée afin d’éviter un écart trop important.

Pour empêcher les œuvres les plus longues de dominer l’apprentissage, chaque roman y fournit au maximum l’équivalent de 50 000 mots. Lorsque ce plafond est dépassé, les segments sont échantillonnés de manière reproductible avec une graine fixée à 42. Tous les segments sont en revanche conservés pour la validation et le test. Avec la longueur de 1 000 mots finalement retenue, l’apprentissage comporte 3 049 segments, la validation 1 080 et le test 1 889. Ces effectifs sont exactement les mêmes dans les conditions ANP et SNP, car les noms propres sont supprimés après la constitution des segments.

3.1.4 Deux conditions expérimentales : ANP et SNP

Dans la condition ANP, aucune suppression particulière des noms propres n'est appliquée. Les noms de personnages, de lieux ou d'organisations peuvent donc entrer dans le vocabulaire du modèle, à condition de satisfaire les filtres statistiques du TF-IDF. Cette version mesure le signal lexical disponible dans son ensemble. Elle peut offrir au classifieur des informations utiles, mais aussi l'inciter à reconnaître des univers fictionnels, des lieux récurrents ou des personnages plutôt que des traits plus généraux.

Dans la condition SNP, chaque segment est analysé avec le modèle français de grande taille de spaCy, `fr_core_news_lg`, déjà utilisé dans le chapitre précédent. Un token est supprimé lorsqu'il est reconnu comme nom propre par l'étiquette grammaticale `PROPN`, ou lorsqu'il appartient à une entité de type personne, lieu, organisation ou entité diverse, notées `PER`, `LOC`, `ORG` et `MISC`. Le nom n'est pas remplacé par une catégorie générique : il est retiré du texte avant la création de la matrice TF-IDF.

Cette suppression est automatique et ne doit pas être considérée comme parfaite. Le modèle linguistique peut manquer certains noms, notamment dans des textes du XIX^e siècle, ou supprimer à tort des formes ambiguës. La condition SNP réduit donc la présence d'identifiants directs, mais elle ne neutralise ni le vocabulaire thématique, ni les métiers, ni les objets ou les milieux sociaux représentés. Elle ne produit pas davantage une mesure d'un « style pur » : elle teste seulement la persistance du signal après le retrait d'une catégorie précise d'indices.

3.1.5 Représentation des textes et modèles comparés

Dans les deux conditions, les segments sont représentés par des unigrammes pondérés avec le TF-IDF. Les textes ne sont ni lemmatisés ni filtrés à l'aide d'une liste de mots-outils. Le vectoriseur convertit les formes en minuscules, limite le vocabulaire à 50 000 traits, écarte les termes présents dans moins de deux segments ou dans plus de 80 % du corpus d'apprentissage, applique une transformation sous-linéaire aux fréquences et normalise chaque vecteur selon la norme L2³. Le vocabulaire et les pondérations sont ajustés uniquement sur l'ensemble d'apprentissage, puis appliqués sans réajustement à la validation et au test.

Trois classifieurs sont comparés : un modèle bayésien naïf multinomial, une régression logistique avec pondération équilibrée des classes, et une analyse discriminante linéaire précédée d'une réduction SVD à 100 dimensions puis d'une standardisation. Dans les notebooks, cette dernière méthode est abrégée « LDA », pour *Linear Discriminant Analysis*.

Pour chaque condition, la recherche combine les trois tailles de segments, les trois

3. Gerard Salton et Christopher Buckley, « Term-Weighting Approaches in Automatic Text Retrieval », *Information Processing & Management*, vol. 24, no 5, 1988, p. 513-522.

modèles et deux seuils de décision, 0,40 et 0,50, soit dix-huit configurations. Chaque modèle est entraîné sur le seul ensemble d'apprentissage et produit un score d'appartenance à la classe naturaliste pour chaque segment de validation.

3.1.6 Sélection des configurations et évaluation

Les scores des segments d'un même roman sont moyennés afin d'obtenir une décision unique au niveau de l'œuvre. Le critère principal de sélection est le F1 macro calculé séparément pour chacun des trois auteurs de validation, puis moyenné en leur accordant le même poids. La *balanced accuracy* moyenne par auteur, le F1 du moins bon auteur et les mesures globales par œuvre servent ensuite à départager les configurations. Les résultats calculés par segment sont conservés comme diagnostics, mais ne participent pas à la sélection, car plusieurs passages issus d'un même roman ne constituent pas des observations indépendantes.

Cette procédure retient, dans les deux conditions, des segments de 1 000 mots et l'analyse discriminante linéaire. Le seuil choisi sur la validation est de 0,50 pour la condition ANP et de 0,40 pour la condition SNP. Le modèle final est ensuite réentraîné depuis le début sur le seul ensemble d'apprentissage. Les œuvres de validation ne lui sont pas ajoutées, car cela introduirait d'autres auteurs naturalistes dans la classe positive et modifierait la question initiale, fondée sur un apprentissage positif exclusivement zolien.

L'évaluation principale est réalisée au niveau des œuvres, puis répétée séparément pour chaque auteur. Elle repose sur l'exactitude, le F1 macro, la *balanced accuracy*, le rappel de chacune des deux classes et l'aire sous la courbe ROC. Deux analyses de sensibilité examinent également l'effet de la chronologie. La première limite le test aux œuvres publiées entre 1865 et 1903 ; la seconde apparie, chez un même auteur, des œuvres des deux classes publiées à cinq ans d'écart au maximum. L'année n'est jamais fournie au classifieur comme variable prédictive.

Ce protocole réduit plusieurs risques de fuite d'information et permet une comparaison directe entre l'ANP et la SNP. Sa portée reste néanmoins exploratoire. Zola demeure l'unique source positive de l'apprentissage, seulement trois auteurs sont utilisés pour la validation et trois pour le test, et ce dernier ensemble a été consulté au cours du développement. Les résultats ne constituent donc pas une validation définitive d'un classifieur du naturalisme. Ils permettent plutôt d'examiner si le signal lexical appris chez Zola se transfère à quelques trajectoires littéraires distinctes, et dans quelle mesure ce transfert dépend de la présence des noms propres. Les performances des deux conditions sont présentées séparément dans la section suivante avant d'être confrontées.

3.2 Résultats des expériences ANP et SNP

Les résultats sont présentés séparément pour chacune des deux conditions. L'évaluation principale porte sur les 25 œuvres du test, tandis que les mesures calculées sur les segments ne sont utilisées que comme diagnostics. Les scores par auteur reçoivent une attention particulière, car les trois écrivains ne sont pas représentés par le même nombre de romans.

3.2.1 Résultats de l'expérience ANP

Sur l'ensemble de validation, la procédure retient l'analyse discriminante linéaire appliquée à des segments de 1 000 mots, avec un seuil de décision fixé à 0,50. Le F1 macro moyen par auteur atteint 0,583 et la *balanced accuracy* moyenne 0,675. Les trois longueurs de segments testées produisent exactement les mêmes résultats principaux au niveau des œuvres ; la taille de 1 000 mots est donc retenue par la règle de départage prévue dans le protocole, et non parce qu'elle serait nettement supérieure. Les résultats restent variables selon les auteurs de validation : le F1 macro vaut 0,750 pour Camille Lemonnier, 0,667 pour Guy de Maupassant et 0,333 pour Georges Eekhoud. Ce dernier résultat ne repose toutefois que sur deux œuvres.

Au niveau des segments du test, l'exactitude atteint 0,682 et le F1 macro 0,670. Le rappel est de 0,832 pour la classe « autre courant » et de 0,515 pour la classe naturaliste. Ces valeurs décrivent le comportement local du modèle, mais elles ne doivent pas être lues comme si les 1 889 segments constituaient autant d'observations indépendantes.

Après agrégation des scores à l'échelle des romans, 18 œuvres sur 25 sont correctement classées. L'exactitude est de 0,720, le F1 macro de 0,713 et la *balanced accuracy* de 0,728. Le modèle reconnaît onze des douze œuvres relevant d'un autre courant et sept des treize œuvres naturalistes. Pour cette dernière classe, la précision atteint 0,875, tandis que le rappel reste limité à 0,538. Ainsi, lorsqu'une œuvre est déclarée naturaliste, cette décision est le plus souvent correcte, mais une partie importante des romans naturalistes ne franchit pas le seuil retenu.

Le tableau 3.2 détaille les résultats pour chacun des trois auteurs du test. L'AUC est calculée à partir des scores continus et ne dépend donc pas du seuil de 0,50.

TABLE 3.2 – Résultats de l'expérience ANP par auteur du test

Auteur	Correctes	F1	BA	Rappel nat.	Rappel autre	AUC
Goncourt	6/10	0,583	0,750	0,500	1,000	0,813
J.-K. Huysmans	7/9	0,750	0,750	0,667	0,833	0,889
Octave Mirbeau	5/6	0,778	0,750	0,500	1,000	0,875

En accordant le même poids à chaque auteur, le F1 macro moyen s'établit à 0,704, la *balanced accuracy* moyenne à 0,750 et l'AUC moyenne à 0,859. Cette dernière valeur indique que l'ordre des œuvres selon leur score reste informatif, même lorsque le passage à une décision binaire produit plusieurs faux négatifs.

Les sept erreurs permettent de préciser ce résultat. Chez les Goncourt, *Charles Demailly*, *Chérie*, *Madame Gervaisais* et *Manette Salomon* sont étiquetés naturalistes mais classés dans l'autre catégorie. Chez Huysmans, *Marthe*, *histoire d'une fille* constitue un faux négatif, tandis que *En rade* est le seul faux positif de l'expérience. Enfin, *Le Calvaire* de Mirbeau n'est pas reconnu comme naturaliste. Certaines décisions sont proches du seuil, notamment celles de *Marthe* (0,477) et de *Madame Gervaisais* (0,465). D'autres sont beaucoup plus tranchées : *Charles Demailly* et *Chérie* n'obtiennent respectivement que 0,072 et 0,189.

L'examen postérieur des coefficients montre enfin la diversité du signal mobilisé. Parmi les termes fortement associés au prototype zolien figurent des formes discursives comme « lorsque », « tandis », « eut » ou « regardait », des mots liés aux personnes et aux milieux, tels que « enfant », « femme » et « milieu », mais aussi des noms comme « Rougon », « Saccard » ou « Jacques ». À l'inverse, « Bouvard », « Pécuchet », « Arnoux » et « Dambreuse » comptent parmi les termes associés à l'autre classe. Le classement ANP repose donc sur un ensemble mêlant habitudes lexicales, contenus thématiques et éléments propres aux univers romanesques.

3.2.2 Résultats de l'expérience SNP

Dans l'expérience SNP, la validation retient l'analyse discriminante linéaire et des segments de 1 000 mots. Le seuil sélectionné est fixé à 0,40. Le F1 macro moyen par auteur atteint 0,637 et la *balanced accuracy* moyenne 0,730. Les F1 obtenus séparément sont de 0,829 pour Guy de Maupassant, 0,750 pour Camille Lemonnier et 0,333 pour Georges Eekhoud. La sélection demeure donc fragile, notamment parce que le dernier auteur n'est représenté que par deux œuvres.

Le diagnostic au niveau des segments donne une exactitude de 0,639 et un F1 macro de 0,600. Le rappel atteint 0,904 pour la classe « autre courant » et 0,343 pour la classe naturaliste. Ces mesures décrivent les décisions effectuées sur les passages, sans constituer l'unité principale d'interprétation.

Au niveau des œuvres, 17 romans sur 25 sont correctement classés. L'exactitude atteint 0,680, le F1 macro 0,653 et la *balanced accuracy* 0,692. Les douze œuvres de la classe « autre courant » sont reconnues, de même que cinq des treize œuvres naturalistes. La précision de la classe naturaliste est donc de 1,000, pour un rappel de 0,385. Au seuil retenu, le modèle adopte ainsi un comportement très conservateur : aucune œuvre de l'autre classe n'est déclarée naturaliste, mais huit œuvres naturalistes sont laissées

de côté.

Le détail par auteur est présenté dans le tableau 3.3.

TABLE 3.3 – Résultats de l’expérience SNP par auteur du test

Auteur	Correctes	F1	BA	Rappel nat.	Rappel autre	AUC
Goncourt	5/10	0,495	0,688	0,375	1,000	0,688
J.-K. Huysmans	7/9	0,679	0,667	0,333	1,000	0,944
Octave Mirbeau	5/6	0,778	0,750	0,500	1,000	0,875

Le F1 macro moyen donnant le même poids aux auteurs vaut 0,650, la *balanced accuracy* moyenne 0,701 et l’AUC moyenne 0,836. Le cas de Huysmans illustre la différence entre le classement continu et la décision au seuil : l’AUC atteint 0,944, alors qu’une seule de ses trois œuvres naturalistes est reconnue comme telle. Dans cet échantillon, les scores ordonnent donc assez nettement ses œuvres, mais le seuil de 0,40 ne transforme pas entièrement cet ordre en classifications correctes.

Les huit erreurs sont toutes des faux négatifs. Elles concernent *Charles Demailly*, *Chérie*, *Madame Gervaisais*, *Manette Salomon* et *Renée Mauperin* chez les Goncourt, *En ménage* et *Marthe, histoire d’une fille* chez Huysmans, ainsi que *Le Calvaire* chez Mirbeau. Le score de *La Fille Élisa*, correctement classée, se situe juste au-dessus du seuil à 0,414. La plupart des œuvres mal classées reçoivent en revanche des scores plus éloignés de la frontière de décision ; *Charles Demailly* et *Chérie* obtiennent par exemple 0,058 et 0,091.

Après la suppression automatique des noms propres, les termes les plus associés au prototype zolien comprennent notamment « lorsque », « ça », « nouveau », « frère », « regardait », « milieu », « enfant », « rire », « face » et « femme ». Des termes comme « abbé », « curé » ou « prêtre » contribuent aussi aux scores de certaines œuvres de Mirbeau. Ces coefficients font apparaître à la fois des habitudes lexicales, des verbes de perception ou de parole et des champs thématiques liés à la parenté, au corps, à la religion ou aux milieux sociaux. Leur interprétation reste postérieure à l’évaluation : ils servent à décrire le comportement du modèle, et non à modifier ses paramètres après consultation du test.

3.3 Comparaison des expériences ANP et SNP

Les deux expériences ne se distinguent que par le traitement des noms propres. Elles peuvent donc être mises en regard comme les deux conditions d’une même expérience d’ablation. Le tableau 3.4 rassemble les principaux résultats sur le test. La condition

ANP obtient les meilleures mesures globales, mais son avantage reste modéré : elle classe correctement 18 œuvres sur 25, contre 17 pour la condition SNP.

TABLE 3.4 – Comparaison des résultats ANP et SNP sur les œuvres du test

Indicateur	ANP	SNP
Œuvres correctement classées	18/25	17/25
Exactitude	0,720	0,680
F1 macro par œuvre	0,713	0,653
<i>Balanced accuracy</i> par œuvre	0,728	0,692
F1 macro moyen par auteur	0,704	0,650
<i>Balanced accuracy</i> moyenne par auteur	0,750	0,701
AUC moyenne par auteur	0,859	0,836
Rappel de la classe naturaliste	0,538	0,385
Rappel de la classe « autre courant »	0,917	1,000

3.3.1 Effet du retrait des noms propres

L'écart le plus visible concerne le rappel de la classe naturaliste. En conservant les noms propres, sept des treize œuvres naturalistes sont reconnues ; après leur suppression, cinq seulement le sont. En contrepartie, le SNP ne produit aucun faux positif : toutes les œuvres qu'il déclare naturalistes le sont selon les étiquettes du corpus. Cette précision parfaite ne doit cependant pas masquer son faible rappel. Elle traduit surtout une décision plus conservatrice, qui laisse huit œuvres naturalistes sous le seuil.

L'avantage global de l'ANP tient à très peu de cas. Les deux conditions donnent la même étiquette à 22 œuvres sur 25. *Renée Mauperin* et *En ménage* sont correctement classées uniquement en ANP, tandis que *En rade* est correctement classé uniquement en SNP. Deux changements favorisent donc l'ANP et un seul le SNP. Sur un échantillon aussi réduit, cette différence ne permet pas d'établir la supériorité générale de la condition avec noms propres.

Cette prudence est renforcée par la validation, où l'ordre était inversé : le F1 moyen par auteur atteignait 0,637 en SNP, contre 0,583 en ANP. Le passage de trois auteurs de validation à trois autres auteurs de test suffit donc à modifier la condition la mieux classée. Ce résultat signale davantage une sélection instable sur de petits effectifs qu'un avantage régulier des noms propres.

Les scores continus conduisent à la même prudence. Leur corrélation de rang atteint 0,972 : les deux modèles ordonnent presque toujours les romans de la même manière. Tous les scores SNP sont néanmoins inférieurs à leur équivalent ANP, leur moyenne passant de 0,379 à 0,235. Ce déplacement ne mesure pas directement la « part » des noms propres, car les modèles sont réentraînés dans deux espaces lexicaux différents et

leurs seuils ont été réglés séparément, à 0,50 et 0,40. Il montre plutôt que la suppression modifie l'échelle des scores et réduit la propension du modèle à attribuer la classe naturaliste, sans bouleverser l'ordre général des œuvres.

L'effet varie d'ailleurs selon les auteurs. Les décisions concernant Mirbeau sont identiques dans les deux expériences. Chez Huysmans, l'AUC progresse en SNP alors que le F1 diminue, ce qui indique un classement continu pertinent mais mal traduit par le seuil. La baisse moyenne provient surtout des Goncourt. Le retrait des noms propres n'a donc pas un effet uniforme sur les différents univers littéraires.

3.3.2 Nature du signal et effet de la chronologie

Le maintien d'une AUC moyenne de 0,836 en SNP constitue un résultat important : les personnages et les lieux ne suffisent pas à expliquer le classement. Un signal lexical appris à partir de Zola subsiste chez des auteurs absents de l'apprentissage. Il ne correspond pas pour autant à un style naturaliste isolé. Les termes encore disponibles associent des formes discursives, comme « lorsque » ou « regardait », à des mots liés à la parenté, au corps, à la religion et aux milieux sociaux. Avec des unigrammes TF-IDF, habitudes d'écriture et contenu des romans restent ainsi mêlés.

La chronologie représente un autre facteur de confusion. Lorsque le test est limité aux 21 œuvres publiées entre 1865 et 1903, les deux conditions atteignent la même exactitude de 0,714. Les F1 macro restent proches, avec 0,697 en ANP et 0,679 en SNP. La petite avance globale de l'ANP n'est donc pas robuste à cette restriction. Celle-ci conserve toutefois des écarts de dates importants à l'intérieur de la période et ne neutralise pas l'évolution propre à chaque écrivain. L'appariement d'œuvres des deux classes publiées à cinq ans d'écart au maximum va dans le même sens : l'ANP ordonne correctement trois des quatre paires et le SNP deux. Quatre paires sont trop peu nombreuses pour lever le doute sur un effet de période.

3.3.3 Portée, limites et prolongements

Le protocole présente plusieurs points forts. Les auteurs de l'apprentissage, de la validation et du test sont disjoints, les copies exactes sont recherchées, et l'évaluation principale porte sur les œuvres plutôt que sur des segments corrélés. Le calcul séparé par auteur évite aussi que les Goncourt, plus représentés, déterminent seuls le résultat. Enfin, l'ablation ANP/SNP porte sur les mêmes textes et montre que le signal ne disparaît pas avec les identifiants fictionnels. Les deux modèles font nettement mieux qu'une décision fondée uniquement sur la classe majoritaire du test, qui ne classerait correctement que 13 œuvres sur 25.

Ces garanties ne suffisent cependant pas à faire de l'expérience une validation définitive. Zola demeure l'unique auteur positif de l'apprentissage : le modèle apprend

nécessairement un mélange de naturalisme, le lexique zolien et de contenus propres à ses romans. Le test ne réunit que trois auteurs et 25 œuvres, et il a été consulté pendant le développement. Les catégories littéraires peuvent en outre être discutées pour certaines œuvres de transition. Enfin, la suppression automatique des noms propres n'est pas infaillible et son taux d'erreur n'a pas été mesuré sur ce corpus du XIX^e siècle.

Plusieurs tests complémentaires permettraient d'approfondir ce travail. La priorité serait de constituer un nouveau test réellement aveugle, avec davantage d'auteurs et des œuvres mieux équilibrées par période. L'apprentissage pourrait ensuite intégrer plusieurs écrivains naturalistes, puis évaluer successivement un auteur tenu à l'écart ; une telle validation distinguerait mieux le courant littéraire de la seule signature de Zola. Un modèle fondé uniquement sur l'année fournirait par ailleurs un témoin simple, à dépasser avant d'attribuer les résultats au texte. Enfin, la comparaison de familles de traits — mots-outils, ponctuation, n-grammes de caractères, catégories grammaticales ou relations syntaxiques — aiderait à séparer les régularités formelles du vocabulaire thématique. Pour la condition SNP, remplacer les entités par des catégories génériques, comme [PER] ou [LOC], et vérifier manuellement un échantillon permettrait aussi de conserver la structure des phrases tout en contrôlant la qualité de la reconnaissance.

Conclusion du chapitre

Ce chapitre montre qu'une partie du signal appris à partir de Zola se transfère à des œuvres naturalistes de Goncourt, Huysmans et Mirbeau, alors même que ces auteurs sont absents de l'apprentissage. Les résultats sont supérieurs à une règle majoritaire et le classement des œuvres reste largement informatif. Surtout, la forte proximité entre les scores ANP et SNP indique que ce transfert ne repose pas uniquement sur les noms de personnages ou de lieux.

La réponse à la problématique demeure toutefois partielle. Le modèle met en évidence une proximité textuelle avec Zola ; il ne démontre pas encore l'existence de marqueurs du naturalisme indépendants de l'auteur, des thèmes et de la chronologie. Le faible rappel des œuvres naturalistes, la variation entre auteurs et la fragilité des contrôles temporels invitent à ne pas transformer ces résultats en critères de classement littéraire. Ils restent néanmoins exploitables dans le cadre d'un test exploratoire : ils valident l'intérêt du protocole, rendent visibles ses principaux biais et fournissent une base précise pour une expérimentation ultérieure, plus large et véritablement confirmatoire.

Conclusion

Ce mémoire avait pour objectif de déterminer dans quelle mesure la modélisation thématique et la classification automatique permettent d’identifier des marqueurs du naturalisme sans confondre ce mouvement avec la signature de Zola, les sujets de ses romans ou les effets de constitution du corpus. Les trois chapitres ont abordé cette question de manière progressive : les deux premiers ont dégagé des régularités internes à l’œuvre zolienne, tandis que le troisième a cherché à savoir si une partie de ce signal se retrouvait chez d’autres auteurs.

Le premier chapitre a montré que la NMF et K-means pouvaient organiser les trente et un romans de Zola en ensembles lexicaux interprétables. Le travail, la mine, l’argent, la religion, la famille, la guerre, le commerce et les espaces domestiques ou urbains réapparaissent dans les deux analyses. Cette convergence reste toutefois exploratoire : les méthodes utilisent les mêmes segments et la même matrice TF-IDF, tandis que les 29 clusters de K-means ont été retenus en partie pour conserver une granularité comparable aux 29 topics de la NMF. Elles décrivent donc des régularités internes à Zola, sans se valider indépendamment l’une l’autre.

Le deuxième chapitre a retrouvé plusieurs de ces domaines avec BERTopic, malgré une segmentation et une représentation différentes. Les correspondances sont les plus nettes pour les vocabulaires spécialisés de la finance, de la mine, du chemin de fer, de la guerre ou de l’alimentation populaire. L’analyse chronologique fait aussi apparaître des recompositions : les relations affectives sont très présentes dans plusieurs œuvres de jeunesse, tandis que les institutions religieuses, politiques et judiciaires occupent une place plus importante dans les cycles tardifs. Ces observations ne décrivent cependant pas une évolution continue de l’écriture. Certains sommets sont principalement portés par un seul roman, et plus des trois quarts des segments ont reçu leur topic après une réaffectation aux noyaux initialement découverts. Il me semble donc plus juste de considérer les 17 topics comme une cartographie exploratoire que comme des catégories naturelles du corpus.

Le troisième chapitre a déplacé l’analyse vers un corpus comparatif. Le modèle entraîné avec Zola comme unique auteur positif classe correctement 18 œuvres sur 25 dans la condition avec noms propres et 17 sur 25 après leur suppression automatique. Les AUC moyennes par auteur restent respectivement de 0,859 et 0,836, et l’ordre des

scores des deux conditions est très proche, avec une corrélation de rang de 0,972. Dans cet échantillon, le signal ne disparaît donc pas lorsque les noms propres détectés sont retirés. Je ne peux cependant pas affirmer qu'il s'agit d'un style naturaliste autonome : le rappel des œuvres naturalistes reste faible, l'effet varie selon les auteurs et les contrôles chronologiques sont trop réduits pour exclure un effet de période.

Au regard de ces résultats, il me semble que la réponse à la problématique est partiellement positive. Les méthodes employées permettent de repérer des marqueurs candidats, d'en observer la réapparition à travers plusieurs chaînes de traitement et de tester leur circulation hors de l'œuvre de Zola. Elles ne permettent pas encore de séparer complètement contenu thématique, signature d'auteur et artefacts de corpus. Le résultat le plus solide n'est donc pas la découverte d'une définition automatique du naturalisme, mais la mise en évidence d'une proximité textuelle mesurable entre Zola et certaines œuvres naturalistes d'autres auteurs.

Cette conclusion doit rester liée au caractère exploratoire du travail. Le premier corpus ne comprend qu'un auteur, le modèle de classification n'apprend la classe naturaliste qu'à partir de Zola, et le test comparatif ne porte que sur trois auteurs. Les catégories littéraires de certaines œuvres peuvent également être discutées. Enfin, plusieurs choix de segmentation, de nettoyage, de nombre de groupes et de seuil ont été guidés en partie par l'interprétabilité. Ces limites ne rendent pas les résultats inutiles ; elles définissent plutôt ce qu'ils permettent réellement d'avancer et ce qui reste à vérifier.

Une première suite consisterait à constituer un nouveau test réellement aveugle, plus large et mieux équilibré selon les auteurs et les périodes. L'apprentissage pourrait intégrer plusieurs écrivains naturalistes, puis laisser successivement un auteur entier hors du modèle. Un témoin reposant uniquement sur l'année de publication aiderait également à mesurer ce que le texte apporte au-delà de la chronologie. Je pense que cette étape serait prioritaire avant de tester des modèles plus complexes.

Il serait ensuite utile de confronter séparément le contenu et la forme. Les topics dégagés dans les deux premiers chapitres pourraient être recherchés dans le corpus comparatif, tandis qu'une autre expérience utiliserait des mots-outils, la ponctuation, les n-grammes de caractères ou les catégories grammaticales. La suppression des noms propres pourrait aussi être évaluée manuellement et comparée à leur remplacement par des catégories génériques. Ces prolongements ne garantissent pas qu'un style naturaliste stable puisse être isolé, mais ils permettraient de préciser progressivement la part respective des thèmes, de l'époque et des habitudes d'écriture dans les résultats observés.

Bibliographie

- BAZÁN, Emilia Pardo (1886). *Le Naturalisme*. Paris : Giraud.
- BIGOT, Charles (sept. 1879). « L'Esthétique naturaliste ». In : *Revue des Deux Mondes*.
- BLEI, David M. (2012). « Probabilistic Topic Models ». In : *Communications of the ACM* 55.4, p. 77-84.
- BLEI, David M., Andrew Y. NG et Michael I. JORDAN (2003). « Latent Dirichlet Allocation ». In : *Journal of Machine Learning Research* 3, p. 993-1022.
- BRUNETIÈRE, Ferdinand (1883). *Le roman naturaliste*. Paris : Calmann-Lévy.
- BURROWS, John (2002). « Delta : A Measure of Stylistic Difference and a Guide to Likely Authorship ». In : *Literary and Linguistic Computing* 17.3, p. 267-287.
- CATTIER, Edmond (1897). *Le Naturalisme littéraire*. Bruxelles : Weissenbruch.
- CHANG, Jonathan et al. (2009). « Reading Tea Leaves : How Humans Interpret Topic Models ». In : *Advances in Neural Information Processing Systems 22*. Curran Associates, p. 288-296.
- DESPREZ, Louis Marie (1884). *L'Évolution naturaliste*. Paris : Tresse.
- DEVLIN, Jacob et al. (2019). « BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding ». In : *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies*. Minneapolis, Minnesota : Association for Computational Linguistics, p. 4171-4186.
- DIENG, Adji B., Francisco J. R. RUIZ et David M. BLEI (2020). « Topic Modeling in Embedding Spaces ». In : *Transactions of the Association for Computational Linguistics* 8, p. 439-453. URL : <https://aclanthology.org/2020.tacl-1.29/>.
- DUDA, Richard O., Peter E. HART et David G. STORK (2001). *Pattern Classification*. 2^e éd. Wiley-Interscience.
- EDWARDS, Aleksandra et Jose CAMACHO-COLLADOS (2024). « Language Models for Text Classification : Is In-Context Learning Enough ? » In : *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation*. Torino, Italy : ELRA et ICCL, p. 10058-10072.
- GRIMMER, Justin et Brandon M. STEWART (2013). « Text as Data : The Promise and Pitfalls of Automatic Content Analysis Methods for Political Texts ». In : *Political Analysis* 21.3, p. 267-297.

- GROOTENDORST, Maarten (2022). « BERTopic : Neural Topic Modeling with a Class-Based TF-IDF Procedure ». In : *arXiv preprint arXiv :2203.05794*. DOI : 10.48550/arXiv.2203.05794.
- HALKIDI, Maria, Yannis BATISTAKIS et Michalis VAZIRGIANNIS (2001). « On Clustering Validation Techniques ». In : *Journal of Intelligent Information Systems* 17, p. 107-145.
- HAMON, Philippe (1983). *Le Personnel du roman : Le système des personnages dans les Rougon-Macquart d'Émile Zola*. Histoire des idées et critique littéraire 211. Genève : Librairie Droz.
- HUBERT, Lawrence et Phipps ARABIE (1985). « Comparing Partitions ». In : *Journal of Classification* 2, p. 193-218.
- HURET, Jules (1891). *Enquête sur l'évolution littéraire*. Paris : Charpentier.
- LEBART, Ludovic et André SALEM (1994). *Statistique textuelle*. Paris : Dunod.
- MACROBE, Antoine (1883). *La flore pornographique : glossaire de l'École naturaliste, extrait des œuvres de M. Émile Zola et de ses disciples*. Paris : Doublet.
- MANNING, Christopher D., Prabhakar RAGHAVAN et Hinrich SCHÜTZE (2008). *Introduction to Information Retrieval*. Cambridge : Cambridge University Press.
- MITTERAND, Henri (1986). *Zola et le naturalisme*. Que sais-je ? 2314. Paris : Presses Universitaires de France.
- (1994). *L'Illusion réaliste : De Balzac à Aragon*. Écriture. Paris : Presses Universitaires de France.
- MOSTELLER, Frederick et David L. WALLACE (1964). *Inference and Disputed Authorship : The Federalist*. Reading, Massachusetts : Addison-Wesley.
- MOULAVI, Davoud et al. (2014). « Density-Based Clustering Validation ». In : *Proceedings of the 2014 SIAM International Conference on Data Mining*. Society for Industrial et Applied Mathematics, p. 839-847.
- PAGÈS, Alain (déc. 2000). « L'espace littéraire du naturalisme ». In : *Pratiques* 107-108.
- RAND, W. M. (1971). « Objective criteria for the evaluation of clustering methods ». In : *Journal of the American Statistical Association* 66.336, p. 846-850.
- RÖDER, Michael, Andreas BOTH et Alexander HINNEBURG (2015). « Exploring the Space of Topic Coherence Measures ». In : *Proceedings of the Eighth ACM International Conference on Web Search and Data Mining*. WSDM '15. Association for Computing Machinery, p. 399-408.
- ROUSSEEUW, Peter J. (nov. 1987). « Silhouettes : A graphical aid to the interpretation and validation of cluster analysis ». In : *Journal of Computational and Applied Mathematics* 20, p. 53-65.
- SAPORTA, Gilbert (2006). *Probabilités, analyse des données et statistiques*. Paris : Éditions Technip. 622 p.

- SEBASTIANI, Fabrizio (2002). « Machine Learning in Automated Text Categorization ». In : *ACM Computing Surveys* 34.1, p. 1-47.
- STAMATATOS, Efstathios (2009). « A Survey of Modern Authorship Attribution Methods ». In : *Journal of the American Society for Information Science and Technology* 60.3, p. 538-556.
- TERREAU, Enzo (2024). « Apprentissage de représentations d’auteurs et d’autrices à partir de modèles de langue pour l’analyse des dynamiques d’écriture ». Thèse de doct. Lyon : Université Lumière Lyon 2.
- WU, Xiaobao, Thong NGUYEN et Anh Tuan LUU (2024). « A Survey on Neural Topic Models : Methods, Applications, and Challenges ». In : *Artificial Intelligence Review* 57. Article 18.
- ZOLA, Émile (1881). *Le Roman expérimental*. Paris : Charpentier.

Sitographie

- CONTRIBUTEURS À WIKIPÉDIA (2026a). *Émile Zola*. Wikipédia, l'encyclopédie libre. URL : https://fr.wikipedia.org/wiki/%5C%C3%5C%89mile_Zola (visité le 12/08/2026).
- (2026b). *Frères Goncourt*. Wikipédia, l'encyclopédie libre. URL : https://fr.wikipedia.org/wiki/Fr%C3%5C%A8res_Goncourt (visité le 12/08/2026).
- (2026c). *Gustave Flaubert*. Wikipédia, l'encyclopédie libre. URL : https://fr.wikipedia.org/wiki/Gustave_Flaubert (visité le 12/08/2026).
- (2026d). *Guy de Maupassant*. Wikipédia, l'encyclopédie libre. URL : https://fr.wikipedia.org/wiki/Guy_de_Maupassant (visité le 12/08/2026).
- (2026e). *Naturalisme (littérature)*. Wikipédia, l'encyclopédie libre. URL : [https://fr.wikipedia.org/wiki/Naturalisme_\(litt%C3%5C%A9rature\)](https://fr.wikipedia.org/wiki/Naturalisme_(litt%C3%5C%A9rature)) (visité le 12/08/2026).
- GROOTENDORST, Maarten (2026). *Outlier reduction*. BERTopic Documentation. URL : <https://maartengr.github.io/BERTopic/api/bertopic.html> (visité le 27/08/2026).

Annexe technique

.1 Reflexion sur le stockage des données

Après avoir récupéré un nombre conséquent de romans naturalistes et non naturaliste, il a fallu réfléchir à un moyen de les stocker quelque part. Pour cela, j'ai réfléchi à plusieurs idées pour procéder. Le choix c'est porté sur une base de données SQL avec comme interface PHP admin. Cette base de données à d'abord été remplie en local pour effectuer des tests et ensuite, une fois que tout fonctionnait correctement, j'ai pu extraire un fichier *Dumps* et l'importer dans PHP Admin.

.2 Nettoyage des textes

Après avoir réfléchi à la manière de stocker les romans, il a fallu réfléchir à un moyen de les nettoyer. En effet, les romans contiennent beaucoup de caractères spéciaux qui ne sont pas utiles pour l'analyse, notamment les caractères de mise en forme, la pagination, les notes de bas de page, les chapitres ainsi que les prologues. En effet, les prologues sont souvent des textes qui ne sont pas écrits par l'auteur du roman et qui ne sont donc pas représentatifs de son style d'écriture.

Les romans naturalistes et non naturalistes sont issus de types de données différents. Il y a trois groupes de formats de données : les romans au format *.epub*, les romans au format *.pdf* et les romans au format *.txt*⁴.

Pour ce qui est des textes au format *.epub*, j'ai utilisé le logiciel *Calibre*⁵ pour les convertir au format *.txt*. Pour les textes au format *.pdf*, j'ai utilisé le logiciel *Adobe Acrobat Pro* afin de les convertir au format *.txt*. Pour les textes au format *.txt*, j'ai utilisé un script Python⁶ pour regrouper les fichiers en un seul fichier par roman.

La grande majorité de mes romans étaient au format *.epub*. Après leur conversion au format *.txt*, j'ai donc utilisé un script Python⁷ pour nettoyer les textes. Ce script

4. Ici, les textes au format *.txt* sont organisés en dossiers, c'est-à-dire qu'un fichier *.txt* correspond à une page du roman. Il a donc fallu les regrouper pour obtenir un seul fichier *.txt* par roman.

5. Lien du logiciel : <https://calibre-ebook.com/fr/about>, site consulté le 18 juin 2026.

6. Le script est disponible en annexe.

7. Le script est disponible en annexe. Il faut préciser que je n'ai pas utilisé un seul script, mais plusieurs. Il s'agira donc d'un script général. Il y a eu énormément de modifications internes, notamment

supprime les caractères spéciaux, les notes de bas de page, les chapitres et les prologues. Il supprime également les lignes vides et les espaces en trop. Le script est basé sur des expressions régulières pour identifier les éléments à supprimer.

Pour ce qui est du choix des éléments à supprimer, j'ai fait le choix de supprimer les chapitres, car ils ne sont pas représentatifs du style d'écriture de l'auteur. De plus, comme nous l'avons vu dans le chapitre 2, j'ai passé un détecteur de motifs sur les textes afin d'identifier les motifs récurrents. J'ai donc gardé uniquement le corps du texte pour l'analyse. Ce choix se justifie également par la volonté d'obtenir une normalisation entre les textes⁸(une ligne est égal a une phrase), ce choix peut être mis en opposition avec le choix de garder la distinction entre les différents chapitres du romans mais je me défend en prenant en compte que certains romans ne sont pas découpés en chapitres. Les différents romans sont soit découpés en partie (exemple : Partie I, Partie II, etc.), soit en chapitres (exemple : Chapitre I, Chapitre II, etc.), soit avec une combinaison des deux (exemple : Partie I, Chapitre I, Chapitre II, Partie II, Chapitre III, etc.). Ou pour finir, le titre du chapitre est écrit en majuscules, avec des chiffres romains, ou sans chiffres romains. Il aurait donc fallu faire des ajustements à chaque fois pour identifier les chapitres. De plus, certains romans résultaient de l'assemblage de plusieurs fichiers *.txt*. Dans ces cas, la séparation entre les chapitres, initialement présente dans la structure HTML du roman, n'était plus conservée.

.3 Création de la base de données

Après avoir nettoyé les textes, il a fallu créer une base de données pour stocker les informations relatives aux romans. J'ai choisi d'utiliser le système de gestion de base de données relationnelle *MySQL*, car il permet d'organiser les données sous forme de tables et de conserver des relations claires entre les auteurs, les romans et les unités textuelles extraites.

Je vais donc présenter la structure de cette base de données ainsi que les différentes tables qui la composent. Chaque table a un rôle précis : certaines servent à stocker les informations bibliographiques, tandis que d'autres permettent de conserver les textes, les segments ou encore les phrases extraites pour l'analyse.

J'ai choisi de présenter ce code directement dans le corps du mémoire⁹ et non uniquement en annexe, afin de rendre plus claire la manière dont les données ont été organisées avant l'analyse.

Ce code permet de créer la base de données utilisée pour stocker les romans du corpus

pour les chapitres qui sont soit en majuscules, avec chiffres romains, ou sans chiffres romains. Il a donc fallu faire des ajustements à chaque fois.

8. certains textes de disposant pas de

9. Je précise également que tous les codes utilisés pour la réalisation de ce mémoire sont disponibles sur mon GitHub.

```

1 CREATE DATABASE romans_nlp;
2 USE romans_nlp;
3
4 -- Creation des tables pour la base de donnees des romans et des auteurs
5 CREATE TABLE auteurs (
6     id_auteur INT PRIMARY KEY AUTO_INCREMENT,
7     nom VARCHAR(100) NOT NULL,
8     prenom VARCHAR(100)
9 );
10
11 -- Table pour stocker les romans, avec leur titre et leur annee de publication
12 CREATE TABLE romans (
13     id_roman INT PRIMARY KEY AUTO_INCREMENT,
14     titre VARCHAR(255) NOT NULL,
15     annee_publication INT,
16     texte_brut LONGTEXT
17 );
18
19 -- Table d'association pour gerer la relation plusieurs-a-plusieurs entre auteurs et romans
20 CREATE TABLE auteurs_romans (
21     id_auteur INT NOT NULL,
22     id_roman INT NOT NULL,
23     PRIMARY KEY (id_auteur, id_roman),
24     FOREIGN KEY (id_auteur) REFERENCES auteurs(id_auteur),
25     FOREIGN KEY (id_roman) REFERENCES romans(id_roman)
26 );
27
28 -- Table pour stocker les segments extraits des romans, avec leur ordre de segmentation
29 CREATE TABLE segments (
30     id_segment INT PRIMARY KEY AUTO_INCREMENT,
31     id_roman INT NOT NULL,
32     ordre_segment INT NOT NULL,
33     texte_segment LONGTEXT NOT NULL,
34     FOREIGN KEY (id_roman) REFERENCES romans(id_roman)
35 );
36
37 /*
38  Apres reflexion, il est egalement possible d'ajouter les dates
39  de naissance et de mort des auteurs afin d'enrichir la base de donnees.
40  */
41 ALTER TABLE auteurs
42 ADD date_naissance INT;
43
44 ALTER TABLE auteurs
45 ADD date_mort INT;
46
47 -- Table pour stocker les phrases extraites des romans, avec leur motif d'extraction
48 CREATE TABLE phrase_roman (
49     id_phrase INT PRIMARY KEY AUTO_INCREMENT,
50     id_roman INT NOT NULL,
51     ordre_phrase INT NOT NULL,
52     texte_phrase TEXT NOT NULL,
53     motif_phrase TEXT NOT NULL,
54     FOREIGN KEY (id_roman) REFERENCES romans(id_roman)
55 );

```

Listing 1 – Création de la base de données romans_nlp

ainsi que les informations nécessaires à leur analyse. La base, nommée **romans_nlp**, est d'abord créée puis sélectionnée afin que toutes les tables suivantes y soient enregistrées.

La première table, **auteurs**, sert à stocker les informations relatives aux auteurs. Chaque auteur reçoit un identifiant unique, auquel sont associés son nom et, lorsque l'information est disponible, son prénom. Cette table est ensuite complétée par deux colonnes supplémentaires, **date_naissance** et **date_mort**, afin d'enrichir la description des auteurs et de permettre d'éventuelles analyses chronologiques.

La table **romans** contient les informations principales sur les œuvres du corpus. Elle associe à chaque roman un identifiant unique, un titre, une année de publication ainsi que le texte brut du roman. Le choix du type **LONGTEXT** pour le champ **texte_brut** permet de stocker des textes longs, ce qui est nécessaire dans le cas de romans complets.

La table **auteurs_romans** permet de faire le lien entre les auteurs et les romans. Elle sert à gérer une relation de type plusieurs-à-plusieurs : un auteur peut être associé à plusieurs romans, et un roman peut éventuellement être associé à plusieurs auteurs. Les clés étrangères **id_auteur** et **id_roman** permettent de relier cette table aux tables **auteurs** et **romans**.

La table **segments** sert à stocker les segments extraits des romans. Chaque segment est rattaché à un roman grâce à la clé étrangère **id_roman**. Le champ **ordre_segment** permet de conserver l'ordre d'apparition des segments dans le texte d'origine. Cela est important, car même si le texte est découpé pour les traitements, il reste possible de retrouver sa progression initiale.

Enfin, la table **phrase_roman** permet de stocker les phrases extraites des romans. Chaque phrase est associée au roman dont elle provient, à son ordre d'apparition, à son contenu textuel et au motif qui a permis son extraction. Ce dernier champ est important, car il permet de garder une trace de la méthode utilisée pour sélectionner les phrases et de relier chaque extraction à un critère précis.

L'ensemble de cette structure permet donc de conserver à la fois les textes complets, leurs découpages en segments, les phrases extraites et les informations bibliographiques liées aux auteurs et aux œuvres. Elle constitue ainsi une base organisée pour les traitements de fouille de texte et d'analyse automatique du corpus.

.4 Création des informations pour la base de données

Après avoir créé les tables nécessaires pour stocker les informations sur les auteurs, les romans et les relations entre eux, il est temps d'insérer les données relatives aux frères Goncourt et à leurs œuvres. Le code suivant présente donc l'insertion des auteurs, des romans et des relations entre ces deux tables.

```

1  /*
2  Insertion des freres Goncourt.
3  */
4  INSERT INTO auteurs (nom, prenom)
5  VALUES
6      ('de Goncourt', 'Edmond'),
7      ('de Goncourt', 'Jules');
8  /*
9  Insertion des romans des freres Goncourt
10 */
11 INSERT INTO romans (titre, annee_publication)
12 VALUES
13     ('Charles Demailly', 1860),
14     ('Soeur Philomene', 1861),
15     ('Renee Mauparin', 1864),
16     ('Germinie Lacerteux', 1865),
17     ('Manette Salomon', 1867),
18     ('Madame Gervaisais', 1869),
19     ('La Fille Elisa', 1877),
20     ('Freres Zemganno', 1879),
21     ('La Faustin', 1882),
22     ('Cherie', 1884);
23 /*
24 Insertion des relations entre les auteurs et les romans.
25 Les six premiers romans sont associes aux deux freres Goncourt.
26 Les romans suivants sont associes uniquement a Edmond de Goncourt.
27 */
28 INSERT INTO auteurs_romans (id_auteur, id_roman)
29 VALUES
30     (1,1), (2,1),
31     (1,2), (2,2),
32     (1,3), (2,3),
33     (1,4), (2,4),
34     (1,5), (2,5),
35     (1,6), (2,6),
36     (1,7),
37     (1,8),
38     (1,9),
39     (1,10);
40 -- Mise a jour des dates de naissance et de mort de Jules de Goncourt.
41 UPDATE auteurs
42 SET date_naissance = 1830,
43     date_mort = 1870
44 WHERE id_auteur = 2;
45
46 -- Mise a jour des dates de naissance et de mort d'Edmond de Goncourt.
47 UPDATE auteurs
48 SET date_naissance = 1822,
49     date_mort = 1896
50 WHERE id_auteur = 1;
51

```

Ce code permet d'insérer dans la base de données les informations relatives aux frères Goncourt et à leurs romans. Dans un premier temps, les deux auteurs sont ajoutés dans la table **auteurs**. Ils reçoivent chacun un identifiant, qui permettra ensuite de les relier aux œuvres présentes dans la base.

La deuxième partie du code insère les romans des frères Goncourt dans la table

romans. Chaque œuvre est associée à son titre et à son année de publication. Cette étape permet donc de constituer une partie du corpus à partir des romans retenus pour l'analyse.

Ensuite, la table **auteurs_romans** est utilisée pour associer les auteurs aux romans. Cette table est importante, car elle permet de gérer le cas particulier des œuvres écrites à deux mains. Les six premiers romans sont associés à Edmond et Jules de Goncourt, tandis que les romans publiés après la mort de Jules sont associés uniquement à Edmond. Cela permet de conserver une information plus précise sur l'attribution des œuvres.

Enfin, les deux dernières requêtes mettent à jour les dates de naissance et de mort des auteurs. Ces informations biographiques ne sont pas directement nécessaires pour stocker les textes, mais elles permettent d'enrichir la base de données. Elles peuvent aussi être utiles par la suite si l'on souhaite croiser les résultats de l'analyse avec des éléments chronologiques ou biographiques.

Ce passage sert donc à remplir une première partie de la base de données avec les auteurs, les romans et les relations entre eux. Il montre aussi l'intérêt de séparer les informations dans plusieurs tables : les auteurs sont stockés d'un côté, les romans de l'autre, et la relation entre les deux est conservée dans une table spécifique.

Pour ne pas surcharger le mémoire, je n'ai pas présenté l'insertion de tous les romans du corpus. Le code complet est disponible sur mon [GitHub](#), où l'on peut retrouver l'ensemble des auteurs et des œuvres ajoutées.